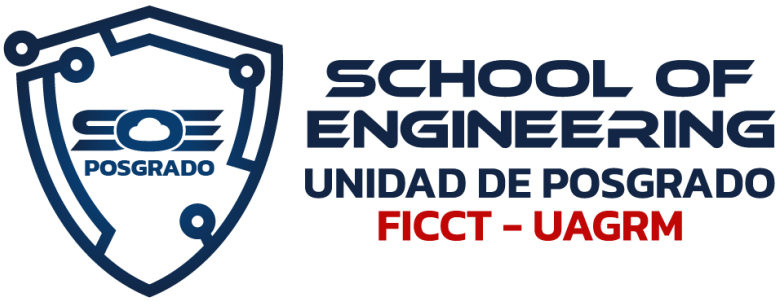
UNIVERSIDAD AUTÓNOMA "GABRIEL RENÉ MORENO"

FACULTAD DE INGENIERÍA EN CIENCIAS DE LA COMPUTACIÓN Y TELECOMUNICACIONES

"UAGRM SCHOOL OF ENGINEERING"



MAESTRÍA EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

DISEÑO DE UN MOTOR DE PRONÓSTICO DE DEMANDA BASADO EN SERIES TEMPORALES PARA MEJORAR LA PRECISIÓN DE LA PLANIFICACIÓN DE LA DEMANDA EN NOVAPACK S.A. PARA LA GESTIÓN 2026

TRABAJO FINAL DE GRADO BAJO LA MODALIDAD DE TESIS PARA OPTAR AL TÍTULO DE MAESTRO EN CIENCIAS.

AUTOR:

ING. NICOLAS OPORTO ROJAS

DIRECTOR DE TRABAJO FINAL DE GRADO:

M.Sc. JUAN CARLOS SANJINES CASTRO

Santa Cruz, Bolivia

Octubre, 2026

UNIVERSIDAD AUTÓNOMA “GABRIEL RENÉ MORENO”

FACULTAD DE INGENIERÍA EN CIENCIAS DE LA COMPUTACIÓN Y TELECOMUNICACIONES

“UAGRM SCHOOL OF ENGINEERING”



MAESTRÍA EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

DISEÑO DE UN MOTOR DE PRONÓSTICO DE DEMANDA BASADO EN SERIES TEMPORALES PARA MEJORAR LA PRECISIÓN DE LA PLANIFICACIÓN DE LA DEMANDA EN NOVAPACK S.A. PARA LA GESTIÓN 2026

TRABAJO FINAL DE GRADO BAJO LA MODALIDAD DE TESIS PARA OPTAR AL TÍTULO DE MAESTRO EN CIENCIAS.

AUTOR:

ING. NICOLAS OPORTO ROJAS

DIRECTOR DE TRABAJO FINAL DE GRADO:

M.Sc. JUAN CARLOS SANJINES CASTRO

Santa Cruz, Bolivia

Octubre, 2026

Cesión de derechos

Declaro bajo juramento que el trabajo aquí descrito, titulado “DISEÑO DE UN MOTOR DE PRONÓSTICO DE DEMANDA BASADO EN SERIES TEMPORALES PARA MEJORAR LA PRECISIÓN DE LA PLANIFICACIÓN DE LA DEMANDA EN NOVAPACK S.A. PARA LA GESTIÓN 2026” es de propia autoría; que no ha sido previamente presentado para ningún grado de calificación profesional; y que se han consultado las referencias bibliográficas que se incluyen en este documento.

A través de la presente declaro que cedo mi derecho de propiedad intelectual correspondiente a este trabajo, a la UAGRM Facultad de Ingeniería en Ciencias de la Computación y Telecomunicaciones, según lo establecido por la Ley de Propiedad Intelectual, por su Reglamento y por la normatividad institucional vigente.

_____

Ing. Nicolas Oporto Rojas

DEDICATORIA

Dedico este trabajo a mi familia, por su apoyo incondicional, paciencia y confianza a lo largo de este proceso.

A mis padres, por enseñarme con su ejemplo el valor del esfuerzo y la perseverancia.

Y a todas las personas que, con sus palabras de aliento y compañía, hicieron posible que este proyecto se concrete.

AGRADECIMIENTO

Quiero expresar mi agradecimiento a NOVAPACK S.A. por brindar las condiciones necesarias para el desarrollo de esta investigación y por permitir el acceso a información clave del proceso de planificación de la demanda.

Mi reconocimiento especial al equipo del área de planificación de la empresa, por su predisposición, claridad y tiempo durante la entrevista y la sesión de observación, lo cual fue fundamental para comprender a profundidad el contexto operativo del proceso.

También agradezco a Juan Carlos Sanjines Castro, que me acompañó en este proceso académico, cuyas orientaciones metodológicas y sugerencias enriquecieron significativamente el desarrollo del trabajo.

A mi familia, por su apoyo constante, por motivarme en los momentos difíciles y por confiar siempre en mi capacidad para alcanzar los objetivos propuestos.

Finalmente, a todas las personas que, directa o indirectamente, aportaron a la construcción de esta tesis, gracias por formar parte de este logro.

Gracias.

ÍNDICE DEL CONTENIDO

INTRODUCCIÓN 1
Antecedentes del problema 2
Situación problemática 4
Formulación del problema 5
Objetivos de la investigación 5
Objetivo general 5
Objetivos específicos 5
Justificación de la investigación 6
Justificación teórica 6
Justificación práctica 6
Justificación metodológica 6
Justificación social 7
Novedad científica 7
Objeto de estudio y campo de acción 8
Objeto de estudio 8
Campo de acción 8
Límites y alcances de la investigación 8
Hipótesis para defender mediante la validación 9
Identificación de las variables 9
Variable independiente: motor de pronóstico automatizado 9
Variable dependiente: precisión del pronóstico de demanda 9
Delimitación de la investigación 13
Delimitación temática 13
Delimitación espacial 14
Delimitación temporal 14
CAPÍTULO I. FUNDAMENTACIÓN TEÓRICA 15
1.1 Estado del arte 15
1.2 Marco teórico 18
1.2.1 Fundamentos de la planificación de la demanda 19
1.2.2 Variable independiente: motor de pronóstico automatizado 19

1.2.3 Sistemas inteligentes de apoyo a la decisión (DSS) 20
1.2.4 Arquitectura de sistemas de pronóstico automatizados 21
1.2.5 Modelos de suavizado exponencial y métodos para demanda intermitente 23
1.2.6 Modelos de boosting aplicados al pronóstico de demanda 24
1.2.7 LightGBM: funcionamiento y ventajas en series temporales 24
1.2.8 Comparación entre modelos estadísticos y de aprendizaje automático 26
1.2.9 Variable dependiente: precisión del pronóstico de demanda 27
1.2.10 Métricas estadísticas para la evaluación del desempeño 28
1.2.11 Sesgo del pronóstico, funciones de pérdida y métricas ponderadas por valor 29
1.2.12 Criterios de selección y validación de modelos predictivos 30
1.2.13 Evaluación fuera de muestra: partición temporal, orígenes rodantes y horizonte 31
1.2.14 La combinación de pronósticos y su robustez ante cambios de régimen 32
1.2.15 Factores que afectan la precisión del pronóstico en entornos empresariales 33
1.2.16 Aplicaciones del pronóstico en cadenas de suministro y retail 35
1.2.17 Retos del pronóstico a nivel SKU en entornos reales 35
1.2.18 Marco metodológico teórico 36
1.2.19 Marco tecnológico 39
1.3 Marco conceptual 42
1.3.1 Demanda y planificación de la demanda 42
1.3.2 Serie temporal y pronóstico de demanda 42
1.3.3 SKU, canal, regional y combinación de negocio 43
1.3.4 Clasificación de los patrones de demanda: intermitencia y variabilidad 43
1.3.5 Motor de pronóstico automatizado 44
1.3.6 Aprendizaje automático y boosting por gradiente 44

1.3.7 Precisión del pronóstico y métricas de error 45
1.3.8 Evaluación fuera de muestra del pronóstico 45
1.4 Marco contextual 45
1.4.1 Contexto empresarial de la planificación de la demanda en NOVAPACK S.A. 45
1.4.2 Rol del pronóstico en la cadena de suministro y logística 46
1.4.3 Impacto de la precisión del pronóstico en la gestión de inventarios 47
1.4.4 Casos de aplicación en empresas del sector retail y distribución 47
1.4.5 Relevancia de la transformación digital en NOVAPACK S.A. 48
1.5 Marco legal normativo 48
1.5.1 Normativas sobre protección y uso de datos empresariales en Bolivia 48
1.5.2 Políticas de confidencialidad y cesión de derechos en investigaciones de posgrado 49
1.5.3 Políticas de gobernanza de datos, seguridad de la información y reserva comercial 50
CAPÍTULO II. DISEÑO METODOLÓGICO 54
2.1 Paradigma de la investigación 54
2.2 Diseño, enfoque y tipo de investigación 54
2.3 Métodos de investigación 56
2.3.1 Métodos teóricos 56
2.3.2 Métodos empíricos 57
2.4 Técnicas de recolección de datos de la investigación 58
2.4.1 Revisión documental 58
2.4.2 Observación estructurada 58
2.4.3 Análisis de datos secundarios 59
2.4.4 Entrevista semiestructurada 59
2.5 Instrumentos de investigación 59
2.5.1 Guía de entrevista semiestructurada 59

2.5.2 Guía de observación estructurada 60
2.5.3 Matriz de recolección y análisis de datos históricos 60
2.5.4 Ficha de registro documental 61
2.6 Población y muestra 61
2.6.1 Población 61
2.6.2 Muestra 61
2.6.3 Criterios de inclusión y exclusión 63
2.6.4 Fuentes de información 64
2.7 Análisis de los datos 65
CAPÍTULO III. RESULTADOS, ANÁLISIS Y DISCUSIÓN 71
3.1 Acercamiento al contexto donde se investiga 71
3.2 Procedimiento para el diagnóstico 72
3.2.1 Definición conceptual de las variables 74
3.2.2 Definición operacional de las variables 75
3.2.3 Instrumentos de investigación para el diagnóstico 75
3.3 Validación de los instrumentos de investigación 76
3.4 Análisis de los resultados de la aplicación de los instrumentos 78
3.4.1 Resultados de la entrevista semiestructurada 78
3.4.2 Resultados de la observación estructurada 80
3.4.3 Resultados del análisis documental 83
3.4.4 Resultados del análisis de los datos históricos (2017–2026) 87
3.5 Triangulación metodológica y discusión de los resultados 93
3.6 Conclusiones sobre el estado del problema 97
CAPÍTULO IV. PROPUESTA DE SOLUCIÓN 99
4.1 Esquema general de la propuesta 99
4.2 Desarrollo de la propuesta 104
4.2.1 Fases del desarrollo de la propuesta 106
4.2.2 Arquitectura funcional del sistema 116
4.2.3 Tratamiento de datos para la operación del motor 119
4.2.4 Protocolo de tratamiento de eventos exógenos 123
4.2.5 Arquitectura de microservicio propuesta para la operación 127

4.2.6 Recursos empleados y recursos previstos para la implementación 138
4.3 Constatación y validación de la propuesta de solución 141
4.3.1 Validación metodológica 141
4.3.2 Validación técnica 142
4.3.3 Extensión exploratoria: combinación de pronósticos y conmutación por régimen 166
4.3.4 Valoración económica 176
4.4 Hoja de ruta de implementación propuesta 184
CONCLUSIONES 189
RECOMENDACIONES 194
REFERENCIAS BIBLIOGRÁFICAS 199
BIBLIOGRAFÍA 207
ANEXOS 209

ÍNDICE DE FIGURA

Figura 1 Partición temporal del estudio: bloques, pliegue interno de calibración y evento exógeno 66
Figura 2 Esquema de la evaluación multihorizonte con orígenes rodantes en el bloque de prueba 69
Figura 3 Esquema actual del flujo de planificación de la demanda en NOVAPACK S.A. 86
Figura 4 Perfil estacional del valor por categoría: participación de cada mes de la gestión comercial en el valor anual 91
Figura 5 Esquema propuesto del flujo de planificación de la demanda en NOVAPACK S.A. 102
Figura 6 Contribuciones TreeSHAP del modelo global por variable: meses de pico frente al resto del año 114
Figura 7 Arquitectura funcional del motor automatizado de pronóstico 118
Figura 8 Arquitectura de microservicio propuesta para la operación mensual del motor: contexto e interior del servicio 129
Figura 9 Reparto de la selección del motor por modelo (1.668 series de la muestra) 148
Figura 10 Diagrama de diferencia crítica del post hoc de Nemenyi sobre los rangos de Friedman 153
Figura 11 Error compuesto valorizado D por horizonte de pronóstico (orígenes rodantes) 158
Figura 12 WMAPE valorizado por mes del bloque de prueba, por modelo 162
Figura 13 Casos representativos por régimen de demanda: ventas observadas y pronósticos en validación y prueba. Paneles: (a) estacional de campaña; (b) recurrente; (c) esporádico; (d) volátil 163
Figura 14 Sensibilidad al régimen en la extensión exploratoria: error compuesto valorizado D a un paso en las dos gestiones de prueba 175
Figura 15 Cascada de conformación de la muestra y sensibilidad del umbral de intermitencia. Paneles: (a) cascada de inclusión; (b) sensibilidad del umbral 243
Figura 16 Curva de concentración de la demanda valorizada por SKU (Pareto) ... 246

Figura 17 Demanda valorizada por gestión comercial y su asignación a los bloques del estudio 247
Figura 18 Búsqueda de hiperparámetros: error interno valorizado por ensayo y función de pérdida 249
Figura 19 Efecto de las variables explicativas y de la calibración: D valorizada antes y después, a un paso y en el horizonte. Paneles: (a) a un paso; (b) en el horizonte 250
Figura 20 Descomposición del error compuesto valorizado D por modelo (bloque de prueba, a un paso) 256
Figura 21 Dispersión del error por serie: MAE frente a Bias, por modelo (bloque de prueba) 257
Figura 22 Vista de contexto del motor: personas y sistemas de la empresa con los que intercambia datos 282
Figura 23 Vista de despliegue del motor en la infraestructura de la empresa 285

ÍNDICE DE TABLAS

Tabla 1 Operacionalización de las variables 11
Tabla 2 Resumen de la validación de instrumentos por juicio de expertos 78
Tabla 3 Resultados de la entrevista semiestructurada aplicada al informante clave IC-01 79
Tabla 4 Resultados de la observación estructurada del proceso de planificación de la demanda 81
Tabla 5 Resultados del análisis documental de los registros y reportes utilizados en la planificación de la demanda 84
Tabla 6 Resultados del análisis exploratorio de los datos históricos de ventas (2017–2026) 88
Tabla 7 Triangulación metodológica de problemas identificados y requisitos de diseño 94
Tabla 8 Comparación de desempeño de modelos de pronóstico 145
Tabla 9 Error compuesto valorizado D por estrato: mejor método estadístico, motor y LightGBM, a un paso y en el horizonte 160
Tabla 10 Error compuesto valorizado D de los sistemas de combinación y del sistema conmutado en las dos gestiones de prueba 173
Tabla 11 Contraste entre el proceso de planificación vigente y el proceso propuesto 178
Tabla 12 Protocolo de medición del impacto operativo en la hoja de ruta de implementación 186
Tabla 13 Guía de observación estructurada del proceso de planificación de la demanda 216
Tabla 14 Registro de la sesión de observación aplicada 218
Tabla 15 Campos de la ficha de registro documental 219
Tabla 16 Variables de la matriz de recolección y análisis de datos históricos 220
Tabla 17 Ficha documental aplicada al reporte histórico consolidado de ventas 223
Tabla 18 Normalidad de las diferencias pareadas del contraste (prueba de Shapiro-Wilk) 227
Tabla 19 Rangos medios de Friedman y post hoc de Nemenyi frente al motor 227

Tabla 20 Incertidumbre agrupada de las diferencias del contraste, por conglomerados de SKU y por bloques de meses 229
Tabla 21 Incertidumbre agrupada de las diferencias de la extensión exploratoria en sus dos gestiones de prueba, por conglomerados de SKU y por bloques de meses 232
Tabla 22 Etapas del registro de flujo de la corrida principal y su duración 238
Tabla 23 Corridas de variantes del estudio y sus anulaciones 239
Tabla 24 Señal de sesgo móvil y peso del conjunto diverso, mes a mes 241
Tabla 25 Sensibilidad de la cohorte de evaluación: tamaño, cobertura y D valorizada a un paso en el bloque de prueba 244
Tabla 26 Conjunto de modelos del estudio: hipótesis, criterio de inclusión y respaldo 248
Tabla 27 Trazabilidad de los requisitos de diseño del diagnóstico en el motor propuesto 250
Tabla 28 Hiperparámetros del modelo global: valor elegido, rango explorado, función y lectura de la búsqueda 252
Tabla 29 Coherencia entre el marco metodológico declarado y la propuesta desarrollada 255
Tabla 30 Tratamiento propuesto por caso de dato para la operación del motor 259
Tabla 31 Estado de actividad e inclusión en la muestra de las combinaciones de la población objetivo 265
Tabla 32 Combinaciones de la población objetivo por primer criterio de la cascada que las excluye y estado de actividad 266
Tabla 33 Taxonomía de eventos exógenos, tratamiento propuesto y evidencia del estudio 268
Tabla 34 Ficha de registro del evento exógeno de la pandemia según el protocolo propuesto 270
Tabla 35 Componentes del microservicio propuesto, principio de operación que atienden y estado 272
Tabla 36 Contrato mínimo de la API del microservicio (versión /v1) 273
Tabla 37 Tablas de datos del esquema propio del microservicio y sus claves 275

Tabla 38 Contrato de integración entre el motor y la plataforma de planificación colaborativa, por etapa del plan mensual 276
Tabla 39 Señales de observabilidad del microservicio: fuente, línea base del estudio, umbral inicial y acción 277
Tabla 40 Prácticas de operación del ciclo de vida de los modelos (MLOps): lo que el estudio ya hace y lo que agrega la operación 279
Tabla 41 Interfaces del motor con los sistemas de la empresa: dirección, contrato, frecuencia, autenticación y responsable 283
Tabla 42 Decisiones de arquitectura: alternativa descartada, motivo y consecuencia 285
Tabla 43 Referencias publicadas por familia del conjunto de modelos y resultado obtenido en este estudio 290
Tabla 44 Costo de cómputo y precisión por brazo en la corrida principal 293
Tabla 45 Costo de cómputo y precisión de los pronosticadores de la extensión exploratoria en las dos gestiones de prueba 294
Tabla 46 Norma, política y mecanismo: gobernanza de datos, seguridad de la información y reserva comercial 296
Tabla 47 Documentos bajo custodia: documento, firmante según su rol, fecha y ubicación 298
Tabla 48 Sellos de trazabilidad de las corridas bajo custodia: código, configuración, insumos y salida pública 299

ÍNDICE DE ANEXOS

ANEXO 1. Guía de entrevista semiestructurada: diagnóstico del proceso de planificación de la demanda en NOVAPACK S.A. 210
ANEXO 2. Acuerdo de confidencialidad para el uso de información empresarial 214
ANEXO 3. Guía de observación estructurada 216
ANEXO 4. Ficha de registro documental 219
ANEXO 5. Estructura de la matriz de recolección y análisis de datos históricos 220
ANEXO 6. Ejemplo de ficha documental aplicada 223
ANEXO 7. Enlace al repositorio 225
ANEXO 8. Script de contraste estadístico de la hipótesis (Python) 227
ANEXO 9. Registro de flujo de la corrida principal: etapas, duración, entorno y variantes 238
ANEXO 10. Traza mensual del detector de régimen en las dos gestiones de prueba 241
ANEXO 11. Caracterización del histórico y justificación del muestreo 243
ANEXO 12. Documentación del diseño y la calibración del motor 248
ANEXO 13. Validación metodológica y desempeño desagregado 255
ANEXO 14. Tratamiento de datos y de eventos exógenos para la operación .. 258
ANEXO 15. Diseño del microservicio de operación: componentes, contratos, integración, observabilidad y ciclo de vida 272
ANEXO 16. Evaluación comparativa de referencia (benchmarks) de los modelos elegidos 288
ANEXO 17. Correspondencia entre normas, políticas de datos y mecanismos del diseño 296
ANEXO 18. Índice de documentos bajo custodia 298

RESUMEN

La presente tesis abordó el diseño de un motor híbrido de pronóstico de demanda, que combina métodos estadísticos y aprendizaje automático, para mejorar la precisión de la planificación por SKU, canal y regional en NOVAPACK S.A.[1], una empresa con portafolio extenso y alta variabilidad del consumo. La investigación siguió un enfoque mixto de predominancia cuantitativa, de tipo propositivo, con entrevista semiestructurada, observación estructurada, revisión documental del proceso de planificación y análisis de datos históricos de ventas. El diagnóstico evidenció una fuerte dependencia de herramientas manuales, criterios empíricos y ausencia de automatización. El motor integró diez modelos, desde métodos de referencia hasta Holt-Winters, Croston y LightGBM con variables explicativas, seleccionando automáticamente el más preciso para cada unidad de análisis, y se evaluó sobre 1.668 series de ventas observadas con el error compuesto valorizado D = WMAPE + |Bias| y pruebas de significancia. Los resultados mostraron que, en la evaluación a un paso, el motor alcanza la menor D del portafolio (75,4 %, frente a 100,0 % de la réplica de la fórmula base sin ajustes de consenso), con una diferencia de efecto grande frente a esa réplica (mediano frente al promedio móvil simple) que se sostiene agrupando por SKU, y que el modelo de aprendizaje automático mantiene la precisión en el horizonte de planificación. Se concluye que el sistema es técnicamente viable como proceso automatizado, adaptable y replicable; sus efectos sobre quiebres, nivel de servicio y costos son hipótesis de impacto.

Palabras clave: planificación de la demanda; motor híbrido de pronóstico; aprendizaje automático; series temporales; LightGBM.

[1] NOVAPACK S.A. es un seudónimo: el nombre real de la empresa se sustituye por confidencialidad, conforme al acuerdo suscrito con la organización (Anexo 2). Los datos utilizados en el estudio son reales.

ABSTRACT

This thesis addressed the design of a hybrid demand forecasting engine, combining statistical methods and machine learning, to improve planning accuracy by SKU, channel, and region at NOVAPACK S.A., a company with an extensive portfolio and high variability in consumption patterns. The study followed a predominantly quantitative mixed-methods approach with a solution-oriented design, using a semi-structured interview, structured observation, documentary review of the current planning process, and analysis of historical sales data. The diagnostic phase revealed a strong dependence on manual tools, empirical judgment, and a lack of automation. The engine integrated ten models, from benchmark methods to Holt-Winters, Croston, and LightGBM with explanatory variables, automatically selecting the most accurate one for each unit of analysis, and was evaluated on 1,668 series of observed sales using the cost-weighted composite error D = WMAPE + |Bias| and statistical significance tests. Results showed that, in the one-step-ahead evaluation, the engine achieves the lowest cost-weighted composite error across the portfolio (D = 75.4% versus 100.0% for the replica of the base planning formula without consensus adjustments), a difference with a large effect size against that replica (medium against the simple moving average) that holds under SKU-clustered resampling, with the machine learning model sustaining accuracy over the planning horizon. It was concluded that the system is technically viable as an automated, adaptable, and replicable process; its effects on stockouts, service level, and costs are impact hypotheses.

Keywords: demand planning; hybrid forecasting engine; machine learning; time series; LightGBM.

INTRODUCCIÓN

La presente investigación se centra en el diseño de un motor híbrido de pronóstico de demanda basado en series temporales, capaz de integrar modelos estadísticos tradicionales y de aprendizaje automático (machine learning). La propuesta responde a la necesidad de NOVAPACK S.A. de optimizar la planificación de inventarios y el abastecimiento, dada la alta variabilidad de la demanda en un portafolio que supera los 900 SKU (stock keeping unit, la unidad de mantenimiento de existencias) y que, desagregado por canal y regional, excede las 4.000 combinaciones SKU-canal-regional.

NOVAPACK S.A. abastece al mercado nacional a través de canales mayoristas, minoristas, distribuidores regionales y clientes institucionales. Su portafolio, organizado en doce categorías, abarca desde papelería y útiles escolares hasta insumos gráficos y otros artículos de consumo. Esta diversidad, combinada con estacionalidad y diferencias regionales, hace indispensable un sistema de pronóstico adaptativo por SKU-canal-regional.

Una planificación de demanda más precisa permitiría decisiones mejor informadas sobre producción, logística y compras, con una operación más eficiente y menores costos. Actualmente existen limitaciones en herramientas analíticas y ausencia de un sistema automatizado de pronósticos; por ello, se plantea una solución integral y replicable a entornos similares.

El documento se organiza en cuatro capítulos. El primero reúne el estado del arte y los marcos teórico, conceptual, contextual y legal; el segundo expone el diseño metodológico; el tercero presenta los resultados, el análisis y la discusión del diagnóstico del proceso de planificación de la demanda en NOVAPACK S.A.; y el cuarto desarrolla la propuesta del motor de pronóstico, su constatación y validación, y la hoja de ruta para su implementación. Cierran el documento las conclusiones, las recomendaciones, las referencias bibliográficas, la bibliografía y los anexos. La

investigación se inscribe en la línea institucional de investigación “Redes y Tecnologías Informáticas” de la UAGRM, en el eje temático de desafíos de sistemas de información y modelado de datos.

Antecedentes del problema

El pronóstico de la demanda ha sido objeto de numerosas investigaciones empíricas en el ámbito de la gestión empresarial y la analítica de datos, debido a su relevancia en la optimización de inventarios y la planificación de recursos. A nivel internacional, Makridakis et al. (2018) compararon el desempeño de métodos estadísticos y de aprendizaje automático sobre más de mil series mensuales de la competencia M3 y encontraron que los de aprendizaje automático no superaron a los estadísticos, evidencia de que la precisión de cada enfoque depende de las características de los datos.

Posteriormente, la competencia M5 (Makridakis et al., 2022), desarrollada sobre datos reales de demanda minorista de Walmart, demostró que los algoritmos de aprendizaje automático basados en gradient boosting (en particular LightGBM) alcanzan la mayor precisión en escenarios con grandes volúmenes de datos y múltiples series jerárquicas simultáneas. En la misma línea, Fildes et al. (2009) evidenciaron, a partir del estudio de cuatro empresas de la cadena de suministro del Reino Unido, que los ajustes manuales basados en juicio experto no siempre mejoran el pronóstico: los pequeños a menudo dañan la precisión y los que lo elevan muestran un sesgo optimista sistemático, hallazgo que respalda acotar esos ajustes sobre un pronóstico automatizado. Estos aportes constituyen el estado del arte actual, donde la automatización representa la tendencia dominante para entornos empresariales de alta complejidad.

En el contexto latinoamericano, investigaciones aplicadas como las de Castro Morales (2024) en una empresa colombiana de consumo masivo, Maciel Carpio et al. (2023) en una embotelladora de bebidas peruana y Valdivia Espinosa (2019) en un supermercado chileno han evaluado modelos de aprendizaje automático frente a los métodos tradicionales de pronóstico, y han resaltado los desafíos que la variabilidad

de la demanda plantea a la planificación de esas empresas. Se evidencia que algunas organizaciones continúan utilizando métodos empíricos o planificaciones basadas en la experiencia, lo cual se asocia con ineficiencias logísticas y sobrecostos.

Desde una visión general, el problema de la predicción de la demanda afecta a empresas de distribución, manufactura y comercio en todo el mundo, dado que una estimación imprecisa conlleva pérdidas económicas, sobreinventarios o quiebres de stock. Desde una visión particular, en el sector de artículos de oficina y papelería, la demanda se caracteriza por una marcada estacionalidad asociada a períodos escolares y campañas corporativas, además de variaciones regionales en los patrones de consumo. Finalmente, desde una visión singular, NOVAPACK S.A. enfrenta estas mismas dificultades, con un amplio portafolio de productos y canales de distribución y sin un sistema automatizado que aproveche sus datos históricos mediante modelos estadísticos y de aprendizaje automático.

El análisis desde diferentes perspectivas refuerza la relevancia del problema. Desde la perspectiva social, una gestión eficiente de la demanda permitiría una mejor disponibilidad de insumos y materiales esenciales para escuelas, oficinas e instituciones, mejorando el nivel de servicio y la satisfacción de los clientes. En el plano económico, el uso de modelos de pronóstico más precisos contribuiría a la reducción de costos asociados a los excesos o quiebres de inventario, disminuiría el capital inmovilizado y mejoraría el flujo de caja de la empresa. En la dimensión política, una planificación de la demanda alineada con los cronogramas educativos y las compras públicas facilitaría la coordinación con políticas nacionales de abastecimiento y las normativas de importación y comercialización de productos. Desde el enfoque sociológico, el estudio permite comprender los patrones de consumo vinculados al calendario escolar y a las campañas de regreso a clases, a los que podrían ajustarse las estrategias logísticas y de distribución. En el ámbito antropológico y cultural, se reconocen los hábitos locales de compra por temporada y celebraciones, asociados a los picos de demanda que la planificación de los inventarios debe anticipar. Finalmente, en la dimensión ecológica, una gestión de inventarios más precisa y ajustada a la demanda real reduciría las mermas, los reprocesos y la sobreproducción, y contribuiría a una menor huella ambiental y a la sostenibilidad empresarial.

En conclusión, los antecedentes demuestran que el uso de modelos combinados estadísticos y de aprendizaje automático representa una solución innovadora y eficaz para mejorar la precisión del pronóstico de demanda. NOVAPACK S.A., como una de las principales proveedoras del sector, dispone de nueve gestiones de registros históricos estructurados por SKU, canal y regional, condición que la sitúa en posición de implementar este tipo de herramienta tecnológica, con beneficios operativos, económicos y sociales esperables y con un aporte al desarrollo de prácticas empresariales más sostenibles en el contexto boliviano.

Situación problemática

En NOVAPACK S.A. la planificación de la demanda se sustenta actualmente en métodos empíricos: el área de planificación elabora una propuesta a partir de promedios de períodos anteriores en hojas de cálculo, el área comercial aporta la suya sobre la base de su lectura del mercado, y ambas cifras se concilian por consenso en la reunión mensual de planificación de la demanda. Este procedimiento resulta insuficiente frente a un portafolio superior a 900 SKU (más de 4.000 combinaciones SKU-canal-regional), comercializado a través de canales mayoristas, minoristas, distribuidores regionales y clientes institucionales, cuyo comportamiento presenta una marcada estacionalidad asociada principalmente al período escolar y diferencias regionales significativas.

En ese contexto, la empresa enfrenta desviaciones recurrentes entre la demanda estimada y la demanda real, que se asocian con excesos de inventario en productos de baja rotación, quiebres de stock en artículos de alta demanda, inmovilización de capital de trabajo y decisiones de compra y abastecimiento tomadas sobre estimaciones poco confiables. A ello se suma la ausencia de indicadores formales de error que permitan evaluar de manera objetiva la calidad de los pronósticos generados, así como la elevada carga operativa que implica elaborarlos manualmente para cada combinación SKU-canal-regional.

De mantenerse esta situación, es previsible que la empresa siga asumiendo costos logísticos evitables y perdiendo capacidad de respuesta frente a un mercado

crecientemente competitivo. Este escenario configura la necesidad de incorporar un sistema automatizado de pronóstico que sustituya la estimación empírica por criterios cuantitativos verificables y reproducibles.

Formulación del problema

¿Cómo mejorar la precisión del pronóstico de la demanda mensual por SKU, canal y regional en la empresa NOVAPACK S.A., en Santa Cruz de la Sierra, durante la gestión 2026, frente a la fórmula de planificación vigente, basada en promedios de períodos anteriores y previa a los ajustes por criterio comercial?

Objetivos de la investigación

Objetivo general

Diseñar un motor de pronóstico basado en series temporales que integre modelos estadísticos y de aprendizaje automático para seleccionar el modelo más preciso en la predicción de la demanda mensual por SKU, canal y regional en NOVAPACK S.A., en Santa Cruz de la Sierra, para la gestión 2026.

Objetivos específicos

a) Fundamentar teórica y metodológicamente los modelos estadísticos y de aprendizaje automático aplicados al pronóstico de series temporales, como base conceptual para el diseño de la propuesta.

b) Diagnosticar la situación actual del proceso de planificación de la demanda en NOVAPACK S.A. y el comportamiento histórico de las ventas, con el fin de identificar las limitaciones existentes y los requisitos de diseño de la solución.

c) Diseñar conceptualmente un motor de pronóstico automatizado, estructurado para seleccionar el modelo óptimo por combinación de negocio (SKU-canal-regional), integrando modelos estadísticos y de aprendizaje automático según el desempeño obtenido en la evaluación empírica fuera de muestra.

d) Evaluar de manera comparativa el desempeño de los modelos de pronóstico considerados en el diseño del motor, mediante métricas cuantitativas de error (error absoluto medio, MAE; error porcentual absoluto medio, MAPE; raíz del error cuadrático medio, RMSE; y sesgo promedio, Bias) y pruebas estadísticas de significancia, con el fin de determinar la efectividad del enfoque propuesto frente a los métodos tradicionales utilizados por la empresa.

Justificación de la investigación

Justificación teórica

El estudio contribuye al conocimiento aplicado en series temporales y aprendizaje automático, ofreciendo un marco práctico de comparación entre métodos estadísticos clásicos y modelos modernos de aprendizaje automático. Se propone un enfoque automatizado que permite evaluar el desempeño de diferentes métodos por unidad de análisis, lo cual es relevante para futuras investigaciones y desarrollos de sistemas de pronóstico.

Justificación práctica

Se espera que la implementación de un motor de pronóstico mejore la planificación del inventario, reduzca los costos operativos y permita alinear mejor la oferta con la demanda real, en línea con lo documentado en un contexto comparable por Castro Morales (2024) y con la mejora de precisión que mostró la competencia M5. La arquitectura propuesta es replicable en otras organizaciones con estructuras similares, si bien la magnitud de los resultados requiere validación en cada contexto, conforme a los límites declarados de esta investigación.

Justificación metodológica

Se sustenta en un enfoque mixto con predominancia cuantitativa, que combina el análisis estadístico de los datos históricos de ventas con la información cualitativa obtenida mediante entrevista semiestructurada y observación estructurada, integrada

a través de triangulación metodológica. La medición de la precisión de los distintos modelos de pronóstico se complementa con pruebas estadísticas de significancia, y la metodología empleada, apoyada en el modelo CRISP-DM (Cross Industry Standard Process for Data Mining), sustenta la validez de los resultados, su trazabilidad y su reproducibilidad condicionada al acceso autorizado a los insumos, y su aplicabilidad en el contexto real de NOVAPACK S.A.

Justificación social

Una mejor gestión de inventarios conllevaría mayor disponibilidad de productos esenciales para instituciones educativas, oficinas y empresas, con un mejor servicio al cliente, menos desperdicios y un uso más eficiente de los recursos logísticos.

Novedad científica

La novedad científica del presente trabajo radica en el diseño de un motor de pronóstico que incorpora un mecanismo de selección automática del modelo más preciso para cada combinación SKU-canal-regional, en lugar de aplicar un único método a la totalidad del portafolio, práctica que el diagnóstico constató en la empresa estudiada. Frente a los precedentes que emplean o respaldan una lógica de selección por unidad de análisis (Castro Morales, 2024; Valdivia Espinosa, 2019), el aporte de este trabajo reside en someter esa decisión a un protocolo de validación formal (contraste no paramétrico pareado sobre el conjunto completo de series y evaluación fuera de muestra con un bloque de prueba ajeno a la selección y al ajuste de los modelos) y en adoptar una métrica de decisión valorizada por el costo del producto, sobre datos reales de una empresa boliviana que fabrica, importa, comercializa y distribuye artículos de oficina y papelería.

El aporte se concreta en tres planos. En el **plano teórico**, sistematiza y contrasta el desempeño de modelos estadísticos tradicionales y de aprendizaje automático sobre datos reales de una empresa boliviana que fabrica, importa, comercializa y distribuye artículos de oficina y papelería, contexto escasamente documentado en la literatura regional revisada. En el **plano metodológico**, integra la metodología CRISP-DM con un procedimiento de validación estadística basado en

pruebas no paramétricas para muestras pareadas, aplicado al error de pronóstico obtenido por serie. En el **plano práctico**, ofrece una arquitectura funcional replicable, construida con herramientas de código abierto, susceptible de ser adoptada por organizaciones con estructuras de datos similares.

Objeto de estudio y campo de acción

Objeto de estudio

La planificación de la demanda de productos en NOVAPACK S.A. ante la ausencia de un sistema automatizado de pronóstico basado en modelos estadísticos y de aprendizaje automático.

Campo de acción

El proceso de desarrollo del motor automatizado de pronóstico de demanda aplicado a la planificación mensual por SKU, canal y regional en NOVAPACK S.A., en Santa Cruz de la Sierra, durante la gestión 2026.

Límites y alcances de la investigación

El alcance de la investigación comprende el diseño, la fundamentación y la validación técnica de un motor de pronóstico de demanda para NOVAPACK S.A., a partir del análisis del histórico de ventas mensuales del período abril de 2017 a marzo de 2026 y del diagnóstico del proceso vigente de planificación. Incluye la comparación del desempeño de modelos estadísticos y de aprendizaje automático, la definición de la arquitectura funcional del sistema y la valoración de su impacto potencial.

Los **límites** de la investigación son los siguientes: el estudio alcanza el nivel propositivo y no contempla la implementación operativa ni la puesta en producción del motor dentro de la empresa; el análisis se realiza con granularidad mensual, por lo que no aborda la planificación diaria o semanal; los resultados se circunscriben al portafolio y a los canales de NOVAPACK S.A., y la validación empírica se realiza sobre cinco de sus doce categorías (el 72,4 % de la demanda valorizada) y sobre la muestra de 1.668 series que resulta de los criterios de inclusión, de modo que su extensión a las siete

categorías restantes y su generalización a otras organizaciones requieren validación adicional; y la calidad de las estimaciones depende de la integridad de los registros históricos disponibles, cuyas inconsistencias se documentan en el diagnóstico. La precisión se compara con la réplica de la fórmula de las planillas de planificación, previa a los ajustes por criterio comercial (apartado 2.7); el error del plan final consensuado no se midió: incorpora recortes por suministro y ajustes de juicio que lo hacen no comparable con un pronóstico de demanda (apartado 3.4.3).

Hipótesis para defender mediante la validación

El diseño y la evaluación retrospectiva de un motor de pronóstico automatizado, que integra modelos estadísticos tradicionales y algoritmos de aprendizaje automático, muestran que este mejora significativamente la precisión en la predicción de la demanda mensual por SKU, canal y regional en NOVAPACK S.A. La precisión se mide contra las ventas mensuales registradas, es decir, la demanda atendida, que no incluye la venta perdida por falta de existencia: la hipótesis se contrasta sobre las ventas observadas y no sobre la demanda solicitada, y los efectos del motor sobre los quiebres y el nivel de servicio quedan como hipótesis de impacto.

Identificación de las variables

Variable independiente: motor de pronóstico automatizado

Corresponde a la solución planteada para resolver la problemática identificada. Se define como un sistema tecnológico que integra modelos estadísticos y algoritmos de aprendizaje automático, capaz de seleccionar de forma automática el modelo más preciso para cada combinación SKU-canal-regional, con el fin de mejorar la planificación de la demanda en NOVAPACK S.A. Por integrar en un mismo conjunto de candidatos métodos estadísticos y de aprendizaje automático y elegir entre ellos para cada combinación, el motor se denomina en adelante motor híbrido de pronóstico (en la constatación técnica, motor de selección automática); el apartado 1.3.5 precisa el alcance del término.

Variable dependiente: precisión del pronóstico de demanda

Representa el problema abordado en la investigación. Se entiende como el grado de exactitud con que se anticipan los valores reales de la demanda mensual, observados en las ventas registradas (la demanda atendida, sin la venta perdida), medido a través de indicadores cuantitativos por serie (el error absoluto medio, MAE; el error porcentual absoluto medio, MAPE; la raíz del error cuadrático medio, RMSE; y el sesgo promedio, Bias), por la suma por serie del MAE y del valor absoluto del sesgo (MAE + |Bias|, en unidades, criterio con el que el motor selecciona el modelo de cada serie y estadístico del contraste pareado) y, para la comparación agregada entre modelos, mediante el error compuesto valorizado D = WMAPE + |Bias| (error porcentual absoluto medio ponderado, WMAPE, más el sesgo absoluto), que pondera el error de cada serie por el costo unitario del producto.

La operacionalización de ambas variables, con su definición conceptual, dimensiones e indicadores, se presenta en la Tabla 1.

Tabla 1
Operacionalización de las variables

Tema:

Diseño de un motor de pronóstico de demanda basado en series temporales para mejorar la precisión de la planificación de la demanda en NOVAPACK S.A. para la gestión 2026

Pregunta de investigación:

¿Cómo mejorar la precisión del pronóstico de la demanda mensual por SKU, canal y regional en la empresa NOVAPACK S.A., en Santa Cruz de la Sierra, durante la gestión 2026, frente a la fórmula de planificación vigente, basada en promedios de períodos anteriores y previa a los ajustes por criterio comercial?

Variable	Definición conceptual	Dimensiones	Indicadores
Variable independiente: Motor de pronóstico automatizado	Sistema de análisis que combina modelos estadísticos y de aprendizaje automático para seleccionar el mejor modelo de predicción para cada unidad de análisis (Hyndman & Athanasopoulos, 2018)	- Modelado predictivo	- Número de modelos candidatos integrados en el motor (10 en el experimento: seis métodos de referencia, suavizado exponencial, Holt-Winters, Croston y LightGBM). - Porcentaje de series SKU-canal-regional con modelo asignado por la regla de selección (1.668 de 1.668, 100 %; 0 series sin candidato válido; 130 series con empate en el criterio de validación, 7,8 %).
		- Automatización del análisis	- Presencia del motor de pronóstico.

Tema:

Diseño de un motor de pronóstico de demanda basado en series temporales para mejorar la precisión de la planificación de la demanda en NOVAPACK S.A. para la gestión 2026

Pregunta de investigación:

¿Cómo mejorar la precisión del pronóstico de la demanda mensual por SKU, canal y regional en la empresa NOVAPACK S.A., en Santa Cruz de la Sierra, durante la gestión 2026, frente a la fórmula de planificación vigente, basada en promedios de períodos anteriores y previa a los ajustes por criterio comercial?

Variable	Definición conceptual	Dimensiones	Indicadores
			- Prueba de automatización: ejecución sin intervención manual.
Variable dependiente: Precisión del pronóstico de demanda	Grado de exactitud con el que se anticipan los valores reales de demanda futura, observados en las ventas registradas. Se mide a través de métricas estadísticas de error (Chopra, 2019).	- Exactitud de la predicción	- Error absoluto medio (MAE) - Error porcentual absoluto medio (MAPE) - Raíz del error cuadrático medio (RMSE)

Tema: Diseño de un motor de pronóstico de demanda basado en series temporales para mejorar la precisión de la planificación de la demanda en NOVAPACK S.A. para la gestión 2026			
Pregunta de investigación: ¿Cómo mejorar la precisión del pronóstico de la demanda mensual por SKU, canal y regional en la empresa NOVAPACK S.A., en Santa Cruz de la Sierra, durante la gestión 2026, frente a la fórmula de planificación vigente, basada en promedios de períodos anteriores y previa a los ajustes por criterio comercial?			
Variable	**Definición conceptual**	**Dimensiones**	**Indicadores**
			- Sesgo (Bias) - Error compuesto valorizado D = WMAPE + |Bias| (agregación ponderada por costo)
		- Consistencia de resultados	- Error compuesto por serie MAE + |Bias| en unidades (criterio de selección del motor en validación y estadístico del contraste pareado)

Nota. Elaboración propia.

Delimitación de la investigación

Delimitación temática

La investigación se circunscribe al diseño de un motor de pronóstico de demanda basado en series temporales y algoritmos de aprendizaje automático, orientado a mejorar la precisión en la planificación de la demanda de la empresa NOVAPACK S.A. El estudio aborda los fundamentos teóricos, la estructura funcional, la propuesta metodológica y la validación técnica del sistema mediante una evaluación

retrospectiva controlada con datos históricos. No incluye su despliegue o implementación operativa integral dentro de la organización.

Delimitación espacial

El estudio se desarrolla en el contexto empresarial de NOVAPACK S.A., empresa boliviana que fabrica, importa, comercializa y distribuye artículos de oficina, papelería y suministros escolares, con sede principal en la ciudad de Santa Cruz de la Sierra, Bolivia. La delimitación espacial abarca el entorno administrativo y de planificación de la empresa, donde se genera y gestiona la información de ventas históricas utilizada para el análisis.

Delimitación temporal

La investigación se centra en el análisis del comportamiento histórico de la demanda entre abril de 2017 y marzo de 2026 (las gestiones comerciales 2018 a 2026, definidas de abril a marzo), reservando la gestión 2026 como período de evaluación fuera de muestra del motor propuesto. El inicio en abril de 2017 responde a la disponibilidad de registros consistentes: los cambios de sistema de gestión anteriores a esa fecha fragmentaron la información histórica y alteraron las nomenclaturas de productos y canales, de modo que los registros previos no son homogéneos con los del sistema vigente. El período de desarrollo académico del estudio comprende el año 2026, correspondiente a la elaboración del trabajo final de grado.

CAPÍTULO I. FUNDAMENTACIÓN TEÓRICA

El presente capítulo desarrolla los fundamentos teóricos, conceptuales, metodológicos, tecnológicos, aplicativos y normativos que sustentan la presente investigación. En primer lugar, se aborda el estado del arte del pronóstico de demanda, considerando los principales aportes de los modelos estadísticos tradicionales y de los algoritmos de aprendizaje automático aplicados a series temporales, así como las brechas existentes en su aplicación a contextos empresariales como el de NOVAPACK S.A. Posteriormente, el marco teórico desarrolla los sustentos vinculados con el motor de pronóstico automatizado y con la precisión del pronóstico de demanda, incorporando criterios de evaluación, validación y análisis de los factores que influyen en el desempeño de los modelos predictivos. Asimismo, se presentan los fundamentos metodológicos y tecnológicos que orientan el desarrollo del motor propuesto, incluyendo el análisis de series temporales, la automatización del procesamiento de datos y el uso de herramientas computacionales para su diseño. A continuación, el marco conceptual ofrece un glosario operativo de los términos que atraviesan la tesis. Finalmente, se consideran los aspectos aplicativos y legales que contextualizan la investigación en el entorno organizacional de NOVAPACK S.A., estableciendo la relación entre la base teórica, la propuesta técnica y el marco institucional que respalda el estudio.

1.1 Estado del arte

El desarrollo de motores de pronóstico automatizados ha sido ampliamente explorado en la literatura reciente, particularmente a partir del auge de modelos de aprendizaje automático en contextos comerciales complejos. A continuación, se presentan estudios representativos que aportan antecedentes relevantes para esta investigación, tanto en términos metodológicos como aplicados. Esta revisión es narrativa y no sistemática: reúne estudios representativos elegidos por su pertinencia

para el problema (pronóstico de demanda por SKU, selección automática de modelos, juicio experto y métricas de error), sin pretensión de exhaustividad ni protocolo de búsqueda replicable.

Fildes et al. (2009) analizaron el impacto del juicio experto sobre ajustes en pronósticos automáticos. A partir de su estudio con cuatro empresas de la cadena de suministro del Reino Unido, concluyeron que, si bien la intervención humana puede mejorar la precisión, sobre todo con ajustes grandes, los ajustes pequeños a menudo la dañan y los que elevan el pronóstico muestran un sesgo optimista sistemático. Este trabajo clásico refuerza la importancia de desarrollar sistemas automatizados que minimicen errores subjetivos, aspecto central del motor de pronóstico planteado.

Valdivia Espinosa (2019), en un estudio aplicado a un supermercado de Santiago de Chile, comparó once métodos de pronóstico, desde el ingenuo, el promedio móvil, ARIMA (modelo autorregresivo integrado de medias móviles), SARIMA (su variante estacional) y el suavizado exponencial triple hasta árboles de regresión, Random Forest, máquinas de soporte vectorial y redes neuronales, para estimar la demanda diaria de productos perecibles, incorporando variables explicativas como el precio, la temperatura y el día de la semana. Random Forest resultó el mejor método para los dos productos analizados, con un error porcentual del orden del 22 % al 25 % de las ventas diarias. El trabajo compara los métodos producto por producto antes de elegir uno, procedimiento afín a la decisión de seleccionar el modelo por unidad de análisis en lugar de imponer uno solo a todo el portafolio.

Makridakis et al. (2022) realizaron un estudio como parte de la competencia M5 (M5 Forecasting Competition), en el que evaluaron el rendimiento de modelos estadísticos tradicionales y algoritmos de aprendizaje automático para predecir la demanda minorista en Walmart (EE. UU.). A través del uso de millones de registros diarios y algoritmos como LightGBM y DeepAR, comprobaron que los modelos de aprendizaje automático obtienen una mejor precisión cuando se aplican con técnicas avanzadas de ingeniería de características. Este estudio constituye un referente clave, pues valida empíricamente la superioridad del aprendizaje automático en entornos reales de alta granularidad, reforzando la elección metodológica del presente trabajo.

En Perú, Maciel Carpio et al. (2023) aplicaron modelos de aprendizaje automático a la planificación de la demanda de CBC Peruana S.A.C., empresa embotelladora de bebidas, partiendo del diagnóstico de que la variabilidad de los patrones de consumo dificulta la planificación en esa industria. Compararon LightGBM y regresión lineal frente a los modelos de series de tiempo SARIMA y Prophet sobre dos productos clave, evaluando el desempeño con MAE, MAPE y RMSE de forma conjunta, y reportaron para el modelo Prophet un MAPE promedio de 24,64 %, un MAE de 685,16 y un RMSE de 1.003,90. El antecedente es relevante para el presente trabajo porque reporta MAE, MAPE y RMSE de forma simultánea, práctica que este estudio conserva en el reporte por serie, aunque la decisión entre modelos se tome sobre una métrica agregada única.

Finalmente, Castro Morales (2024) abordó el pronóstico de ventas a corto plazo de una empresa colombiana de consumo masivo del sector alimenticio que, hasta entonces, pronosticaba mediante promedios móviles y el juicio del área comercial: el mismo punto de partida que se describe más adelante para NOVAPACK S.A. El autor implementó y comparó redes neuronales LSTM (long short-term memory), Random Forest, Prophet y SARIMA frente a esa práctica previa, y reporta una reducción del error porcentual absoluto medio del 22,5 % al 12,5 % promedio mensual, junto con un ahorro estimado por menores desviaciones de inventario. El entregable fue una herramienta operativa que incluye un motor de recomendación del mejor modelo para cada referencia de producto, criterio de selección por unidad de análisis que anticipa el adoptado en este trabajo.

En conjunto, estos antecedentes destacan la evolución metodológica del pronóstico de demanda, desde enfoques clásicos hasta soluciones automatizadas basadas en inteligencia artificial. La presente investigación se nutre de estos aportes y propone una arquitectura híbrida capaz de adaptarse al comportamiento específico de cada SKU, canal y regional dentro del contexto operativo de NOVAPACK S.A.

Brecha de conocimiento y justificación del estudio en NOVAPACK S.A.

A pesar de los avances reportados por la literatura especializada en pronóstico de demanda mediante modelos estadísticos y algoritmos de aprendizaje automático, persiste una brecha importante entre el desarrollo académico de estas metodologías y su aplicación efectiva en empresas latinoamericanas con alta complejidad operativa. Gran parte de los estudios revisados se concentra en entornos altamente digitalizados, con disponibilidad de grandes volúmenes de datos estructurados, infraestructura analítica consolidada y procesos estandarizados de planificación. En contraste, algunas organizaciones de la región continúan apoyándose en métodos simples y criterios empíricos, lo que deja margen para incorporar soluciones automatizadas adaptadas a su realidad operativa (Castro Morales, 2024).

En el caso específico de NOVAPACK S.A., esta brecha adquiere especial relevancia debido a la heterogeneidad del portafolio, la segmentación por SKU, canal y regional, y la marcada estacionalidad de la demanda. Si bien existen antecedentes que demuestran la utilidad de enfoques híbridos y automatizados, no se identifican estudios orientados al diseño conceptual de un motor de pronóstico aplicable a una empresa boliviana del sector de distribución y comercialización con características similares. En consecuencia, la presente investigación se justifica porque busca trasladar los aportes teóricos y metodológicos del pronóstico avanzado a un contexto empresarial real, proponiendo una solución factible, escalable y alineada con las necesidades operativas de NOVAPACK S.A. Un antecedente de ese traslado es el pronóstico con modelos que se llevó a una empresa colombiana de consumo masivo, con una herramienta ajustada a su proceso mensual (Castro Morales, 2024).

1.2 Marco teórico

Esta sección desarrolla los sustentos teóricos de la investigación, organizados en torno a las dos variables del estudio. Tras una base común sobre la planificación de la demanda, se exponen primero los fundamentos del motor de pronóstico automatizado (los sistemas de apoyo a la decisión, su arquitectura y las familias de modelos que integra), luego los de la precisión del pronóstico (las métricas de error, los criterios de selección y validación y los diseños de evaluación fuera de muestra) y, finalmente, los fundamentos metodológicos y tecnológicos del desarrollo. Las

definiciones esenciales de los términos que este desarrollo utiliza de forma transversal se reúnen en el marco conceptual.

1.2.1 Fundamentos de la planificación de la demanda

La planificación de la demanda es un proceso estratégico que busca anticipar con la mayor precisión posible la necesidad futura de productos o servicios, con el fin de alinear los recursos operativos y logísticos de la empresa con las expectativas del mercado (Chopra, 2019). Esta planificación constituye una función crítica dentro de la gestión de la cadena de suministro, ya que permite optimizar los niveles de inventario, mejorar la eficiencia del abastecimiento, reducir quiebres de stock y, en última instancia, incrementar el nivel de servicio al cliente.

Existen diversas metodologías para la elaboración de planes de demanda, que van desde técnicas cualitativas basadas en el juicio de expertos hasta modelos cuantitativos que emplean herramientas estadísticas o algoritmos de predicción. En las empresas de la cadena de suministro predominan esquemas híbridos que combinan la experiencia del equipo con pronósticos generados a partir de datos históricos, incorporando ajustes manuales cuando existen factores contextuales no modelables (Fildes et al., 2009).

Un componente esencial de la planificación de la demanda moderna es su capacidad de adaptarse a distintos niveles de desagregación, ya sea por SKU, canal, regional o cliente. Esta flexibilidad permite ajustar los planes operativos de manera más granular y precisa, alineando la producción, compras y distribución con patrones reales de consumo. La propuesta desarrollada en esta investigación responde precisamente a esta necesidad de planificación desagregada, utilizando modelos automatizados que permiten generar pronósticos específicos para cada combinación SKU-canal-regional.

1.2.2 Variable independiente: motor de pronóstico automatizado

1.2.2.1 Modelado predictivo

El modelado predictivo comprende un conjunto de técnicas diseñadas para anticipar comportamientos futuros a partir de patrones históricos. Hyndman y Athanasopoulos (2018) sostienen que los modelos estadísticos clásicos, como ARIMA o el suavizado exponencial de Holt-Winters, son adecuados cuando las series presentan estacionalidad o tendencias claras. Por otro lado, Makridakis et al. (2022) muestran que los modelos de aprendizaje automático, como LightGBM, lograron el mejor desempeño en la competencia M5, sobre ventas minoristas con muchas series de demanda intermitente y sujetas a múltiples factores, como precios y eventos especiales.

En esta investigación, se reconoce la necesidad de incorporar ambos enfoques. La diversidad en los comportamientos de la demanda según categoría, canal o regional exige un sistema capaz de identificar qué modelo funciona mejor en cada situación. Esta flexibilidad metodológica fortalece la precisión general del pronóstico y aporta una solución más robusta frente a la heterogeneidad del portafolio.

1.2.2.2 Automatización del análisis

La automatización en el análisis de datos permite operar con eficiencia sobre grandes volúmenes de información, minimizando la intervención humana y los errores asociados. Según Kreuzberger et al. (2023), los sistemas automatizados son esenciales cuando se requiere escalabilidad y consistencia en la ejecución de tareas analíticas complejas.

La implementación de un motor de pronóstico automatizado responde a la necesidad de aplicar, evaluar y seleccionar modelos predictivos de forma autónoma para miles de combinaciones de negocio. Esto no solo acelera el proceso de generación de pronósticos, sino que favorece la obtención de resultados replicables y listos para su integración con las decisiones operativas.

1.2.3 Sistemas inteligentes de apoyo a la decisión (DSS)

Los sistemas de apoyo a la decisión (DSS, por su sigla en inglés) representan herramientas que permiten a las organizaciones tomar decisiones más informadas

mediante el análisis estructurado de datos. Según Power (2002), un DSS combina modelos, datos y procesos interactivos para asistir en decisiones no estructuradas o semiestructuradas. En el contexto empresarial, estas soluciones permiten mejorar la planificación y la asignación de recursos.

El motor de pronóstico propuesto en esta investigación se alinea con la lógica de un DSS, al automatizar el proceso de selección y aplicación del mejor modelo predictivo para cada unidad de análisis. De esta forma, proporciona al área de planificación de la empresa una herramienta sistemática que transforma los datos históricos en insumos estratégicos para la toma de decisiones.

1.2.4 Arquitectura de sistemas de pronóstico automatizados

Un sistema automatizado de pronóstico de demanda debe integrar múltiples componentes que permitan gestionar datos, construir modelos, evaluar su desempeño y generar predicciones útiles para la toma de decisiones. Según Kreuzberger et al. (2023), una arquitectura robusta en proyectos de aprendizaje automático requiere definir con claridad las etapas de preprocesamiento, entrenamiento, validación, despliegue y monitoreo.

Kuhn y Johnson (2013) describen el modelado predictivo como un proceso por etapas: el preprocesamiento y la transformación de los datos, la ingeniería y la selección de características, el ajuste de parámetros, la selección entre modelos y la evaluación del desempeño con métricas adecuadas.

El motor desarrollado en este estudio sigue esta lógica modular. Primero, se construye un conjunto de características relevantes a partir de datos históricos por SKU, canal y regional. Luego, se entrenan múltiples modelos (como el promedio móvil, el modelo ingenuo y LightGBM) sobre estas combinaciones. El sistema evalúa automáticamente el rendimiento de cada modelo en la ventana de validación con el error compuesto por serie (MAE + |Bias|) y reporta además MAPE y RMSE. Finalmente, selecciona el modelo de menor error compuesto y lo aplica para generar predicciones futuras. Todo este flujo opera de manera automatizada, lo que permite escalar el pronóstico sin depender de procesos manuales repetitivos.

Esta arquitectura no solo mejora la eficiencia, sino que favorece la replicabilidad, la reducción de errores humanos y la adaptabilidad frente a nuevas combinaciones de datos o unidades de análisis.

Llevar un motor de pronóstico construido para un estudio a una operación mensual plantea, además de una pregunta de modelado, una de arquitectura de software. Newman (2021) define los microservicios como servicios que se liberan y despliegan de forma independiente, modelados alrededor de un dominio del negocio, que encapsulan una función y la ponen a disposición de otros sistemas a través de la red. Para un motor de pronóstico ese estilo separa el ciclo pesado de la corrida mensual, que se ejecuta por lotes al cierre de ventas, del consumo liviano y frecuente de sus resultados, y fija un contrato estable que las herramientas de planificación pueden usar sin depender del código de los modelos. Su costo es una complejidad operativa mayor que la de un programa aislado, por lo que se justifica cuando los resultados tienen varios consumidores o cuando hay interacciones que registrar, como los ajustes de la reunión mensual de planificación de la demanda.

Para describir una arquitectura de ese tipo de manera formal, Kruchten (1995) propone cinco vistas complementarias, cada una dirigida a un interesado distinto: la lógica, que descompone el sistema en componentes con sus responsabilidades; la de procesos, que describe la secuencia de ejecución, la concurrencia y el manejo de fallas; la de desarrollo, que organiza el software en módulos y entregables; la física, que asigna esos componentes a nodos de cómputo y redes; y los escenarios, casos de uso que recorren las otras cuatro y sirven para validarlas. El apartado 4.2.5 documenta el diseño con esas vistas.

En los sistemas de aprendizaje automático en operación, el código del modelo es una fracción menor del sistema: la deuda técnica se concentra en el código de integración, las tuberías de datos, la configuración y los lazos de retroalimentación ocultos (Sculley et al., 2015). Las prácticas de operación de modelos de aprendizaje automático (MLOps, por su sigla en inglés) se apoyan en principios: automatización de la integración y la entrega, orquestación del flujo, reproducibilidad, versionado de datos, modelos y código, colaboración, entrenamiento y evaluación continuos, registro

de metadatos, monitoreo continuo y lazos de retroalimentación (Kreuzberger et al., 2023). El monitoreo responde a la deriva de concepto, el cambio en el tiempo de la relación entre las variables de entrada y la variable pronosticada, que obliga a vigilar el desempeño del modelo desplegado (Gama et al., 2014). Como los ajustes por juicio sobre el pronóstico estadístico mejoran o empeoran la precisión según su tamaño y su dirección (Fildes et al., 2009), conviene registrarlos con su motivo para poder evaluarlos. El apartado 4.2.5 aplica estos principios al motor de este estudio.

1.2.5 Modelos de suavizado exponencial y métodos para demanda intermitente

La familia del suavizado exponencial constituye el punto de referencia clásico del pronóstico de series temporales. El suavizado exponencial simple estima el nivel de la serie como un promedio ponderado que privilegia las observaciones recientes mediante un parámetro de suavizamiento; sus extensiones incorporan componentes de tendencia (Holt) y de estacionalidad (Holt-Winters), con lo que la familia cubre los componentes estructurales básicos de una serie de demanda. Hyndman et al. (2002) formalizaron estos métodos en un marco de espacio de estados que habilita su selección y estimación automáticas para cada serie (precedente directo de la lógica de selección por serie que adopta el motor propuesto), y la obra de Hyndman et al. (2008) consolidó su fundamento estadístico.

Para las series intermitentes, aquellas con períodos sin demanda entre transacciones, Croston (1972) demostró que el suavizado convencional responde de forma deficiente y propuso descomponer la serie en dos procesos suavizados por separado: el tamaño de la demanda cuando ocurre y el intervalo entre ocurrencias. La literatura posterior midió la precisión de estos estimadores y de sus variantes en contextos de inventario (Syntetos & Boylan, 2005), consolidando al método de Croston como la referencia para este régimen.

En esta investigación, la familia completa (suavizado exponencial simple con parámetro optimizado, Holt-Winters con estacionalidad anual y Croston) integra el conjunto de candidatos del motor: cada método aporta una hipótesis estructural distinta

(nivel, estacionalidad, intermitencia), y la selección por serie decide cuál describe mejor cada combinación SKU-canal-regional.

1.2.6 Modelos de boosting aplicados al pronóstico de demanda

El enfoque de boosting ha ganado relevancia en los últimos años debido a su capacidad para mejorar el rendimiento predictivo de modelos individuales mediante la combinación secuencial de predictores débiles. A diferencia de los métodos tradicionales que ajustan un único modelo a los datos, el boosting construye una secuencia de modelos en los que cada uno corrige los errores cometidos por el anterior. La planificación de demanda por SKU en empresas con portafolios extensos reúne alta complejidad y un gran volumen de datos. El boosting es particularmente útil en contextos así (Hastie et al., 2009).

En el caso específico del pronóstico de series temporales, los modelos de boosting permiten capturar interacciones no lineales y patrones específicos que pueden pasar desapercibidos para modelos estadísticos simples. Además, su capacidad para incorporar variables adicionales los convierte en una herramienta versátil para la toma de decisiones en entornos comerciales dinámicos (Makridakis et al., 2022).

Entre las variantes más destacadas se encuentran AdaBoost, Gradient Boosting y XGBoost; LightGBM, más reciente, fue diseñado para mejorar la eficiencia y la escalabilidad del boosting por gradiente (Ke et al., 2017). Estos modelos han sido aplicados con éxito en sectores como retail, manufactura y logística, demostrando mejoras significativas en métricas de error frente a métodos tradicionales.

1.2.7 LightGBM: funcionamiento y ventajas en series temporales

LightGBM (Light Gradient Boosting Machine) es una implementación optimizada de gradient boosting desarrollada por Microsoft, diseñada para maximizar la velocidad de entrenamiento y la eficiencia en el uso de memoria (Ke et al., 2017). A diferencia de otros algoritmos que construyen árboles por nivel (level-wise), LightGBM emplea una estrategia de crecimiento por hoja (leaf-wise), que prioriza la reducción del

error de forma más agresiva, permitiendo construir árboles más profundos donde sea necesario.

LightGBM admite técnicas de paralelización y entrenamiento distribuido, y ofrece un control detallado sobre hiperparámetros como la profundidad de los árboles, la tasa de aprendizaje o el número de iteraciones, lo que lo hace altamente personalizable. Una de sus principales ventajas es su capacidad para manejar grandes volúmenes de datos con alta dimensionalidad (Ke et al., 2017).

Los hiperparámetros de un modelo de boosting por gradiente pueden ordenarse según la función que cumplen. Un primer grupo regula la capacidad de cada árbol, que en LightGBM crece hoja por hoja (Ke et al., 2017): por eso el número máximo de hojas reemplaza a la profundidad como control de la complejidad, y el número mínimo de observaciones por hoja impide particiones que se apoyen en pocos datos. Un segundo grupo regulariza el ensamble: la penalización L2 sobre el valor de las hojas, propia de la formulación regularizada del boosting, reduce la magnitud de ese valor, tanto más cuanto menor es la evidencia que sustenta cada hoja (Chen & Guestrin, 2016), y el submuestreo de filas y de variables en cada árbol introduce una aleatoriedad que reduce la varianza del conjunto. Un tercer grupo fija el ritmo del aprendizaje: la tasa de aprendizaje contrae el aporte de cada árbol y se compensa con el número de árboles, porque una tasa menor exige más iteraciones para alcanzar el mismo ajuste; por eso el número de árboles suele fijarse por parada temprana y no de antemano (Hastie et al., 2009, cap. 10). Por encima de los tres grupos está la función de pérdida, un hiperparámetro estructural porque decide qué característica de la demanda aprende el modelo. En la familia Tweedie, una potencia p entre 1 y 2 corresponde a variables no negativas con masa de probabilidad en cero, y su valor regula cuánto crece la varianza con el nivel de la demanda.

En el pronóstico de demanda diaria por SKU, algunos métodos de aprendizaje automático logran mayor precisión y menor sesgo que los métodos estadísticos de referencia (Spiliotis et al., 2022), y Huber y Stuckenschmidt (2020) alcanzan la misma conclusión sobre demanda diaria de retail, donde los árboles potenciados por gradiente superan a los enfoques establecidos. El rendimiento de LightGBM ha sido

validado en competiciones internacionales de ciencia de datos como las organizadas por Kaggle, y se ha consolidado como una opción confiable para tareas de regresión en contextos empresariales reales; la evidencia sobre los modelos globales (un único modelo entrenado sobre el conjunto de las series) respalda además ese diseño (Montero-Manso & Hyndman, 2021).

Los modelos de boosting por gradiente admiten, además, una atribución exacta de cada predicción a las variables que la componen. Los valores SHAP (SHapley Additive exPlanations) reparten la predicción entre las variables de entrada con una formulación derivada de la teoría de juegos cooperativos, y su variante para conjuntos de árboles, TreeSHAP, la calcula de forma exacta y en tiempo polinómico aprovechando la estructura del propio ensamble (Lundberg et al., 2020). Cuando el modelo predice a través de un enlace logarítmico, como ocurre con la pérdida Tweedie, ese reparto es exacto en la escala del modelo y no en unidades: el valor base más la suma de las contribuciones da el logaritmo de la predicción, de modo que cada contribución actúa como un factor multiplicativo sobre ella. Esa atribución exacta convierte al modelo en una herramienta de diagnóstico y no solo de predicción, porque permite cuantificar cuánto aporta cada variable explicativa al pronóstico y verificar que el aporte sea coherente con el conocimiento del negocio.

1.2.8 Comparación entre modelos estadísticos y de aprendizaje automático

Los modelos estadísticos tradicionales como ARIMA, el promedio móvil o el modelo ingenuo han sido ampliamente utilizados por su simplicidad, interpretabilidad y capacidad de adaptarse a series temporales con estructuras definidas (Hyndman & Athanasopoulos, 2018). Sin embargo, su efectividad disminuye ante datos con ruido, múltiples estacionalidades o comportamientos no lineales.

Por otro lado, los modelos de aprendizaje automático permiten incorporar múltiples variables y relaciones sin la necesidad de una especificación funcional estricta, lo que los hace particularmente útiles en entornos comerciales dinámicos. Los árboles potenciados por gradiente, familia a la que pertenecen LightGBM y XGBoost,

mostraron un alto rendimiento en la competencia M5, sobre demanda minorista jerárquica con grandes volúmenes de datos, donde la mayoría de los primeros puestos usó LightGBM (Makridakis et al., 2022). Esa ventaja no es general: sobre series mensuales de la competencia M3, las redes neuronales y otros métodos de aprendizaje automático, ninguno de ellos de boosting por gradiente, no superaron a los métodos estadísticos, como muestran Makridakis et al. (2018).

Integrar ambos enfoques en un motor de pronóstico permite combinar la robustez de los modelos clásicos con la adaptabilidad de las técnicas modernas, generando así un sistema más completo y preciso.

1.2.9 Variable dependiente: precisión del pronóstico de demanda

1.2.9.1 Concepto de precisión en modelos de pronóstico

La exactitud en el pronóstico representa la capacidad de un modelo para aproximarse a los valores reales observados. Chopra (2019) señala que métricas como el error absoluto medio (MAE) y el error porcentual absoluto medio (MAPE) son herramientas clave para evaluar la efectividad de un sistema predictivo en términos operativos.

En el presente estudio, estas métricas se utilizan para comparar el desempeño de distintos enfoques; el MAE, sumado al valor absoluto del sesgo, es además el criterio con que se selecciona el modelo de cada combinación de análisis (apartado 1.2.11). La elección de estas métricas se fundamenta en su utilidad práctica, ya que permiten interpretar fácilmente la magnitud del error y tomar decisiones más precisas respecto a abastecimiento y planificación.

1.2.9.2 Exactitud, consistencia y estabilidad del pronóstico

Además de la precisión puntual, la consistencia es un criterio esencial para evaluar la confiabilidad de un sistema de pronóstico en el tiempo. El sesgo (Bias) mide la tendencia sistemática a sobrestimar o subestimar la demanda, afectando la calidad del pronóstico en contextos reales. Fildes et al. (2009) documentan este sesgo en los

ajustes de criterio que los planificadores aplican a los pronósticos estadísticos, con una tendencia general al optimismo, y desarrollan modelos para corregirlo.

Al incluir el análisis del sesgo dentro del esquema de evaluación, se busca no solo minimizar el error, sino también lograr pronósticos balanceados que reflejen con mayor fidelidad el comportamiento de la demanda. Esto aporta estabilidad en los resultados y favorece la confianza del equipo de planificación en las herramientas automatizadas.

1.2.10 Métricas estadísticas para la evaluación del desempeño

La evaluación de modelos de pronóstico constituye una etapa esencial para garantizar la utilidad práctica de los sistemas predictivos. Las métricas empleadas no solo permiten comparar el rendimiento entre distintos enfoques, sino también identificar posibles sesgos y errores recurrentes en las proyecciones.

Hyndman y Koehler (2006) revisan las métricas más utilizadas para evaluar la calidad de un pronóstico; este estudio emplea tres de ellas y suma el sesgo: el error absoluto medio (MAE), el error porcentual absoluto medio (MAPE), la raíz del error cuadrático medio (RMSE) y el sesgo promedio (Bias). Cada una aporta una perspectiva distinta sobre el desempeño del modelo: mientras el MAE representa el error promedio en unidades reales, el MAPE facilita la comparación en términos relativos, expresados en porcentaje. El RMSE, por su parte, penaliza errores grandes de forma más severa, y el Bias permite identificar si el modelo tiende a subestimar o sobrestimar sistemáticamente la demanda.

En esta investigación se optó por utilizar el MAE, el MAPE, el RMSE y el Bias. Los tres primeros permiten evaluar la magnitud de los errores desde perspectivas complementarias en unidades reales, en términos porcentuales y penalizando con mayor severidad los errores grandes, mientras que el Bias identifica tendencias sistemáticas de sobrestimación o subestimación. Dado que el MAE y el RMSE dependen de la escala de cada serie, ambos se calculan serie por serie y se agregan con la mediana de los valores obtenidos, lo que evita que los productos de mayor volumen dominen la comparación. La correcta elección de métricas de evaluación

resulta crítica cuando se pretende automatizar el proceso, ya que influye directamente en la selección del modelo óptimo para cada unidad de análisis.

1.2.11 Sesgo del pronóstico, funciones de pérdida y métricas ponderadas por valor

La magnitud del error no agota la evaluación de un pronóstico: importa también su dirección. El sesgo (Bias) mide la tendencia sistemática a sobrestimar o subestimar la demanda, y su costo operativo es asimétrico: la sobrestimación acumula inventario, mientras que la subestimación produce quiebres de stock y ventas perdidas. En demanda intermitente, además, los estimadores clásicos presentan sesgos estructurales documentados (Syntetos & Boylan, 2001), por lo que el control del sesgo debe formar parte explícita del criterio de evaluación.

La función de pérdida con que se entrena un modelo de aprendizaje automático determina qué característica de la distribución aprende a predecir: la pérdida absoluta optimiza la mediana condicional, de modo que en distribuciones asimétricas y con alta proporción de ceros (el caso típico de la demanda por SKU) produce subestimación sistemática. Las funciones de la familia Tweedie, concebidas para variables no negativas con masa de probabilidad en cero, desplazan el objetivo hacia la media condicional y corrigen ese sesgo; la elección entre ambas se resolvió empíricamente en este estudio mediante la optimización de hiperparámetros. La elección de la distribución de pérdida para demanda minorista entera es, en sí misma, un objeto de estudio del área (Kolassa, 2016).

Finalmente, la agregación del error entre series exige una unidad común. Cuando las unidades físicas difieren entre SKU, promediar errores porcentuales por serie, como hace el MAPE, otorga el mismo peso a productos marginales y críticos, y se vuelve inestable ante demandas próximas a cero (Hyndman & Koehler, 2006). La alternativa adoptada pondera el error absoluto de cada serie por su demanda valorizada al costo unitario (WMAPE valorizado), y la métrica de decisión del estudio, $D = \text{WMAPE} + |\text{Bias}|$, suma a esa magnitud el valor absoluto del sesgo agregado: un

solo número, alineado con el costo económico de la decisión de planificación, que exige a la vez un error pequeño y un sesgo agregado cercano a cero.

El estudio agrega el error de dos maneras distintas, que conviene escribir por separado. Sea y_{st} la venta observada de la serie s en el mes t, $\hat{y}_{st}$ su pronóstico y c_s el costo unitario del producto. El criterio con que el motor elige el modelo de cada serie, que es también el estadístico del contraste pareado, se calcula serie por serie y en unidades del producto, sobre los meses de la ventana evaluada:

$E_s = MAE_s + |Bias_s|$, con MAE_s = promedio de $|\hat{y}_{st} - y_{st}|$ y $Bias_s$ = promedio de $(\hat{y}_{st} - y_{st})$ (1)

La métrica de decisión del portafolio, en cambio, suma todas las series con costo asignado y se expresa en porcentaje de la demanda valorizada, es decir, de las ventas observadas valorizadas al costo unitario:

$D = WMAPE + |Bias|$, con $WMAPE = 100 \times \Sigma\, c_s\, |\hat{y}_{st} - y_{st}| \,/\, \Sigma\, c_s\, y_{st}$ y $Bias = 100 \times \Sigma\, c_s\, (\hat{y}_{st} - y_{st}) \,/\, \Sigma\, c_s\, y_{st}$, sumando sobre series y meses (2)

Minimizar la primera no garantiza minimizar la segunda. La ecuación (1) se minimiza serie por serie, en unidades y sin ponderar por valor, y penaliza el sesgo de cada serie por separado; la ecuación (2) pondera cada serie por su valor y deja que sesgos de signo opuesto se compensen entre series, de modo que el modelo de menor E_s en cada serie no compone necesariamente el portafolio de menor D.

1.2.12 Criterios de selección y validación de modelos predictivos

La selección de un modelo predictivo no debe sustentarse únicamente en su complejidad algorítmica o en su novedad tecnológica, sino en su capacidad real para ajustarse al comportamiento de la serie analizada y producir resultados confiables. La validación de modelos de pronóstico requiere contrastar su desempeño sobre datos históricos mediante métricas objetivas de error, considerando tanto la exactitud como la estabilidad del resultado. En este sentido, un modelo adecuado es aquel que logra un equilibrio entre precisión, interpretabilidad, robustez y viabilidad de aplicación en el entorno organizacional (Hyndman & Koehler, 2006; Kuhn & Johnson, 2013).

En la presente investigación, la selección del modelo se plantea a partir de un proceso comparativo entre distintos enfoques, utilizando métricas como MAE, MAPE, RMSE y Bias. Estos indicadores permiten evaluar el error absoluto, la magnitud relativa de las desviaciones y la tendencia sistemática a sobrestimar o subestimar la demanda. Asimismo, la validación exige verificar que el modelo mantenga un comportamiento consistente en diferentes combinaciones de análisis, particularmente a nivel SKU, canal y regional. En consecuencia, el criterio de selección adoptado prioriza el modelo de menor error compuesto (MAE + |Bias|) en la ventana de validación; la consistencia se verifica después, en la tasa de acierto de la selección y en la lectura por estratos, lo que sustenta su utilidad práctica para la planificación de la demanda.

1.2.13 Evaluación fuera de muestra: partición temporal, orígenes rodantes y horizonte

En series temporales la validación no puede reordenar aleatoriamente las observaciones: el pronóstico solo tiene sentido hacia adelante, por lo que la evaluación se organiza en particiones cronológicas en las que los modelos se ajustan con el pasado y se miden sobre un futuro que no vieron (Hyndman & Athanasopoulos, 2018; Tashman, 2000). La práctica de referencia distingue además entre la ventana con la que se toman decisiones (selección de modelos, calibración de hiperparámetros) y el bloque final de prueba, que debe permanecer ajeno a la selección y al ajuste de los modelos para que el error reportado sea un estimador honesto del desempeño futuro (Bergmeir & Benítez, 2012).

La calibración de hiperparámetros admite tres estrategias de búsqueda. La búsqueda en rejilla evalúa todas las combinaciones de una lista de valores, y su costo crece de forma exponencial con el número de hiperparámetros. La búsqueda aleatoria, con el mismo número de evaluaciones, prueba más valores distintos de cada hiperparámetro y por eso suele superar a la rejilla, ya que solo unos pocos hiperparámetros influyen de manera sustancial en el error, y no son los mismos en todos los problemas (Bergstra & Bengio, 2012). La optimización bayesiana secuencial usa los ensayos ya evaluados para proponer los siguientes. El estimador de Parzen en árbol (TPE, por su sigla en inglés) lo hace modelando por separado las

configuraciones buenas y las malas, y admite espacios condicionales, como el de una potencia que solo existe cuando la pérdida es Tweedie (Bergstra et al., 2011). La biblioteca Optuna implementa ese estimador (Akiba et al., 2019). En este estudio, los hiperparámetros se eligieron sobre un pliegue interno del entrenamiento; solo el número de árboles se fijó por parada temprana sobre validación, asimetría declarada en el apartado 4.3.2, y el bloque de prueba no intervino en la selección ni en el ajuste de los modelos.

Evaluar desde un único origen temporal, como en la partición cronológica descrita al comienzo de este apartado, expone la medición al azar de ese corte. El esquema de orígenes rodantes (rolling origin) repite el ejercicio desde múltiples puntos de partida y mide el error en función del horizonte de pronóstico, lo que estabiliza la estimación y revela cómo se degrada cada método a medida que proyecta más lejos (Tashman, 2000). Las grandes competencias empíricas del campo evaluaron los métodos fuera de muestra sobre el tramo final de miles de series, con el error promediado a lo largo del horizonte de pronóstico (Makridakis et al., 2020, 2022).

Un riesgo adicional de la selección de modelos sobre ventanas cortas es la sobrestimación del ganador, la llamada maldición del ganador: elegir el mínimo entre varios candidatos evaluados en una misma ventana capitaliza el azar de esa ventana, y el desempeño del elegido fuera de muestra resulta, en promedio, inferior al que exhibió al ser seleccionado. Por ello la eficacia de una regla de selección se verifica en el bloque de prueba mediante su tasa de acierto y la comparación formal entre modelos sobre múltiples series se realiza con pruebas no paramétricas pareadas, conforme al procedimiento recomendado por Demšar (2006).

1.2.14 La combinación de pronósticos y su robustez ante cambios de régimen

Una alternativa a la selección de un único modelo es la combinación de los pronósticos disponibles. El resultado fundacional de Bates y Granger (1969) demostró que combinar dos pronosticadores imperfectos produce, en general, un error menor que el de cualquiera de los dos por separado, porque sus errores no están

perfectamente correlacionados y la mezcla los diversifica. La síntesis de Timmermann (2006) explica además una paradoja persistente de la literatura: los pesos óptimos de combinación deben estimarse a partir de datos, y el error de esa estimación suele consumir la ganancia teórica, de modo que el promedio simple, que asigna pesos iguales sin estimarlos a partir de los datos, resulta extraordinariamente difícil de superar en la práctica; la revisión de Clemen (1989) consolidó esa evidencia sobre más de doscientos trabajos.

La evidencia empírica de las competencias internacionales de pronóstico respalda a gran escala el valor de la combinación: en la competencia M4, con cien mil series, los primeros puestos fueron un método híbrido y combinaciones (Makridakis et al., 2020). La combinación se conecta con la maldición del ganador tratada en la sección anterior: si la selección del mejor modelo sobre una ventana finita de validación es en gran medida ruido, repartir la apuesta entre varios candidatos razonables protege contra ese ruido sin renunciar a la evidencia. El compendio de Petropoulos et al. (2022) recoge la combinación entre las prácticas de consenso del área.

La combinación, sin embargo, tiene una condición de funcionamiento: su ventaja proviene de cancelar sesgos de signo opuesto entre los integrantes del conjunto de modelos combinados. La literatura de deriva de concepto ayuda a precisar cuándo esa condición deja de cumplirse (Gama et al., 2014). Ante un cambio estructural de régimen (una crisis de precios, un quiebre de demanda), los modelos ajustados sobre el pasado tienden a equivocarse todos en la misma dirección, la cancelación desaparece y los métodos adaptativos, que se reanclan en la observación más reciente, recuperan terreno. Esta asimetría motiva los esquemas de monitoreo y conmutación: vigilar el sesgo reciente del sistema con información ya observada y transferir peso hacia los integrantes adaptativos cuando la señal indica un cambio de régimen.

1.2.15 Factores que afectan la precisión del pronóstico en entornos empresariales

La precisión del pronóstico en contextos empresariales está condicionada por múltiples factores que interactúan entre sí y que pueden afectar significativamente el desempeño de los modelos predictivos. Entre los más relevantes se encuentran la calidad de los datos históricos, la frecuencia y continuidad de las observaciones, la presencia de estacionalidad, la existencia de eventos atípicos y la variabilidad inherente del mercado. Cuando los datos presentan inconsistencias, vacíos de información o registros no estandarizados, la capacidad del modelo para identificar patrones válidos disminuye considerablemente (Hyndman & Athanasopoulos, 2018).

A estos factores se suman elementos propios del entorno organizacional, como la falta de integración entre áreas, el uso de criterios subjetivos en los ajustes del pronóstico y la ausencia de mecanismos sistemáticos de retroalimentación. En empresas con portafolios extensos y múltiples canales de comercialización, como NOVAPACK S.A., la heterogeneidad del comportamiento de la demanda entre productos, regiones y segmentos de clientes es otro de esos factores. Por ello, mejorar la precisión del pronóstico no depende únicamente de aplicar algoritmos más sofisticados, sino también de fortalecer la calidad del dato, estandarizar los procesos analíticos y reducir la dependencia de decisiones empíricas no validadas estadísticamente.

Entre esos factores, los eventos atípicos admiten un tratamiento propio. Un evento exógeno es una perturbación de la demanda observada cuya causa es ajena a la dinámica que el modelo aprende de la historia, como una pandemia, una crisis cambiaria, una promoción o una licitación adjudicada. Conviene distinguir dos familias. Los eventos conocidos ex ante, como el calendario escolar, las promociones y los cambios de precio planificados o los lanzamientos de productos, pueden entrar como variables explicativas con su valor futuro declarado. Los que solo se observan ex post, como una pandemia o un quiebre de abastecimiento no planificado, se tratan corrigiendo la historia con que se ajusta el modelo o reconociendo el cambio de régimen que producen. El análisis de intervención formalizó el primer tratamiento: el efecto de un evento se representa con una variable de pulso cuando es transitorio, o de escalón cuando desplaza el nivel de la serie de forma permanente (Box & Tiao, 1975); su versión operativa son las variables indicadoras y de calendario de los

modelos de regresión (Hyndman & Athanasopoulos, 2018). Cuando el evento no se anuncia ni se registra, el recurso que queda es el descrito en la sección anterior: vigilar el desempeño reciente del pronóstico para detectar la deriva (Gama et al., 2014).

1.2.16 Aplicaciones del pronóstico en cadenas de suministro y retail

El pronóstico de la demanda es un componente esencial dentro de la gestión de la cadena de suministro. Chopra (2019) sostiene que un sistema de pronóstico eficaz permite optimizar los niveles de inventario, mejorar el servicio al cliente y reducir costos operativos. En entornos de retail, la precisión del pronóstico impacta directamente en la rotación de productos y en la planificación de compras.

Esta investigación se orienta a fortalecer estos procesos a través de un enfoque automatizado, capaz de adaptarse a distintos patrones de comportamiento de la demanda. Así, se espera que el sistema no solo mejore la planificación de la oferta, sino que contribuya a una cadena de suministro más eficiente y alineada con la demanda real del mercado.

1.2.17 Retos del pronóstico a nivel SKU en entornos reales

El pronóstico de la demanda a nivel de unidad mínima de análisis, como el SKU, presenta múltiples desafíos que exceden la capacidad de los modelos tradicionales cuando se enfrentan a condiciones reales de operación. A diferencia del pronóstico agregado, los modelos a nivel SKU deben lidiar con baja frecuencia de ventas, alta variabilidad, estacionalidades irregulares y la presencia de eventos como promociones o introducción de nuevos productos.

Fildes et al. (2009) muestran que, en empresas de la cadena de suministro, los pronósticos estadísticos por producto se corrigen con frecuencia por criterio, con un esfuerzo de gestión considerable, y que esos ajustes no siempre mejoran la precisión. Por su parte, Boylan y Syntetos (2021) vinculan el pronóstico de la demanda intermitente con sus consecuencias en el inventario, donde los errores a nivel SKU se traducen en sobrecostos por exceso de inventario o en pérdidas por quiebres de stock.

En este estudio, se aborda esta problemática mediante un enfoque modular que permite aplicar modelos ajustados a cada combinación SKU-canal-regional, tomando en cuenta su comportamiento individual. Además, la inclusión de métricas de evaluación específicas y la automatización del proceso facilitan una implementación escalable y sostenible, incluso en portafolios con alta rotación y complejidad operativa.

1.2.18 Marco metodológico teórico

1.2.18.1 Análisis de series temporales en la ciencia de datos

El análisis de series temporales constituye una rama fundamental de la ciencia de datos orientada al estudio de observaciones registradas a lo largo del tiempo, con el propósito de identificar patrones, tendencias, estacionalidades y comportamientos recurrentes que permitan comprender la dinámica de un fenómeno y anticipar su evolución futura. A diferencia de otros tipos de datos, las series temporales presentan dependencia temporal, lo que implica que cada observación guarda relación con valores previos y que el orden cronológico constituye un elemento central del análisis (Hyndman & Athanasopoulos, 2018).

En el ámbito empresarial, el análisis de series temporales resulta especialmente útil para estudiar fenómenos como ventas, demanda, inventarios, precios o producción. Su aplicación permite transformar datos históricos en conocimiento predictivo, facilitando la toma de decisiones basada en evidencia. Dentro de la ciencia de datos, este análisis combina herramientas estadísticas tradicionales con técnicas modernas de aprendizaje automático, permitiendo abordar tanto patrones lineales como comportamientos complejos y no estacionarios. En el caso de la presente investigación, el análisis de series temporales proporciona la base metodológica para diseñar un motor de pronóstico capaz de adaptarse a las variaciones de demanda observadas en NOVAPACK S.A.

1.2.18.2 Modelos estadísticos clásicos: ARIMA, ETS y promedios móviles

Los modelos estadísticos clásicos han sido ampliamente utilizados en el pronóstico de series temporales debido a su solidez teórica, interpretabilidad y eficacia en contextos donde los datos presentan estructuras relativamente estables. Entre los más representativos se encuentra ARIMA, modelo que combina componentes autorregresivos, de diferenciación e integración y de medias móviles, permitiendo modelar series con tendencia y dependencia temporal. Su principal fortaleza radica en la capacidad de capturar patrones internos de la serie a partir de sus propios rezagos (Hyndman & Athanasopoulos, 2018).

Por su parte, los modelos ETS se fundamentan en la descomposición de la serie en componentes de error, tendencia y estacionalidad, ofreciendo una alternativa útil cuando el comportamiento temporal puede explicarse mediante estas estructuras. Los promedios móviles, en cambio, constituyen una técnica más simple orientada al suavizamiento de fluctuaciones de corto plazo, generando estimaciones basadas en la media de observaciones recientes. Aunque estos modelos presentan limitaciones frente a series altamente irregulares o no lineales, continúan siendo relevantes como referencia metodológica y como línea base para comparar el desempeño de enfoques más complejos.

1.2.18.3 Modelos de aprendizaje automático aplicados a datos secuenciales

El avance del aprendizaje automático ha transformado profundamente los enfoques utilizados en el pronóstico de series temporales. Si bien los modelos tradicionales continúan siendo relevantes por su simplicidad y capacidad explicativa, en los últimos años han surgido modelos de aprendizaje automático que superan significativamente en precisión y adaptabilidad a los métodos estadísticos clásicos en muchos contextos.

Makridakis et al. (2022) destacan que algoritmos de boosting por gradiente como LightGBM, cuando se aplican con una adecuada ingeniería de características, permiten capturar relaciones complejas entre variables, lo que los hace especialmente útiles en entornos minoristas con múltiples SKU, tiendas y estacionalidades.

Asimismo, han ganado relevancia modelos de arquitectura neuronal profunda, como N-BEATS o DeepAR, diseñados específicamente para series temporales. Estos modelos pueden aprender representaciones latentes a partir de datos secuenciales, mejorando la capacidad de generalización cuando existen patrones de demanda no lineales o ruidos contextuales. En esa línea se sitúan las arquitecturas que la extensión exploratoria de este trabajo evalúa: la línea base lineal DLinear, el apilamiento jerárquico N-HiTS, sucesor de N-BEATS, y la atención con covariables del Temporal Fusion Transformer (TFT), junto con DeepAR como recurrente probabilístico, evaluado en las iteraciones iniciales y retirado por desempeño (apartado 4.3.3); a ellas se añade una familia distinta, la de los modelos fundacionales de series de tiempo como Chronos, preentrenados sobre grandes colecciones de series y aplicados sin reentrenamiento sobre los datos del caso.

No obstante, estos avances también plantean desafíos relacionados con la interpretación de resultados, la necesidad de mayor capacidad computacional y la dependencia de volúmenes importantes de datos limpios y estructurados. En este trabajo, se ha optado por integrar técnicas como LightGBM, que logran un balance adecuado entre precisión, eficiencia y posibilidad de implementación real en un entorno empresarial como el de NOVAPACK S.A.

1.2.18.4 Metodología CRISP-DM aplicada al desarrollo de motores de pronóstico

La metodología CRISP-DM constituye uno de los marcos de trabajo más utilizados en proyectos de analítica y minería de datos, debido a su enfoque estructurado, iterativo y adaptable a distintos contextos organizacionales. Este modelo organiza el desarrollo analítico en seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Su principal ventaja radica en que vincula los objetivos técnicos con las necesidades reales de la organización, en línea con el principio de que los mejores modelos predictivos se apoyan en el conocimiento experto del contexto del problema y no solo en la técnica de modelado (Kuhn & Johnson, 2013).

Aplicada al desarrollo de un motor de pronóstico, la metodología CRISP-DM permite ordenar el proceso desde la identificación del problema de planificación en NOVAPACK S.A. hasta la formulación de una solución automatizada basada en evidencia. En primer lugar, facilita comprender las limitaciones actuales del proceso de pronóstico; posteriormente, orienta la recolección, depuración y transformación de los datos históricos; luego, guía el entrenamiento y comparación de distintos modelos predictivos; y finalmente, permite evaluar su utilidad práctica y proyectar su integración a los procesos de toma de decisiones.

1.2.19 Marco tecnológico

1.2.19.1 Herramientas y lenguajes de programación utilizados

El desarrollo de soluciones de pronóstico automatizado requiere herramientas tecnológicas que permitan procesar grandes volúmenes de información, construir modelos predictivos y generar resultados reproducibles. En este contexto, Python se ha consolidado como uno de los lenguajes de programación más utilizados en ciencia de datos por su flexibilidad, sintaxis accesible y amplia disponibilidad de bibliotecas especializadas. Su ecosistema facilita abordar de manera integrada la preparación de los datos, el modelado predictivo y la visualización de los resultados (Chollet, 2018).

Dentro de este entorno, pandas cumple un rol central en la manipulación y estructuración de datos tabulares, permitiendo organizar series históricas por SKU, canal y regional. NumPy aporta eficiencia al procesamiento numérico y a la ejecución de operaciones matriciales requeridas en el análisis. Por su parte, LightGBM ofrece una implementación optimizada de boosting por gradiente. A este núcleo se suman SciPy, que provee las pruebas de significancia con las que se contrasta la hipótesis, Optuna, que realiza la búsqueda bayesiana de hiperparámetros, y Matplotlib, que genera de manera programática las figuras del estudio. La combinación de estas herramientas resulta pertinente para el desarrollo del motor propuesto, ya que permite construir un flujo analítico robusto, escalable y compatible con las necesidades operativas de NOVAPACK S.A. Dentro de ese flujo, LightGBM aporta el componente

de aprendizaje automático, con una eficiencia probada sobre grandes volúmenes de datos (Ke et al., 2017).

1.2.19.2 Flujo de procesamiento automatizado de datos

Un flujo de procesamiento automatizado de datos comprende el conjunto de etapas secuenciales mediante las cuales la información es extraída, transformada, analizada y convertida en resultados útiles para la toma de decisiones, minimizando la intervención manual. En el ámbito del pronóstico de demanda, este flujo debe asegurar que los datos históricos ingresen al sistema de manera ordenada, sean depurados según criterios definidos, se transformen en variables analíticas y finalmente alimenten los modelos predictivos que generarán las estimaciones futuras (Kreuzberger et al., 2023; Kuhn & Johnson, 2013).

En la propuesta desarrollada, el flujo automatizado inicia con la ingesta de los registros históricos de ventas, continúa con la validación y limpieza de datos, prosigue con la construcción de variables temporales y de segmentación, y culmina con la ejecución comparativa de los modelos y la selección automática del de mejor desempeño. Esta secuencia permite reducir errores humanos, estandarizar criterios analíticos y acelerar la generación de resultados. Además, facilita la trazabilidad del proceso, dado que cada etapa puede ser documentada y replicada bajo las mismas condiciones, fortaleciendo la confiabilidad del sistema de pronóstico. En la solución desarrollada este flujo parte de una captura congelada: los registros se extraen una sola vez del sistema de gestión, se seudonimizan y se sellan con una huella criptográfica, y a partir de ese momento el pipeline no vuelve a consultar la base de datos. Cada corrida registra en un manifiesto la huella del dato, la de la configuración y la versión del código, de modo que la trazabilidad no es una propiedad declarada sino verificable archivo por archivo.

1.2.19.3 Integración con herramientas de análisis y visualización de resultados

La utilidad de un motor de pronóstico no depende únicamente de la calidad técnica de sus modelos, sino también de su capacidad para traducir los resultados en

información comprensible y accionable para los usuarios del negocio. En la solución desarrollada esa traducción se resuelve en dos planos. El primero es la salida del propio motor, que además de los pronósticos escribe las tablas y las figuras del estudio como archivos versionados junto a su manifiesto de trazabilidad; las figuras se generan de manera programática, de modo que cada gráfico del documento se reproduce ejecutando el flujo y no depende de una edición manual.

El segundo plano es un visor analítico local construido sobre esas mismas salidas, que permite revisar el comportamiento histórico de la demanda, comparar pronósticos frente a valores reales, monitorear las métricas de error por modelo y observar diferencias entre productos, canales y regiones. Este visor es un instrumento de revisión del experimento y no forma parte de los objetivos de la investigación: su función es hacer auditable el resultado de cada corrida. La difusión hacia las áreas de planificación, compras y dirección comercial queda planteada como una etapa posterior de implementación.

1.2.19.4 Escalabilidad y mantenimiento del motor de pronóstico

La escalabilidad de un motor de pronóstico hace referencia a su capacidad para ampliar su cobertura analítica sin perder eficiencia, estabilidad ni calidad en los resultados. En contextos empresariales con miles de SKU, múltiples canales y diversas regiones, resulta indispensable que la solución propuesta pueda adaptarse al incremento del volumen de datos, a la incorporación de nuevas categorías de análisis y a la eventual integración de algoritmos adicionales. Una arquitectura escalable evita que el sistema quede limitado a pruebas aisladas y permite proyectar su uso sostenido en la operación de la empresa (Ke et al., 2017; Kreuzberger et al., 2023).

Por otra parte, el mantenimiento del motor implica establecer procedimientos de actualización, monitoreo y mejora continua. Esto incluye revisar periódicamente la calidad de los datos de entrada, recalibrar modelos cuando cambien los patrones de demanda, incorporar nuevas variables explicativas y verificar que las métricas de desempeño se mantengan dentro de niveles aceptables. En consecuencia, la

sostenibilidad del sistema no depende solo de su diseño inicial, sino también de la capacidad institucional para administrarlo como una herramienta viva, adaptable a la evolución del negocio y del mercado. En la solución desarrollada ese mantenimiento se apoya en dos mecanismos concretos. El entorno de ejecución está empaquetado en una imagen de contenedor que fija la versión del intérprete y de cada biblioteca, de manera que una corrida realizada meses después parte de las mismas condiciones. Y una suite de pruebas automatizadas verifica en cada ejecución las restricciones metodológicas que no pueden relajarse: el orden estricto de la partición temporal, la ausencia de información futura en las variables explicativas y el control de lo que el proyecto publica.

1.3 Marco conceptual

Esta sección reúne, de manera sintética, los conceptos esenciales que la tesis maneja de forma transversal. Cada término se presenta en su acepción operativa dentro de esta investigación; su tratamiento teórico en profundidad se encuentra en el marco teórico.

1.3.1 Demanda y planificación de la demanda

La demanda es la cantidad de un producto que el mercado requiere en un período determinado, y su planificación es el proceso estratégico que busca anticiparla con la mayor precisión posible para alinear los recursos operativos y logísticos de la empresa con las expectativas del mercado (Chopra, 2019). En esta investigación la demanda se mide como la venta mensual registrada por producto, canal y regional, que constituye el insumo histórico del motor de pronóstico.

1.3.2 Serie temporal y pronóstico de demanda

Una serie temporal es una secuencia de observaciones registradas en orden cronológico, cuya característica distintiva es la dependencia temporal: cada valor guarda relación con los anteriores, por lo que el orden constituye información (Hyndman & Athanasopoulos, 2018). El pronóstico de demanda es la estimación de los valores futuros de esa serie a partir de sus patrones históricos de nivel, tendencia

y estacionalidad. En este estudio cada serie corresponde a la demanda mensual de una combinación SKU-canal-regional.

1.3.3 SKU, canal, regional y combinación de negocio

El SKU (stock keeping unit) es el identificador único de un producto en el catálogo comercial: la unidad mínima a la que se registran las ventas y se gestiona el inventario (Chopra, 2019). El canal designa el segmento de comercialización (mayorista, minorista, distribuidores, institucional; consolidados operativamente en esta investigación en dos segmentos: masivo e institucional) y la regional, la unidad geográfica de operación. La combinación SKU-canal-regional, la clave de negocio del estudio, constituye la unidad de análisis del pronóstico: el portafolio de NOVAPACK S.A. supera los 900 SKU que, desagregados por canal y regional, conforman más de 4.000 combinaciones, y el motor está concebido para generar un pronóstico específico por cada una.

1.3.4 Clasificación de los patrones de demanda: intermitencia y variabilidad

No toda la demanda a nivel SKU se comporta como una serie continua y regular. Syntetos et al. (2005) propusieron clasificar los patrones de demanda según dos dimensiones: el intervalo promedio entre demandas (ADI, por su sigla en inglés) y el cuadrado del coeficiente de variación del tamaño de la demanda (CV^2). El cruce de ambas, con umbrales teóricos en 1,32 y 0,49 respectivamente, define cuatro regímenes (demanda suave, errática, intermitente y esporádica de tamaño irregular o lumpy), y la clasificación orienta la elección del método de pronóstico para cada régimen (Boylan & Syntetos, 2021).

Esta clasificación cumple un doble papel en el presente estudio. Primero, fundamenta los criterios de inclusión de la muestra: las series de intermitencia crónica, cuyo error no admite una medición fiable, se excluyen mediante el umbral de proporción de meses sin venta. Segundo, estructura la lectura de los resultados: las métricas de la validación técnica (apartado 4.3.2) se estratifican por régimen ADI-CV^2,

lo que permite verificar si la ventaja de un modelo es transversal o está concentrada en un tipo particular de demanda.

1.3.5 Motor de pronóstico automatizado

Se denomina motor de pronóstico automatizado al sistema que aplica, evalúa y selecciona modelos predictivos de forma autónoma para cada unidad de análisis; como tal, sigue la lógica de los sistemas de apoyo a la decisión basados en modelos (Power, 2002). Su rasgo definitorio no es un algoritmo particular sino el procedimiento: entrenar un conjunto de modelos candidatos por serie, medir su desempeño con métricas objetivas y seleccionar el de mejor resultado para generar el pronóstico. Constituye la variable independiente de esta investigación.

Por la composición de su conjunto de candidatos, el motor es híbrido: reúne métodos estadísticos de series temporales y un modelo de aprendizaje automático, familias cuyo desempeño se ha contrastado empíricamente (Makridakis et al., 2018). Por su mecanismo es de selección, porque elige un único candidato para cada combinación; por eso en la constatación técnica figura como motor de selección automática. El híbrido en sentido estricto fusiona componentes de ambas familias en un único pronóstico, como el método ganador de la competencia M4 (Makridakis et al., 2020); la hibridación por selección, la del motor validado, decide serie por serie entre modelos separados; la hibridación por combinación, medida en la extensión exploratoria, promedia los pronósticos de varios integrantes del conjunto (Bates & Granger, 1969). Ninguno de estos tres tipos de hibridación corresponde a los esquemas híbridos del apartado 1.2.1, que combinan juicio experto y datos. En el reparto de la selección (Figura 9), 1.301 de las 1.668 series quedaron con un método estadístico y 367 con el modelo de aprendizaje automático: ninguna familia quedó vacía.

1.3.6 Aprendizaje automático y boosting por gradiente

El aprendizaje automático agrupa los métodos que aprenden patrones directamente de los datos, sin exigir una especificación funcional previa de la relación entre las variables (Hastie et al., 2009). Dentro de esa familia, el boosting por gradiente

construye un predictor fuerte mediante la suma secuencial de árboles de decisión en la que cada árbol corrige los errores del anterior; LightGBM es la implementación de esta técnica utilizada en el estudio, elegida por su eficiencia sobre conjuntos de datos extensos (Ke et al., 2017).

1.3.7 Precisión del pronóstico y métricas de error

La precisión del pronóstico es el grado de aproximación entre los valores pronosticados y los observados, y se cuantifica mediante métricas de error (Hyndman & Koehler, 2006). En esta investigación se emplean por serie el MAE (error absoluto medio, en unidades), el MAPE (error porcentual absoluto medio), el RMSE (raíz del error cuadrático medio, que penaliza los errores grandes) y el Bias (sesgo promedio, que revela la tendencia sistemática a sobrestimar o subestimar); para la comparación agregada entre modelos se utiliza el error compuesto valorizado D = WMAPE + |Bias|, que pondera el error de cada serie por el costo unitario del producto. Constituye la variable dependiente del estudio.

1.3.8 Evaluación fuera de muestra del pronóstico

La evaluación fuera de muestra consiste en medir el error de un modelo sobre observaciones que no participaron de su ajuste, respetando el orden cronológico: el modelo se entrena con el pasado y se evalúa sobre un futuro que no vio; es el estándar de honestidad metodológica del área, pues el error medido dentro de la muestra tiende a subestimar el error real de pronóstico (Tashman, 2000). Toda la medición del desempeño predictivo de esta tesis se realiza bajo este esquema.

1.4 Marco contextual

1.4.1 Contexto empresarial de la planificación de la demanda en NOVAPACK S.A.

En el ámbito empresarial, la planificación de la demanda constituye un proceso integrador que conecta las necesidades del mercado con las decisiones internas de compras, inventario, producción y distribución. Su finalidad es anticipar la demanda

futura con un nivel de precisión suficiente para asignar recursos de forma eficiente y reducir los riesgos asociados a faltantes o excedentes de inventario. Desde esta perspectiva, la planificación de la demanda no solo representa una actividad técnica, sino una función estratégica que articula distintas áreas de la organización alrededor de una visión común del comportamiento esperado del mercado (Chopra, 2019).

En empresas de distribución y comercialización, la planificación adquiere mayor complejidad cuando el portafolio es amplio, los canales de venta son diversos y existen diferencias regionales en el consumo. Bajo estas condiciones, la gestión basada únicamente en la experiencia o en promedios históricos resulta insuficiente. Por ello, se vuelve necesario incorporar mecanismos analíticos que permitan segmentar la demanda, evaluar distintos comportamientos y formular proyecciones más consistentes. En NOVAPACK S.A., esta necesidad se hace evidente por la combinación de alta rotación en ciertos productos, demanda intermitente en otros y marcada estacionalidad ligada al calendario escolar y comercial.

1.4.2 Rol del pronóstico en la cadena de suministro y logística

Dentro de la cadena de suministro, el pronóstico de la demanda cumple una función articuladora, ya que sirve de base para coordinar las decisiones de abastecimiento, almacenamiento, distribución y reposición. Una estimación adecuada permite alinear la disponibilidad de productos con los requerimientos esperados del mercado, reduciendo las fricciones entre oferta y demanda. En términos logísticos, el pronóstico influye directamente en la programación de compras, la gestión de inventarios, la planificación del transporte y la utilización de capacidad operativa (Chopra, 2019).

Cuando el pronóstico es deficiente, la cadena de suministro tiende a operar de manera reactiva, generando quiebres de stock, sobreinventarios, urgencias logísticas y mayores costos de operación. En cambio, cuando las proyecciones son consistentes y oportunas, se favorece una gestión más anticipativa, con mejor uso de recursos y mayor nivel de servicio al cliente. En el contexto de NOVAPACK S.A., donde convergen distintos canales comerciales y una red de distribución nacional, el rol del pronóstico

resulta especialmente estratégico, pues permite responder con mayor precisión a los ciclos de demanda y sostener la eficiencia del sistema logístico.

1.4.3 Impacto de la precisión del pronóstico en la gestión de inventarios

La precisión del pronóstico incide de manera directa en la gestión de inventarios, debido a que las decisiones de compra, reposición y almacenamiento dependen de la estimación de la demanda futura. Cuando el pronóstico sobrestima la demanda, se produce acumulación de inventario, inmovilización de capital, incremento de costos de almacenamiento y mayor riesgo de obsolescencia. Por el contrario, cuando la demanda es subestimada, aumentan los quiebres de stock, las pérdidas de venta y las dificultades para mantener un nivel adecuado de servicio al cliente (Chopra, 2019; Fildes et al., 2009).

Por esta razón, la mejora de la precisión del pronóstico no constituye únicamente un objetivo analítico, sino un factor determinante para la eficiencia operativa y financiera de la empresa. Una predicción más ajustada permite dimensionar mejor las necesidades de abastecimiento, reducir incertidumbre y optimizar la rotación de productos. En organizaciones con alta variabilidad de demanda y gran número de referencias, como NOVAPACK S.A., este impacto es aún más significativo, ya que pequeñas desviaciones pueden amplificarse al escalarse a cientos o miles de unidades de análisis.

1.4.4 Casos de aplicación en empresas del sector retail y distribución

La aplicación de modelos de pronóstico en empresas del sector retail y distribución ha mostrado resultados relevantes en la mejora de la precisión del pronóstico de demanda y en la optimización de la cadena de suministro. Diversos estudios reportan que los algoritmos de aprendizaje automático y la combinación de pronósticos de varios modelos permiten responder de mejor manera a escenarios con alta granularidad, múltiples productos y comportamientos de consumo diferenciados. En este tipo de organizaciones, la necesidad de proyectar ventas por categoría, punto de venta o región exige soluciones analíticas que superen los métodos tradicionales basados en promedios históricos (Makridakis et al., 2022; Valdivia Espinosa, 2019).

Los casos revisados en el estado del arte evidencian aplicaciones exitosas en sectores como bebidas, alimentos, retail farmacéutico y comercio minorista a gran escala, donde la automatización del pronóstico ha contribuido a mejorar métricas de error y a fortalecer la toma de decisiones operativas. Estos antecedentes resultan pertinentes para NOVAPACK S.A., puesto que demuestran que la adopción de un motor de pronóstico no constituye una innovación aislada, sino una práctica alineada con la transformación analítica del sector.

1.4.5 Relevancia de la transformación digital en NOVAPACK S.A.

La transformación digital representa un proceso de cambio organizacional mediante el cual las empresas incorporan tecnologías, automatización y analítica de datos para mejorar sus procesos, incrementar su eficiencia y fortalecer su capacidad de respuesta frente a un entorno dinámico. En este marco, el desarrollo de un motor automatizado de pronóstico constituye una expresión concreta de transformación digital, ya que sustituye prácticas manuales por un sistema estructurado, basado en datos y orientado a generar conocimiento útil para la toma de decisiones.

En NOVAPACK S.A., la relevancia de esta transformación se vincula con la necesidad de modernizar el proceso de planificación de la demanda, caracterizado actualmente por la dispersión de información, la dependencia de hojas de cálculo y la ausencia de métricas sistemáticas de evaluación. Se espera que la incorporación de soluciones analíticas no solo mejore la precisión de los pronósticos, sino que también impulse una cultura de gestión más objetiva, trazable y replicable. De esta manera, la propuesta del motor de pronóstico se proyecta como una herramienta estratégica dentro del proceso de digitalización de la empresa, favoreciendo una operación más eficiente y sostenible.

1.5 Marco legal normativo

1.5.1 Normativas sobre protección y uso de datos empresariales en Bolivia

En el Estado boliviano, el tratamiento y uso de información empresarial debe enmarcarse en principios de confidencialidad, seguridad y uso legítimo de la información, especialmente cuando esta se encuentra asociada a sistemas digitales, comunicaciones electrónicas o activos de propiedad intelectual. En este contexto, la Ley N.º 164, General de Telecomunicaciones, Tecnologías de Información y Comunicación, constituye un referente normativo relevante para la protección de información en entornos tecnológicos y de comunicación, mientras que la Ley N.º 1322 de Derecho de Autor protege las obras intelectuales originales, incluidas las científicas y los programas de computación que resultan de procesos de investigación o desarrollo (Asamblea Legislativa Plurinacional, 2011; Congreso Nacional, 1992).

En el caso de la presente investigación, el uso de datos históricos de ventas, reportes internos y documentos operativos de NOVAPACK S.A. exige que la información sea empleada exclusivamente con fines académicos, evitando su difusión no autorizada y resguardando su valor estratégico para la organización. En consecuencia, el tratamiento de estos datos debe realizarse bajo criterios de reserva institucional, acceso restringido y responsabilidad ética del investigador. Desde esta perspectiva, el marco normativo no solo respalda la protección jurídica de la información utilizada, sino que también fortalece la legitimidad metodológica del estudio al establecer límites claros para su uso y difusión.

1.5.2 Políticas de confidencialidad y cesión de derechos en investigaciones de posgrado

Las investigaciones de posgrado que se desarrollan con apoyo de información institucional o empresarial deben sustentarse en compromisos formales de confidencialidad y en reglas claras sobre la titularidad y el uso de los resultados obtenidos. La confidencialidad constituye una condición indispensable cuando el estudio involucra datos internos, procesos operativos, documentos técnicos o declaraciones de personal clave, ya que protege a la organización frente a la exposición no autorizada de información sensible. En este sentido, la firma de acuerdos o cláusulas de reserva representa una práctica necesaria para asegurar el uso ético y responsable de la información.

De manera complementaria, la cesión de derechos permite establecer el destino institucional del trabajo académico producido y reconocer el marco normativo bajo el cual la universidad resguarda y administra las obras elaboradas en sus programas de formación avanzada. En el presente estudio, estas políticas adquieren especial relevancia porque la investigación se apoya en información empresarial de NOVAPACK S.A. y, al mismo tiempo, se presenta como trabajo final de grado en un programa de maestría. Por ello, se justifica la inclusión de una declaración de confidencialidad y de cesión de derechos que delimite el uso académico del material, proteja los intereses de la empresa y garantice la correcta adscripción institucional del trabajo.

1.5.3 Políticas de gobernanza de datos, seguridad de la información y reserva comercial

Las normas de los apartados anteriores fijan derechos y obligaciones, pero ninguna prescribe cómo debe tratar sus datos una empresa privada que los cede para una investigación, y no todas alcanzan a este estudio de la misma manera. La Constitución Política del Estado reconoce el derecho a la privacidad y a la intimidad (artículo 21) y una acción de protección de privacidad frente a los datos registrados en archivos o bancos de datos públicos o privados, que pueden interponer personas individuales o colectivas (artículo 130) (Estado Plurinacional de Bolivia, 2009). El reglamento de la Ley N.º 164 (Decreto Supremo N.º 1793) exige, para el tratamiento de datos personales en el sector público y privado, el conocimiento previo y el consentimiento expreso del titular, el uso limitado a la finalidad declarada y medidas técnicas y organizativas que eviten su alteración, pérdida o tratamiento no autorizado (artículo 56) (Órgano Ejecutivo del Estado Plurinacional de Bolivia, 2013); lo hace dentro del régimen de la firma digital, pero con un alcance que el propio artículo extiende a todo tratamiento. La propia Ley N.º 164 dirige sus obligaciones de protección de datos a los operadores y proveedores de servicios, pero reconoce validez jurídica y probatoria a los documentos firmados digitalmente y admite los que no lo están como principio de prueba o indicio, valorando su fiabilidad por la forma en que se generaron, archivaron y comunicaron (artículos 78 y 87) (Asamblea Legislativa

Plurinacional, 2011). La Decisión 486 de la Comunidad Andina, vigente en Bolivia como país miembro, protege como secreto empresarial la información no divulgada que tiene valor comercial por ser secreta, siempre que su poseedor haya tomado medidas razonables para mantenerla en reserva (artículo 260) (Comisión de la Comunidad Andina, 2000). Dos precisiones delimitan el alcance. Los datos de ventas del estudio no son datos personales: están agregados por SKU, canal y regional y no identifican clientes; los únicos datos personales son los del informante clave, los participantes de la observación y los dos jueces que validaron el contenido de los instrumentos. La reserva de la información comercial descansa en el acuerdo del Anexo 2 y en esas medidas razonables. Por eso las políticas que siguen se toman de dos marcos de referencia reconocidos, la norma ISO/IEC 27001 para la seguridad de la información (International Organization for Standardization & International Electrotechnical Commission [ISO/IEC], 2022) y el cuerpo de conocimiento de la gestión de datos (DAMA-DMBOK) para la gobernanza (DAMA International, 2017), y cada una se enlaza con el mecanismo del diseño que la implementa. Los dos son marcos de referencia voluntarios: no constituyen obligaciones jurídicas en Bolivia ni suponen una certificación de la empresa, que el trabajo no afirma ni requiere. La Tabla 46 del Anexo 17 resume la correspondencia entre norma, política y mecanismo.

La primera política es de gobernanza de datos y asigna a cada dato un titular, un custodio y un responsable de su uso (DAMA International, 2017). NOVAPACK S.A. es la titular: limita el uso de sus datos a fines académicos y condiciona a su autorización la presentación del trabajo en espacios públicos, como los repositorios digitales (Anexo 2). El área de tecnologías de la información (TI) custodiaría los datos en su base relacional y en sus servidores y administraría las credenciales (apartado 4.2.5.2). El área de planificación sería dueña de los insumos declarados, el registro de eventos y el maestro de equivalencias (apartados 4.2.3 y 4.2.4), y el científico de datos respondería por el motor, la medición del error y la publicación de cada corrida (Tablas 36 y 38). El catálogo y el linaje se apoyan en metadatos que el motor ya produce: cada corrida registra en su manifiesto la huella de la captura, de los registros auxiliares y de la configuración, la versión del código y el estado del árbol de trabajo, y el registro de flujo describe, etapa por etapa, lo que entró, lo que salió y lo que se decidió (Anexo 9).

La calidad de la señal se gobernaría con reglas declaradas antes de medir, que marcan y no borran, y con un contrato de entrada que detiene la publicación si se incumple (apartados 4.2.3 y 4.2.5.2, Tabla 30). La retención sería explícita y la fijaría la empresa como titular; la propuesta de este trabajo, pendiente de esa aprobación, es conservar las capturas y las corridas publicadas sin sobrescribirlas durante cinco años desde la publicación de cada corrida, prorrogables por decisión de la empresa, y al vencer eliminarlas o archivarlas según esa decisión (Tabla 37). Distinta es la conservación de los respaldos del estudio, que quedan bajo custodia en la carpeta de la empresa con su autorización (Anexo 18). Para las notas de la entrevista y el consentimiento informado, el propio consentimiento fija el plazo: la vigencia del acuerdo de confidencialidad, hasta cinco años después de la presentación y evaluación del trabajo (Anexo 2), y después su eliminación salvo que la empresa disponga otra cosa. Para la captura sellada, los registros auxiliares, las salidas de las corridas y los demás documentos firmados, la empresa, como titular, y el autor acordaron por escrito el mismo plazo y la misma regla en la constancia complementaria 09 de la autorización de custodia, del 4 de noviembre de 2026 (Anexo 18): al vencer el plazo, el autor elimina sus copias y la empresa decide sobre la carpeta compartida; la vigencia del acuerdo fija la reserva y la constancia complementaria 09 fija la conservación.

La segunda política es de seguridad de la información y aplica los controles de la norma ISO/IEC 27001 que corresponden a un servicio analítico interno (ISO/IEC, 2022). Una parte ya rige en el estudio. Ningún secreto se versiona: la extracción tomó las credenciales de variables de entorno, y una prueba automatizada impide versionar un archivo cuyo nombre indique que guarda una credencial. El cálculo de la corrida principal corre aislado en una imagen de contenedor con versiones fijadas, y la integridad se prueba con el sellado SHA-256 de la captura, los registros auxiliares y la configuración, que hace verificables las cifras que el documento obtiene de las corridas en el sentido de fiabilidad por la forma de generación y archivo con que la Ley N.º 164 valora los documentos digitales sin firma. La operación agregaría el resto. El acceso se concedería por rol y con el menor privilegio: el planificador consultaría y registraría ajustes, el científico de datos lanzaría y publicaría corridas, la dirección consultaría, y el motor leería la base solo por vistas de contrato y escribiría solo en su esquema

propio (apartados 4.2.5.2 y 4.2.5.7, Tabla 36). Las credenciales llegarían desde el almacén de secretos de TI, las comunicaciones internas irían cifradas, y los registros por corrida y la auditoría de accesos permitirían reconstruir quién consultó, ajustó o publicó cada número (apartados 4.2.5.2 y 4.2.5.5). La disponibilidad descansaría en el respaldo de la base y del almacén de corridas y en la reconstrucción de cualquier corrida desde su captura, su configuración y su imagen (Figura 23).

La tercera política es de intimidad y reserva comercial y convierte en medidas verificables la reserva que exigen el Anexo 2 y la Decisión 486. El acuerdo del Anexo 2 limita el uso de los datos a fines académicos y fija el seudónimo con que la empresa se identifica en el trabajo, en su repositorio y en toda presentación derivada; al extraer, los códigos de producto se reemplazaron por identificadores estables y las categorías, al cargar, por letras, y las tablas de correspondencia quedaron fuera del repositorio. El repositorio público contiene código y no datos, y su control de confidencialidad, un conjunto de pruebas automatizadas que corre con la suite, falla si se versiona un archivo de datos, un documento ofimático, la configuración de extracción o cualquier identificador de una lista local de patrones de la empresa que no se publica (Anexo 7). En la operación interna el motor trabajaría con los códigos reales, y la reserva se sostendría con roles, autenticación, cifrado y auditoría; la seudonimización se conservaría para todo lo que salga de la empresa (apartado 4.2.5.2). La intimidad de las personas que participaron se protege con su identificación por código, con la omisión de sus datos personales en los anexos y con su consentimiento o autorización por escrito, que el autor conserva fuera del documento (Anexo 18). El artículo 56 del reglamento de la Ley N.º 164 exige el conocimiento previo y el consentimiento expreso del titular; esos documentos firmados son ratificaciones posteriores de lo consentido o autorizado en su momento y no prueban por sí solos ese cumplimiento previo: acreditan la declaración de cada firmante de que lo otorgó entonces. Las tres políticas no agregan obligaciones nuevas al diseño: hacen explícito, con su fundamento, lo que el estudio ya aplica y lo que la operación agregaría.

CAPÍTULO II. DISEÑO METODOLÓGICO

El diseño metodológico constituye el plan estructurado que guía el proceso de investigación para obtener la información necesaria y dar respuesta al planteamiento del problema. En esta sección se define el enfoque, tipo y alcance de la investigación, así como los métodos, técnicas e instrumentos empleados para la recolección y análisis de los datos.

2.1 Paradigma de la investigación

La investigación se inscribe en el paradigma pragmático, perspectiva epistemológica que sustenta los diseños de métodos mixtos y que orienta la elección de los procedimientos por su utilidad para responder al problema planteado, antes que por su adscripción exclusiva a una tradición cuantitativa o cualitativa (Hernández Sampieri et al., 2014).

Esta perspectiva resulta coherente con la naturaleza del estudio: la medición objetiva del error de pronóstico exige procedimientos cuantitativos y verificables, mientras que la comprensión del proceso de planificación vigente en la empresa (sus criterios, restricciones y necesidades) requiere aproximaciones cualitativas. El conocimiento se construye así mediante la integración de ambas fuentes de evidencia, con el propósito de sustentar una solución aplicable al contexto real de NOVAPACK S.A.

2.2 Diseño, enfoque y tipo de investigación

La investigación adopta un **enfoque mixto con predominancia cuantitativa**. El componente cuantitativo, de carácter dominante, se sustenta en la recolección, análisis y procesamiento de datos numéricos con el propósito de medir objetivamente la precisión de distintos modelos de pronóstico, analizando la relación entre la variable independiente (motor de pronóstico automatizado) y la variable dependiente (precisión

del pronóstico) mediante procedimientos estadísticos que posibilitan la verificación de la hipótesis. El componente cualitativo, de carácter complementario, se apoya en la entrevista semiestructurada y la observación estructurada aplicadas durante el diagnóstico, cuyos hallazgos se integran con los resultados cuantitativos mediante triangulación metodológica.

De acuerdo con Hernández Sampieri et al. (2014), los métodos mixtos representan un conjunto de procesos sistemáticos que implican la recolección y el análisis de datos cuantitativos y cualitativos, así como su integración y discusión conjunta, para lograr un mayor entendimiento del fenómeno bajo estudio. En el presente caso, la integración corresponde al diseño anidado o incrustado concurrente de modelo dominante (DIAC) de esa taxonomía: el componente cuantitativo conduce el estudio (la medición del error de los modelos de pronóstico y la verificación de la hipótesis), mientras que el componente cualitativo, incrustado en el mismo período de recolección, aporta la comprensión del contexto y de los requisitos del proceso de planificación.

El tipo de investigación es propositivo, de carácter aplicado. Se adopta esta categoría en el sentido que le da Hurtado de Barrera (2010) a la investigación proyectiva dentro de la clasificación holística de la investigación: aquella que, a partir de un diagnóstico, culmina en la elaboración de una propuesta como respuesta a la necesidad identificada, sin que su puesta en operación forme parte del estudio. Se orienta, en consecuencia, al diseño de una solución tecnológica (un motor de pronóstico automatizado) fundamentada en métodos estadísticos y de aprendizaje automático, sin llegar a su implementación operativa dentro de la empresa. La investigación busca resolver un problema real en el contexto de NOVAPACK S.A. mediante una propuesta factible, estructurada y técnicamente fundamentada.

En cuanto a la validación de la propuesta, se adopta un diseño no experimental, de corte longitudinal y carácter retrospectivo. La clasificación sigue la taxonomía de Hernández Sampieri et al. (2014): la investigación es no experimental porque no se manipulan deliberadamente variables ni se asignan grupos (se analizan fenómenos ya ocurridos, tal como quedaron registrados en su contexto), y es longitudinal, en su

variante de panel, porque las mismas unidades de análisis (las series SKU-canal-regional) se observan mes a mes a lo largo del período de estudio. El carácter retrospectivo se materializa en un backtesting temporal que reproduce, en cada punto del tiempo, la información que habría estado disponible para pronosticar. Este diseño permite comparaciones controladas entre modelos (el ingenuo, los promedios móviles, el suavizado exponencial, Holt-Winters, Croston y LightGBM), utilizando los datos históricos de ventas como base empírica y contrastando las diferencias observadas con intervalos que respetan la dependencia entre series y, como complemento, con pruebas estadísticas de significancia, en apoyo de la validez interna del análisis sin requerir una aplicación en entorno real. Cabe precisar que el diseño no es cuasiexperimental: en los términos de la misma fuente, los cuasiexperimentos manipulan deliberadamente al menos una variable independiente sobre grupos intactos, condición que no se cumple cuando los modelos se evalúan sobre la historia observada.

El **alcance** de la investigación es **descriptivo** con orientación **propositiva**.

- Es **descriptivo** porque caracteriza el proceso actual de planificación de la demanda en NOVAPACK S.A. y el comportamiento histórico de las ventas.
- Es **propositivo** porque formula el diseño estructural de un motor de pronóstico que integra modelos estadísticos y de aprendizaje automático como alternativa de mejora para la planificación de la demanda.

2.3 Métodos de investigación

Para el desarrollo del presente estudio se aplicaron métodos teóricos y empíricos, orientados a estructurar el diseño del motor de pronóstico de demanda y fundamentar su viabilidad técnica desde un enfoque mixto de predominancia cuantitativa y de tipo propositivo.

2.3.1 Métodos teóricos

Analítico-sintético:

Se empleó para descomponer el problema de planificación de la demanda en sus principales componentes (datos históricos; comportamiento por SKU, canal y regional) y posteriormente integrar los elementos conceptuales y técnicos en un diseño coherente del motor de pronóstico.

Inductivo-deductivo:

Se utilizó para derivar conclusiones generales a partir del análisis de los datos y estudios previos sobre modelos de pronóstico. A partir de estos resultados, se dedujeron los requerimientos técnicos y funcionales que debería cumplir el motor propuesto.

Histórico-lógico:

Permitió examinar la evolución de los métodos de pronóstico utilizados en NOVAPACK S.A. y su relación con las tendencias actuales en modelado predictivo, justificando así la necesidad de un diseño automatizado que optimice la precisión del proceso.

Abstracto-concreto:

Este método posibilitó pasar del análisis conceptual de los modelos estadísticos y de aprendizaje automático a la definición concreta de los componentes funcionales del motor de pronóstico propuesto.

2.3.2 Métodos empíricos

Entrevista semiestructurada:

Se aplicó a la jefatura de Planificación, responsable del proceso, para relevar desde la voz de quien lo ejecuta las prácticas vigentes, las herramientas empleadas y las limitaciones percibidas. Es la técnica que aporta el componente cualitativo del enfoque mixto.

Revisión documental:

Se aplicó para analizar la información secundaria relacionada con la planificación de la demanda en NOVAPACK S.A., incluyendo reportes históricos,

documentos técnicos internos y literatura científica sobre pronóstico de series temporales y aprendizaje automático.

Observación estructurada:

Se realizó una observación estructurada del proceso actual de planificación de la demanda, con el fin de identificar las herramientas, procedimientos y limitaciones operativas existentes. Esta información sirvió como base para definir los requerimientos del diseño del sistema.

Análisis de datos históricos:

Se efectuó un examen estadístico del comportamiento de la demanda mensual registrada en los sistemas de la empresa, con el propósito de caracterizar patrones, estacionalidades y tendencias que sustentan el diseño del modelo predictivo.

2.4 Técnicas de recolección de datos de la investigación

La recolección de información en esta investigación se basó en técnicas cuantitativas y cualitativas, en coherencia con el enfoque mixto de la investigación y con el carácter documental y analítico del estudio. Dichas técnicas permitieron obtener, organizar y analizar los datos necesarios para sustentar el diseño del motor de pronóstico propuesto.

2.4.1 Revisión documental

Consistió en la recopilación y análisis de documentos internos de NOVAPACK S.A., tales como reportes históricos de ventas, registros de planificación y formatos de consolidación de información. Esta técnica permitió comprender el funcionamiento actual del sistema de planificación de la demanda y establecer las bases conceptuales para el diseño del nuevo modelo predictivo.

2.4.2 Observación estructurada

Se aplicó para identificar de manera directa las etapas, procedimientos y herramientas empleadas en la elaboración de los pronósticos actuales dentro de la empresa. La observación se efectuó de forma no participante, siguiendo una guía

previamente establecida, con el objetivo de detectar limitaciones y oportunidades de mejora en el proceso de estimación de la demanda.

2.4.3 Análisis de datos secundarios

Se utilizaron los datos históricos de ventas mensuales por SKU, canal y regional correspondientes al período de abril de 2017 a marzo de 2026, junto con los registros de costos unitarios, quiebres de inventario y tipo de cambio. Estos datos sirvieron para caracterizar el comportamiento de la demanda y sustentar la evaluación comparativa de modelos que definió los criterios técnicos del motor de pronóstico.

2.4.4 Entrevista semiestructurada

Como técnica del componente cualitativo del estudio, se aplicó una entrevista semiestructurada al informante clave IC-01, persona con responsabilidad directa sobre el proceso de planificación de la demanda en la empresa, con el fin de obtener información cualitativa sobre las principales dificultades del proceso actual y los requerimientos funcionales esperados en una herramienta de pronóstico automatizada.

2.5 Instrumentos de investigación

Los instrumentos de investigación utilizados en el presente estudio fueron diseñados para recolectar información confiable y pertinente que permitiera analizar el proceso actual de planificación de la demanda en NOVAPACK S.A. y sustentar el diseño del motor de pronóstico propuesto. Estos instrumentos se adecuaron a las técnicas seleccionadas y se aplicaron de manera estructurada conforme a los principios del enfoque mixto adoptado en la investigación.

2.5.1 Guía de entrevista semiestructurada

Elaborada con el propósito de obtener información cualitativa del personal del área de planificación. Este instrumento permitió identificar las prácticas actuales de pronóstico, las herramientas empleadas y las principales dificultades que enfrenta la

empresa. Las respuestas proporcionaron insumos valiosos para establecer los requerimientos funcionales del motor de pronóstico.

2.5.2 Guía de observación estructurada

Utilizada durante la observación del proceso real de planificación, con el fin de registrar de manera sistemática el uso de herramientas, criterios de ajuste, tiempos de elaboración y participación de los actores involucrados. Este instrumento permitió caracterizar objetivamente las condiciones operativas que influyen en la generación de los pronósticos.

2.5.3 Matriz de recolección y análisis de datos históricos

Matriz de datos en formato tabular, obtenida mediante una consulta parametrizada al sistema de gestión y congelada como captura inmutable verificable por su huella criptográfica, que recopila, organiza y permite analizar los registros de ventas mensuales por SKU, canal y regional correspondientes al período 2017–2026. Junto con las ventas, la matriz recoge el precio unitario y la venta perdida registrada por consulta sin existencia disponible, y se complementa con tres registros auxiliares alineados por mes, dos de ellos también por producto: el costo unitario del maestro de productos, los quiebres de inventario y la serie mensual del tipo de cambio. Esta matriz permitió identificar patrones, tendencias y estacionalidades de la demanda, los cuales sirvieron de base para definir la estructura y los parámetros técnicos del motor de pronóstico; su estructura completa se detalla en el Anexo 5.

La matriz proviene del reporte histórico consolidado de ventas (Anexo 6), en el que cada código de producto se expresa en su código vigente según el maestro de portafolio, un maestro de datos que mantiene Planificación. Cuando un producto fue reemplazado, la venta del código anterior se traslada al vigente multiplicada por el factor de conversión, de modo que cada serie conserva la historia de la demanda y no la del código, en la unidad principal. El mismo factor expresa los combos y las presentaciones múltiples en unidades del producto base. Los códigos fuera del portafolio vigente se excluyen en origen. El tratamiento de estos casos en la operación del motor se propone en el apartado 4.2.3.

2.5.4 Ficha de registro documental

Se empleó para sistematizar la información proveniente de documentos internos de la empresa (reportes de ventas, informes de abastecimiento y planificaciones mensuales). Este instrumento permitió mantener la trazabilidad de los datos y dar sustento al análisis comparativo.

2.6 Población y muestra

2.6.1 Población

En correspondencia con el enfoque mixto de la investigación, se definieron dos unidades de análisis. La primera, de carácter cuantitativo, está constituida por el conjunto de productos con movimiento efectivo de ventas en el período analizado: del catálogo comercial de NOVAPACK S.A., 970 SKU registran ventas en la ventana de estudio y conforman la población pronosticable. Esos SKU se distribuyen en doce categorías de producto y, desagregados por canal y regional, dan lugar a 5.930 combinaciones SKU-canal-regional con registro de ventas: la clave de negocio que constituye la unidad potencial de análisis del pronóstico.

Estos productos se comercializan a nivel nacional en cinco regionales y a través de múltiples canales comerciales que, para efectos del análisis, se consolidan en dos: el canal masivo, que agrupa los canales de consumo para evitar la fragmentación excesiva de las series, y el canal institucional, que concentra los pedidos de tipo corporativo e industrial. Cada combinación SKU-canal-regional representa así una unidad potencial de análisis dentro del proceso de pronóstico. La segunda unidad de análisis, de carácter cualitativo, está conformada por el personal del área de planificación de NOVAPACK S.A., responsable de la elaboración de los pronósticos y de la gestión del proceso de planificación de la demanda.

2.6.2 Muestra

Para la unidad de análisis cuantitativa, y en coherencia con el tipo propositivo de la investigación, se trabajó con una muestra no probabilística e intencional, definida

en dos etapas. En la primera se acotó la población objetivo a cinco categorías representativas del portafolio (D, E, I, J y K), que concentran el 72,4 % de la demanda valorizada del período y reúnen los dos regímenes de comportamiento comercial que interesa pronosticar: la demanda recurrente a lo largo del año y la demanda estacional de campaña escolar. Esta acotación constituye una decisión de diseño del estudio: incorporar la totalidad del portafolio agregaría series marginales sin patrón interpretable, cuyo ruido dificultaría la comparación entre modelos. La población objetivo comprende 684 SKU y 4.406 combinaciones SKU-canal-regional con registro de ventas en el período analizado. Por reserva, las categorías se identifican con letras, con la misma lógica que los códigos de producto (apartado 4.2.6): D y E son las de campaña escolar, e I, J y K, las de demanda recurrente.

En la segunda etapa se aplicaron los criterios de inclusión y exclusión que se detallan más adelante, mediante una cascada documentada que descarta las combinaciones sin historia suficiente para el entrenamiento de los modelos o sin presencia en los bloques de evaluación. La muestra quedó conformada por 1.668 combinaciones SKU-canal-regional, que concentran el 95,0 % de la demanda valorizada del bloque de entrenamiento dentro de la población objetivo; de ellas, 1.513 disponen de costo unitario asignado y sustentan las métricas valorizadas del estudio. Las 155 restantes (productos sin ficha de costo vigente) quedan fuera de la agregación por valor, pero de forma idéntica para todos los modelos comparados, de modo que la exclusión afecta el nivel de la métrica y no la comparación entre modelos; el contraste estadístico de la hipótesis, por su parte, se ejecuta sobre la totalidad de las series.

Para la unidad de análisis cualitativa se empleó un muestreo no probabilístico por conveniencia, bajo el criterio de informante clave: se seleccionó a la persona responsable del proceso de planificación de la demanda (codificada como IC-01 para resguardar su identidad), por concentrar el conocimiento integral del proceso de pronóstico, de las herramientas utilizadas y de las necesidades funcionales de la empresa, y a ella se aplicó la entrevista semiestructurada. La suficiencia de un único informante para este componente se sustenta en su posición dentro del proceso: es la jefatura que consolida el trabajo de los responsables de línea y la única persona con visión completa del ciclo de planificación. Sus declaraciones no se tomaron como

evidencia autónoma, sino que se contrastaron con la observación estructurada del proceso y con el análisis documental de los registros, conforme al esquema de triangulación descrito más adelante.

La selección de la muestra cuantitativa permitió analizar el desempeño comparativo de distintos métodos de pronóstico y sustentar el diseño conceptual del motor automatizado sin requerir la implementación operativa en la totalidad de la base de productos.

2.6.3 Criterios de inclusión y exclusión

Se incluyeron en el análisis las combinaciones SKU-canal-regional de la población objetivo que cumplieron simultáneamente tres criterios calculados sobre el bloque de entrenamiento: contar con un historial mínimo de 36 meses desde su primera venta, presentar una proporción de meses sin venta no mayor al 70 % y acumular un volumen de al menos 50 unidades. Cada umbral responde a un requisito del diseño y no a una convención: los 36 meses equivalen a tres ciclos estacionales anuales completos, mínimo para que los modelos con componente estacional y los rezagos interanuales dispongan de repeticiones suficientes; el 70 % de meses sin venta marca la frontera por encima de la cual el error porcentual deja de ser medible de forma fiable y la serie pasa al régimen de intermitencia crónica descrito en el marco conceptual; y las 50 unidades descartan series cuyo volumen acumulado no permite distinguir la señal del ruido de registro. Adicionalmente, se exigió que la combinación estuviera presente en los bloques de validación y de prueba, es decir, que el tramo entre su primera y su última venta alcanzara ambos bloques, condición necesaria para medir el error fuera de muestra con este protocolo.

Quedaron excluidas, en consecuencia, las combinaciones sin historial suficiente para el entrenamiento, como las de incorporación reciente, así como las series de intermitencia crónica o de volumen marginal, cuyo error no admite una medición fiable. En la construcción del panel se previó el descarte de devoluciones (cantidades negativas), de las que la captura no contiene ninguna, y los meses intermedios sin venta, entre la primera y la última venta de cada serie, se completaron con cero para

obtener un panel mensual continuo; fuera de ese tramo no se completaron, de modo que la ausencia del producto no se confunda con ausencia de demanda. La aplicación secuencial de los criterios se documentó en una cascada de exclusión que parte de las 4.406 combinaciones de la población objetivo y concluye en las 1.668 de la muestra. Su último paso, la presencia en el bloque de prueba, que excluye 144 combinaciones sin venta en esa gestión, no es un criterio de la población sino un requisito del protocolo de medición; ese paso y la delimitación de cada serie entre su primera y su última venta usan información posterior al origen de la prueba, y por eso su efecto se midió aparte, en un análisis de sensibilidad que repite la evaluación sin ese paso (apartado 4.3.2 y Tabla 25 del Anexo 11). Ese análisis tiene dos variantes: una retrospectiva, que sigue midiendo la presencia en validación sobre la vida observada de cada serie, de su primera a su última venta, aunque esa última venta caiga en la prueba, y otra, la más estricta, con solo las series activas al origen. La elección de los umbrales se respaldó, además, con un análisis de sensibilidad que recalculó el tamaño y la cobertura de la muestra para configuraciones vecinas de los tres criterios (historial de 24 a 48 meses, proporción de ceros del 60 % al 90 % y volumen de 0 a 100 unidades), verificando que la cobertura se mantiene estable entre el 93 % y el 97 % de la demanda valorizada de entrenamiento en todo el rango explorado; la cascada completa y la sensibilidad al umbral de proporción de ceros, con los otros dos criterios en su valor adoptado, se reproducen en el Anexo 11 (Figura 15).

Las 2.738 combinaciones excluidas salen del protocolo de medición, no del alcance de la propuesta. Cada una queda clasificada por su estado de actividad al cierre del entrenamiento y atribuida al primer criterio que la excluyó, con su peso valorizado (Anexo 14). Reúnen el 5,0 % del valor de entrenamiento y, como la población se renueva, el 10,1 % del de prueba; su tratamiento se propone en el apartado 4.2.3.

2.6.4 Fuentes de información

Las fuentes primarias corresponden a la entrevista semiestructurada aplicada al informante clave IC-01 y a la observación estructurada del proceso vigente de elaboración de pronósticos.

Las fuentes secundarias comprenden los registros históricos de ventas mensuales de NOVAPACK S.A. del período comprendido entre abril de 2017 y marzo de 2026, organizados por SKU, canal y regional; los registros de precio unitario y de venta perdida por consulta sin existencia disponible, incorporados a la propia matriz de ventas; los registros auxiliares de costo unitario, de quiebres de inventario y de tipo de cambio, empleados en la valorización de las métricas y en las variables explicativas del modelo de aprendizaje automático; la documentación interna de la empresa vinculada al proceso de planificación y abastecimiento; y la literatura científica especializada consultada para la construcción del estado del arte y del marco teórico.

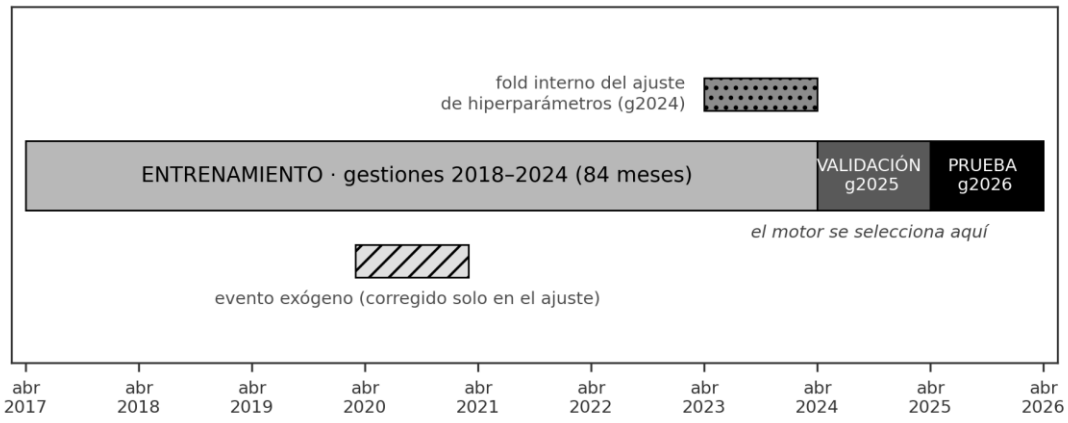
2.7 Análisis de los datos

El análisis de los datos se realizó en coherencia con el enfoque mixto de la investigación. El componente cuantitativo, de carácter dominante, utilizó procedimientos estadísticos y métricas de evaluación orientadas a comparar la precisión de distintos modelos de pronóstico; el componente cualitativo, de carácter complementario, aplicó el análisis de contenido a la información proveniente de la entrevista semiestructurada, la observación estructurada y la revisión documental, cuyos hallazgos se integraron mediante triangulación metodológica en el capítulo de resultados y discusión.

Los datos empleados provinieron de los registros históricos de ventas mensuales de NOVAPACK S.A., organizados por SKU, canal y regional, para el período comprendido entre abril de 2017 y marzo de 2026, equivalente a las gestiones comerciales 2018 a 2026 (definidas de abril a marzo), complementados con los registros de precio unitario, venta perdida, costo unitario, quiebres de inventario y tipo de cambio descritos en las fuentes de información. La variable que el motor pronostica, y contra la que se mide el error, es la venta mensual registrada, es decir, la demanda atendida. La demanda solicitada, que suma a esas ventas la venta perdida registrada por consulta sin existencia disponible, no se reconstruye como variable objetivo, porque ese registro solo alcanza magnitudes sustantivas desde la gestión 2022 (apartado 3.4.3); la venta perdida entra, en cambio, como variable explicativa rezagada del modelo de aprendizaje automático, y esa demanda solicitada, o demanda no

restringida, queda como objetivo alternativo para cuando el registro acumule historia (Anexo 14). Para evaluar los modelos en condiciones equivalentes a la operación real, el panel se dividió cronológicamente en tres bloques: entrenamiento (abril de 2017 a marzo de 2024, 84 meses), validación (gestión 2025) y prueba (gestión 2026). Los modelos se ajustaron únicamente con el bloque de entrenamiento; el bloque de validación se reservó para la selección de modelo por serie que realiza el motor y para la parada temprana del modelo global de aprendizaje automático (LightGBM, entrenado sobre el conjunto de las series), con los hiperparámetros ya calibrados sobre un pliegue interno del entrenamiento (la gestión 2024); y el bloque de prueba, ajeno a la selección y al ajuste de los modelos, sustentó la evaluación final fuera de muestra. La estructura completa de la partición, incluidos el pliegue interno de calibración de hiperparámetros y el tramo del evento exógeno, se esquematiza en la Figura 1.

Figura 1
Partición temporal del estudio: bloques, pliegue interno de calibración y evento exógeno



Nota. En la figura, “fold interno del ajuste de hiperparámetros” es el pliegue interno de calibración (gestión 2024), y “el motor se selecciona aquí” señala el bloque de validación, donde el motor elige el modelo de cada serie. Elaboración propia.

El tramo comprendido entre marzo de 2020 y febrero de 2021 se trató como un evento exógeno, correspondiente a la disrupción provocada por la pandemia de COVID-19. Siguiendo la práctica documentada de la empresa, los valores de ese tramo se reemplazaron por los de la gestión previa únicamente en el panel con que se

ajustan los modelos; la evaluación del error se realizó siempre contra las ventas realmente observadas, y el efecto del tratamiento se examinó mediante una corrida de ablación sin dicho ajuste (variante 1 del Anexo 9), cuyo resultado se informa en el apartado 4.3.2.

Sobre esta base se ejecutaron diez modelos de pronóstico y, como propuesta central, el motor de selección automática. Los modelos comprenden: el modelo ingenuo (Naïve) y el promedio móvil en ventanas de 2 y 12 meses (cada uno en su versión simple y en la variante con corrección de tendencia por factor de crecimiento del año móvil, que replica la fórmula utilizada por la empresa), el suavizado exponencial simple con parámetro optimizado, el método de Holt-Winters con estacionalidad anual, el método de Croston para demanda intermitente y el algoritmo de aprendizaje automático LightGBM. El motor, por su parte, evalúa el desempeño de todos los modelos en el bloque de validación y selecciona, para cada combinación SKU-canal-regional, el de menor error compuesto, que aplica luego en el bloque de prueba; la elección del modelo a la que se refiere el tercer objetivo específico ocurre, así, en el bloque de validación, fuera de la muestra de entrenamiento. Las variantes con factor de crecimiento replican la fórmula parametrizada en las planillas de planificación (apartado 3.4.3), que da la cifra base de la propuesta del área de planificación antes de los ajustes por juicio comercial que la reunión mensual de planificación aplica sin registro formal (Tablas 4 y 11). El estudio compara contra esa réplica, y no contra el plan final consensuado ni contra las referencias que el equipo empleó en la sesión observada (Tabla 4), y en adelante la denomina réplica de la fórmula base sin ajustes de consenso: la fórmula base es la que produce la cifra inicial de la propuesta del área de planificación, y los ajustes de consenso, los que la reunión mensual aplica sobre ella sin registro formal.

La precisión se midió en dos planos complementarios. Por serie se calcularon las métricas descritas en la operacionalización de variables: MAE, MAPE, RMSE y Bias. Para la comparación agregada entre modelos se adoptó como métrica de decisión el error compuesto valorizado D = WMAPE + |Bias|. La valorización responde a una restricción del objeto de estudio: las unidades físicas difieren entre SKU, de modo que los errores de series distintas no pueden sumarse directamente; al ponderar

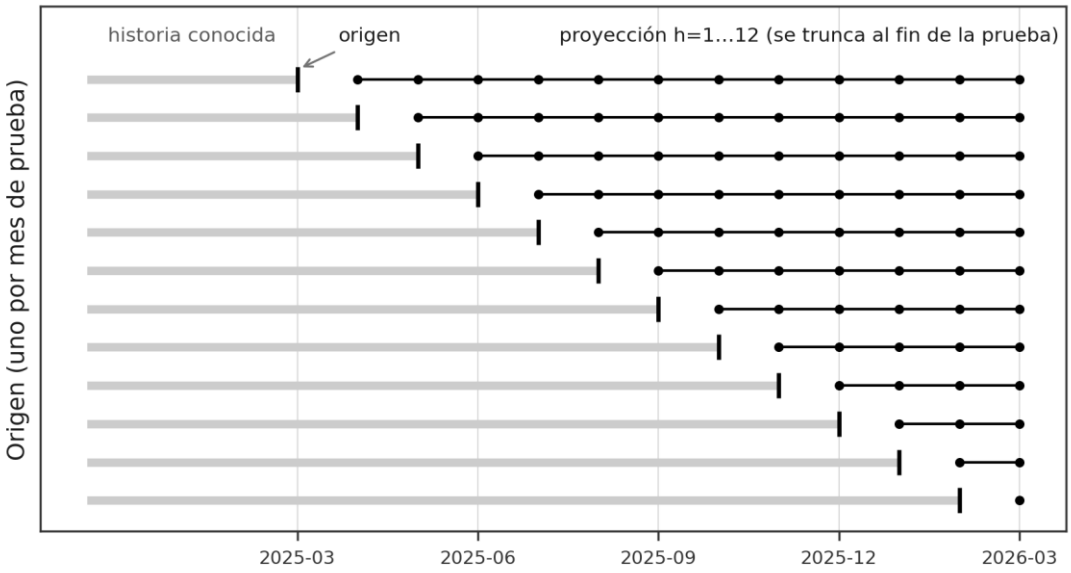
cada error por el costo unitario del producto, la métrica agrega el desempeño de todo el portafolio en una unidad monetaria común y asigna a cada serie un peso proporcional a su relevancia económica. El componente WMAPE captura la magnitud del error, mientras que el término |Bias| penaliza el sesgo sistemático de sobrestimación o subestimación. La suma de ambos con pesos unitarios responde a que están expresados en la misma unidad (porcentaje de la demanda valorizada del portafolio) y a que la empresa no dispone de una cuantificación de los costos unitarios de faltante y de exceso que permita fundamentar una ponderación asimétrica; ante esa ausencia se adopta la alternativa conservadora, que penaliza el sesgo con el mismo peso que la magnitud del error. La conclusión principal del estudio es robusta a esa elección: frente a la réplica de la fórmula base sin ajustes de consenso (la variante del promedio móvil de 12 meses con factor de crecimiento), el motor presenta simultáneamente menor WMAPE valorizado y menor sesgo absoluto, de modo que su ventaja se mantiene bajo cualquier ponderación de los dos términos; su ventaja sobre el modelo global aislado, en cambio, sí depende de esa ponderación, como se desprende de la descomposición de la D reportada en la validación técnica (apartado 4.3.2).

Esta ponderación tiene, además, un fundamento empírico directo: el valor del portafolio está fuertemente concentrado. La curva de concentración de la demanda valorizada del período de estudio por SKU se reproduce en el Anexo 11 (Figura 16): el 20 % del padrón concentra el 76,4 % del valor, y el 80 % del valor se acumula en apenas el 22,9 % de los 338 SKU de la muestra con costo asignado. En un portafolio así, un promedio de errores sin ponderar trataría por igual el error de un producto marginal y el de uno crítico para el abastecimiento; la agregación valorizada asigna a cada serie exactamente el peso de su relevancia económica.

La evaluación se realizó en dos modalidades complementarias: a un paso, en la que cada mes del bloque de prueba se pronostica desde el mes inmediatamente anterior, y multihorizonte con orígenes rodantes, en la que desde el cierre de cada uno de los 12 meses que van de marzo de 2025 a febrero de 2026 se proyecta de forma recursiva hasta 12 meses hacia adelante, sin salir del bloque de prueba, reproduciendo la mecánica de la corrida mensual de planificación de la empresa. Esta segunda

modalidad permite medir la degradación del error a medida que se amplía el horizonte, condición determinante para el uso operativo del pronóstico. El esquema de los orígenes rodantes se ilustra en la Figura 2.

Figura 2
Esquema de la evaluación multihorizonte con orígenes rodantes en el bloque de prueba



Nota. Cada fila es un origen: la historia conocida crece un mes por vez y la proyección recursiva alcanza hasta 12 meses, truncada al fin del bloque de prueba, de modo que en el horizonte h son evaluables 13 − h de los 12 orígenes: doce en h = 1 y uno solo en h = 12. Elaboración propia.

La comparación descriptiva de las métricas se complementó con pruebas estadísticas de significancia sobre los errores por serie, a fin de contrastar la hipótesis de investigación. Dado que las distribuciones de los errores de pronóstico no cumplen el supuesto de normalidad, se emplearon pruebas no paramétricas para muestras pareadas: la prueba de rangos con signo de Wilcoxon, en su variante unilateral y con un nivel de significancia de $\alpha = 0{,}05$, para contrastar el error del motor frente al promedio móvil de 12 meses en sus dos variantes (la que suma el factor de crecimiento, fórmula de las planillas de planificación, y la simple, referencia más exigente a un paso en la gestión de prueba) y frente al modelo ingenuo, reportando en cada caso el tamaño del efecto ($r = Z/\sqrt{N}$, leído con los umbrales convencionales de 0,1 para pequeño, 0,3 para mediano y 0,5 para grande); y la prueba de Friedman con

análisis post hoc de Nemenyi para la comparación simultánea de todos los modelos. Como las series de un mismo SKU y las que comparten un mes no son independientes, las diferencias se acompañan además de intervalos percentiles al 95 % obtenidos con dos remuestreos que respetan esa dependencia, por conglomerados de SKU y por bloques móviles de tres meses, que constituyen la evidencia principal del contraste, mientras que los valores p por serie se leen como evidencia complementaria (apartado 4.3.2 y Tabla 20 del Anexo 8). Una extensión exploratoria, que no interviene en el contraste de la hipótesis, examina la combinación de pronósticos y la conmutación por régimen (apartado 4.3.3).

Todo el procesamiento se implementó en Python (bibliotecas pandas, NumPy, LightGBM y SciPy), dentro de un repositorio versionado cuyo flujo de ejecución genera cada tabla y figura del estudio a partir de una configuración declarada. Cada corrida produce además un manifiesto que registra los datos, la configuración y la versión del código con que se obtuvo cada resultado, lo que sostiene la trazabilidad completa del flujo analítico y una reproducibilidad condicionada al acceso autorizado a los insumos sellados, no una reproducción pública integral (Anexo 7).

CAPÍTULO III. RESULTADOS, ANÁLISIS Y DISCUSIÓN

Este capítulo presenta el diagnóstico del contexto organizacional en NOVAPACK S.A. y del proceso actual de planificación de la demanda. Primero se describe el entorno donde se desarrolla la investigación; luego se expone el procedimiento metodológico de diagnóstico, incluyendo la definición conceptual y operacional de las variables y los instrumentos utilizados. A continuación, se analizan los resultados obtenidos mediante las cuatro técnicas declaradas: entrevista semiestructurada, observación estructurada, análisis documental y análisis de los datos históricos de ventas mensuales por SKU, canal y regional (abril de 2017 a marzo de 2026). Los hallazgos permiten identificar limitaciones del sistema vigente y justifican el diseño de un motor automatizado de pronóstico como propuesta técnica para la gestión 2026. La validación de los instrumentos de investigación se presenta en el apartado 3.3, antes de los resultados, y completan el capítulo la triangulación metodológica y la discusión de los resultados a la luz de los antecedentes (apartado 3.5) y las conclusiones sobre el estado del problema (apartado 3.6).

3.1 Acercamiento al contexto donde se investiga

La investigación se realizó en el contexto empresarial de NOVAPACK S.A., una compañía boliviana con amplia trayectoria en la fabricación, importación, comercialización y distribución de artículos de oficina y papelería, entre otras líneas de producto. Su operación abarca todo el territorio nacional y se organiza en cinco regionales, con una red de distribución que integra canales mayoristas, minoristas, distribuidores e institucionales, lo que la posiciona como una de las principales proveedoras del sector en el país.

En sus lineamientos institucionales, que aquí se parafrasean y adaptan para preservar la reserva sobre la identidad de la empresa, NOVAPACK S.A. declara como visión llegar a ser la empresa más innovadora del país en los mercados en que

participa y, como misión, ofrecer a sus clientes de manera continua productos novedosos y formas nuevas de trabajar que superen sus expectativas. Esa orientación a la innovación, que alcanza tanto a lo que la empresa vende como a la manera en que opera, es el marco estratégico en el que se inscribe la propuesta de esta investigación: automatizar el pronóstico de la demanda con métodos estadísticos y de aprendizaje automático es, precisamente, una forma nueva de hacer la planificación.

Este entorno empresarial presenta un alto grado de complejidad: en él se combinan la diversidad del portafolio (superior a 900 SKU y a 4.000 combinaciones SKU-canal-regional), la marcada estacionalidad del mercado y la necesidad de responder a diferentes patrones de consumo asociados a períodos escolares, campañas corporativas y variaciones regionales. En este contexto, la planificación de la demanda se convierte en un proceso crítico para garantizar la disponibilidad de productos, evitar sobreinventarios y mantener la eficiencia operativa.

Sin embargo, el proceso actual de pronóstico en NOVAPACK S.A. depende principalmente de procedimientos manuales basados en hojas de cálculo y en la experiencia de los planificadores, sin una medición sistemática de la precisión de las proyecciones y con criterios que varían entre responsables. Estas condiciones hacen evidente la necesidad de contar con herramientas analíticas avanzadas que permitan automatizar el proceso y aprovechar de manera más efectiva la información histórica disponible.

Por tanto, comprender el contexto operativo, logístico y organizacional de NOVAPACK S.A. resulta esencial para dimensionar la problemática abordada y justificar el diseño de un motor de pronóstico automatizado que responda a las particularidades del entorno comercial boliviano y a las dinámicas específicas de la empresa.

3.2 Procedimiento para el diagnóstico

El procedimiento de diagnóstico se estructuró en función de las técnicas de investigación declaradas (revisión documental, observación estructurada, entrevista semiestructurada y análisis de datos históricos), con el objetivo de comprender

integralmente el proceso de planificación de la demanda en NOVAPACK S.A. y los problemas asociados a la precisión de sus pronósticos.

En primera instancia, se realizó una revisión documental de los reportes mensuales de ventas por SKU, las planillas de planificación de inventarios, los informes de abastecimiento, los registros de desempeño comercial y los formatos de consolidación de información, junto con los registros auxiliares de venta perdida, quiebres de inventario y tipo de cambio, con el fin de identificar los métodos y criterios actualmente empleados para la elaboración de pronósticos y de evaluar la disponibilidad y consistencia de los datos históricos. Este análisis permitió reconocer la estructura general del proceso y los vacíos metodológicos existentes.

Posteriormente, se efectuó una observación estructurada del flujo operativo real durante una sesión de planificación mensual, siguiendo una guía previamente diseñada. Esta observación permitió registrar de manera objetiva las etapas, herramientas utilizadas, tiempos de ejecución y grado de participación del personal involucrado, verificando las limitaciones y oportunidades de mejora del proceso.

De forma complementaria, se aplicó una entrevista semiestructurada al informante clave IC-01, orientada a profundizar en los criterios empleados para la proyección de la demanda, las principales dificultades percibidas y las expectativas frente a la automatización del proceso.

Finalmente, se desarrolló un análisis de datos históricos de ventas mensuales correspondientes al período 2017–2026, segmentados por SKU, canal y regional. Estos datos se utilizaron para identificar patrones de comportamiento, estacionalidades y tendencias que sustentan los criterios técnicos del motor de pronóstico.

La información obtenida con la guía de entrevista, la guía de observación y la ficha de registro documental fue organizada, contrastada y validada mediante triangulación metodológica (cuadro de triangulación del apartado 3.5), y los hallazgos de la matriz de recolección y análisis de datos históricos se incorporaron a esa triangulación como evidencia complementaria, permitiendo establecer un diagnóstico

preciso del estado actual del proceso y definir los requisitos funcionales para el diseño de la propuesta tecnológica presentada en el siguiente capítulo.

3.2.1 Definición conceptual de las variables

3.2.1.1 Variable independiente: motor de pronóstico automatizado

Corresponde a la solución tecnológica propuesta para optimizar la planificación de la demanda en NOVAPACK S.A. Se define como un sistema analítico capaz de integrar modelos estadísticos y algoritmos de aprendizaje automático para generar pronósticos precisos de forma autónoma. Este motor evalúa el desempeño de múltiples modelos predictivos y selecciona automáticamente el que presenta el menor error para cada combinación SKU-canal-regional, reduciendo la intervención manual y estandarizando el proceso de proyección de la demanda. Su aplicación busca mejorar la eficiencia operativa y la capacidad de respuesta de la empresa frente a la variabilidad del mercado.

3.2.1.2 Variable dependiente: precisión del pronóstico de demanda

Hace referencia al grado de exactitud con que los valores estimados por el modelo se aproximan a los datos reales de demanda observados, es decir, a las ventas mensuales registradas (la demanda atendida, sin la venta perdida). Conceptualmente, representa la capacidad del sistema para generar predicciones confiables que minimicen el error estadístico. En esta investigación, la precisión se evalúa mediante métricas cuantitativas como el error absoluto medio (MAE), el error porcentual absoluto medio (MAPE), la raíz del error cuadrático medio (RMSE) y el sesgo promedio (Bias), indicadores que permiten medir la consistencia, equilibrio y desempeño de los modelos aplicados. Estos indicadores se calculan por serie; para la comparación agregada entre modelos, el estudio adopta el error compuesto valorizado D = WMAPE + |Bias|, que pondera el error de cada serie por el costo unitario del producto y actúa como métrica de decisión del experimento.

En conjunto, ambas variables mantienen una relación directa: el motor de pronóstico automatizado (variable independiente) influye en la precisión del pronóstico de demanda (variable dependiente), relación que la evaluación retrospectiva contrasta sobre las ventas observadas.

3.2.2 Definición operacional de las variables

La presente investigación contempla dos variables principales: una independiente y una dependiente. La variable independiente corresponde al motor de pronóstico automatizado, entendido como una solución tecnológica capaz de integrar y seleccionar modelos predictivos para anticipar la demanda de forma segmentada por SKU, canal y regional. La variable dependiente es la precisión del pronóstico de demanda, la cual se evaluó mediante métricas cuantitativas de error como el MAE, MAPE, RMSE y Bias.

Ambas variables fueron descompuestas en dimensiones e indicadores como se muestra en la Tabla 1, en el apartado “Identificación de las variables” de la Introducción, de tal manera que se pueda facilitar su análisis empírico. La operacionalización permitió evaluar tanto la funcionalidad del sistema propuesto como la precisión de su pronóstico frente a la réplica de la fórmula base sin ajustes de consenso; su efecto sobre la planificación de inventarios de NOVAPACK S.A. queda como hipótesis de impacto (apartados 4.3.4 y 4.4).

3.2.3 Instrumentos de investigación para el diagnóstico

Para la aplicación de las técnicas seleccionadas en el proceso de diagnóstico, se definieron y utilizaron diversos instrumentos orientados a recolectar información precisa, confiable y pertinente sobre el proceso de planificación de la demanda en NOVAPACK S.A. Cada instrumento fue diseñado de acuerdo con los objetivos específicos de la investigación y con la naturaleza de los datos requeridos.

En la revisión documental, se utilizó una ficha de registro documental destinada a recopilar y sistematizar información proveniente de reportes internos, planillas de planificación, políticas de abastecimiento y documentos técnicos relacionados con el

pronóstico de la demanda. Este instrumento permitió registrar de forma trazable las fuentes consultadas.

Para la observación estructurada, se empleó una guía de observación orientada al registro sistemático de las actividades, herramientas, tiempos y criterios utilizados durante el proceso real de elaboración del pronóstico. Este instrumento permitió identificar las limitaciones operativas y las oportunidades de mejora del sistema actual.

En cuanto a la entrevista semiestructurada, se aplicó una guía de entrevista dirigida al informante clave IC-01, responsable del proceso de planificación de la demanda. Este instrumento permitió obtener información cualitativa sobre las prácticas vigentes, los principales problemas percibidos y los requerimientos funcionales esperados en un sistema automatizado de pronóstico.

Finalmente, para el análisis de datos históricos, se utilizó una matriz de recolección y análisis de datos en formato digital, diseñada para consolidar los registros de ventas mensuales por SKU, canal y regional. Este instrumento sirvió como base para la caracterización estadística del comportamiento de la demanda y para la evaluación comparativa de los modelos predictivos.

En conjunto, estos instrumentos proporcionaron la información necesaria para comprender el estado actual del proceso de planificación, validar los hallazgos del diagnóstico y sustentar el diseño metodológico y técnico del motor automatizado de pronóstico propuesto.

3.3 Validación de los instrumentos de investigación

Para asegurar la validez de contenido de los instrumentos diseñados (guía de entrevista, guía de observación, ficha de registro documental y matriz de recolección y análisis de datos históricos) se realizó un proceso de validación por juicio de expertos. Este procedimiento consistió en la revisión técnica de las preguntas, categorías, apartados e indicadores por parte de dos jueces: una especialista en gestión de la cadena de suministro, con maestría en la disciplina y a cargo de la gerencia de operaciones de la empresa, en el plano técnico, y el director académico del trabajo, en el plano metodológico. La jueza técnica integra la empresa en la que se

realizó el estudio y no participó como informante; ese vínculo se declara y la independencia del juicio se apoya en el segundo juez. De forma complementaria y por separado, la persona responsable del proceso de planificación revisó la pertinencia operativa de la terminología empleada; esa revisión no se computa como validación independiente, por tratarse del informante clave del estudio. La identidad de la jueza técnica se reserva conforme al acuerdo de confidencialidad suscrito con la organización (Anexo 2). Los formularios individuales firmados por los dos jueces, el consentimiento informado del informante clave IC-01, la autorización de la observación estructurada y la constancia de la empresa sobre el uso de la información y la revisión del texto y del repositorio público se conservan en original en poder del autor y, en copia escaneada, bajo custodia en una carpeta compartida de la empresa con acceso restringido. El documento no los reproduce, para no publicar información reservada, y el Anexo 18 los inventaría por documento, rol del firmante y fecha, verificables a solicitud del tribunal. Esos documentos se firmaron después de los hechos que documentan, y cada uno acredita algo distinto. Los formularios de los jueces, el consentimiento informado y la autorización de la observación declaran en su texto que la firma deja constancia escrita de la valoración, el consentimiento o la autorización dados en su momento (la validación, en marzo de 2026; la entrevista, el 6 de abril; la observación, el 10 de mayo). El acceso a los datos históricos lo respalda la constancia de la empresa, que declara haber autorizado el uso de la información de ventas y de los registros auxiliares para el trabajo, sin indicar la fecha de esa autorización (fila 5 de la Tabla 47); la captura es del 7 de agosto de 2026 (fila 8 de la misma tabla). La misma constancia declara autorizado también el uso de la información recogida mediante la entrevista, la observación del proceso y la revisión documental. El acuerdo de confidencialidad (Anexo 2) rige la reserva y el uso académico de la información desde su firma; no contiene una declaración sobre ese acceso y no se invoca como tal. No existe un registro escrito contemporáneo de esos actos, y el trabajo no lo afirma.

Los expertos valoraron cada instrumento (Tabla 2) con base en los criterios de claridad, relevancia, coherencia y suficiencia, verificando su correspondencia con el problema de investigación, los objetivos específicos, las técnicas declaradas y la matriz de operacionalización de variables. A partir de la revisión y de los comentarios

recibidos durante la validación, se realizaron ajustes de forma y contenido antes de su aplicación definitiva.

Tabla 2
Resumen de la validación de instrumentos por juicio de expertos

Criterio de validación	Descripción del ajuste realizado	Resultado final
Claridad	Se ajustó el lenguaje técnico en las preguntas de la entrevista para asegurar que la terminología sobre “modelos predictivos” fuera comprensible para el personal operativo.	**Aprobado**
Relevancia	Se eliminaron ítems de la guía de observación que no aportaban directamente a la identificación de causas de la baja precisión en el pronóstico.	**Aprobado**
Coherencia	Se verificó que cada pregunta de los instrumentos tuviera una relación directa con los indicadores establecidos en la matriz de operacionalización de variables.	**Aprobado**
Suficiencia	Se agregaron ítems en la ficha de registro documental para garantizar la captura de datos sobre estacionalidad y variaciones regionales.	**Aprobado**

Nota. Elaboración propia.

El proceso de validación permitió perfeccionar los instrumentos de recolección de datos, para que su contenido fuese pertinente, comprensible y metodológicamente coherente con los fines del estudio. Los ajustes realizados se orientaron a fortalecer la capacidad de los instrumentos para obtener información relevante sobre el proceso actual de planificación de la demanda en NOVAPACK S.A. En consecuencia, los instrumentos quedaron aptos para su aplicación en el diagnóstico, como base del análisis posterior y de la propuesta de solución.

3.4 Análisis de los resultados de la aplicación de los instrumentos

3.4.1 Resultados de la entrevista semiestructurada

Para obtener información directa sobre el proceso actual de planificación de la demanda, se aplicó una entrevista semiestructurada al informante clave IC-01, responsable del proceso en NOVAPACK S.A. El instrumento permitió conocer las

prácticas vigentes, las herramientas utilizadas y las principales limitaciones que enfrenta la empresa en la estimación de la demanda.

A continuación, la Tabla 3 presenta los resultados consolidados de la entrevista, organizados según las categorías de análisis derivadas de las preguntas aplicadas.

Tabla 3
Resultados de la entrevista semiestructurada aplicada al informante clave IC-01

Categoría de análisis	Preguntas asociadas	Resultados obtenidos
Proceso actual de planificación	**1, 4**	El proceso de planificación de la demanda se desarrolla de manera manual y descentralizada. Cada responsable de línea o categoría trabaja sus propias proyecciones y posteriormente estas se consolidan en reuniones de validación.
Herramientas utilizadas	**2**	La herramienta principal empleada es Microsoft Excel. Los datos se exportan desde el sistema y se procesan mediante tablas dinámicas y fórmulas básicas. No se utilizan sistemas automatizados ni software especializado de pronóstico.
Criterios de estimación	**3**	Se consideran como referencia el historial de ventas del mismo mes del año anterior y el promedio de los últimos meses. Sin embargo, el ajuste final depende en gran medida del criterio empírico y de la experiencia del planificador.
Precisión del pronóstico	**5, 10**	El informante clave IC-01 considera que los pronósticos actuales no son suficientemente precisos por la magnitud del portafolio, más de 900 SKU que, desagregados por canal y regional, superan las 4.000 combinaciones, y por la ausencia de medición objetiva del error: no se emplean métricas estadísticas como MAE, MAPE o Bias para evaluar el desempeño del proceso.
Problemas identificados	**6, 7**	Se presentan quiebres de stock en temporadas altas y sobreacumulación en productos de baja rotación. Además, existen diferencias marcadas en el comportamiento de la demanda entre productos, canales y regiones, lo que, según el informante, complejiza la planificación.
Necesidad de mejora y automatización	**8, 9**	Se reconoce la necesidad de modernizar y automatizar el proceso de planificación. Se considera pertinente incorporar un sistema automatizado de pronóstico que procese grandes volúmenes de datos, reduzca la subjetividad y mejore la eficiencia operativa.

Nota. Elaboración propia.

Los resultados de la entrevista evidencian que el proceso actual de pronóstico en NOVAPACK S.A. depende principalmente del uso de hojas de cálculo y del criterio

empírico de quienes intervienen en el proceso, tanto del área de planificación como del área comercial. La ausencia de sistemas automatizados y de modelos estadísticos estructurados coincide con diferencias en los criterios aplicados entre áreas y canales, es decir, con un proceso poco consistente.

Asimismo, se identificó que no existe una validación estadística de la precisión del pronóstico: la retroalimentación y la mejora continua del proceso no cuentan con una medición del error en que apoyarse. La dificultad para incorporar estacionalidades, variaciones regionales y diferencias por canal confirma que el método actual resulta insuficiente frente a un portafolio que, según declara el propio informante, supera los 900 SKU y las 4.000 combinaciones SKU-canal-regional; la magnitud y la estructura de esa complejidad se cuantifican en el análisis de los datos históricos del apartado 3.4.4.

En este contexto, la entrevista permitió corroborar, desde la perspectiva del informante clave, el problema planteado en la investigación y evidenció la necesidad de diseñar una herramienta automatizada que integre modelos estadísticos y de aprendizaje automático, con el fin de reducir la subjetividad, mejorar la eficiencia operativa y aumentar la precisión de las proyecciones empleadas en la planificación del abastecimiento.

3.4.2 Resultados de la observación estructurada

Con el propósito de contrastar la información obtenida en la entrevista y verificar el funcionamiento real del proceso de planificación de la demanda, se aplicó una observación estructurada durante una sesión de trabajo del área de planificación de NOVAPACK S.A. Esta técnica permitió registrar, de manera objetiva y no intrusiva, las etapas, herramientas, tiempos y dinámicas de interacción que intervienen en la elaboración de los pronósticos.

A continuación, la Tabla 4 presenta los resultados consolidados de la observación estructurada, reorganizados en seis categorías analíticas construidas a partir de los ítems de la guía de observación aplicada (Anexo 3).

Tabla 4

Resultados de la observación estructurada del proceso de planificación de la demanda

Categoría / ítem observado	Resultado observado	Valoración del investigador
Herramientas utilizadas	La información histórica se recopila y consolida en hojas de cálculo individuales por categoría. El procesamiento se realiza principalmente en Microsoft Excel.	Se evidencia una alta dependencia de herramientas ofimáticas y trabajo manual, en un proceso poco escalable y expuesto a errores operativos.
Criterios de proyección	Se calculan promedios móviles simples de 3 y 6 meses y comparaciones porcentuales con el mismo mes del año anterior; después, analistas y responsables comerciales ajustan los valores por juicio experto en reuniones internas. Las referencias empleadas en la sesión difieren de la fórmula parametrizada en las planillas de planificación, cuyo nivel base es el último mes o el promedio móvil de 2 o de 12 meses según la campaña, corregido por un factor de crecimiento del año móvil, como se precisa en el apartado 3.4.3.	Predomina la subjetividad en la toma de decisiones, ya que los ajustes finales no se sustentan en métricas cuantitativas de validación.
Flujo del proceso	No existe un flujo estandarizado para la elaboración del pronóstico. Cada responsable utiliza criterios distintos según el producto, la región o la información disponible.	Sin estandarización, los resultados se elaboran con criterios dispares y son difíciles de comparar entre unidades de negocio.
Documentación y trazabilidad	No se observó un registro sistemático de las decisiones tomadas ni de los motivos que justifican los ajustes realizados sobre las proyecciones iniciales.	Sin ese registro, el proceso no deja una base documentada para su retroalimentación ni para el control metodológico del pronóstico.
Tiempo y eficiencia	El equipo declaró que la consolidación en Excel requiere aproximadamente 3 días de trabajo antes de la reunión final de validación, de 2 horas de duración.	Se trata de un procedimiento ineficiente en términos operativos, con alto consumo de tiempo y esfuerzo del personal involucrado.

Categoría / ítem observado	Resultado observado	Valoración del investigador
Control y retroalimentación	No se comparan de forma sistemática los pronósticos anteriores con los resultados reales de ventas.	Sin control del error, el proceso no cuenta con una medida en que apoyar el aprendizaje organizacional ni la mejora continua de la exactitud del pronóstico.

Nota. Elaboración propia.

La observación estructurada permitió confirmar que el proceso actual de planificación de la demanda en NOVAPACK S.A. sigue una secuencia predominantemente manual, basada en la consolidación de datos en hojas de cálculo y en el uso de promedios móviles simples como referencia inicial. Esa referencia se contrasta después en la reunión mensual de planificación de la demanda, donde la cifra propuesta por el área de planificación y la que aporta el área comercial, sustentada en su percepción del mercado y de la estacionalidad, se concilian por consenso hasta fijar el número final; ante una discrepancia, prevalece el criterio comercial sobre el dato histórico.

Asimismo, se constató que no existe un flujo estandarizado ni un mecanismo formal de documentación de las decisiones adoptadas durante el proceso. Esta situación se acompaña de diferencias metodológicas entre responsables, de dificultades para comparar unidades de negocio y de una consolidación prolongada de la planificación mensual, que, según lo declarado por el equipo durante la sesión observada (Anexo 3), demanda aproximadamente 3 días de consolidación en Excel antes de una reunión de validación de 2 horas, cifra comprendida en el rango de 3 a 5 días que el informante clave IC-01 atribuye al armado de las hojas de cálculo (Anexo 1).

De igual forma, se identificó la ausencia de retroalimentación formal sobre la precisión de los pronósticos anteriores, dado que los resultados reales no se comparan sistemáticamente con las estimaciones realizadas. En consecuencia, los hallazgos de la observación confirman la dependencia de métodos empíricos, la escasa automatización y la necesidad de contar con un sistema estructurado que permita

estandarizar, evaluar y optimizar de manera continua el proceso de planificación de la demanda.

3.4.3 Resultados del análisis documental

Como parte del diagnóstico, se realizó un análisis documental orientado a examinar los registros internos y reportes utilizados por NOVAPACK S.A. en la planificación de la demanda. Esta técnica permitió identificar los procedimientos formales y las herramientas empleadas para la proyección de ventas, así como evaluar la consistencia y disponibilidad de los datos históricos entre las diferentes áreas de la empresa.

La revisión incluyó documentos como reportes mensuales de ventas por SKU, que cubren de abril de 2017 a marzo de 2026 (108 meses, gestiones comerciales 2018 a 2026), junto con planillas de planificación de inventarios, informes de abastecimiento y registros de desempeño comercial del mismo período, así como los registros de venta perdida, quiebres de inventario y tipo de cambio, cuya cobertura efectiva es más corta: los quiebres y el tipo de cambio abarcan de abril de 2022 a marzo de 2026 (48 meses); la venta perdida, incorporada a la propia matriz de ventas, presenta su primer registro positivo en enero de 2020 y solo alcanza magnitudes sustantivas a partir de la gestión 2022, pues en las gestiones anteriores representa menos del 0,2 % de la demanda solicitada, frente al 15,5 % que documenta el análisis de los datos históricos (apartado 3.4.4) para las gestiones 2022 a 2026. También se analizaron los formatos empleados para consolidar la información y los criterios utilizados para definir los pronósticos.

A continuación, la Tabla 5 presenta los resultados consolidados del análisis documental realizado.

Tabla 5

Resultados del análisis documental de los registros y reportes utilizados en la planificación de la demanda

Documento o registro analizado	Propósito dentro del proceso	Hallazgos relevantes para la investigación
Reportes mensuales de ventas por SKU	Registrar el comportamiento histórico de la demanda por SKU	El reporte consolidado cubre 108 meses consecutivos (abril de 2017 a marzo de 2026), con registros en todos los meses y sin valores nulos en sus ocho columnas: 970 SKU y 5.930 combinaciones SKU-canal-regional en el archivo completo, y 684 SKU y 4.406 combinaciones en las cinco categorías del estudio. Sin embargo, persisten diferencias en la forma de consolidación entre áreas, y las 572 filas que repiten la clave fecha, SKU, canal y regional (286 pares de filas idénticas de un único producto, cuya suma al construir las series duplicó la demanda de 8 combinaciones, con un efecto despreciable sobre los resultados declarado en el apartado 3.4.4) junto con las diferencias de nomenclatura de canales en 2017 y 2018 (Anexo 6) son indicio de la ausencia de validación automatizada del registro.
Planillas de planificación de inventarios	Sustentar decisiones de abastecimiento y reposición	La información se consolida de forma manual en hojas de cálculo, con duplicidad de datos, inconsistencias y dificultad para mantener trazabilidad entre versiones.
Informes de abastecimiento	Dar seguimiento a requerimientos de compra y disponibilidad de productos	No se evidenció integración sistemática entre los reportes de abastecimiento y los resultados del pronóstico, ni una retroalimentación del proceso a partir de ellos.
Registros de desempeño comercial	Evaluar resultados de ventas y cumplimiento de metas	No incluyen comparaciones sistemáticas entre pronóstico y venta real mediante métricas de error como MAE, MAPE o Bias.
Formatos de consolidación de información	Integrar datos para la elaboración del pronóstico	Se constató la ausencia de un sistema unificado de registro y control, así como la inexistencia de un repositorio centralizado que facilite la actualización y validación automática de la información.

Documento o registro analizado	Propósito dentro del proceso	Hallazgos relevantes para la investigación
Registros de venta perdida por consulta sin existencia	Dimensionar la demanda no atendida por falta de disponibilidad	El registro se genera por consulta de vendedor, pero no se integra al proceso de planificación, y presenta datos únicamente desde enero de 2020; el cómputo se reporta desde la gestión 2022, la primera completa posterior al evento exógeno. Su consolidación mensual permitió cuantificar la demanda no atendida del portafolio, valorizada a precio de venta, en el 15,5 % de la demanda solicitada entre las gestiones 2022 y 2026 (medida sobre el archivo completo de doce categorías) y en el 18,4 % en las dos últimas gestiones (Tabla 6), y aportar una variable explicativa al modelo de aprendizaje automático, con 52.357 celdas serie-mes de venta perdida positiva en las cinco categorías de la población objetivo.
Registros de quiebres de inventario y de tipo de cambio	Documentar la disponibilidad histórica de producto y el contexto macroeconómico	Los quiebres se registran por SKU, regional y mes (220.889 filas de abril de 2022 a marzo de 2026, con el número de semanas medidas y de semanas sin existencia de cada mes, del que se deriva el porcentaje del período con existencia insuficiente); el tipo de cambio es una serie mensual única de 48 meses del mismo período, común a todos los productos, fija en 6,96 hasta enero de 2024 y variable después. Ninguno se emplea sistemáticamente en la planificación; el estudio los incorporó como variables explicativas del modelo de aprendizaje automático, completando los 60 meses anteriores a abril de 2022 del tipo de cambio con el régimen fijo de 6,96 y dejando sin dato ese tramo en los quiebres.

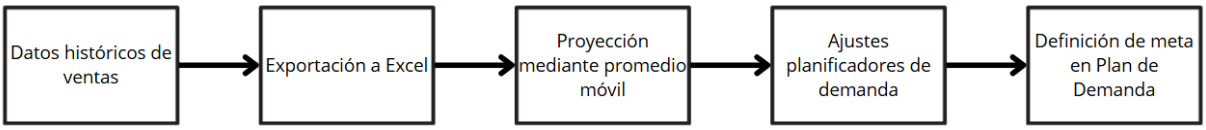
Nota. Elaboración propia.

En cuanto a las herramientas de análisis, se constató que los métodos estadísticos aplicados son básicos, principalmente promedios simples o móviles, y no se utilizan métricas de evaluación de error como MAE, MAPE o Bias. Tampoco se encontró evidencia de un proceso sistemático de retroalimentación o de revisión comparativa entre el pronóstico y las ventas reales. Las planillas revisadas permiten precisar la fórmula vigente: el pronóstico parte de un nivel base (el último mes o el promedio móvil de dos o de doce meses, según la campaña) y le suma un factor de crecimiento del año móvil, la diferencia entre las ventas de los últimos doce meses y las de los doce anteriores dividida entre doce; es la formulación que este estudio replica en las variantes con factor de crecimiento de sus modelos de referencia. La

empresa conserva sus planes mensuales, pero el plan final no es un comparador válido para el motor: incorpora el juicio comercial y recortes por disponibilidad de suministro (si se sabe que un producto no tendrá existencias, el plan lo lleva a cero y su error frente a la venta es nulo), de modo que mide una decisión restringida y no la demanda; por eso el contraste se hace contra la fórmula, que es la etapa que el motor reemplaza, y la medición del plan por etapas queda para la operación (apartado 4.2.5.3 y Tabla 38). La estructura de la ficha documental se reproduce en el Anexo 4 y su aplicación al reporte histórico de ventas, en el Anexo 6.

De manera complementaria, el análisis documental permitió construir el diagrama del flujo actual del proceso de planificación de la demanda (Figura 3), el cual refleja que la estimación se realiza en etapas secuenciales, con una fuerte dependencia de la intervención humana y sin mecanismos de validación automatizada.

Figura 3
Esquema actual del flujo de planificación de la demanda en NOVAPACK S.A.



Nota. Elaboración propia.

Los resultados del análisis documental revelan que el proceso de planificación de la demanda en NOVAPACK S.A. presenta debilidades en la estandarización, gestión y trazabilidad de la información. La elaboración independiente de reportes por parte de distintas áreas o responsables va acompañada de duplicidad de datos, inconsistencias y dificultades para mantener una base confiable y centralizada.

Asimismo, se evidenció que las herramientas analíticas actualmente utilizadas son limitadas, ya que se apoyan en métodos básicos de cálculo y carecen de métricas objetivas para evaluar la precisión del pronóstico. La ausencia de un repositorio centralizado y de mecanismos de validación automática deja la integridad y la actualización de la información sin un control sistemático.

En síntesis, el análisis documental confirma la falta de estandarización, las carencias en la gestión de datos y las limitaciones en el uso de herramientas analíticas

avanzadas, lo que refuerza la necesidad de implementar un sistema automatizado orientado a lograr mayor precisión, integridad y replicabilidad en el proceso de pronóstico de demanda.

3.4.4 Resultados del análisis de los datos históricos (2017–2026)

Como parte del diagnóstico, se efectuó un análisis exploratorio de los registros históricos de ventas de NOVAPACK S.A., correspondientes al período 2017–2026, con el propósito de comprender el comportamiento general de la demanda y las condiciones en que se desarrolla la planificación actual. Este análisis tuvo un carácter descriptivo, orientado a identificar patrones, estacionalidades y factores de variabilidad relevantes para el pronóstico de la demanda.

La información utilizada provino de los reportes consolidados de ventas mensuales por SKU, canal y regional, recopilados y sistematizados a partir de las bases de datos internas de la empresa. El proceso de carga leyó 204.096 filas y no descartó ninguna: no se encontraron fechas ni cantidades no convertibles, claves nulas ni cantidades negativas (devoluciones), de modo que el descarte de devoluciones previsto en el diseño no tuvo efecto; las 572 filas que compartían fecha, SKU, canal y regional (286 pares) se agregaron por suma. Una revisión posterior mostró que son filas idénticas en todas sus columnas de un único producto, de modo que la suma duplicó la demanda de sus 8 combinaciones (5 en la muestra); el exceso equivale al 0,48 % del volumen de la población objetivo, y esas cinco combinaciones pesan el 0,14 % de la demanda valorizada de prueba de la muestra, un efecto despreciable que se declara como limitación del estudio. La población objetivo, acotada a las cinco categorías definidas en el diseño metodológico, retuvo 147.701 filas (56.395 quedaron fuera, correspondientes a las siete categorías restantes) de 684 SKU, dos canales consolidados (masivo e institucional) y cinco regionales, que forman 4.406 combinaciones con venta de las 6.840 posibles (64,4 %). Sobre ellas se construyó un panel mensual que abarca los 108 meses del período, de abril de 2017 a marzo de 2026, con 255.418 filas serie-mes, de las cuales 108.003 (42,3 %) corresponden a meses intermedios sin venta completados con cero dentro de la vida de cada serie. Con ese panel se elaboraron resúmenes estadísticos y representaciones comparativas

que permitieron observar las principales tendencias del comportamiento de la demanda a lo largo del período analizado.

A continuación, la Tabla 6 presenta los resultados consolidados del análisis de los datos históricos.

Tabla 6

Resultados del análisis exploratorio de los datos históricos de ventas (2017–2026)

Dimensión analizada	Resultados obtenidos	Implicación para la investigación
Comportamiento temporal de la demanda	En el bloque de entrenamiento, la demanda valorizada de la población objetivo se concentra en diciembre (14,6 %) y enero (16,9 %), que suman 31,5 % de la gestión comercial; con febrero (11,1 %) el pico reúne 42,6 % y el tramo de noviembre a febrero, 50,7 %. El valle va de abril (5,1 %, mínimo) a julio, y enero equivale a 3,3 veces abril. Marzo (6,4 %) ya queda por debajo del reparto uniforme (8,3 %): el pico precede al inicio del ciclo escolar.	Confirma que la demanda no es uniforme a lo largo del año y que el pronóstico debe incorporar componentes temporales y estacionales.
Diferencias por categoría de producto	Las categorías de campaña escolar presentan los patrones estacionales más pronunciados: en el bloque de entrenamiento (abril de 2017 a marzo de 2024), la categoría D concentra entre noviembre y febrero el 88,3 % de su valor anual y la E, el 72,1 %; las categorías de demanda recurrente muestran perfiles mucho más planos (K 41,1 %, J 39,3 % e I 34,2 %), frente al 33,3 % que correspondería a un reparto uniforme.	Evidencia que no todas las categorías pueden ser proyectadas bajo la misma lógica de estimación.

Dimensión analizada	Resultados obtenidos	Implicación para la investigación
Diferencias por canal de comercialización	El canal masivo concentra el 95,5 % del valor de la población objetivo del período y reúne el 51,3 % del valor de su bloque de entrenamiento entre noviembre y febrero, frente al 37,6 % del canal institucional y al 33,3 % que correspondería a un reparto uniforme. La irregularidad del canal institucional se manifiesta serie por serie: entre las combinaciones con historia de entrenamiento, la mediana de la proporción de meses sin venta alcanza el 82,1 %, frente al 28,6 % del canal masivo, y solo 102 de sus 1.412 combinaciones (7,2 %) cumplen los criterios de inclusión, frente a 1.566 de 2.994 (52,3 %).	Justifica la necesidad de segmentar el análisis y evitar pronósticos agregados que oculten diferencias estructurales entre canales.
Diferencias por regional	Las cinco regionales comparten la forma del ciclo anual, con el máximo en enero y el mínimo en abril, y difieren en peso y en intensidad: sobre el valor de la población objetivo del período, La Paz reúne el 32,2 %, Santa Cruz el 32,0 %, Cochabamba el 17,6 %, Sucre el 10,8 % y Tarija el 7,3 %. En el bloque de entrenamiento, Santa Cruz concentra el 54,3 % de su valor entre noviembre y febrero, frente a valores entre el 47,3 % y el 49,9 % en las demás regionales, y la mediana de la proporción de meses sin venta por serie alcanza allí el 50,0 %, frente al 28,8 % de Sucre.	Refuerza la necesidad de considerar la regional como una dimensión clave en el diseño del motor de pronóstico.
Variabilidad por nivel de rotación	Los SKU de baja rotación presentan alta irregularidad y discontinuidad en las ventas, mientras que los productos de alta rotación muestran mayor estabilidad relativa.	Los métodos simples resultan insuficientes para proyectar series heterogéneas; se requiere selección diferenciada de modelos según comportamiento histórico.
Sensibilidad a factores comerciales	Se identificó que ciertos productos estables también presentan alteraciones asociadas a campañas y cambios estacionales; el efecto de promociones no pudo aislarse (Anexo 5).	El sistema propuesto debe ser adaptable y sensible a los múltiples factores asociados a la variación de la demanda.

Dimensión analizada	Resultados obtenidos	Implicación para la investigación
Demanda no atendida por quiebre	El registro interno de venta perdida, que se activa cuando un vendedor consulta un producto y el sistema verifica que no hay existencia suficiente para atenderlo, documenta, sobre el archivo histórico completo de doce categorías, que entre las gestiones 2022 y 2026 la demanda no atendida equivalió al 15,5 % de la solicitada, con un 16,3 % en los meses de pico de la campaña escolar (diciembre a febrero) y un 18,4 % en las dos últimas gestiones.	Cuantifica el margen económico en juego; que un pronóstico más preciso reduzca esa demanda no atendida es una hipótesis de impacto (apartado 4.3.4). Valorada a precio de venta, la proporción de demanda no atendida apenas es mayor en los meses de pico (16,3 % entre diciembre y febrero frente a 15,5 % del período y 15,0 % entre marzo y noviembre), pero esos tres meses reúnen el 42,8 % de la venta perdida de las gestiones 2022 a 2026 (enero por sí solo, 17,7 %) porque concentran el 40,8 % de la demanda solicitada: la venta perdida se concentra en la campaña sobre todo por volumen y solo marginalmente por intensidad.

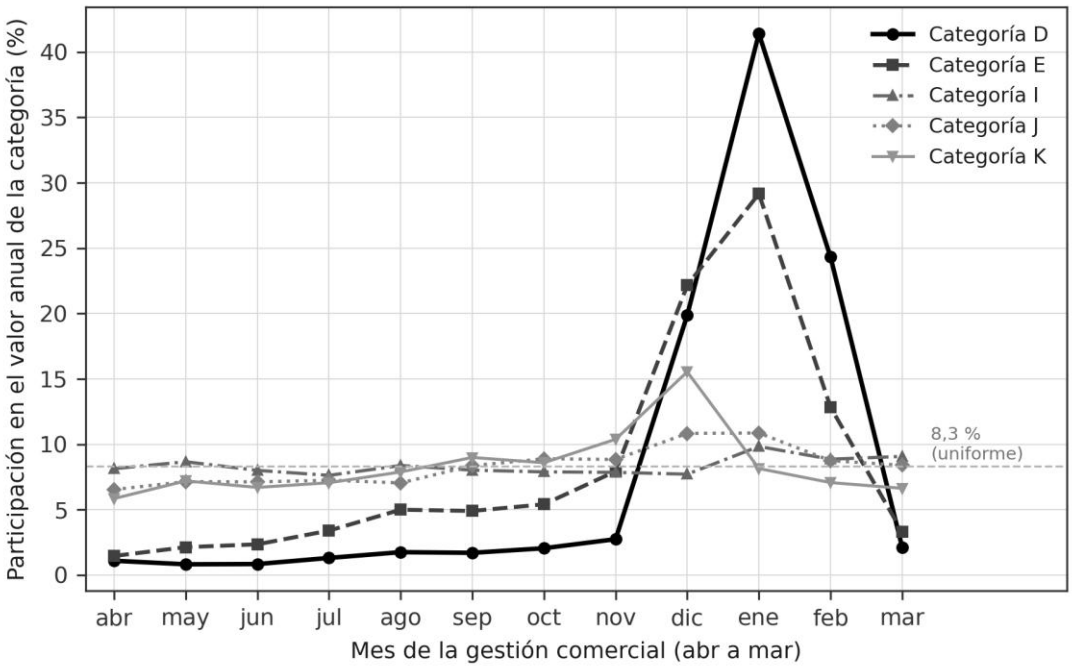
Nota. Elaboración propia.

Los resultados evidenciaron que la demanda presenta una estacionalidad pronunciada: en el bloque de entrenamiento, la participación mensual del valor de la población objetivo asciende de forma gradual desde agosto (6,47 %) hasta noviembre (8,09 %) y de forma abrupta en diciembre y enero (14,55 % y 16,95 %, es decir, 31,5 % del valor anual entre ambos), se mantiene en febrero (11,12 %) por encima de la participación uniforme (8,3 %), cae a 6,37 % en marzo y a 5,11 % en abril, su mínimo (un descenso del 69,9 % respecto de enero en tres meses), y permanece entre 5,1 % y 5,9 % de abril a julio. El máximo de enero precede al inicio del ciclo escolar, en febrero, y los últimos meses del año calendario corresponden a la subida de la campaña, no a una caída. Este patrón corresponde a dos de las cinco categorías de la población objetivo: la categoría D, que concentra el 88,3 % de su valor del bloque de entrenamiento entre noviembre y febrero (41,4 % solo en enero), y la categoría E, con el 72,1 %. La K (41,1 %, con un pico en diciembre del 15,5 %), la J (39,3 %) y la I (34,2 %) quedan mucho más cerca del reparto uniforme de 33,3 % para esos cuatro meses que de la concentración de campaña, y se comportan como categorías recurrentes.

El perfil mensual del valor por categoría confirma este patrón (Figura 4):

Figura 4

Perfil estacional del valor por categoría: participación de cada mes de la gestión comercial en el valor anual



Nota. El eje sigue el orden de la gestión comercial, de abril a marzo, y la participación se calcula sobre el bloque de entrenamiento; la línea punteada marca la participación mensual uniforme (8,3 %). Elaboración propia.

La evolución del valor total por gestión comercial, con su asignación a los bloques de la partición, se reproduce en el Anexo 11 (Figura 17): las gestiones 2025 y 2026 conforman los bloques de validación y de prueba, y la gestión 2021 concentra el tramo del evento exógeno.

También se identificaron diferencias cuantificables entre canales y regionales. En el bloque de entrenamiento, el canal masivo concentra el 95,4 % de la demanda valorizada de la población objetivo y presenta una estacionalidad definida: el 51,3 % de su valor anual se vende entre noviembre y febrero, con pico en enero (17,3 %). El canal institucional aporta el 4,6 % restante con un perfil mensual casi plano (37,6 % entre noviembre y febrero) pero discontinuo: en el período completo 2017–2026, sus 1.412 series (32,0 % de las 4.406) venden en una mediana de 4 meses frente a 37 en el canal masivo, la proporción mediana de meses sin venta dentro de la vida de cada serie es del 78,2 % (27,2 % en el masivo) y su valor por gestión fluctúa más a lo largo

de las nueve gestiones (coeficiente de variación de 0,30 frente a 0,17). Por regional, en el bloque de entrenamiento La Paz (33,0 %) y Santa Cruz (32,0 %) reúnen casi dos tercios del valor, seguidas de Cochabamba (17,5 %), Sucre (10,6 %) y Tarija (6,8 %); las cinco regionales alcanzan su pico en enero, pero Santa Cruz muestra la estacionalidad más aguda, con el 54,3 % de su valor anual entre noviembre y febrero y un pico del 20,0 %, frente a entre 47,3 % y 49,9 % y picos de 15,0 % a 16,6 % en las otras cuatro. Estas cifras corroboran la apreciación del informante (Tabla 3) sobre las diferencias marcadas entre canales y regiones, incluida la singularidad de Santa Cruz señalada en la entrevista. El registro histórico no contiene variables sobre el tipo de compra ni sobre contratos, por lo que no es posible atribuir la discontinuidad del canal institucional a compras puntuales o a contratos específicos.

Por otra parte, la variabilidad en la demanda de ciertos SKU de baja rotación representa un desafío para la planificación: sus ventas son discontinuas, un rasgo que los promedios simples de la planificación vigente no contemplan. En contraste, los productos de alta rotación son más estables en continuidad, pero no en magnitud: de las 980 series de alta rotación de la muestra (intervalo medio entre ventas inferior a 1,32 meses), 668 (68,2 %) son erráticas, con un coeficiente de variación al cuadrado de la demanda no nula igual o superior a 0,49, y solo 312 son suaves; a ello se suma la estacionalidad de campaña, que en las categorías D y E concentra el 88,3 % y el 72,1 % del valor anual entre noviembre y febrero. El efecto de promociones comerciales no pudo contrastarse: el campo previsto para registrarlo en la matriz de datos (Anexo 5) resultó incompleto en la fuente y no se incorporó como variable del modelo, y tampoco aparece entre los hallazgos de la entrevista, la observación ni el análisis documental (Tablas 3 a 5).

El análisis exploratorio de los datos históricos permitió confirmar que el comportamiento de la demanda en NOVAPACK S.A. es heterogéneo y estacional. En el bloque de entrenamiento de la población objetivo, las categorías de campaña concentran en noviembre a febrero el 88,3 % (categoría D, con el 41,4 % de su valor solo en enero) y el 72,1 % (categoría E) de su valor anual, mientras que las categorías I (34,2 %) y J (39,3 %) se mantienen cerca del reparto uniforme (33,3 %) y la K (41,1 %) combina un perfil moderado con un pico de diciembre (15,5 % frente al 8,3 %

mensual uniforme); las diferencias agregadas por canal y por regional reflejan sobre todo la distinta mezcla de categorías de cada segmento. La coexistencia de estos perfiles indica que una proyección basada únicamente en promedios históricos, aplicada de manera uniforme, difícilmente capta la estructura del fenómeno; esa insuficiencia se contrasta empíricamente en el capítulo IV, donde la réplica de la fórmula base de la empresa, sin ajustes de consenso, se compara con el motor propuesto sobre un mismo bloque de prueba.

Asimismo, la variabilidad observada entre productos de alta y baja rotación evidencia que no es metodológicamente adecuado aplicar un único criterio de estimación a todo el portafolio. Clasificadas sobre el bloque de entrenamiento según la matriz ADI-CV² presentada en el marco conceptual (apartado 1.3.4), las 1.668 series de la muestra se reparten en 312 suaves (18,7 %), 668 erráticas (40,0 %), 642 esporádicas (38,5 %) y 46 intermitentes (2,8 %), y el mismo SKU cambia de régimen según el canal y la regional en 212 de los 335 SKU con más de una combinación (63,3 %). En consecuencia, los hallazgos respaldan la necesidad de contar con un sistema automatizado y adaptable que permita segmentar, analizar y proyectar la demanda con mayor precisión y eficiencia, considerando las particularidades de cada combinación SKU-canal-regional; el capítulo IV verifica que, a un paso, el método de menor error difiere entre regímenes (apartado 4.3.2).

3.5 Triangulación metodológica y discusión de los resultados

La triangulación metodológica permitió integrar y contrastar los resultados obtenidos mediante la entrevista semiestructurada, la observación estructurada y el análisis documental, incorporando además como evidencia complementaria los hallazgos del análisis de los datos históricos. Este proceso tuvo como finalidad garantizar una visión más completa, consistente y validada del diagnóstico del proceso actual de planificación de la demanda en NOVAPACK S.A.

La triangulación consistió en comparar los hallazgos obtenidos con cada instrumento, identificando coincidencias, complementariedades y relaciones entre los problemas detectados y los requerimientos funcionales que debe cumplir el motor

automatizado de pronóstico propuesto. Como resultado, se evidenció un alto nivel de convergencia en torno a los siguientes problemas fundamentales del contexto investigado:

- Dependencia de procedimientos manuales y empíricos, basados en hojas de cálculo y juicio experto.
- Ausencia de herramientas automatizadas para generar, evaluar y retroalimentar los pronósticos.
- Falta de estandarización en los criterios y metodologías utilizadas por las distintas áreas o canales.
- Inexistencia de indicadores de precisión (MAE, MAPE, RMSE y Bias) que permitan evaluar objetivamente el desempeño de los pronósticos.
- Retrasos en la consolidación de la planificación, asociados a la dispersión de la información y la duplicidad de reportes.
- Carencia de un repositorio centralizado de datos que garantice trazabilidad, coherencia y actualización automática.
- Alta variabilidad de la demanda por SKU, canal y regional, que un criterio uniforme de estimación no capta.

Estos hallazgos fueron organizados en el cuadro de triangulación de la Tabla 7, donde se relacionan los problemas identificados, las fuentes que los reportan y los requisitos de diseño derivados para el desarrollo del motor de pronóstico automatizado.

Tabla 7
Triangulación metodológica de problemas identificados y requisitos de diseño

Indicador / problema identificado	Entrevista	Observación	Análisis documental	Requisito de diseño derivado
Dependencia de hojas de cálculo y procedimientos manuales	✓	✓	✓	Incorporar automatización integral del proceso de pronóstico

Indicador / problema identificado	Entrevista	Observación	Análisis documental	Requisito de diseño derivado
Ausencia de estandarización entre áreas	✓	✓	✓	Diseñar un flujo de trabajo unificado y parametrizable
Falta de retroalimentación o control de precisión	✓	✓	✓	Integrar métricas de evaluación como MAE, MAPE, RMSE y Bias
Demora en la elaboración de pronósticos	✓	✓	✓	Optimizar tiempos mediante ejecución automatizada y programación periódica
Inconsistencia en registros y reportes históricos		✓	✓	Establecer un repositorio centralizado de datos históricos
Alta variabilidad de la demanda por SKU, canal y regional	✓		✓	Incorporar selección automática del modelo según comportamiento histórico
Subjetividad en ajustes por juicio experto	✓	✓		Minimizar la intervención manual y fortalecer la validación objetiva

Nota. Elaboración propia.

Cada marca del cuadro indica que el problema fue evidenciado por el instrumento correspondiente: la entrevista mediante la declaración del informante, la observación mediante el registro de la sesión y el análisis documental mediante la revisión de reportes, planillas y registros históricos; la convergencia de dos o más instrumentos sobre un mismo problema constituye su corroboración por triangulación. La triangulación metodológica permitió confirmar que los principales problemas del proceso actual de planificación de la demanda en NOVAPACK S.A. no son aislados, sino estructurales y recurrentes. La coincidencia entre los resultados obtenidos mediante entrevista, observación y análisis documental muestra que la empresa depende de procedimientos manuales, carece de mecanismos objetivos de evaluación de precisión y no dispone de una infraestructura de datos suficientemente integrada para sustentar pronósticos consistentes.

De manera complementaria, los hallazgos del análisis de los datos históricos mostraron que la demanda presenta un comportamiento heterogéneo, estacional y variable según SKU, canal y regional, lo que refuerza la necesidad de una solución automatizada y adaptable. En consecuencia, la triangulación no solo corrobora el problema de investigación, sino que también permite traducir los hallazgos del diagnóstico en requisitos concretos de diseño para el motor de pronóstico propuesto.

Estos hallazgos coinciden con la literatura revisada. El ajuste por juicio experto sin registro ni retroalimentación reproduce el patrón que Fildes et al. (2009) documentaron en empresas manufactureras, donde esos ajustes tienden a introducir sesgos sistemáticos; el punto de partida de NOVAPACK S.A., promedios de períodos anteriores corregidos por el criterio comercial, se asemeja al que describe Castro Morales (2024) antes de su intervención; y la coexistencia de series suaves, erráticas, esporádicas e intermitentes en el portafolio es la situación en la que, según la clasificación de Syntetos et al. (2005), el régimen de cada serie orienta la elección del método (Boylan & Syntetos, 2021).

Jerarquización de los problemas o requisitos de diseño

A partir de la triangulación metodológica, se procedió a jerarquizar los problemas identificados según su relevancia para el diseño de la solución propuesta. Esta jerarquización siguió un criterio descriptivo, que no supone relaciones causales: la ubicación de cada problema respecto del método con que se elabora y se evalúa el pronóstico, cuya precisión es la variable dependiente del estudio. El nivel 1 agrupa los problemas propios de ese método, el nivel 2 las condiciones estructurales de datos y de organización en que ese método se aplica, y el nivel 3 las manifestaciones operativas que se observan en su ejecución. La frecuencia de detección entre instrumentos se empleó como criterio de corroboración de la existencia de cada problema, no de su prioridad: la demora en la consolidación mensual, por ejemplo, fue señalada por los tres instrumentos y se ubica en el nivel 3 porque corresponde a la ejecución del procedimiento manual y no es un problema propio del método con que se elabora el pronóstico.

Los problemas priorizados se agrupan en tres niveles:

Nivel 1, alta prioridad (críticos):

- Ausencia de un sistema automatizado de pronóstico.
- Dependencia de hojas de cálculo y del criterio empírico: ante una discrepancia en la reunión mensual de planificación de la demanda prevalece el criterio comercial sobre el dato histórico.
- Falta de métricas de evaluación de precisión (MAE, MAPE, RMSE y Bias).

Nivel 2, prioridad media (estructurales):

- Inconsistencias entre las planillas de planificación, falta de integración de los registros auxiliares de venta perdida, quiebres de inventario y tipo de cambio en el proceso de planificación, y ausencia de un repositorio centralizado.
- Falta de estandarización metodológica entre áreas o categorías.

Nivel 3, prioridad baja (operativa):

- Retrasos en la consolidación de la planificación mensual.
- Ajustes manuales recurrentes sin registro formal ni retroalimentación posterior.

3.6 Conclusiones sobre el estado del problema

El diagnóstico permite establecer el estado del problema en tres planos. Como regularidad, los tres instrumentos de la triangulación, con el análisis de los datos históricos como evidencia complementaria, coinciden en que la planificación descansa en hojas de cálculo y en el criterio empírico, sin métricas de error ni retroalimentación. Como problemas prioritarios, la jerarquización ubica en el primer nivel la ausencia de un sistema automatizado, la dependencia del criterio empírico y la falta de métricas de precisión. Como necesidad de transformación, la heterogeneidad de las 1.668 series de la muestra (312 suaves, 668 erráticas, 642 esporádicas y 46 intermitentes) muestra que un criterio uniforme de estimación no capta la estructura de la demanda; de ahí los requisitos de diseño que se enumeran a continuación.

Esta jerarquización permitió definir los principales requisitos funcionales y técnicos que el motor de pronóstico debe cumplir, los cuales se consolidan en la propuesta desarrollada en el capítulo siguiente:

- Automatización del proceso de generación de pronósticos.
- Integración de métricas de precisión y evaluación comparativa.
- Centralización y depuración de los datos históricos.
- Estandarización de flujos y criterios analíticos.
- Reducción de la intervención manual mediante reglas de selección automática.

La jerarquización de los problemas permitió establecer un orden lógico de intervención, priorizando los propios del método con que se elabora y se evalúa el pronóstico. En este sentido, los problemas clasificados como críticos constituyen la base del diseño de la solución propuesta. Por su parte, los problemas estructurales y operativos complementan el diagnóstico y orientan la definición de requisitos técnicos destinados a fortalecer la trazabilidad, estandarización y sostenibilidad del sistema propuesto.

CAPÍTULO IV. PROPUESTA DE SOLUCIÓN

Este capítulo presenta la propuesta técnica y metodológica desarrollada a partir de los hallazgos del diagnóstico realizado en NOVAPACK S.A. Su propósito es diseñar y validar un motor automatizado de pronóstico de demanda basado en series temporales, que integre modelos estadísticos tradicionales y algoritmos de aprendizaje automático para mejorar la precisión del proceso de planificación.

La propuesta se estructura de manera progresiva. Primero se expone el esquema general y los fundamentos que orientan el diseño del sistema. Posteriormente, se detalla su desarrollo, describiendo las fases de construcción, la arquitectura funcional, el diseño de su operación y los recursos empleados. Finalmente, se presentan la validación metodológica y técnica del motor, la extensión exploratoria, la valoración económica y la hoja de ruta para su implementación.

De esta forma, el capítulo constituye la materialización práctica de la investigación, al traducir los resultados del diagnóstico en una solución tecnológica aplicable al contexto empresarial de NOVAPACK S.A.

4.1 Esquema general de la propuesta

El diseño de la propuesta surge como respuesta directa a los problemas identificados durante el diagnóstico: la dependencia de procedimientos manuales, la ausencia de métricas de evaluación, la falta de estandarización entre áreas y la inexistencia de un sistema automatizado de pronóstico. Ante este contexto, se plantea una solución tecnológica integral orientada a automatizar, evaluar y optimizar el proceso de planificación de la demanda en NOVAPACK S.A.

La propuesta consiste en un motor híbrido y automatizado de pronóstico de demanda basado en series temporales, que integra modelos estadísticos clásicos y algoritmos de aprendizaje automático, permitiendo seleccionar de forma automática el

modelo con mejor desempeño según el comportamiento de la demanda en cada combinación SKU-canal-regional.

Este enfoque combina la eficiencia interpretativa de los modelos estadísticos tradicionales con la capacidad predictiva y adaptativa del aprendizaje automático. El conjunto completo de modelos candidatos, con la hipótesis que aporta cada uno y su criterio de inclusión, se detalla en el apartado 4.2.1.3 y en la Tabla 26 del Anexo 12. El costo computacional de esa combinación es acotado y quedó medido en la corrida del estudio. Sobre la muestra de 1.668 series y 108 meses, el ajuste de los 10 modelos candidatos y la selección por serie suman 17,7 segundos. El detalle por etapa consta en el registro de flujo de la corrida (apartado 4.2.1.6 y Anexo 9). Sobre esa base, el diseño se orienta a que el tamaño del portafolio sea una decisión de alcance analítico antes que una restricción de cómputo, extremo que deberá comprobarse al extender la ejecución más allá de la muestra.

El motor propuesto se estructura sobre una arquitectura modular inspirada en el estándar CRISP-DM, cuya definición y cuyas seis fases se exponen en el marco metodológico teórico (apartado 1.2.18). En este capítulo el marco se desarrolla en dos planos: las seis fases del desarrollo del apartado 4.2.1 y, como su forma ejecutable, los cinco módulos funcionales del apartado 4.2.2. Lo que sigue en este apartado es una descripción general de esa misma cadena: la lógica de selección, los tres componentes esenciales y el flujo propuesto que sintetiza la Figura 5. Su ejecución queda registrada, etapa por etapa, en el registro de flujo que cada corrida deposita junto al manifiesto de trazabilidad. Ambos se describen en el apartado 4.2.1.6, y este último se remite al Anexo 7.

El motor opera bajo una lógica de selección automatizada de modelos. En ella, cada serie temporal (definida por SKU, canal y regional) es evaluada mediante todos los modelos candidatos sobre el bloque de validación. Se selecciona aquel que minimiza el error compuesto (MAE + |Bias|, ambos en unidades) en esa ventana. El modelo elegido es el que genera el pronóstico de la serie en el bloque de prueba. Este mecanismo garantiza que la asignación sea reproducible y provenga del candidato de

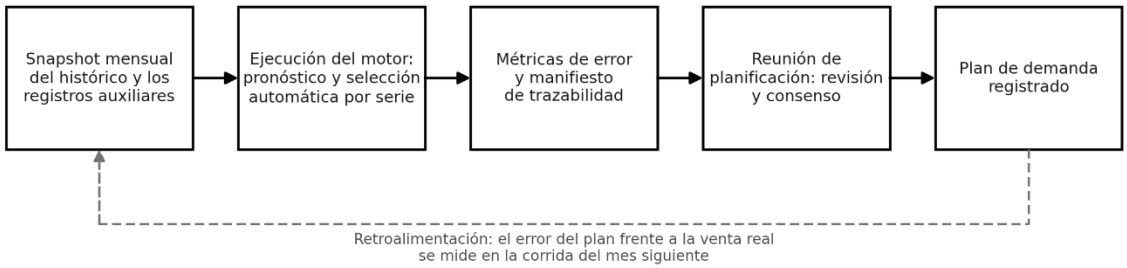
menor error compuesto en la ventana de validación; su acierto fuera de muestra se mide en la constatación técnica.

El esquema general de la propuesta contempla tres componentes esenciales:

- **Componente analítico:** encargado del procesamiento de datos históricos y la ejecución de los modelos predictivos.
- **Componente evaluativo:** orientado al cálculo de las métricas de error por serie (MAE, MAPE, RMSE y Bias) y de la métrica valorizada de decisión D = WMAPE + |Bias|, con la que se compara el desempeño agregado de los modelos sobre el portafolio.
- **Componente automatizado:** responsable de integrar las etapas anteriores, ejecutar el flujo completo de manera automatizada, programable en la implementación, y generar los resultados finales en formato de reporte o integración con herramientas de visualización.

La Figura 5 sintetiza el proceso propuesto con la misma estructura de cinco etapas del esquema actual del diagnóstico (Figura 3), lo que hace directa la comparación. Las etapas manuales del flujo vigente, la exportación a hojas de cálculo, la proyección por promedio móvil y los ajustes sin registro, se sustituyen por la ejecución automatizada del motor sobre una captura mensual del histórico. Esa ejecución tiene como salidas métricas de error y manifiesto de trazabilidad. La reunión de planificación se conserva como instancia de revisión y consenso. Además, se incorpora el lazo de retroalimentación cuya ausencia documentó el diagnóstico, de modo que el error del plan frente a la venta real quede medido en la corrida del mes siguiente; el motor construido mide el error de sus propios candidatos, y la medición del plan consensuado empieza con el piloto en paralelo y queda incorporada al proceso en la segunda etapa de la hoja de ruta (apartado 4.4 y Tabla 12).

Figura 5
Esquema propuesto del flujo de planificación de la demanda en NOVAPACK S.A.



Nota. Las cinco etapas se corresponden una a una con las del flujo actual (Figura 3); la línea punteada señala la retroalimentación mensual que el proceso vigente no contempla. En la figura, “snapshot” designa la captura mensual de los datos. Elaboración propia.

Se espera que la implementación de este motor permita a NOVAPACK S.A. mejorar la precisión de sus pronósticos, reducir la intervención manual, estandarizar los criterios de planificación y consolidar un sistema replicable que contribuya a la eficiencia operativa de la empresa.

Por qué y cómo del objetivo general

El objetivo general de esta investigación consiste en diseñar un motor de pronóstico basado en series temporales que integre modelos estadísticos y de aprendizaje automático para seleccionar el modelo más preciso en la predicción de la demanda mensual por SKU, canal y regional en NOVAPACK S.A., en Santa Cruz de la Sierra, para la gestión 2026.

El porqué de este objetivo se fundamenta en la necesidad evidenciada durante el diagnóstico: la empresa no dispone de un procedimiento automatizado de pronóstico incorporado a la decisión de planificación, capaz de generar proyecciones confiables, evaluables y replicables. Actualmente la planificación depende de hojas de cálculo y del juicio experto de los planificadores, sin control estadístico del error ni retroalimentación sistemática, según se documentó en las Tablas 3, 4 y 5. Junto a esa carencia, el diagnóstico registró dos magnitudes: una del nivel de servicio y otra del tiempo del proceso. Por el lado del servicio al cliente, el registro interno de venta

perdida se tomó en bruto y se valorizó a precio sobre el archivo histórico completo de ventas. Ese registro documenta que la demanda no atendida por falta de existencia equivalió al 15,5 % de la demanda solicitada en las gestiones 2022 a 2026 y al 18,4 % en las dos últimas gestiones, 2025 y 2026 (Tabla 6). Por el lado del proceso, la consolidación mensual demanda alrededor de 3 días de trabajo en hojas de cálculo antes de una reunión de validación de 2 horas. Así lo declaró el equipo durante la sesión observada (Anexo 3). Ese tiempo queda dentro del rango de 3 a 5 días que el informante clave IC-01 atribuye al armado de las hojas de cálculo (Anexo 1).

Por lo tanto, resulta indispensable diseñar una herramienta que sistematice el proceso de pronóstico, incorpore métodos analíticos validados y reduzca la dependencia de la intervención manual. Un motor automatizado de pronóstico ofrece una solución integral, al permitir el análisis simultáneo de múltiples series de datos y la selección objetiva del modelo más adecuado para cada combinación de negocio.

El cómo del objetivo se materializa a través del diseño de un sistema que integra tres enfoques complementarios:

- El **enfoque estadístico**, representado por una familia de métodos tradicionales que reparte entre sus integrantes los componentes estructurales de la demanda: la persistencia y el promedio, con el modelo ingenuo y los promedios móviles de 2 y 12 meses, incluidas las variantes con factor de crecimiento que replican la práctica de la empresa; el nivel con memoria exponencial, con el suavizado exponencial simple de parámetro optimizado por serie; la tendencia y la estacionalidad anual, con el método de Holt-Winters; y la demanda intermitente, con el método de Croston, conjunto que proporciona líneas base robustas y cubre los distintos regímenes de demanda del portafolio.
- El **enfoque de aprendizaje automático**, implementado mediante el algoritmo LightGBM (Light Gradient Boosting Machine), entrenado de forma global sobre todas las series con variables explicativas (los rezagos y ventanas móviles de la propia serie, el mes, el año y la tendencia, el precio, los quiebres de inventario, la venta perdida, el tipo de cambio y la categoría, a las que el modelo global suma la identidad del producto como variable categórica) y con la función

de pérdida Tweedie, seleccionada mediante optimización de hiperparámetros por su capacidad de corregir el sesgo de subestimación que la pérdida absoluta induce en demanda asimétrica.

- El **enfoque automatizado**, basado en un flujo programado de procesamiento, modelado y evaluación, que compara los resultados de cada modelo sobre el bloque de validación y selecciona automáticamente, para cada serie, aquel con menor error compuesto (MAE + |Bias|).

El motor propuesto utiliza los registros históricos de ventas por SKU, canal y regional como insumo principal. El proceso automatizado que ejecuta sobre ellos va del preprocesamiento de los datos a la salida de resultados. Ese proceso se detalla en los apartados 4.2.1 y 4.2.2.

En conjunto, este procedimiento hace que cada pronóstico sea el resultado de un proceso analítico objetivo, reproducible y escalable. La reproducibilidad no queda como atributo declarado. Cada corrida se define en un archivo de configuración y se ejecuta con semillas fijas y con LightGBM en modo determinista. Cada una deja también un manifiesto de trazabilidad que la sella, descrito en el apartado 4.2.1.6. El repositorio incorpora además 261 pruebas automatizadas en 21 archivos (una se omite por diseño), que verifican desde el contrato de los datos de entrada hasta la ausencia de fuga temporal en las variables explicativas. Cada resultado que el documento obtiene de las corridas queda así rastreable hasta los insumos, la configuración y la versión del código con que se obtuvo. La reducción del margen de error se cuantifica en el apartado 4.3, donde el desempeño del motor se contrasta con el de la réplica de la fórmula base de la empresa sin ajustes de consenso.

4.2 Desarrollo de la propuesta

Objetivos de la propuesta

Objetivo general de la propuesta. Disponer de un motor automatizado de pronóstico que, sobre la captura mensual del histórico de ventas de NOVAPACK S.A., genere para cada combinación SKU, canal y regional el pronóstico mensual del modelo

con menor error compuesto en validación, acompañado de sus métricas de error y de un manifiesto de trazabilidad, como insumo de la planificación de la demanda.

Objetivos específicos de la propuesta:

a) Preparar de forma reproducible el panel mensual de cada combinación SKU, canal y regional y sus variables explicativas, desplazando en el tiempo las que provienen de datos observados para que cada pronóstico use solo observaciones anteriores al mes que predice (apartados 4.2.1.2 y 4.2.3).

b) Ajustar el conjunto de diez modelos candidatos, estadísticos y de aprendizaje automático, y obtener el pronóstico de cada uno para cada serie (apartado 4.2.1.3).

c) Seleccionar para cada serie, con una regla única y reproducible, el candidato de menor error compuesto MAE + |Bias| en el bloque de validación (apartados 4.2.1.4 y 4.2.1.5).

d) Medir el desempeño del motor con las métricas por serie y con el error compuesto valorizado D, frente a la réplica de la fórmula de planificación vigente, sin los ajustes de consenso (apartado 4.3).

e) Organizar el flujo en módulos ejecutables de forma programada, con cada corrida sellada por su manifiesto y con un diseño de operación que lo integre a la planificación colaborativa (apartados 4.2.1.6, 4.2.2 y 4.2.5).

El desarrollo de la propuesta se basa en la construcción de un motor automatizado de pronóstico de demanda, concebido como una herramienta analítica capaz de integrar modelos estadísticos y de aprendizaje automático para optimizar la planificación por SKU, canal y regional en NOVAPACK S.A.

El diseño se estructuró conforme al marco CRISP-DM expuesto en el apartado 1.2.18, complementado con principios del diseño funcional de sistemas. Esta combinación permitió organizar las fases del desarrollo desde la comprensión del problema hasta la validación de resultados, con miras a un proceso riguroso, sistemático y replicable. El apartado se despliega en cuatro planos: las fases del

desarrollo, la arquitectura funcional que las ejecuta, el diseño de su operación (tratamiento de datos, eventos exógenos y microservicio) y los recursos que exige.

4.2.1 Fases del desarrollo de la propuesta

El desarrollo de la solución comprendió seis fases, que se corresponden con las seis del marco CRISP-DM expuesto en el apartado 1.2.18 mediante dos ajustes declarados. La comprensión del negocio y el modelado se corresponden uno a uno con sus homólogas del marco. El primer ajuste es una fusión: la comprensión y la preparación de los datos se tratan en una sola fase, porque ambas se resuelven sobre el mismo panel mensual y con las mismas decisiones de depuración. El segundo es un desdoblamiento: la evaluación del marco se abre en dos, evaluación de desempeño y selección automatizada del modelo, porque cada una responde a una decisión distinta del diseño, la vara con que se mide y la regla con que se elige. El despliegue, por último, toma aquí su forma conceptual: el diseño del flujo automatizado y la salida de resultados. El tramo que el motor ejecuta, desde la preparación de los datos hasta la salida de resultados, queda documentado en cada corrida por el registro de flujo que describe el apartado 4.2.1.6. Las seis fases se detallan a continuación.

4.2.1.1 Comprensión del negocio

Se identificaron las limitaciones del proceso actual de planificación de la demanda en NOVAPACK S.A., caracterizadas por el uso de hojas de cálculo, ausencia de automatización y falta de métricas de evaluación. A partir de este diagnóstico, se definió como requerimiento principal el diseño de un sistema automatizado capaz de reducir la intervención manual y mejorar la precisión de las proyecciones.

4.2.1.2 Comprensión y preparación de los datos

Se recopilaron los registros históricos de ventas mensuales por SKU, canal y regional del período abril de 2017 a marzo de 2026, junto con los costos unitarios, los quiebres de inventario y el tipo de cambio. Los datos fueron depurados y estructurados en un panel mensual continuo por combinación: se previó el descarte de devoluciones (ninguna en la captura, apartado 3.4.4), se completaron con cero los meses

intermedios sin venta y se trató el tramo de la pandemia como evento exógeno. Sobre el panel se construyeron variables explicativas: mes, año y tendencia, rezagos y ventanas móviles de la propia serie, precio, quiebres, venta perdida, tipo de cambio y categoría, a las que el modelo global suma la identidad del producto como variable categórica. Las variables que provienen de datos observados (rezagos, ventanas móviles, precio, quiebres, venta perdida y tipo de cambio) se desplazaron en el tiempo para garantizar que cada pronóstico utilice solo observaciones anteriores al mes que predice.

La preparación descrita corresponde al protocolo de medición, que opera sobre la muestra. La corrida mensual de la operación abarcaría además las series que la cascada excluyó y los casos que el experimento resolvió en origen o no llegó a enfrentar (productos nuevos, reemplazos de código, atributos faltantes, atípicos, filas duplicadas y venta no atendida), cuyas reglas se proponen en el apartado 4.2.3. Para proyectar, las variables explicativas sin valor futuro conocido (precio, quiebres, venta perdida y tipo de cambio) se extienden en el horizonte con su último valor conocido en el origen, supuesto de persistencia declarado que nunca las fija en cero, salvo que un evento conocido ex ante declare su valor futuro (apartado 4.2.4); las deterministas (mes, año y tendencia) se calculan para el mes que se pronostica. La pandemia, un evento exógeno observado solo ex post, se trató con la copia de la gestión previa únicamente en el panel de ajuste: reemplazó 24.194 de las 32.229 observaciones de la ventana, en 2.486 series, y las 8.035 restantes (24,9 %), sin historia doce meses antes, conservaron su valor observado. Como la copia vuelve idénticos los pares interanuales de la ventana, ese tramo se excluyó de las mediciones de deriva y de correlación de la etapa de unidad de análisis (Tabla 22). La constancia del precio en la captura se declara en el Anexo 5.

4.2.1.3 Modelado

En esta fase se aplicaron diez modelos de pronóstico y, sobre ellos, el motor de selección automática:

- Modelos de referencia: el modelo ingenuo (Naïve) y los promedios móviles de 2 y 12 meses, cada uno en versión simple y con la corrección de tendencia por factor de crecimiento del año móvil que replica la fórmula de las planillas de planificación de la empresa, sin los ajustes por juicio comercial del plan final; a esa réplica se refiere este trabajo como réplica de la fórmula base sin ajustes de consenso.
- Modelos de suavizado y de demanda intermitente: el suavizado exponencial simple con parámetro optimizado, el método de Holt-Winters con estacionalidad anual y el método de Croston para series intermitentes.
- LightGBM: algoritmo de aprendizaje automático basado en árboles de decisión con boosting por gradiente, entrenado de forma global sobre todas las series con variables explicativas y función de pérdida Tweedie calibrada por optimización de hiperparámetros.

La composición de este conjunto de modelos candidatos respondió a criterios técnicos y de evidencia empírica: cada familia se incorporó por la hipótesis estructural que aporta y por el respaldo que la sostiene. Los modelos de referencia fijan el punto de partida. El modelo ingenuo y los promedios móviles constituyen la línea base estándar del análisis de series temporales. Sus variantes con factor de crecimiento reproducen además la fórmula de las planillas de planificación de la empresa; las simples corresponden al nivel base de esa fórmula, sin la corrección. Su inclusión permite que cada resultado del estudio se mida no solo contra los demás modelos, sino contra el procedimiento que la planificación aplica en la actualidad.

Los modelos de suavizado y de demanda intermitente amplían el punto de comparación estadístico y reparten entre sus tres integrantes el nivel, la tendencia, la estacionalidad y la intermitencia, esta última una hipótesis que ninguno de los otros dos contempla. Del régimen intermitente se adoptó la formulación clásica de Croston; la corrección de sesgo de Syntetos y Boylan (2005) se plantea como refinamiento de trabajo futuro dentro del mismo marco de evaluación.

La elección del representante estadístico de referencia recayó en esta familia y no en ARIMA, y no se dirimió por exactitud: ambos son los enfoques más usados del

pronóstico de series de tiempo y ofrecen aproximaciones complementarias al problema (Hyndman & Athanasopoulos, 2018). El criterio decisorio fue la automatización: ARIMA exige la identificación del orden (p, d, q) serie por serie, procedimiento difícil de automatizar de forma robusta y auditable sobre miles de combinaciones, mientras que la formulación en espacio de estados del suavizado exponencial, cuyos parámetros este estudio ajusta por rejilla determinista, permite estimarlos de forma automática y bajo el mismo criterio para todas las series (Hyndman et al., 2002).

LightGBM se seleccionó como representante del aprendizaje automático por tres razones concurrentes. La primera es su desempeño sobresaliente en la competencia M5 sobre demanda minorista jerárquica (Makridakis et al., 2022). La segunda, su capacidad para capturar relaciones no lineales, propia de un ensamble de árboles de decisión con boosting por gradiente (Ke et al., 2017), cualidad que el diseño aprovecha, dado que el modelo se entrena de forma global sobre todas las series y con variables explicativas. La tercera es una eficiencia computacional que este estudio pudo verificar sobre su propio insumo. La verificación se hizo con los hiperparámetros ya fijados por la búsqueda que se describe más adelante en este mismo apartado. El ajuste del modelo global sobre las 1.668 series de la muestra y el pronóstico a un paso sobre el panel completo de 108 meses demandaron 11,25 segundos según el registro de tiempos de la corrida. Ese costo es el que hizo viable reentrenar el modelo en cada uno de los 12 orígenes de la evaluación multihorizonte que se reporta en el apartado 4.3. Es también el único de los tres criterios que no proviene de la literatura, sino de una medición sobre el propio insumo del estudio.

El conjunto de once brazos, los diez modelos candidatos y el motor que selecciona entre ellos, se definió tanto por lo que incorpora como por lo que deja fuera. Cinco alternativas se consideraron y no lo integran: ARIMA, cuya elección quedó dirimida al escoger el representante estadístico de referencia; Random Forest, representado por su familia; las redes neuronales profundas, evaluadas aparte; y XGBoost y Prophet, diferidos como trabajo futuro. Las cuatro últimas no quedaron fuera por el mismo motivo, de modo que se exponen a continuación.

Random Forest no fue descartado, sino representado. LightGBM pertenece a la familia de los ensambles de árboles, la misma de Random Forest, el mejor método en el antecedente de Valdivia Espinosa (2019). La evidencia comparada en demanda minorista indica que los métodos de aprendizaje automático, entre ellos el boosting por gradiente, superan a los métodos establecidos (Huber & Stuckenschmidt, 2020), por lo que se retuvo a ese exponente de la familia: el antecedente queda cubierto y la hipótesis estructural que ambos comparten entra al conjunto una sola vez, a través de su implementación mejor respaldada en esta clase de problema.

Las redes neuronales profundas quedaron fuera del conjunto principal por tres motivos concurrentes. El primero es de tamaño de muestra: la granularidad mensual del histórico disponible ofrece un número reducido de observaciones por serie, insuficiente para el entrenamiento robusto de arquitecturas profundas. El segundo es de costo computacional. El tercero es de interpretabilidad, menor que la de las alternativas retenidas. Conviene precisar el alcance de la decisión: excluye a estas arquitecturas del conjunto principal de once brazos y no las declara inadecuadas para el problema.

La pregunta por su aporte, sin embargo, es legítima, y el estudio la respondió con evidencia propia. La extensión exploratoria del apartado 4.3.3 amplió el conjunto de candidatos con cuatro arquitecturas de redes neuronales globales. También incorporó un modelo fundacional de series de tiempo aplicado sin reentrenamiento. Todos ellos se evaluaron bajo el mismo protocolo congelado y en un entorno de ejecución distinto del contenedor del flujo principal. Sus resultados no admiten una lectura simple. Una de las arquitecturas se retiró por desempeño y otra resultó el mejor pronosticador individual en el escenario más exigente de esa extensión. El modelo fundacional, por su parte, compitió con los mejores brazos sin reentrenamiento sobre los datos de la empresa y con la sola calibración de un factor de escala por categoría estimado en validación. El diferimiento se mantiene en sus propios términos para las arquitecturas entrenadas sobre el histórico; la medición del aporte de todas ellas se documenta en el apartado 4.3.3 y su evaluación ulterior se plantea entre las recomendaciones.

XGBoost y Prophet quedan planteados como línea de trabajo futuro. Su diferimiento no responde a una debilidad atribuida a uno u otro, sino al alcance que el estudio se fijó. Las razones técnicas de cada incorporación, con su respaldo bibliográfico, se formulan en las recomendaciones de este trabajo.

El conjunto reúne once brazos: los métodos estadísticos y de referencia, el modelo global de aprendizaje automático y el motor que selecciona entre ellos; la hipótesis estructural que aporta cada uno, su criterio de inclusión y su respaldo bibliográfico se reproducen en la Tabla 26 del Anexo 12.

La calibración de LightGBM se realizó mediante una búsqueda bayesiana de 60 ensayos. Esa búsqueda comparó tres funciones de pérdida sobre un pliegue interno del bloque de entrenamiento, la gestión 2024 (abril de 2023 a marzo de 2024). El criterio aplicado fue la D interna valorizada, esto es, WMAPE más |Bias| ponderados por el costo unitario sobre las series del pliegue con costo asignado. La familia Tweedie dominó la búsqueda: la separación frente a las otras dos funciones de pérdida fue nítida y de ella salió la configuración ganadora; el optimizador asignó a esa familia 45 de los 60 ensayos, frente a 8 de pérdida absoluta y 7 de pérdida cuadrática. El número de ensayos se fijó en 60 para un espacio de ocho dimensiones. Los diez primeros, de exploración aleatoria, ya bastaron para separar las familias: toda configuración Tweedie superó a toda configuración con pérdida absoluta o cuadrática (de los 60 ensayos, el mejor de esas dos familias, con 72,6 % de D interna, erró más que el peor de la familia Tweedie, con 71,4 %). El peor de todos fue el ensayo 9, con pérdida cuadrática y una D interna de 95,6 %. La búsqueda completa demandó cerca de ocho minutos con un solo hilo. Después del ensayo 30 el mejor valor mejoró alrededor de un punto, y los once ensayos posteriores al óptimo (ensayo 48) no lo mejoraron. El recorrido completo de la búsqueda, con el error interno de cada ensayo y su función de pérdida, se reproduce en el Anexo 12 (Figura 18).

La configuración adoptada responde a una lógica de diseño: árboles capaces de representar interacciones finas, compensados con una regularización fuerte (Tabla 28). Cada árbol admite hasta 137 hojas para combinar rezagos, estacionalidad, categoría y variables exógenas en un modelo global de 33 variables. Esa capacidad

se contiene con un mínimo de 61 observaciones por hoja, una penalización L2 de 24,5, que encoge las correcciones apoyadas en poca evidencia, y un submuestreo que entrena cada árbol sobre el 58 % de las variables y el 87 % de las filas. Con una tasa de 0,053, la parada temprana fija cuántos árboles se suman: 87 en el pliegue interno y 76 en la corrida principal. La potencia Tweedie de 1,465 ubica la pérdida entre Poisson y gamma, coherente con una venta mensual no negativa, con ceros y dispersión creciente con el nivel. Los rangos explorados contienen los valores por defecto de la biblioteca y la configuración previa a la búsqueda (variante 4 de la Tabla 23), con escala logarítmica para la tasa, las hojas y el mínimo por hoja, cuyo efecto es multiplicativo. Esta lógica es una razón de diseño, no un efecto demostrado. Se declaran dos aspectos: en la búsqueda, la parada temprana usó el pliegue donde se midió la D interna (un optimismo leve que no alcanza a validación ni a prueba), y la regularización de las variables categóricas, entre ellas el código de producto, quedó por defecto.

Lo decisivo en la búsqueda fue la función de pérdida, y operó por el sesgo, no por la magnitud del error: el mejor ensayo con pérdida absoluta igualó casi el WMAPE interno del mejor Tweedie (59,9 % y 59,6 %), pero con sesgos de −12,7 % y +0,2 %. Según el evaluador de importancia de Optuna, que ajusta un bosque aleatorio sobre los ensayos y descompone la varianza de sus predicciones entre los hiperparámetros, la pérdida explica 0,84 de la varianza de la D interna en los 60 ensayos; dentro de Tweedie pesan las hojas (0,25), la L2 (0,21) y la potencia (0,20), y casi nada la tasa y el mínimo por hoja (0,05 cada uno), porque la parada temprana compensa la tasa con los árboles (correlación de rangos de −0,83). Los nueve mejores, todos Tweedie, quedan a menos de 1,5 puntos del óptimo en una región compacta (hojas de 77 a 189, L2 de 24,5 a 29,9); como TPE concentra sus ensayos cerca del mejor, esa región describe la búsqueda y no prueba robustez. La L2 elegida quedó cerca del techo y la D interna mejora con ella: el óptimo podría estar fuera del rango, límite que pasa a la recalibración. El sesgo casi nulo del pliegue interno se trasladó solo en parte a la prueba (−14,1 %, Tabla 8), coherente con lo observado en el apartado 4.3.3 ante el cambio de régimen.

El efecto conjunto de las variables explicativas y de la calibración se reproduce en el Anexo 12 (Figura 19). El brazo de aprendizaje automático redujo su error compuesto valorizado, frente a la versión inicial del modelo (variables iniciales y parámetros sin calibrar), en 18,3 puntos porcentuales a un paso y en 26,3 en el horizonte. El motor heredó parte de esa mejora (4,7 y 8,5 puntos, respectivamente).

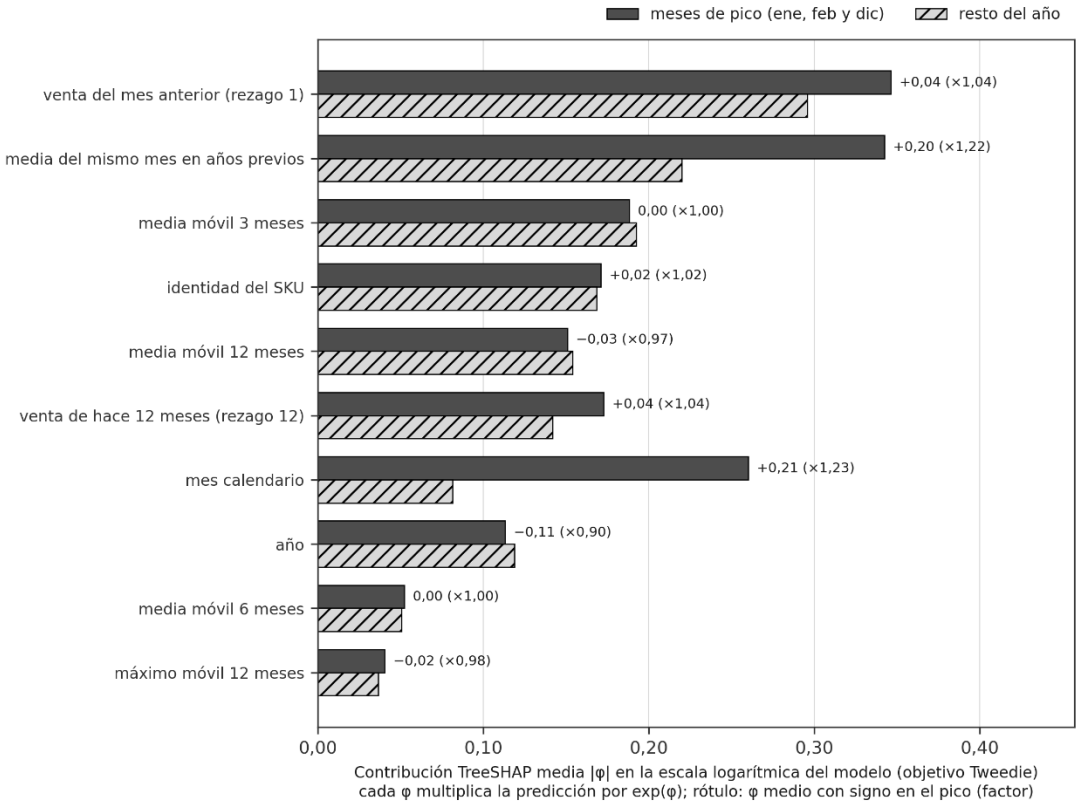
La Figura 6 muestra cómo compone el modelo global sus predicciones sobre el bloque de prueba, mediante las contribuciones TreeSHAP (la descomposición aditiva exacta de cada predicción). Con el objetivo Tweedie esa descomposición es exacta en la escala logarítmica del modelo: el valor base más la suma de las contribuciones da el logaritmo de la predicción, de modo que la predicción es un nivel base multiplicado por un factor exp(φ) por cada variable, y una contribución φ la multiplica por exp(φ). Esa exactitud se comprueba numéricamente, con datos sintéticos, en la suite de pruebas automatizadas del repositorio. Las contribuciones explican la predicción, no su error ni la reducción del error compuesto descrita en el párrafo anterior, y no tienen lectura causal sobre las ventas.

El análisis se dirigió a los meses de pico estacional, de diciembre a febrero, identificados como de pico por una regla declarada. Son de pico aquellos meses cuya participación en las ventas valorizadas anuales del bloque de entrenamiento supera en un 25 % la participación uniforme de un doceavo. Ese margen aísla la campaña sin capturar los meses que apenas superan el promedio y coincide con el perfil estacional documentado en el diagnóstico. Al medir la importancia como reparto de la contribución absoluta media en esa escala, la venta del mes anterior es la variable de mayor peso (15,9 % del total) y fija el nivel del pronóstico. Las variables que codifican el perfil estacional, esto es, la media del mismo mes en años previos (12,9 %), el rezago interanual (7,7 %) y el mes calendario (6,4 %), suman en conjunto cerca del 27 %. Son las variables con las que el modelo compone el pronóstico de campaña: en los meses de pico la contribución absoluta media de la media del mismo mes prácticamente iguala a la del rezago inmediato (0,34 frente a 0,35), y su contribución media con signo, +0,20, equivale a multiplicar la predicción por 1,22 (en torno a un 22 % más, como factor medio geométrico). El mes calendario, por su parte, triplica su contribución absoluta media respecto del resto del año (0,26 frente a 0,08), con un factor medio

geométrico de 1,23 en los meses de pico (+0,21). Las variables exógenas (precio, quiebres, venta perdida y tipo de cambio) participan del modelo, pero aportan en conjunto menos del 5 % de la contribución absoluta total; ese peso bajo en la predicción es coherente con la recomendación de fortalecer su registro histórico antes de esperar de ellas una mejora material, aunque por sí solo no mide cuánto cambiaría el error con un registro mejor.

Figura 6

Contribuciones TreeSHAP del modelo global por variable: meses de pico frente al resto del año



Nota. Contribuciones TreeSHAP calculadas sobre las 18.502 predicciones del bloque de prueba, en la escala logarítmica del modelo (objetivo Tweedie). Las barras muestran la contribución absoluta media en los meses de pico (diciembre, enero y febrero) y en el resto del año, para las diez variables de mayor contribución. El número junto a cada barra oscura es la contribución media con signo en los meses de pico y, entre paréntesis, su factor exp(φ). Elaboración propia con el script 'scripts/figura_contribuciones.py' del repositorio (Anexo 7), a partir de las salidas del motor.

4.2.1.4 Evaluación de desempeño

Los resultados de cada modelo se evaluaron utilizando métricas de precisión ampliamente reconocidas en la literatura:

- Error absoluto medio (MAE)
- Error porcentual absoluto medio (MAPE)
- Raíz del error cuadrático medio (RMSE)
- Sesgo promedio (Bias)

La combinación de estas métricas permitió analizar tanto la exactitud como la consistencia de los modelos. Para la comparación agregada se adoptó además la métrica valorizada D = WMAPE + |Bias|. Esa métrica pondera el error de cada serie por el costo unitario del producto, lo que lleva los errores de todas las series a una unidad monetaria común, y lo expresa en porcentaje de la demanda valorizada. Así determina el desempeño de cada modelo sobre el portafolio completo.

4.2.1.5 Selección automatizada del modelo óptimo

Se diseñó un algoritmo que compara los resultados de todos los modelos en el bloque de validación y selecciona automáticamente, para cada serie, aquel que presenta el menor error compuesto (MAE + |Bias|) en esa ventana. El procedimiento cierra sobre la muestra completa: los 10 candidatos se evalúan en las 1.668 series sin excepción. Ninguna serie queda sin candidato válido. Los 130 empates registrados en la ventana de validación (diferencias entre candidatos por debajo de 10^{-12}), el 7,8 % de la muestra, se dirimen con una regla fija y declarada: los candidatos se recorren en orden alfabético y, entre los empatados exactos, se conserva el primero; en los cuasiempates decide la diferencia numérica mínima que el cálculo registra. La regla hace que la asignación sea reproducible corrida a corrida. Ese cierre es lo que sostiene una asignación reproducible del modelo a cada unidad de análisis y lo que permite afirmar que se elimina la necesidad de intervención manual, porque no queda ninguna serie esperando una decisión humana. La regla no supone, en cambio, que el modelo asignado mirando validación vaya a ser también el de menor error en el bloque de prueba. Su eficacia se verifica allí mediante la tasa de acierto de la selección. Esa tasa

se define como la proporción de series en las que el candidato elegido resulta efectivamente el de menor error en prueba. Esa medición, junto con el margen que la separa del acierto esperable al azar, se reporta en la constatación técnica de la propuesta. La decisión se toma sobre el error a un paso porque ese es el protocolo confirmatorio declarado en el diseño metodológico (capítulo II), con partición, métrica y contraste fijados antes de observar los resultados. La selección con el error multihorizonte de validación se examinó después como corrida de ablación (Tabla 23, variante 2), y su traslado al criterio del motor se plantea entre las recomendaciones, para no cambiar el diseño una vez vistos los resultados.

4.2.1.6 Diseño del flujo automatizado y salida de resultados

Finalmente, se construyó el flujo integral del motor, que ejecuta todas las fases de manera secuencial y automatizada a partir de una configuración declarada. La corrida que respalda los resultados de este documento depositó los pronósticos consolidados por SKU, canal y regional junto a la demanda observada, las métricas de desempeño por modelo y por serie, las tablas del estudio, el catálogo de figuras generadas de forma programática y dos artefactos de trazabilidad de naturaleza distinta: el manifiesto, que sella los datos, la configuración y la versión del código con que se ejecutó, y el registro del flujo, que documenta las 15 etapas de la corrida una por una. El inventario de salidas y el detalle de lo que sella cada artefacto se reproducen en el Anexo 9. Así, la auditoría del procedimiento no depende de la memoria de quien lo ejecutó ni de volver a correr el flujo. El diseño contempla además un visor analítico local para la inspección de resultados y la integración futura con las herramientas de visualización de la empresa. El diseño de su operación mensual como microservicio, con la conexión a la base de datos y la programación periódica de la corrida, se desarrolla en el apartado 4.2.5; su implementación queda para la hoja de ruta (apartado 4.4).

4.2.2 Arquitectura funcional del sistema

La arquitectura traduce a componentes ejecutables las fases que el apartado 4.2.1 desarrolló: los cinco módulos que siguen son la forma en que el sistema las

realiza, no una descomposición alternativa. Este apartado describe primero los módulos del núcleo productivo, luego sus puntos de extensión y, por último, la trazabilidad de los requisitos del diagnóstico en el diseño.

4.2.2.1 Módulos del núcleo productivo

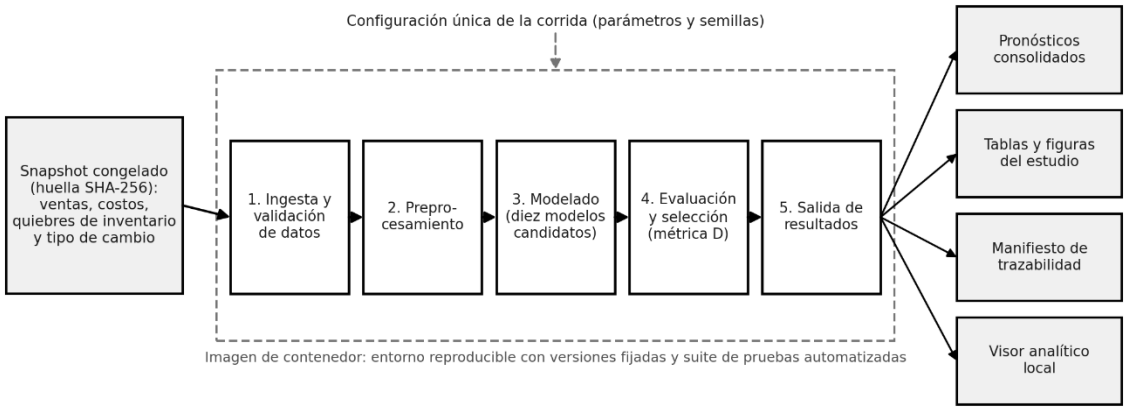
El motor automatizado de pronóstico se compone de cinco módulos funcionales interconectados de manera secuencial, que constituyen su núcleo productivo, esto es, lo que la empresa ejecutaría cada mes para obtener un pronóstico. La corrida del estudio ejecutó además etapas de instrumentación que la operación mensual no necesitaría repetir. La primera comprende la explicación del modelo global mediante contribuciones TreeSHAP y el análisis de Pareto del valor, de los que provienen la Figura 6, el corte mensual del error de la validación técnica (apartado 4.3.2) y la Figura 16 del Anexo 11. A ella siguen el contraste estadístico de la hipótesis y la evaluación multihorizonte con orígenes rodantes. Esa evaluación reentrena el modelo global en cada uno de los 12 orígenes del bloque de prueba y concentra por sí sola el 94 % del tiempo del registro de flujo. La duración de las 15 etapas se reproduce en el Anexo 9. Los resultados de las dos últimas se presentan en la constatación y validación de la propuesta; en la operación mensual bastaría con proyectar desde un único origen y con el modelo que el motor asignó a cada serie. La distinción importa porque el costo de cómputo de la propuesta operativa es el del núcleo, no el del estudio. Los cinco módulos del núcleo son:

1. Ingesta y validación de datos: importación de los registros históricos (ventas, costos unitarios, quiebres de inventario y tipo de cambio) y verificación de su estructura e integridad.
2. Preprocesamiento: construcción del panel mensual continuo (regla de devoluciones, ceros intermedios y evento exógeno), aplicación de la cascada de población y muestra, y generación de las variables explicativas.
3. Modelado: ejecución de los diez modelos candidatos sobre cada combinación de SKU, canal y regional.

4. Evaluación y selección: cálculo de las métricas por serie y de la métrica valorizada D, y selección automática, por serie, del modelo con menor error compuesto en el bloque de validación.
5. Salida de resultados: generación de los pronósticos consolidados, las tablas y figuras del estudio y los dos artefactos de trazabilidad de cada corrida, el manifiesto y el registro de flujo, con un visor analítico local para su inspección.

La Figura 7 presenta esta arquitectura en forma gráfica. La captura congelada, cuya huella SHA-256 queda registrada en el manifiesto, alimenta la cadena de los cinco módulos. Esa cadena se ejecuta dentro de la imagen de contenedor bajo una configuración única por corrida y entrega las cuatro salidas del sistema. Estas son los pronósticos consolidados, las tablas y figuras del estudio, el manifiesto de trazabilidad y el visor analítico local.

Figura 7
Arquitectura funcional del motor automatizado de pronóstico



Nota. Los módulos corresponden a los cinco descritos en este apartado; el marco punteado delimita el entorno reproducible (imagen de contenedor con versiones fijadas y suite de pruebas automatizadas) y la flecha superior, la configuración única que parametriza cada corrida. En la figura, “snapshot congelado” designa la captura congelada, y la métrica D del módulo 4 compara los modelos en el agregado, mientras que la selección por serie usa el error compuesto MAE + |Bias| en el bloque de validación. Elaboración propia.

4.2.2.2 Escalabilidad y puntos de extensión

La arquitectura modular descrita permite la escalabilidad del sistema, de modo que puedan incorporarse en el futuro nuevos modelos predictivos o nuevas categorías de productos sin alterar la estructura principal. Los puntos de extensión son explícitos: tanto el conjunto de modelos activos como las categorías de la población se declaran como listas del archivo de configuración, y el flujo admite, al invocarlo, sobrescribir el valor de cualquier clave ya declarada, sin editar su código. De ese modo se obtuvieron cinco corridas completas de variantes del estudio; cada una queda identificada por las anulaciones (los valores que sobrescriben la configuración declarada) que su manifiesto registra, junto con la huella de la configuración y la versión del código. La lista de las variantes y de sus anulaciones se reproduce en el Anexo 9. La ampliación efectiva del conjunto de candidatos, que sí requiere sumar código al módulo de modelado, se documenta en la extensión exploratoria del apartado 4.3.3.

4.2.2.3 Trazabilidad de los requisitos de diseño

El cierre del diseño frente al diagnóstico queda trazado requisito por requisito: los siete requisitos de diseño derivados de la triangulación metodológica (Tabla 7) quedan atendidos por componentes concretos del motor, dos de ellos solo en parte, y constatados con evidencia de este capítulo. El cruce completo, con el componente que atiende cada requisito y la evidencia de lo que cubre, se reproduce en la Tabla 27 del Anexo 12.

4.2.3 Tratamiento de datos para la operación del motor

Los criterios de inclusión del apartado 2.6.3 definen el protocolo de medición del estudio, no el alcance de la operación. La muestra reúne el 95,0 % de la demanda valorizada del bloque de entrenamiento, pero la población se renueva. En la gestión de prueba, el 10,1 % del valor a costo de las series con costo asignado correspondió a combinaciones que la cascada había excluido. Ese décimo se reparte, en cifras redondeadas, en 4,3 puntos de series sin venta en el entrenamiento (388 que venden en esa gestión), 4,8 de historia corta (209) y 0,9 de intermitencia crónica (410). A precio, la proporción es del 10,9 %, y en la gestión de validación la muestra cubrió el 92,4 % del valor a costo. El resultado validado (D de 75,4 %) vale para lo que la

muestra mide; la operación tendría que pronosticar también ese décimo, con las reglas declaradas de antemano que este apartado propone.

El tratamiento se organizaría en dos ejes, evaluados en cada corrida. El primero es el estado de actividad de la serie al último mes cerrado. Una serie es activa si vendió en los últimos seis meses; nueva, si su primera venta tiene menos de seis meses; reciente, si tiene de seis a once meses; dormida, si lleva de seis a once meses sin venta; descontinuada, si lleva doce o más; y sin historia, si nunca vendió. La condición de nueva o reciente prevalece sobre las demás. El segundo eje son los meses de historia, en cuatro tramos (1 a 11, 12 a 23, 24 a 35 y 36 o más), que fijarían el conjunto de modelos elegibles. Holt-Winters y las variantes con factor de crecimiento solo entrarían con 24 meses o más, porque necesitan dos ciclos anuales completos, y Croston solo cuando el intervalo promedio entre demandas (ADI) alcanza 1,32. Cada serie recibiría además un modelo de respaldo, que se publicaría si el elegido fallara, y una marca de calidad con las reglas que se le aplicaron. Ninguna serie se descartaría en silencio: la que no recibiera pronóstico quedaría registrada con su motivo, como en la cascada del estudio. La Tabla 30 del Anexo 14 detalla el tratamiento caso por caso.

Por debajo de 36 meses, la primera opción sería el modelo global, que aprende del conjunto de las series y puede pronosticar combinaciones cuya historia individual no alcanzaría para ajustar un modelo local (Montero-Manso & Hyndman, 2021). La exclusión por historia corta respondió a requisitos de la medición, no a que esas series no admitan pronóstico: con reglas simples, las 108 series de historia corta que seguían activas y vendieron en la gestión de prueba registran una D de 71,5 % con el promedio móvil de dos meses, frente a 84,9 % de la misma regla en la muestra (Tabla 30). La lectura es descriptiva y frágil, porque diez de esas 108 series concentran el 68,1 % de su demanda valorizada. Lo que sí eleva el error es el arranque en frío y la intermitencia, con D de 121,9 % y 167,1 % para el modelo ingenuo. El estudio entrenó LightGBM solo sobre las 1.668 series de la muestra; en la operación se entrenaría sobre la población completa, y el piloto verificaría sobre la lectura de la muestra que esa ampliación no degrade el resultado validado. Mientras tanto, las series de la muestra conservarían el modelo validado.

Los productos sin historia se pronosticarían, hasta su primera venta, por un análogo que declara Planificación (la demanda de un producto existente multiplicada por un factor de escala) o por el perfil de su categoría, canal y regional. El número se registraría como ajuste de juicio, porque esos ajustes mejoran o empeoran la exactitud según su tamaño y su dirección (Fildes et al., 2009); solo su registro permite auditarlos. Se distinguiría la extensión de un producto existente a otra combinación, que heredaría el perfil del mismo producto (129 de las 469 series sin historia), del producto realmente nuevo (340). En el otro extremo del ciclo de vida, la serie dormida se pronosticaría con un método que actualiza cada mes la probabilidad de demanda y la lleva hacia cero mientras no hay venta (Teunter et al., 2011). La descontinuada recibiría pronóstico cero con alarma de reactivación: 71 de las 227 dormidas y 172 de las 1.044 descontinuadas volvieron a vender en la gestión de prueba. La intermitencia crónica se trataría con Croston o con su corrección de sesgo (Syntetos & Boylan, 2005), y su error se evaluaría en agregado y no serie por serie.

Los reemplazos de código se gobernarían con un maestro de equivalencias versionado, en el que cada fila declara el código anterior, el vigente, el factor de conversión, el tipo de equivalencia y la fecha de vigencia. La historia del código anterior se transferiría al vigente multiplicada por el factor, como ya hace el reporte consolidado del que proviene la matriz (apartado 2.5.3), y los quiebres y la venta perdida se reexpresarían con la misma regla, cosa que la captura del estudio no hace con los quiebres. Si el reemplazo ocurre dentro del horizonte, el motor cortaría en la fecha de vigencia: pronosticaría el código anterior hasta el mes previo y el vigente desde ese mes. El corte con transferencia por factor sería la única regla del motor para los reemplazos, sin curva de transición. El agotamiento del inventario remanente del código anterior no es una regla del motor, sino una decisión comercial y del ciclo de vida del producto que, si afecta el plan, entraría como ajuste registrado. Los combos y las presentaciones múltiples se expresan en el producto base con el mismo factor. El maestro es uno a uno y no prevé reemplazos de un código por varios; si aparecieran, se usarían participaciones declaradas que suman uno. Los códigos fuera del portafolio vigente quedarían excluidos, y el factor y la unidad de cada equivalencia se validarían al darla de alta.

Los atributos del maestro faltantes o inválidos se tratarían con una regla genérica. El contrato de entrada los detectaría (nulos, ceros, negativos o incoherentes, como un costo mayor que el precio), cada atributo tendría una imputación declarada que deja una marca en la serie, nada se descartaría en silencio y el registro de flujo contaría las imputaciones de cada corrida. Cuatro ejemplos muestran la regla. El costo falta por producto completo, nunca en una combinación aislada, y se concentra en la categoría K, cuya razón entre costo y precio es estrecha (mediana 0,535; rango intercuartílico de 0,493 a 0,582). Se imputaría con la razón de la categoría y la serie quedaría marcada, fuera de la medición confirmatoria. El precio de la captura es un valor vigente único por combinación (Anexo 5), no una historia de precios. Si faltara, se tomaría el último precio promedio histórico de la serie o, en su defecto, la mediana de la categoría, con marca. El peso y el volumen, que el estudio no usa, se imputarían de forma jerárquica (producto equivalente, luego categoría) con marca: no cambian el pronóstico en unidades, solo su conversión a kilos, volumen o pallets.

Los datos erróneos seguirían reglas de calidad de la señal declaradas de antemano. Los atípicos se marcarían y no se borrarían, con un criterio que compara cada mes con el mismo mes calendario de otras gestiones. Un recorte automático a tres desvíos por serie afectaría 2.709 celdas en 1.522 de las 1.668 series de la muestra (91,2 %), el 72,4 % de ellas entre noviembre y febrero, de modo que borraría la campaña escolar. Un mes en cero es demanda nula dentro de la vida de la serie, ausencia del producto fuera de ella y demanda censurada si hay quiebre registrado; la venta perdida se conservaría como señal de esa censura, y los meses con quiebre o venta perdida se informarían aparte al medir el error. Las devoluciones se separarían de la demanda y se contarían. Para los duplicados convivirían dos reglas (Tabla 39): las filas idénticas en todas sus columnas se deduplicarían y se registrarían, en lugar de sumarse como ocurrió en el estudio con un producto (apartado 3.4.4); una misma clave con valores distintos, en cambio, detendría la publicación de las series afectadas, porque no hay modo de saber cuál fila es la correcta. Las nomenclaturas de canal y regional se traducirían con una tabla de correspondencia versionada, y la unidad de medida se validaría contra la unidad principal del maestro.

El alcance de la operación también excede a la población del estudio. Las siete categorías que quedaron fuera de ella, el 27,6 % de la demanda valorizada del período, entrarían por etapas con las mismas reglas. El canal institucional aporta 1.310 de las 2.738 combinaciones excluidas, pero solo el 8,9 % del valor a precio que quedó fuera de la muestra en la gestión de prueba. Se pronosticaría por agregado de canal y regional con reparto por participación, o como cartera de pedidos declarada. El criterio para identificar un pedido firme sería documental y no un umbral de cantidad: el pedido adjudicado, con cantidad y fecha de entrega comprometidas, se registraría como componente firme, fuera de la selección del motor, y se sumaría al pronóstico estadístico del resto del canal. Por último, cada regla aplicada se contaría en el registro de flujo (apartado 4.2.1.6), como hoy la cascada cuenta las series que excluye, y así la cobertura, las imputaciones y los respaldos quedarían auditables en cada corrida.

4.2.4 Protocolo de tratamiento de eventos exógenos

El estudio aplicó cuatro tratamientos de eventos exógenos sin ordenarlos como protocolo: la copia de la gestión previa en el tramo de la pandemia, solo en el panel de ajuste (apartado 2.7); las exógenas rezagadas, extendidas en el horizonte con su último valor conocido (apartado 4.2.1.2); un calendario comercial de variables deterministas, y la detección del cambio de régimen (apartado 4.3.3). En el primero, el estudio replicó la práctica de la empresa porque la línea base debía ser el método real, y la ablación (variante 1, Anexo 9) mostró que el tratamiento no altera el podio: sin él, la D del motor fue de 74,7 % a un paso y de 91,6 % en el horizonte, frente a 75,4 % y 91,2 % con él (apartado 4.3.2). En la operación de NOVAPACK S.A., cada tratamiento se mantendría mientras una ablación sobre la gestión cerrada no lo desaconsejara. Los eventos de un solo producto (lanzamientos, descontinuaciones y reemplazos) se tratan en el apartado 4.2.3.

Cada evento se clasificaría en dos ejes (Tabla 33 del Anexo 14). El primero es si se conoce ex ante, es decir, si puede registrarse antes de ocurrir (un calendario escolar, una promoción, una licitación adjudicada), o si solo se observa ex post (una pandemia, una crisis cambiaria): lo primero puede entrar como variable en el horizonte; lo segundo solo puede corregirse en la historia o reconocerse como cambio de

régimen. El segundo eje es el alcance (portafolio, categoría, regional o SKU), que decide cómo se detecta el evento: el detector del estudio mira el agregado valorizado del portafolio, y un evento de una categoría o de una regional puede pasarle inadvertido. Al registrarlo se declararía además si se lo espera transitorio o permanente (pulso o escalón, apartado 1.2.15).

La corrección del panel de ajuste se reservaría para choques observados ex post de alcance portafolio o categoría, nunca por SKU. Su ventana se delimitaría por regla y no por fechas fijas: el valor a costo de cada mes frente al del mismo mes de la última gestión anterior al evento, entendida como en la copia del apartado 2.7 (los doce meses que preceden a su inicio), con dos meses consecutivos para abrirla y para cerrarla. El umbral sería un parámetro declarado al registrar el evento y revisable con cada gestión cerrada; el estudio no lo fija, porque su ventana replicó la práctica de la empresa. La base previa es imprescindible, porque la comparación interanual simple se contamina apenas el evento termina: con una sola definición, a costo (convención del Anexo 5), abril de 2021 superó en 906,4 % a abril de 2020, pero solo en 5,2 % a abril de 2019. La profundidad tampoco fue uniforme: el tramo cayó 40,1 % frente a los doce meses previos, con abril de 2020 en −89,6 % y caídas de entre 5,1 % y 24,1 % de septiembre a diciembre de 2020. Como lectura retrospectiva, y no como umbral, siete de los doce meses quedaron por debajo de un corte ilustrativo de −30 %.

Las variables indicadoras de pulso o escalón servirían para eventos con fecha conocida, cuyo efecto solo aprendería el modelo global: los métodos estadísticos del conjunto de modelos candidatos no reciben variables externas. Las variables de calendario se calcularían para el mes que se pronostica, y las exógenas rezagadas conservarían la persistencia del último valor conocido, un supuesto declarado y no una protección frente a un cambio brusco. La conmutación por régimen seguiría siendo exploratoria, porque sus umbrales se fijaron sobre las mismas dos gestiones en que se midió (apartado 4.3.3). Los pedidos institucionales adjudicados, con cantidad y fecha comprometidas, se separarían como un componente firme que se suma al pronóstico estadístico, con el criterio del apartado 4.2.3.

El protocolo se apoyaría en un registro de eventos declarado, que el motor leería en cada corrida como un insumo más (apartado 4.2.5). Cada evento tendría identificador, tipo, alcance, fecha de alta (el mes desde el que rige), fecha de cierre prevista y efectiva, conocimiento ex ante, fecha de registro, tratamiento con sus parámetros, responsable, estado (propuesto, abierto, cerrado o descartado) y evaluación ex post. La Tabla 34 del Anexo 14 llena esa ficha con el único evento que el estudio trató, la pandemia. La fecha de registro impediría la fuga de información: en un ensayo retrospectivo, un evento solo podría usarse como variable futura en los orígenes posteriores a su registro. La serie observada seguiría siendo la referencia de toda evaluación. Cada corrida dejaría en su manifiesto la huella del registro usado y, en el registro de flujo, los conteos de cada evento.

La gobernanza seguiría el reparto de la reunión mensual de planificación. El área de planificación sería dueña del registro: abriría, cerraría y descartaría eventos. El área comercial propondría en esa reunión los eventos que conoce (promociones, cambios de lista de precios, licitaciones y lanzamientos), del mismo modo que los ajustes registrados de la hoja de ruta (apartado 4.4). El científico de datos validaría cada alta y ejecutaría el tratamiento asignado. El motor solo leería lo registrado: la señal de sesgo podría sugerir que hay un evento, pero el alta la decidiría Planificación. Cada evento se cerraría en la fecha declarada o cuando lo indicara la regla de ventana, y se auditaría con la gestión cerrada siguiente.

El caso más exigente es el evento en curso: a diferencia de la pandemia, ocurre en los meses recientes y no dentro del bloque de entrenamiento, y deja de valer la garantía de que su ventana cae íntegra en el entrenamiento. Si el evento no fue anunciado, aparecería primero en el sesgo valorizado móvil de tres meses del monitor (apartado 4.2.5.5). La rampa del detector, desde el 10 %, se mostraría como señal informativa. La alerta con acción, un sesgo móvil mayor que 20 % en valor absoluto durante dos meses seguidos con el mismo signo (umbral inicial revisable), obligaría a Planificación a decidir si registra un evento.

Una vez registrado el evento, sus meses se marcarían o se excluirían de la ventana de selección del motor mientras siguiera abierto. Como esa ventana sería la

última gestión cerrada, fija durante la gestión (apartado 4.2.5.4), la marca regiría cuando se recalculara la selección, sea al cierre de la gestión o en una recalibración adelantada por la alerta (apartado 4.2.5.6). Los indicadores de seguimiento mensual se informarían con y sin los meses del evento. El juicio comercial sobre la duración y la profundidad del evento entraría como ajuste registrado sobre el número del motor (apartado 4.4), nunca como corrección silenciosa de la historia.

Un tratamiento nuevo, o la continuidad de uno vigente, se decidiría como en la variante 1: con una ablación sobre la gestión cerrada que compare la D valorizada con y sin él en las dos modalidades, con prioridad del horizonte (apartado 4.3.2), y sin que el motor empeore. El calendario comercial de la extensión muestra por qué el criterio se fija antes de medir: redujo el sesgo valorizado del modelo global de −14,1 % a −10,7 %, y con ello su D a un paso, pero elevó su WMAPE de 62,9 % a 63,8 % (apartado 4.3.3) y, según la auditoría que conserva el repositorio (Anexo 7), empeoró su D en el horizonte y la del motor de esa iteración; con señales opuestas, quedaría en exploración. Las alternativas a la copia pasarían por la misma ablación: una indicadora solo la vería el modelo global, y excluir la ventana del ajuste no impediría que los rezagos de doce meses la lean.

El primer límite del protocolo es que las promociones y los cambios de precio no son tratables con la captura disponible, porque el precio es un valor de lista único por combinación en todo el período (Anexo 5) y el campo de promociones resultó incompleto en la fuente (apartado 3.4.4); serían tratables tras al menos dos gestiones de registro, una para estimar su efecto y otra para validarlo. El segundo límite es que el detector de régimen tiene alcance de portafolio y no ve eventos de una categoría o de una regional; su extensión queda como recomendación.

El tipo de cambio subió 54 % entre el inicio y el cierre de la gestión 2025, tocó su máximo en junio de 2025, ya en la gestión 2026, y cerró esa gestión 42 % por debajo de su valor inicial. Cuando este documento llama “normal” a la gestión 2026 (apartado 4.3.3 y nota de la Figura 14), se refiere al comportamiento de la demanda frente a los conjuntos de modelos de pronóstico, no a la macroeconomía. El modelo global casi no recurrió al tipo de cambio: sus dos variables intervinieron en 11 y 7 divisiones de los

árboles, frente a 493 del rezago de un mes. En la extensión exploratoria, fue el detector el que absorbió la crisis.

4.2.5 Arquitectura de microservicio propuesta para la operación

Este apartado lleva hasta la operación el objetivo específico de diseñar conceptualmente el motor, dentro del alcance propositivo de la investigación: es un diseño, y ninguno de sus componentes nuevos se construyó ni se midió en este estudio. Los cinco módulos del apartado 4.2.2 serían el núcleo del servicio, sin cambios metodológicos. Operarlo requeriría cuatro adiciones acotadas: una partición operativa sin bloque de prueba, cuya ventana de validación sería la última gestión cerrada, fija durante toda la gestión; la proyección desde el último mes cerrado, con la mecánica recursiva ya construida para la evaluación multihorizonte; la política de respaldo del apartado 4.2.3 para las series que la cascada de inclusión deja fuera; y la persistencia de las salidas en una base consultable, además de los archivos.

La corrida seguiría siendo un proceso por lotes mensual; el servicio expondría además una interfaz delgada para consultar los resultados y registrar los ajustes del plan, y por eso se diseña como microservicio y no como un programa aislado. Las reglas de datos del apartado 4.2.3 y el registro de eventos del apartado 4.2.4 entran como insumos declarados, y los contratos detallados se reúnen en las Tablas 35 a 42 del Anexo 15.

El diseño se documenta con las vistas del modelo 4+1 (Kruchten, 1995). La vista lógica, que el apartado 4.2.5.1 presenta como vista de componentes, reúne los componentes y sus responsabilidades (Figura 7, franja inferior de la Figura 8 y Tabla 35 del Anexo 15); la de procesos, la secuencia de la corrida mensual y su ruta de falla (apartado 4.2.5.4); la de desarrollo, los módulos del núcleo, la imagen de contenedor y la configuración versionada (apartado 4.2.2 y Anexo 7); y la física, o de despliegue, la asignación de los contenedores a la infraestructura de la empresa (Figura 23 del Anexo 15). Los escenarios son el ciclo mensual completo: corrida, publicación, ajustes de la reunión y cierre con el error de cada etapa (Tabla 38). La vista de contexto de la Figura 8 se completa en la Figura 22 con las personas y los sistemas de la empresa

que intercambian datos con el motor; las interfaces de ese intercambio, con su dirección, contrato, frecuencia, autenticación y responsable, se reúnen en la Tabla 41, y las decisiones de arquitectura, con las alternativas descartadas y sus consecuencias, en la Tabla 42.

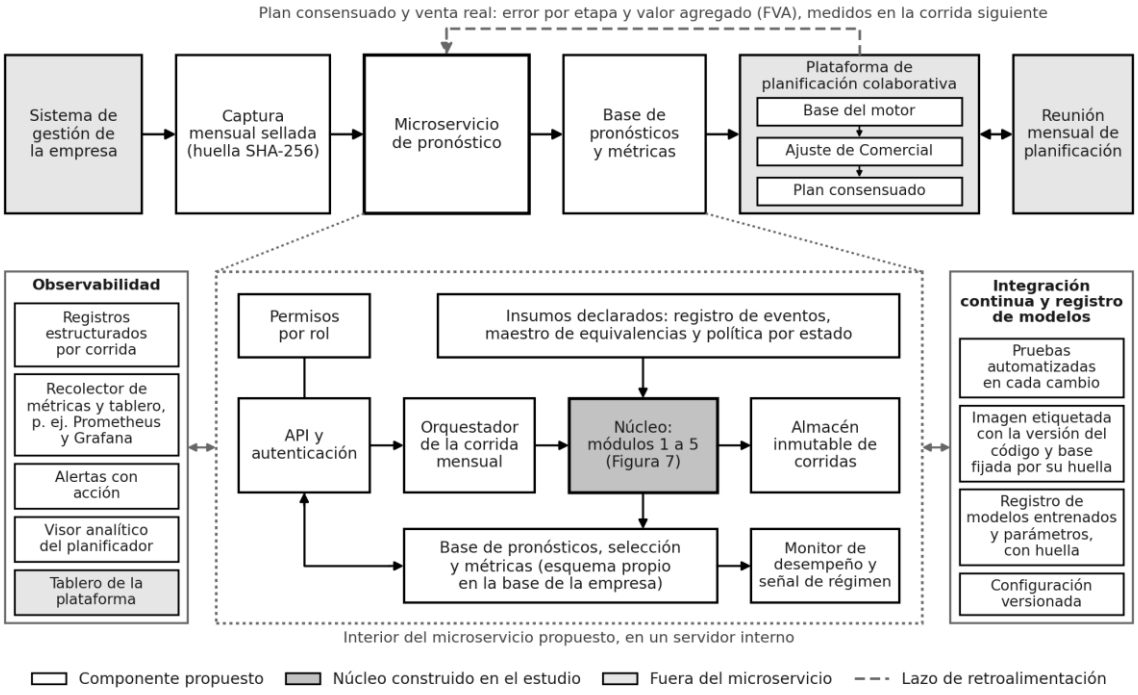
4.2.5.1 Contexto y componentes

La vista de contexto ubica al microservicio entre la fuente de los datos y la decisión de planificación (Figura 8, franja superior). Al cierre de ventas de cada mes, se extraería del sistema de planificación de recursos empresariales (ERP, por su sigla en inglés) una captura sellada con su huella criptográfica. El microservicio la procesaría y escribiría sus resultados en una base de pronósticos y métricas, de donde los leerían la plataforma de planificación colaborativa y el visor analítico. Sobre esa base, la reunión mensual de planificación de la demanda construiría el plan consensuado, y en la corrida siguiente ese plan y la venta real volverían al microservicio, que mediría con ellos el error de cada etapa. Ese retorno es el lazo de retroalimentación de la Figura 5, previsto hasta aquí sin un componente que lo materializara.

La vista de componentes descompone el microservicio en nueve piezas (Figura 8, franja inferior). La interfaz de programación de aplicaciones (API, por su sigla en inglés), con su autenticación, sería la única puerta para consultar resultados, lanzar corridas y registrar ajustes (contrato mínimo en la Tabla 36). El orquestador pediría la captura, validaría los insumos y encadenaría las etapas. El núcleo serían los módulos 1 a 5 de la Figura 7. Los insumos declarados reunirían el registro de eventos del apartado 4.2.4 y el maestro de equivalencias y la política por estado del apartado 4.2.3. El almacén inmutable guardaría la captura, la configuración, el manifiesto, el registro de flujo y las salidas de cada corrida, y la base de pronósticos, selección y métricas haría consultable lo que hoy son archivos. El monitor compararía cada mes lo pronosticado, lo planificado y lo vendido, y calcularía la señal de régimen. Los permisos por rol separarían la consulta, el registro de ajustes y el lanzamiento de corridas, y el recolector de métricas, el tablero y las alertas del apartado 4.2.5.5 completarían el conjunto.

Figura 8

Arquitectura de microservicio propuesta para la operación mensual del motor: contexto e interior del servicio



Nota. Diseño propuesto, no implementado. La franja superior muestra el contexto de la corrida mensual, desde el sistema de gestión hasta la reunión mensual de planificación de la demanda; la inferior, dentro del marco de puntos, el interior del microservicio y sus dos bandas laterales. Los módulos 1 a 5 son los de la Figura 7, construidos en el estudio, y se representan en una sola caja. La línea punteada con flecha es el lazo de retroalimentación de la Figura 5. El recolector de métricas y el tablero se nombran como ejemplo de implementación (Prometheus y Grafana, o cualquier recolector compatible), no como requisito del diseño. Elaboración propia con el script 'scripts/figura_microservicio.py' del repositorio (Anexo 7).

De esas piezas, el núcleo ya existe como resultado del estudio, con la proyección recursiva, el manifiesto, el registro de flujo, las pruebas y la imagen de contenedor; otras cuatro existen en parte, y la API, el orquestador, la base y el recolector son propuestos. El estado de cada componente y el principio de operación que atiende se detallan en la Tabla 35 del Anexo 15.

Se consideró una alternativa más simple: un trabajo programado que escribiera los resultados en una base y un tablero que los mostrara, sin un servicio encendido ni una interfaz que versionar. Se descartó porque no ofrece un contrato estable para

varios consumidores, como la plataforma y el visor, ni un lugar donde registrar los ajustes de la reunión con su autor y su motivo, condición para medir su valor. El diseño conserva esa lógica en su interior: la corrida es un trabajo por lotes y la API solo la expone.

4.2.5.2 Conexión con la base de datos

El microservicio leería la base relacional de la empresa solo a través de vistas de contrato versionadas y de solo lectura, una por insumo: ventas mensuales consolidadas al código vigente, con precio y venta perdida; costos unitarios; inventario semanal, del que se derivan los quiebres; tipo de cambio; portafolio y equivalencias; y registro de eventos. Una vista de contrato desacopla al motor de las tablas internas del ERP: si estas cambian, se ajusta la vista y no el motor. La conexión usaría un rol de mínimo privilegio, cifrado en la red interna, pocas conexiones con tiempos máximos de espera y credenciales inyectadas por variables de entorno desde el almacén de secretos de TI. Es el patrón con que ya se extrajo la captura del estudio, con consulta parametrizada, controles previos y lectura por lotes.

Al cierre de ventas, el orquestador ejecutaría los controles previos, extraería el período y sellaría la captura con su huella SHA-256 y su manifiesto de extracción. El cómputo correría siempre sobre esa captura y nunca contra la base viva, porque la extracción mensual repetiría el ciclo de capturar, sellar y calcular del estudio; así sigue valiendo lo dicho en el marco tecnológico, que el flujo no consulta la base mientras calcula. Antes de modelar, un contrato de entrada verificaría columnas, tipos, claves no nulas, rango de fechas y frescura de la captura de ventas; si fallara, la corrida se detendría sin publicar nada. Los duplicados y las cantidades negativas seguirían las reglas del apartado 4.2.3.

La escritura iría a un esquema propio del microservicio dentro de la base relacional de la empresa, en sus servidores y con las credenciales de TI; el motor no escribiría en ninguna otra parte. Las tablas de ese esquema, con su contenido y sus claves, se detallan en la Tabla 37 del Anexo 15, cuya nota estima el volumen por captura. La clave natural de una corrida sería la combinación de fecha de corte, huella

de la captura, huella de la configuración, versión del código y huella de la imagen: dos corridas con la misma clave son la misma corrida. Cada corrida se escribiría en estado “en curso” y se cerraría en una sola transacción; publicarla sería mover hacia ella el puntero del período, y revertirla, volver a apuntar a la anterior, sin borrar nada. Los cambios de esquema se aplicarían con migraciones versionadas, y lo publicado y las capturas se conservarían durante el plazo de retención que fije la empresa; la propuesta es de cinco años desde la publicación de cada corrida, prorrogables (apartado 1.5.3).

En la operación interna el motor trabajaría con los códigos reales de producto, canal y regional, porque Planificación los necesita para decidir. La confidencialidad dejaría entonces de resolverse con seudónimos y pasaría a resolverse con roles, autenticación de la API, cifrado en tránsito y auditoría de accesos; la seudonimización se conservaría para todo lo que salga de la empresa, en los términos del Anexo 2 y del marco legal del apartado 1.5.

4.2.5.3 Integración con la plataforma de planificación colaborativa (S&OP)

La integración se diseña para conectarse con la plataforma de planificación colaborativa que la empresa adopte: el diseño fija solo el contrato y los requisitos mínimos, sin proponer un producto ni construir un módulo propio. Se la entiende como la evolución del proceso observado en el diagnóstico hacia una planificación de ventas y operaciones (S&OP, por su sigla en inglés), que coordina periódicamente la demanda prevista con la capacidad de abastecerla (Chopra, 2019). La empresa no tiene hoy ese proceso formalizado: Planificación arma su propuesta, Comercial aporta su propia cifra y ambas se concilian por consenso en la reunión mensual. El diseño conserva esa reunión y agrega lo que el diagnóstico echó en falta: el registro y la medición de cada intervención sobre el número.

El plan del mes se construiría por etapas, cada una guardada como cifra completa por serie y mes, con versión, usuario, fecha y un motivo de una lista cerrada. Serían cinco: la referencia ingenua que calcula el motor, el pronóstico base del motor,

la propuesta de Planificación, la cifra o el ajuste de Comercial y el plan consensuado de la reunión, que quedaría como versión inmutable con su huella; un cambio posterior abriría otra versión con su motivo. Un ajuste nunca sobrescribiría el pronóstico base del motor: se guardaría a su lado como una etapa más. El contrato de cada etapa, con dos etapas opcionales, se detalla en la Tabla 38 del Anexo 15.

Hacia la plataforma, el microservicio publicaría por serie y mes la corrida, el modelo elegido, el valor y el tramo del horizonte con su evidencia: el primer mes, validado en el contraste del estudio; del segundo al duodécimo, medidos en la evaluación multihorizonte, con la miopía del error a un paso que las recomendaciones proponen corregir; y los posteriores, si la operación los pidiera, marcados como no validados. De vuelta, en la corrida siguiente leería el plan consensuado y la venta real, y calcularía para cada etapa la D valorizada, el sesgo móvil y el valor agregado al pronóstico (FVA, por su sigla en inglés): el error de la etapa anterior menos el de la etapa, positivo cuando la intervención mejora el número que recibió (Gilliland, 2010). La medida principal sería el error con un mes de anticipación, y los meses con quiebre o venta perdida se informarían aparte, porque en ellos la venta subestima la demanda. Como los ajustes por juicio mejoran o empeoran la precisión según su tamaño y su dirección (Fildes et al., 2009), así se mediría por primera vez en la empresa cuáles ajustes la mejoran y cuáles la empeoran.

El intercambio evolucionaría por etapas: en el piloto bastaría un archivo con huella por corrida, llevado a la reunión; desde la adopción como número base, el microservicio publicaría vistas versionadas y la API permitiría consultar y registrar ajustes. Ningún sistema escribiría en las tablas internas del otro, y cada número tendría un solo dueño y una sola versión vigente: el motor, del pronóstico base y de la medición del error; la plataforma, del plan consensuado y de las etapas que aportan las personas. Si la corrida no terminara a la fecha de la reunión, la plataforma recibiría la última corrida publicada, desplazada un mes y marcada, y la reunión nunca quedaría sin número.

4.2.5.4 Secuencia de la corrida mensual y ruta de falla

La corrida mensual seguiría nueve pasos. Primero, al cierre de ventas, el orquestador pediría la captura y registraría su huella; si ya existiera una corrida con la misma captura y configuración, la devolvería sin recalcular, y relanzarla no tendría efectos. Segundo, validaría el contrato de datos y los insumos declarados; si algo fallara, no publicaría nada y seguiría vigente la corrida anterior. Tercero, ejecutaría los módulos 1 a 4 con la partición operativa; los hiperparámetros, el conjunto de modelos candidatos y la asignación de modelo por serie se recalcularían una vez por gestión cerrada: la ventana de validación sería la última gestión cerrada anterior al origen, fija durante la gestión, y el criterio, el validado (MAE + |Bias| a un paso); el criterio multihorizonte de las recomendaciones quedaría como versión alternativa de la configuración.

Cuarto, el modelo global se reentrenaría con toda la historia cerrada y el número de árboles congelado, como en la evaluación multihorizonte; los métodos estadísticos proyectarían con sus parámetros vigentes; el precio, los quiebres y el tipo de cambio futuros tomarían su último valor conocido, el supuesto con que se evaluó el horizonte, que al congelar el tipo de cambio es una política declarada y no una protección; y la proyección iría del último mes cerrado al horizonte configurado, de doce meses por defecto. Quinto, escribiría pronósticos, selección y métricas y sellaría el manifiesto y el registro de flujo. Sexto, el monitor compararía el pronóstico del mes anterior, el plan consensuado y la venta real, y actualizaría el sesgo móvil. Séptimo, se publicaría. Octavo, en la reunión se registrarían los ajustes. Noveno, al mes siguiente su error quedaría medido. La evaluación multihorizonte, la explicación TreeSHAP y el contraste quedarían fuera del ciclo, como instrumentación del estudio (apartado 4.2.2).

4.2.5.5 Observabilidad del servicio

La observabilidad se organizaría en tres planos. El plano técnico respondería a si el servicio funciona: estado y duración de la corrida y de cada etapa, que el registro de flujo ya mide; series sin pronóstico o resueltas con respaldo, ninguna en el estudio; errores, latencia y disponibilidad de la API; y uso de procesador y memoria, que el manifiesto actual no registra. El plano de datos respondería a si la entrada es confiable: el contrato de carga como control obligatorio, cuyo incumplimiento impide publicar la

corrida; los duplicados, con la regla del apartado 4.2.3, que detiene solo las series afectadas; la cobertura de costo y de precio; la frescura del inventario y del tipo de cambio; la deriva del volumen y de la proporción de ceros por categoría; las transiciones de estado de las series; y los cambios del maestro de equivalencias.

El plano de modelo y negocio respondería a si el pronóstico sirve: la D por modelo a un paso sobre los últimos doce meses cerrados, como seguimiento mensual y no como ventana de selección, con la lectura por horizonte aparte; el sesgo valorizado móvil de tres meses del detector de régimen, medido en el estudio sobre la mezcla de la extensión y a recalcular sobre el motor; la tasa de acierto de la selección frente al azar; el reparto de la selección y su cambio entre corridas; la estabilidad de la proyección, como razón entre lo proyectado a doce meses y la venta de los últimos doce, marcada si supera 2 o baja de 0,5; y el error y el valor agregado de cada etapa del plan. Cada señal, con su fuente, línea base, umbral inicial y acción, se detalla en la Tabla 39 del Anexo 15.

Cuatro instrumentos cubrirían esos planos: registros estructurados con el identificador de la corrida en cada línea; métricas expuestas por la API en el formato de exposición de Prometheus, recolectadas por un servidor Prometheus o cualquier recolector compatible, con tableros en Grafana y alertas en Alertmanager, que se nombran como ejemplo de implementación y no como requisito, como el documento nombra React y Apache ECharts para el visor; el visor, como vista del planificador; y el tablero de la plataforma, como vista del negocio. El plano técnico viviría en el recolector; los planos de datos y de modelo, mensuales y auditables por corrida, en la tabla de métricas de la base, que el tablero leería directamente, y el monitor expondría además al recolector el sesgo persistente y la deriva, para que todas las alertas salieran por un solo camino. Para un proceso mensual la pila es una carga modesta, que justifican la API siempre encendida, la vigilancia de que la corrida termine en la fecha acordada y que los mismos instrumentos sirvan a otros servicios; su costo serían dos contenedores más, con su configuración versionada.

Las alertas serían pocas, cada una con su acción: corrida no terminada en la fecha acordada, contrato de datos roto, deriva de los datos y sesgo persistente,

definido como un sesgo móvil mayor que el 20 % en valor absoluto durante dos meses seguidos con el mismo signo. La rampa del detector, que se activa desde el 10 %, se mostraría en el tablero como señal informativa, sin alerta. Leída en retrospectiva sobre la Tabla 24, la regla del sesgo persistente habría activado la alerta en 7 de los 12 meses de la gestión de quiebre y en 1 de los 12 de la gestión normal; como se formuló después de conocer esas gestiones, su umbral es inicial y revisable. La deriva y el sesgo persistente dispararían la recalibración fuera de ciclo, nivel (iii) de la política del apartado 4.2.5.6, y el cambio del reparto de la selección entre corridas permitiría vigilar el efecto de cada recalibración.

4.2.5.6 Operación del ciclo de vida de los modelos (MLOps)

A la luz de los principios de Kreuzberger et al. (2023), el estudio ya incorpora algunas prácticas del ciclo de vida de los modelos: cada corrida se declara en una configuración con sus anulaciones registradas, parte de una captura con huella y deja un manifiesto y un registro de flujo. Además, las tres corridas del flujo principal selladas en la Tabla 48 del Anexo 18 (la publicada y las sensibilidades A y B) son deterministas, usan un código que cuenta con una suite de pruebas automatizadas y corrieron en una imagen de contenedor con versiones verificadas; las de la extensión exploratoria se ejecutaron fuera de ella, en un entorno con aceleración por hardware gráfico (apartado 4.3.3). La búsqueda de hiperparámetros, por su parte, se hizo fuera del flujo, con sus ensayos publicados. Con eso quedan cubiertos el versionado de datos, código y configuración y el registro de metadatos; la reproducibilidad lo está en esas tres corridas, condicionada al acceso autorizado a los insumos sellados y a la imagen conservada por el autor (nota de la Tabla 48). No queda cubierto el versionado del modelo entrenado: se guardan los parámetros de los métodos estadísticos, pero no el modelo global ajustado.

La operación agregaría lo que falta: un registro de modelos por corrida, con el modelo global ajustado; una integración continua que corriera la suite en cada cambio y construyera la imagen etiquetada con la versión del código, con el árbol de trabajo limpio y la imagen base fijada por su huella como condiciones para publicar; y el motor validado como campeón, con la combinación y la conmutación como retadoras en

sombra, promovidas solo después de una gestión cerrada. Aprobarían cada promoción la jefatura de Planificación, que ya participa de la reunión mensual, y el científico de datos del apartado 4.2.6.2; todo cambio de código o de configuración tendría la revisión de una segunda persona, y la documentación operativa completaría el manual de usuario pendiente (apartado 4.2.6.4). Las prácticas, con su evidencia y su dueño, se detallan en la Tabla 40 del Anexo 15.

La política de reentrenamiento tendría tres niveles. El primero (i), mensual y automático: en cada corrida el modelo global se reajustaría con toda la historia cerrada, con hiperparámetros y número de árboles congelados, y los métodos estadísticos avanzarían sus estados. El segundo (ii), la recalibración por gestión cerrada, programada y con una puerta (un criterio de aprobación que debe cumplirse antes de adoptar el cambio): búsqueda de hiperparámetros con el protocolo del estudio (pliegue interno, D interna, TPE con semilla fija y ensayos publicados, Tabla 28) y conjunto de candidatos y asignación por serie sobre la última gestión cerrada; una configuración nueva se adoptaría solo si redujera la D interna en más de un punto porcentual (seis de los 60 ensayos, incluido el elegido, quedaron a menos de un punto de la mejor D interna), sin perder estabilidad, tras una gestión en sombra frente al campeón, con aprobación de ambos roles y reversión al puntero anterior. El tercero (iii), la recalibración fuera de ciclo, que la deriva o el sesgo persistente adelantarían con la misma puerta. Entre recalibraciones quedarían fijos los hiperparámetros, el número de árboles, el conjunto de candidatos, la asignación por serie y los umbrales. La promoción nunca sería automática: una búsqueda mensual se movería dentro del ruido de la meseta y desarmaría la selección validada.

4.2.5.7 Requisitos no funcionales y despliegue

Los requisitos no funcionales se apoyan, donde es posible, en lo ya medido. Reproducibilidad: toda corrida se reconstruiría desde su captura con huella, su configuración inmutable, su manifiesto y una imagen de ejecución fijada por su huella. Determinismo: semillas fijas, un hilo por proceso y LightGBM en modo determinista, como en el estudio; repartir el cálculo en lotes exigiría antes una prueba automatizada de igualdad de resultados. Tiempo: de la carga a la selección por serie el núcleo tardó

49,2 s sobre la muestra, 27,8 s de ellos en construir las variables (Tabla 22). La proyección a doce meses desde un único origen no se midió aislada, porque el estudio solo proyectó desde orígenes rodantes; se mediría en el piloto, sobre la muestra y la población, antes de comprometer infraestructura. Escala: primero, calcular las variables solo para el mes nuevo en cada paso de la proyección, porque reconstruirlas en cada paso es su componente más costoso; después, repartir series entre procesos, con la prueba de igualdad.

Control de acceso por rol: el planificador consultaría y registraría ajustes, el científico de datos lanzaría corridas y versionaría la configuración, y la dirección consultaría. Versionado: cada fila de pronóstico llevaría su corrida y, con ella, la versión del modelo, de la configuración y del código. Pruebas: la suite existente, más las del contrato de la API, como compuerta de cada publicación. Observabilidad: la del apartado 4.2.5.5.

Despliegue: un único archivo de composición, como ya ocurre con el motor y el visor del estudio, declararía los contenedores de la API, del trabajador (worker) de la corrida, del visor y del recolector de métricas con su tablero. Correrían en un servidor interno de la empresa, a cargo del científico de datos y del soporte de TI del apartado 4.2.6.2. En la empresa, el esquema propio del motor viviría en su base relacional (apartado 4.2.5.2), y el archivo de composición de la operación no incluiría una base de datos; una base relacional en contenedor solo se usaría en el piloto o en una demostración del diseño, nunca como destino de la operación. La evolución no tocaría el núcleo: módulos opcionales en sombra y recalibraciones como versiones nuevas de la configuración (apartado 4.2.5.6).

La Figura 23 del Anexo 15 representa ese despliegue. Un servidor interno administrado por TI alojaría los contenedores de la API, del trabajador de la corrida, del visor y de la observabilidad, con un volumen para el almacén inmutable de corridas, y alcanzaría por la red interna, con cifrado en tránsito, el servidor de base de datos de la empresa, donde viven las vistas de contrato y el esquema propio del motor. Las personas accederían por navegador al visor y a la plataforma de planificación, nunca a la base. El respaldo seguiría la política de TI para la base de la empresa, que incluye

el esquema propio, y alcanzaría también al almacén de corridas; como cada corrida se reconstruiría desde su captura, su configuración y su imagen, la pérdida del servidor de aplicación no supondría la pérdida de ningún resultado publicado: bastaría con volver a desplegar el archivo de composición y restaurar el volumen de corridas desde el respaldo. El servidor no se dimensiona en este trabajo: el motor validado no requirió hardware especializado, porque su corrida completa se ejecutó en un equipo de gama corriente (apartado 4.2.6.4), y la capacidad se fijaría en el piloto con la proyección a doce meses sobre la población completa, que el estudio no midió aislada.

4.2.6 Recursos empleados y recursos previstos para la implementación

Este apartado distingue dos conjuntos de recursos que no coinciden. El primero son los que sustentaron el estudio, que comprenden los humanos y de información, los tecnológicos y los materiales. El segundo es la dotación humana que la empresa requeriría para llevar el motor a operación, que se presenta inmediatamente después de los recursos humanos del estudio para contrastar ambos planos.

4.2.6.1 Recursos humanos y de información empleados en el estudio

Los recursos humanos empleados en el estudio fueron el investigador, responsable del diseño, la construcción y la ejecución del motor; el informante clave IC-01, a quien se aplicó la entrevista semiestructurada; las personas del proceso de planificación y del área comercial que intervinieron en la sesión de observación estructurada del proceso vigente, registrada en el Anexo 3; y los dos jueces que validaron el contenido de los instrumentos. A ellos se sumaron el acceso a la captura del histórico de ventas, los registros auxiliares de costo unitario, quiebres de inventario y tipo de cambio, y la documentación interna sistematizada mediante la ficha de registro documental, todo ello en los términos declarados en el capítulo III.

4.2.6.2 Recursos humanos previstos para la implementación

Los recursos humanos que se enumeran a continuación no describen al equipo que ejecutó la investigación. Describen la dotación que la empresa requeriría para

poner el motor en operación y sostenerlo. Esa etapa queda excluida expresamente por la delimitación del estudio, que fija su alcance en el nivel propositivo. Su composición y su número constituyen una estimación de diseño, no un resultado medido.

- Científico de datos (1)
- Analistas de planificación (2)
- Jefes de producto (3)
- Soporte técnico en tecnologías de la información (1)

4.2.6.3 Recursos tecnológicos

- Lenguajes y entornos: Python 3.13.16 en la corrida principal reportada, con bibliotecas de código abierto de versión fijada en el repositorio y registradas por el manifiesto de cada corrida tal como fueron cargadas en tiempo de ejecución; la lista de versiones se reproduce en el Anexo 9. La extensión exploratoria emplea el entorno adicional declarado en el apartado 4.3.3.
- Herramientas de apoyo: control de versiones con Git y un visor analítico web local, construido con React y Apache ECharts, para la inspección de las salidas de cada corrida.
- Infraestructura: entorno de ejecución local reproducible, empaquetado en una imagen de contenedor que fija el intérprete y las versiones de las bibliotecas, con semillas declaradas (Anexo 9) y LightGBM en modo determinista y de un solo hilo; el manifiesto de cada corrida sella los datos, la configuración y la versión del código (Anexo 7); el diseño admite su despliegue posterior en servidores de la empresa o en la nube. El apartado 4.2.5.7 especifica ese despliegue como microservicio en contenedores, con sus requisitos no funcionales.

4.2.6.4 Recursos materiales y documentación técnica

- Equipo de cómputo de gama corriente, sin infraestructura especializada: la corrida completa del protocolo principal sobre las 1.668 series de la muestra se

ejecutó en menos de 40 minutos. Esa corrida transcurrió dentro de un contenedor y con las bibliotecas numéricas fijadas a un solo hilo por determinismo. El manifiesto de la corrida registra la plataforma de ejecución y, como el registro de flujo, LightGBM en modo determinista y de un solo hilo; el hilo único de las demás bibliotecas numéricas lo fija el Dockerfile del repositorio (Anexo 7). Más del 90 % de ese tiempo correspondió a la evaluación multihorizonte del apartado 4.3. Esa evaluación es instrumentación de medición del estudio y no un componente de la corrida mensual que la empresa ejecutaría. El ajuste de los modelos y la selección por serie suman 17,7 segundos (Anexo 9).

- Acceso a la base histórica de ventas: una captura congelada de 204.096 filas que cubre de abril de 2017 a marzo de 2026. La huella SHA-256 de esa captura queda registrada en el manifiesto de trazabilidad de cada corrida. De ese modo, cada cifra que el documento obtiene de las corridas puede verificarse contra el insumo con el que se obtuvo. A él se suman los tres registros auxiliares descritos en las fuentes de información (apartado 2.6.4): el costo unitario del maestro de productos, el registro de quiebres de inventario y la serie mensual del tipo de cambio. Estos dos últimos registros tienen cobertura de abril de 2022 a marzo de 2026. El acceso a esa captura y a los registros auxiliares lo respalda la constancia de la empresa (fila 5 de la Tabla 47 del Anexo 18); el acuerdo de confidencialidad (Anexo 2) rige la reserva y el uso académico de la información desde su firma. Como los códigos de producto, que se reemplazaron por identificadores estables al extraer, las categorías se seudonimizan al cargar la captura: una tabla de correspondencia local, fuera del repositorio y sellada por el manifiesto de cada corrida, las reemplaza por letras, de modo que la captura y su huella no cambian. La observancia del acuerdo está automatizada: el directorio del dato crudo queda excluido del control de versiones. Además, seis pruebas automatizadas verifican que ni los datos, ni las salidas, ni identificadores internos lleguen a los archivos versionados.

- Documentación técnica del motor, que es producto del trabajo y no insumo del estudio: un archivo con las instrucciones de instalación y ejecución del flujo y del visor. Incluye también una especificación técnica que numera 10 requerimientos funcionales y seis requerimientos no negociables de la construcción del motor. Un manual de usuario dirigido al planificador queda como entregable pendiente, ligado a la implementación operativa que la delimitación de la investigación excluye.

4.3 Constatación y validación de la propuesta de solución

La validación de la propuesta se realizó con el propósito de verificar la coherencia metodológica, técnica y práctica del diseño del motor automatizado de pronóstico de demanda.

Esta validación se estructuró en tres niveles complementarios:

- Validación metodológica, que evalúa la correspondencia entre el diseño del sistema y el enfoque de investigación.
- Validación técnica, que examina el desempeño del motor en la generación de pronósticos.
- Valoración económica, que estima el impacto operativo y financiero potencial de la implementación.

A estos tres niveles se suma, entre la validación técnica y la valoración económica, la extensión exploratoria del apartado 4.3.3, que informa la evolución del sistema sin modificar la validación precedente.

4.3.1 Validación metodológica

La validación metodológica tuvo como finalidad demostrar que el diseño y desarrollo del motor automatizado de pronóstico de demanda mantienen coherencia interna con los elementos planteados en el marco metodológico de la investigación. La demostración se planteó en términos de tipo de estudio, enfoque, diseño no experimental longitudinal retrospectivo.

En primer lugar, la propuesta responde al tipo de investigación propositivo, de carácter aplicado, dado que busca ofrecer una solución tecnológica viable para un problema real de planificación empresarial, sin requerir su implementación operativa inmediata. El motor propuesto se fundamenta en un análisis cuantitativo de datos históricos, en consonancia con el componente cuantitativo dominante del enfoque mixto definido en el diseño metodológico.

Asimismo, el desarrollo del sistema siguió el diseño no experimental, longitudinal y retrospectivo declarado. Ese diseño se materializó en un backtesting temporal. Los distintos métodos de pronóstico se compararon bajo condiciones idénticas: los mismos datos de entrada, la misma partición cronológica y las mismas métricas. La comparación se hizo sin manipulación de las condiciones reales de la empresa. Este procedimiento permitió contrastar el desempeño del motor con el de los diez modelos candidatos. Permitió así observar la relación entre la variable independiente (el motor de pronóstico automatizado) y la variable dependiente (la precisión del pronóstico). Esa observación recayó sobre fenómenos ya ocurridos, sin manipular ninguna de las dos. Las diferencias observadas se contrastaron con intervalos que respetan la dependencia entre series y, como complemento, con pruebas estadísticas por serie (apartado 4.3.2).

La coherencia metodológica se evidencia en los aspectos desarrollados en los párrafos precedentes; su resumen tabulado, elemento por elemento, se reproduce en la Tabla 29 del Anexo 13.

De esta manera, se confirma que la propuesta responde al problema identificado en el diagnóstico y mantiene consistencia con el marco metodológico y con los criterios de validez interna establecidos en la investigación. También se confirma que permite contrastar empíricamente la relación entre las variables planteadas dentro de los límites declarados en la introducción. Esos límites circunscriben los resultados al portafolio y a los canales de NOVAPACK S.A.

4.3.2 Validación técnica

La validación técnica tuvo como objetivo comprobar el desempeño cuantitativo y funcional del motor automatizado de pronóstico de demanda, verificando su capacidad para mejorar la precisión de las proyecciones frente a los métodos tradicionales utilizados por NOVAPACK S.A.

Para ello se emplearon los datos históricos descritos en el diseño metodológico (abril de 2017 a marzo de 2026), con la partición por gestiones allí definida. Los modelos se ajustaron con el bloque de entrenamiento. El motor realizó su selección por serie sobre el bloque de validación (gestión 2025). Esa ventana de validación cumplió, además, una segunda función: sobre ella LightGBM fijó, por parada temprana, el número de árboles de su modelo global (76 iteraciones). Ningún otro candidato la utilizó durante su ajuste. La calibración de hiperparámetros se había resuelto antes sobre un pliegue interno del propio bloque de entrenamiento. De ese modo, la asimetría de protocolo que ello introduce queda declarada de forma explícita. Todos los resultados que siguen corresponden al bloque de prueba (gestión 2026), que no intervino ni en el ajuste de los modelos ni en la selección por serie del motor. Sobre esta base se evaluaron los once brazos de pronóstico:

- Los modelos de referencia: el ingenuo (Naïve) y los promedios móviles de 2 y 12 meses, en versión simple y con el factor de crecimiento que replica la fórmula de planificación de la empresa, sin los ajustes de consenso del plan final (la réplica de la fórmula base sin ajustes de consenso).
- Los modelos de suavizado y de demanda intermitente: el suavizado exponencial simple optimizado, Holt-Winters y Croston.
- El modelo LightGBM y, sobre todos los anteriores, el motor de selección automática, objeto de la propuesta.

El desempeño se evaluó con las métricas por serie definidas en la operacionalización de variables, que suman el sesgo a las medidas de error absoluto, cuadrático y porcentual de uso general (Hyndman & Koehler, 2006), y, para la comparación agregada entre modelos, con la métrica valorizada D = WMAPE + |Bias|, que pondera el error de cada serie por el costo unitario del producto. Las 1.513 series con costo unitario asignado son el 90,7 % de las 1.668 series de la muestra y, en el

bloque de prueba, reúnen el 98,6 % de las unidades demandadas y el 93,9 % de su valor a precio de venta; la cobertura se expresa aquí a precio porque las 155 series sin ficha de costo vigente carecen, por definición, de demanda valorizada a costo con la cual compararse. Las métricas por serie son las siguientes:

- **MAE (Mean Absolute Error):** mide el error promedio absoluto entre los valores reales y los pronosticados.
- **MAPE (Mean Absolute Percentage Error): expresa el error promedio en términos porcentuales. Se reporta por comparabilidad con la literatura, no como criterio de decisión, ya que queda indefinido en los meses de demanda cero. En el bloque de prueba, esos meses representaron en promedio el 25,7 % de los meses evaluados de cada una de las 1.668 series de la muestra y quedaron fuera de su cálculo.**
- **RMSE (Root Mean Squared Error)**: penaliza con mayor severidad los errores de gran magnitud, complementando la lectura del MAE; se calcula por serie y se agrega sobre los valores obtenidos por combinación.
- **Bias (sesgo promedio):** indica la tendencia sistemática a sobrestimar o subestimar la demanda.

Los resultados obtenidos se resumen en la Tabla 8. Las métricas por serie de la tabla (MAE, MAPE y RMSE) se reportan como mediana y no como promedio; en el MAE y el RMSE, que dependen de la escala, promediar entre productos de volúmenes muy distintos dejaría que los de mayor rotación dominen la comparación. El MAPE mediano por serie se sitúa entre 100,0 % y 121,7 % según el modelo; una razón es que 688 de las 1.668 series de la muestra son de demanda irregular, 642 de régimen esporádico y 46 de régimen intermitente, y en esas series los meses de venta muy baja inflan el cociente porcentual. Esa limitación conocida de la métrica se suma a su indefinición en los meses de demanda cero, ya señalada al definirla, como razón para tomar la decisión sobre el WMAPE valorizado y no sobre el MAPE.

Tabla 8

Comparación de desempeño de modelos de pronóstico

Modelo	WMAPE valorizado (%)	Bias valorizado (%)	D = WMAPE + |Bias| (%)	MAE mediano por serie (unid.)	MAPE mediano por serie (%)	RMSE mediano por serie (unid.)
Motor de selección automática	70,1	−5,3	75,4	11,5	100,0	16,5
LightGBM	62,9	−14,1	77,0	11,9	102,6	16,0
Suavizado exponencial simple	77,6	−1,9	79,5	14,0	106,2	18,6
Holt-Winters	77,8	+5,7	83,5	13,8	104,7	18,6
Promedio móvil 2 meses	79,6	−5,4	84,9	13,6	104,3	19,1
Promedio móvil 12 meses	80,9	−4,5	85,4	13,7	100,1	17,9
Ingenuo (Naïve)	81,9	−3,6	85,6	13,8	105,2	20,4
Croston	84,1	+2,0	86,1	16,1	121,7	19,8
Ingenuo con factor de crecimiento	88,9	−7,5	96,4	15,3	113,3	22,1
Prom. móvil 2 m con factor de crecimiento	87,5	−10,6	98,0	15,1	108,2	21,0
Prom. móvil 12 m con factor de crecimiento	83,8	−16,1	100,0	13,8	100,0	19,3

Nota. Métricas valorizadas calculadas sobre las 1.513 series con costo unitario asignado. MAE, MAPE y RMSE medianos sobre las 1.668 series de la muestra. Evaluación a un paso en la gestión 2026. La D se calcula con los valores sin redondear, por lo que puede diferir en una décima de la suma del WMAPE y del valor

absoluto del Bias impresos. El promedio móvil de 12 meses con factor de crecimiento es la réplica de la fórmula base sin ajustes de consenso, el comparador del estudio (apartado 2.7). Elaboración propia a partir de las salidas del motor.

Los resultados evidencian que el motor de selección automática alcanza el menor error compuesto valorizado del portafolio (D = 75,4 %), seguido por LightGBM (77,0 %) y por el suavizado exponencial simple (79,5 %). Los métodos de referencia quedan por detrás: el promedio móvil de 12 meses obtiene una D de 85,4 % en su versión simple y de 100,0 % con el factor de crecimiento (la réplica de la fórmula base sin ajustes de consenso), y el modelo ingenuo alcanza 85,6 %. La magnitud de estas cifras es la esperable en el nivel de desagregación evaluado: en el pronóstico por SKU la demanda a menudo es intermitente, con períodos de demanda baja o nula en que las medidas porcentuales de error se vuelven inadecuadas o inaplicables (Kolassa, 2016; Syntetos & Boylan, 2005), y la competencia M5 mostró que la precisión mejora sistemáticamente con la agregación y que, en el nivel de ítem, las mejoras frente a las referencias simples se estrechan (Makridakis et al., 2022). Los valores de referencia disponibles confirman esa escala: en el pronóstico mensual por SKU de un fabricante de bienes de consumo, el pronóstico estadístico registró un MAPE en torno al 48 % (Davydenko & Fildes, 2013); el WMAPE de 70,1 % del motor, medido en un nivel aún más desagregado (SKU, canal y regional), es coherente con esa escala. Por ello, la lectura relevante es la comparación relativa entre métodos sobre las mismas series (Hyndman & Koehler, 2006), y en esa lectura el motor mejora entre 21,0 y 24,6 puntos porcentuales a la réplica de la fórmula base sin ajustes de consenso en sus tres variantes de nivel base con factor de crecimiento (96,4 %, 98,0 % y 100,0 %), 24,6 de ellos frente al promedio móvil de 12 meses con factor, que este trabajo toma como representante de esa práctica. El apartado siguiente contrasta la diferencia frente a ese representante y las diferencias frente al promedio móvil simple y al modelo ingenuo.

La descomposición de la D explica por qué la propuesta es el motor y no un modelo único. LightGBM logra el mejor WMAPE del estudio (62,9 %), pero con un sesgo de subestimación de −14,1 %. El motor, en cambio, combina un WMAPE de 70,1 % con un sesgo de −5,3 %. Lo que el motor minimiza al seleccionar el modelo de

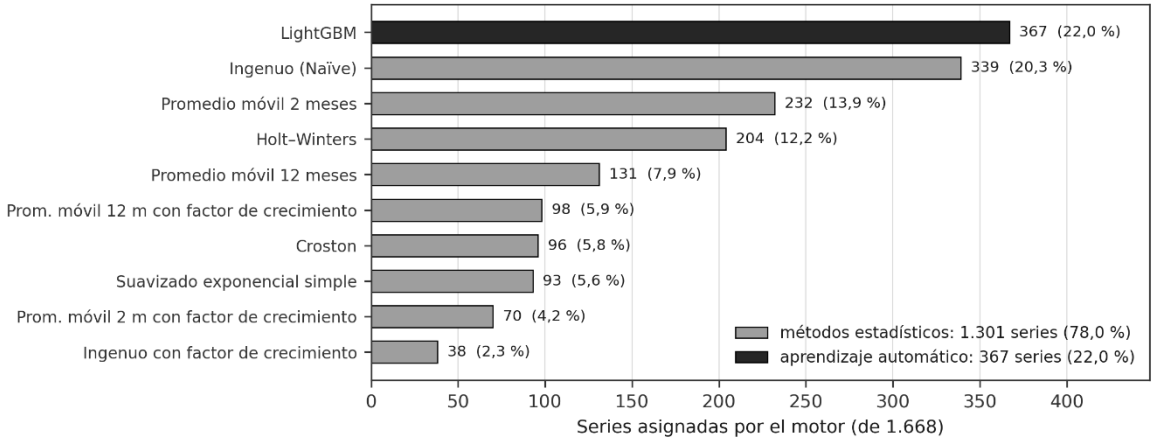
cada serie es la suma de magnitud y sesgo en unidades, serie por serie (ecuación 1), y no cada término por separado: el brazo de menor sesgo absoluto de la Tabla 8, el suavizado exponencial simple, cierra con un sesgo de −1,9 %, pero con un WMAPE de 77,6 %, que lo deja en una D de 79,5 %. Esa suma, a su vez, no es la D del portafolio (ecuación 2), que pondera cada serie por su valor y deja que los sesgos de signo opuesto se compensen entre series. La ventaja del motor sobre LightGBM sí depende del peso relativo del sesgo: con una métrica D(w) = WMAPE + w × |Bias| y la composición del motor fija en la de la corrida, el motor aventaja al modelo global para w mayor que 0,82 y queda por detrás de él para valores menores; ante la ausencia de costos de faltante y de exceso sistematizados, el estudio adopta w = 1 y declara esa dependencia. El MAE mediano por serie confirma la lectura de la descomposición: 11,5 unidades para el motor y 11,9 para LightGBM, frente a valores de 13,6 a 16,1 en los métodos estadísticos. El RMSE mediano por serie, que penaliza con mayor severidad los errores de gran magnitud, vuelve a separar del resto a los dos brazos propuestos, aunque intercambia sus posiciones (16,0 unidades para LightGBM y 16,5 para el motor, frente a 17,9 a 22,1 en los nueve métodos estadísticos restantes), de modo que la ventaja de los dos brazos propuestos no depende de la métrica de error elegida. La pérdida Tweedie, elegida para contener la subestimación, no la eliminó: el sesgo residual del modelo global se concentra en las series de mayor valor, y el calendario comercial de la extensión exploratoria lo recorta a −10,7 %.

La descomposición gráfica del error compuesto valorizado por modelo, que separa en cada barra el WMAPE del valor absoluto del Bias, se reproduce en el Anexo 13 (Figura 20).

El carácter híbrido del motor se constata en el reparto de su selección (Figura 9): de las 1.668 series de la muestra, 1.301 (el 78,0 %) quedaron asignadas a un método estadístico y 367 (el 22,0 %) al modelo de aprendizaje automático. Ningún brazo domina el portafolio: el modelo ingenuo encabeza los métodos estadísticos con 339 series, seguido por el promedio móvil de 2 meses (232) y Holt-Winters (204), y aun el brazo menos elegido conserva 38 series. Este reparto es compatible con el fundamento del diseño, según el cual en un portafolio heterogéneo el mejor modelo es distinto en cada serie, y esa es la razón por la que la propuesta es un motor de

selección y no un modelo único. La evidencia directa de esa heterogeneidad es la lectura por estratos de la Tabla 9, donde el método estadístico de menor D cambia de un estrato a otro; el reparto incorpora además el ruido de selección, cuantificado por la tasa de acierto que se reporta en el contraste estadístico.

Figura 9
Reparto de la selección del motor por modelo (1.668 series de la muestra)



Nota. Series asignadas por el motor a cada modelo según el registro de flujo de la corrida, con la regla de selección aplicada sobre el bloque de validación. La barra oscura es el único brazo de aprendizaje automático; las claras, los métodos estadísticos. Elaboración propia a partir de las salidas del motor.

Adicionalmente, la dispersión por serie, cuya nube completa se reproduce en el Anexo 13 (Figura 21), muestra el desempeño de los once brazos combinación por combinación. El motor y LightGBM presentan las medianas de MAE más bajas, 11,5 y 11,9 unidades, con sesgos medianos contenidos, de −3,4 % y +1,3 %. En cambio, las tres variantes con factor de crecimiento desplazan sistemáticamente su nube hacia la subestimación, con sesgos medianos de entre −11,2 % y −13,9 %, frente al rango de −3,6 % a +1,4 % de sus contrapartes sin ese factor. Ese desplazamiento anticipa la degradación de esas variantes en horizontes largos. Estas medianas se calculan serie por serie sobre las 1.668 de la muestra (el MAE en unidades y el sesgo en porcentaje de la demanda de cada serie), sin ponderar por valor; el error compuesto con que el motor selecciona y con que se contrasta la hipótesis usa, en cambio, el sesgo en unidades. Por eso no coinciden con los sesgos valorizados de la Tabla 8, que ponderan

cada serie por su peso en el valor. Es decir, el −14,1 % de LightGBM proviene de las series de mayor valor y no de la serie típica.

4.3.2.1 Contraste estadístico de la hipótesis

Para verificar formalmente la hipótesis de investigación, la comparación descriptiva se complementó con un contraste estadístico sobre el error compuesto (MAE + |Bias|) por serie en el bloque de prueba, bajo el esquema de partición temporal descrito en el diseño metodológico. Dado que todos los modelos se evaluaron sobre las mismas 1.668 series, los errores constituyen muestras pareadas. Siguiendo a Demšar (2006), se emplearon la prueba de Wilcoxon de rangos con signo para las comparaciones por pares y la de Friedman con post hoc de Nemenyi para la comparación simultánea de los once modelos. Como las series de un mismo SKU y las que comparten un mes no son independientes, la evidencia principal del contraste son los intervalos con incertidumbre agrupada de la Tabla 20 del Anexo 8, que se presentan a continuación de las hipótesis; las pruebas por serie se informan después como evidencia complementaria. Las hipótesis estadísticas se formularon de la siguiente manera:

- H0: no existen diferencias significativas en el error de pronóstico de las ventas mensuales observadas, por serie, entre el motor de selección automática y los métodos de referencia (promedio móvil de 12 meses, con y sin factor de crecimiento, y modelo ingenuo).
- H1: el motor de selección automática presenta un error de pronóstico de las ventas mensuales observadas, por serie, significativamente menor que el de los métodos de referencia.

Los intervalos que respetan la dependencia entre series son la evidencia principal del contraste; las pruebas por serie que se informan después son complementarias. La dependencia entre las series de un mismo SKU, y entre las que comparten un mismo mes, se midió de forma directa con dos remuestreos que la respetan, sobre las mismas salidas publicadas y sin volver a ajustar ningún modelo (Tabla 20 del Anexo 8): por conglomerados, sorteando SKU completos con todas sus

series (369 SKU que agrupan las 1.668 series), y por bloques móviles de tres meses del bloque de prueba, de modo que un mes atípico afecte a todas las series a la vez. Con 2.000 réplicas por remuestreo e intervalos percentiles al 95 %, una diferencia se sostiene con incertidumbre agrupada por SKU cuando su intervalo por conglomerados excluye el cero, y se lee como evidencia descriptiva del conjunto evaluado cuando no lo excluye. Frente a la réplica de la fórmula base sin ajustes de consenso, la diferencia se sostiene con incertidumbre agrupada por SKU en las tres magnitudes: la diferencia media por serie es de −42,52 unidades (intervalo de −65,58 a −24,01), la mediana, de −2,02 unidades (de −2,54 a −1,60), y la de la D del portafolio, de −24,6 puntos (de −32,0 a −17,0). Los tres intervalos excluyen también el cero al remuestrear meses. Frente al promedio móvil de 12 meses también se sostiene por SKU en las tres magnitudes (media de −32,77 unidades, de −49,01 a −19,11; mediana de −0,38 unidades, de −0,56 a −0,20; D de −10,0 puntos, de −14,0 a −6,1). Al remuestrear meses, excluyen el cero los intervalos de la media y de la D, mientras que el de la mediana llega al cero (de −1,24 a 0,00). Frente al modelo ingenuo, en cambio, la diferencia por serie es evidencia descriptiva del conjunto evaluado en los dos esquemas de remuestreo: la mediana es nula, con intervalo de 0,00 a 0,00 en ambos, y el de la diferencia media contiene el cero tanto por SKU (de −9,34 a 0,99 unidades) como al remuestrear meses (de −44,87 a 9,55). Solo la menor D del motor (−10,2 puntos) se sostiene por SKU (de −14,7 a −5,4), pero no al remuestrear meses (de −32,1 a 0,9). La ventaja de LightGBM sobre el promedio móvil de 12 meses se sostiene en la diferencia media en los dos esquemas y en la D solo por SKU, pero no en la mediana, cuyo intervalo contiene el cero en ambos (de −0,40 a 0,24 unidades por SKU). Frente al ingenuo, ninguna diferencia por serie de LightGBM excluye el cero a su favor: el intervalo de la media lo contiene en los dos esquemas y el de la mediana lo excluye en su contra por SKU (0,36 unidades, de 0,02 a 0,71) y lo contiene por bloques. La menor D de LightGBM (−8,6 puntos) se sostiene por SKU (de −13,7 a −3,3), pero no al remuestrear meses. Las pruebas de Friedman y de Nemenyi tratan también las series como independientes, por lo que el ordenamiento de los once modelos se lee como descriptivo.

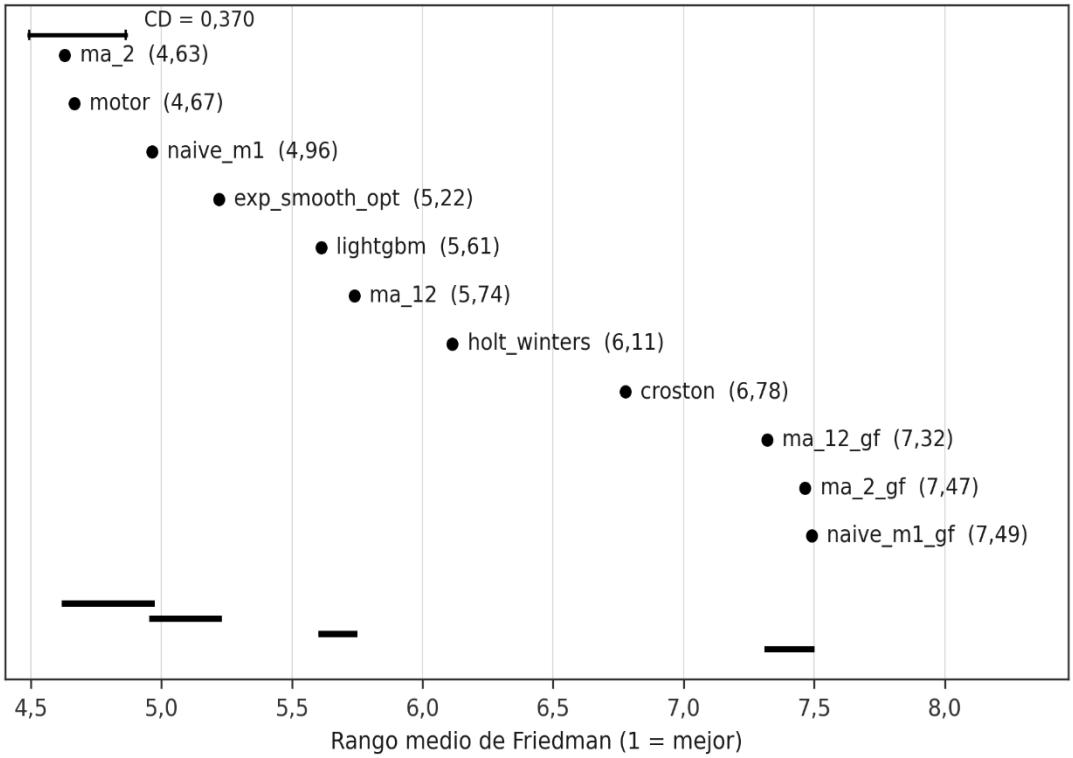
La normalidad de las diferencias pareadas se examinó con la prueba de Shapiro-Wilk en las cinco comparaciones pareadas del contraste. En las cinco se rechaza, con W entre 0,16 y 0,22 y p inferior a 1×10^{-16} sobre las 1.668 diferencias por serie del bloque de prueba; el detalle por par se reproduce en la Tabla 18 del Anexo 8. El rechazo es esperable en distribuciones de errores de pronóstico, con asimetría marcada y valores extremos; ello ratifica la elección adoptada a priori de pruebas no paramétricas. El contraste de Wilcoxon se aplicó en su variante unilateral con un nivel de significancia de $\alpha = 0,05$, convención del área para el control del error de tipo I. La variante unilateral se deriva de la direccionalidad de la hipótesis de investigación, formulada antes de observar los resultados: el motor reduce el error frente a los métodos de referencia. No se aplicó una corrección por multiplicidad a los contrastes de Wilcoxon. Sus valores p son evidencia complementaria, y ajustar el umbral no corregiría la dependencia entre series, que es la razón por la que esos valores subestiman la incertidumbre. De esa dependencia dan cuenta los intervalos agrupados ya presentados, cada uno con un nivel individual del 95 %.

Los resultados del contraste fueron los siguientes. Frente al promedio móvil de 12 meses, el motor obtiene un error menor en el 57,1 % de las series: 952 de 1.668, contra 559 a favor del promedio móvil. Ese resultado se acompaña de $W = 358.368,0$, $Z = -12,54$, $p < 0,001$ y un tamaño del efecto $r = -0,31$, de magnitud mediana. Frente a la variante con factor de crecimiento, réplica de la fórmula base sin ajustes de consenso, el motor obtiene un error menor en el 68,7 % de las series (1.146 de 1.668, contra 346), con $Z = -21,68$, $p < 0,001$ y un tamaño del efecto grande ($r = -0,53$). Frente al modelo ingenuo, el valor p por serie también queda por debajo del umbral ($Z = -3,54$; $p = 2,04 \times 10^{-4}$), pero el tamaño del efecto es insignificante ($r = -0,09$), el reparto es mucho más ajustado que el anterior y, como muestran los intervalos agrupados ya presentados, la diferencia por serie no se sostiene en ninguno de los dos esquemas de agrupación: es evidencia descriptiva del conjunto evaluado. Una cuarta parte de las series empata exactamente y, descontados los empates, la proporción a favor del motor es del 56,1 %; el reparto completo de series ganadas, perdidas y empatadas se reproduce en el Anexo 8. Además, la mediana de la diferencia de error compuesto en unidades es de 0,0000, es decir que la serie central

del reparto no separa a ambos métodos, lectura coherente con la cercanía de ambos en la Tabla 8. El mismo contraste se aplicó al brazo de aprendizaje automático por separado, es decir, la comparación “tradicional frente a LightGBM” en sentido estricto. Ese contraste muestra su ventaja sobre el promedio móvil de 12 meses, con un tamaño del efecto insignificante (menor error en el 50,8 % de las series; $p = 6{,}9 \times 10^{-5}$; $r = -0{,}09$), aunque los intervalos agrupados no la sostienen en la diferencia mediana por serie bajo ninguno de los dos esquemas. Sobre el modelo ingenuo, en cambio, ese contraste no la confirma ($p = 0{,}9998$). Este resultado, lejos de debilitar la propuesta, precisa su alcance: lo que aventaja al promedio móvil de 12 meses también en la diferencia mediana por serie, con agrupación por SKU, no es LightGBM aislado, sino el motor que selecciona para cada serie el modelo más adecuado. La prueba ómnibus de Friedman rechaza la igualdad de los once modelos ($\chi^2 = 1.897{,}3$; $k = 11$; $N = 1.668$; $p < 0{,}001$). El post hoc de Nemenyi ubica al motor en el grupo de mejor rango, del que también participan el promedio móvil de 2 meses y el modelo ingenuo; los rangos medios, sus distancias y sus valores p se reproducen en la Tabla 19 del Anexo 8. Ese post hoc compara en simultáneo los rangos medios de los once modelos y no la diferencia pareada de dos, de lectura por ello más conservadora que la del contraste pareado ya reportado. El primer modelo del que el motor sí se distingue es el suavizado exponencial simple (Figura 10). Todos estos valores se calculan sobre la matriz de error por serie que la corrida publica como archivo, y el script del Anexo 8 los reproduce íntegramente a partir de ella.

Figura 10

Diagrama de diferencia crítica del post hoc de Nemenyi sobre los rangos de Friedman



Nota. α = 0,05; 1.668 series y 11 modelos. Los modelos unidos por una barra horizontal no son distinguibles entre sí; la regla superior muestra la longitud de la diferencia crítica (CD). Los rótulos son los identificadores de los brazos en el repositorio (Tabla 26 del Anexo 12): naive_m1, ingenuo; ma_2 y ma_12, promedios móviles de 2 y 12 meses; exp_smooth_opt, suavizado exponencial simple; holt_winters, Holt-Winters; croston, Croston; lightgbm, LightGBM; el sufijo _gf marca la variante con factor de crecimiento. Elaboración propia a partir de las salidas del motor.

Al obtenerse valores p inferiores al nivel de significancia adoptado, se rechaza la hipótesis nula del contraste por serie: la reducción del error alcanzada por el motor frente a los métodos de referencia es significativa cuando cada serie se trata como una observación independiente. Las series, sin embargo, no son observaciones independientes: las de un mismo SKU en distintas regionales y canales comparten producto y campaña, y todas se evalúan sobre los mismos meses del bloque de prueba. Al tratarlas como independientes, las pruebas por serie sobrestiman la evidencia y, con 1.668 series, alcanzan valores p pequeños aun con un tamaño del

efecto insignificante: frente al modelo ingenuo, con $p = 2{,}04 \times 10^{-4}$ y $r = -0{,}09$, la diferencia por serie no se sostiene con incertidumbre agrupada en ninguno de los dos esquemas. Por eso la lectura sustantiva se apoya en los intervalos agrupados ya presentados y, en segundo término, en el tamaño del efecto, grande frente a la réplica de la fórmula base sin ajustes de consenso, mediano frente al promedio móvil simple e insignificante frente al ingenuo a un paso. Esa lectura se complementa con la tasa de acierto de la selección: el modelo elegido en validación resultó ser efectivamente el mejor en prueba en el 20,8 % de las series, el doble del 10 % esperable al azar. El contraste, unilateral y sobre un único corte temporal, no se extrapola a horizontes mayores; esa dimensión se examina en el apartado siguiente.

La cohorte evaluada se sometió, además, a un análisis de sensibilidad (Tabla 25 del Anexo 11). La cascada de inclusión exige venta en el bloque de prueba y acota cada serie entre su primera y su última venta, dos condiciones que usan información posterior al origen de la prueba. Por eso la corrida completa se repitió con dos cohortes alternativas, con el mismo código y la misma configuración salvo esas reglas. La variante A no exige presencia en la prueba y extiende la vida de cada serie con ceros hasta marzo de 2026: reúne las series que superan los cinco primeros criterios de la cascada, es decir, las 1.668 publicadas y las 144 que excluía el requisito de venta en la prueba. La A es, sin embargo, una sensibilidad retrospectiva y no una cohorte seleccionada enteramente al origen, porque su paso de presencia en validación se sigue midiendo sobre la vida observada de cada serie, de su primera a su última venta en todo el período, incluida la prueba. La variante B, la sensibilidad más estricta, conserva de ella solo las series activas al origen, según la regla de estado del apartado 4.2.3 y del Anexo 14 (activa: venta en los seis meses previos; dormida: seis a once meses sin venta; descontinuada: doce o más), medida al cierre de validación sobre la actividad observada. Dentro de la población objetivo, la composición de la B no depende de ventas posteriores a ese cierre, porque toda serie activa al origen tiene venta en el bloque de validación. La A reúne 1.812 series, 1.657 con costo y el 96,18 % del valor de entrenamiento; la B, 1.661 series, 1.506 con costo y el 91,66 %, frente a las 1.668 series, 1.513 con costo y el 95,04 % de la cohorte publicada. Con la vida extendida, los pasos de historial, de proporción de ceros y de volumen se calculan

sobre otro número de meses, y la cascada de la A pasa por 3.291, 1.980 y 1.964 series en ellos, frente a 2.774, 1.978 y 1.963 en la publicada, aunque termina en el mismo conjunto que esta deja tras el paso de presencia en validación.

Frente a los demás modelos de su misma cohorte, el motor conserva la menor D de los once: 75,1 % en la A y 74,5 % en la B, frente a 100,0 % y 98,8 % de la réplica de la fórmula base sin ajustes de consenso, 85,4 % y 84,3 % del promedio móvil de 12 meses, 85,6 % y 85,2 % del ingenuo y 77,1 % y 75,6 % de LightGBM; su distancia a esa réplica pasa de −24,6 puntos en la cohorte publicada a −24,9 en la A y a −24,3 en la B. El script que arma la Tabla 25 verifica el hash de cada insumo contra el manifiesto de su corrida y se detiene si la D reconstruida no reproduce la de cada corrida.

Que la D de varias referencias no se mueva en la A tiene una razón mecánica. En un mes sin venta todo lo pronosticado es error; si el pronóstico de un modelo no cambia y el modelo sigue subestimando en el agregado, ese error suma al WMAPE lo mismo que resta al valor absoluto del sesgo. En las tres corridas, los nueve modelos estadísticos pronostican exactamente lo mismo en los meses que evalúa la corrida publicada, y por eso la D de la réplica de la fórmula base sin ajustes de consenso, del promedio móvil de 12 meses y del ingenuo, entre otras, es idéntica en la cohorte publicada y en la A. En los modelos con sesgo positivo, en cambio, ese error se suma dos veces, al WMAPE y al valor absoluto del sesgo, porque sostienen un nivel positivo después de la última venta: Holt-Winters pasa de 83,5 % a 92,5 % y Croston, de 86,1 % a 93,8 %; el suavizado exponencial simple, cuyo sesgo pasa de −1,9 % a +0,6 %, sube de 79,5 % a 80,7 %. En el motor, el WMAPE sube de 70,1 % a 71,8 % y el sesgo pasa de −5,3 % a −3,2 %, sin que los meses en cero muevan su D: restringida a los meses que evalúa la corrida publicada, su D en la A es la misma, 75,1 %. Su leve baja proviene de que la corrida A vuelve a entrenar el modelo global sobre su propia cohorte, con lo que cambian los pronósticos de LightGBM y la elección del motor en 108 de las 1.668 series. En la B, que también reentrena el modelo global, la elección cambia en 147 de las 1.565 series que comparte con la cohorte publicada.

Las 144 series sin venta en la prueba explican poco de la subida del WMAPE: pesan el 1,14 % del valor de entrenamiento y su error agrega 0,05 puntos al motor y

0,02 a la réplica de la fórmula base sin ajustes de consenso; el resto proviene de los meses posteriores a la última venta de las 1.668 series, que la A evalúa y la corrida publicada no (20.016 meses-serie frente a 18.502). De esas 144, 96 estaban activas al origen y 48 dormidas; 141 tienen medición de existencias en el bloque de prueba, 131 registran al menos un mes con semanas de existencia en cero en la prueba y 117 tienen existencia en cero en todas sus semanas medidas (cruce por SKU y regional con el registro de quiebres), de modo que la captura no permite separar la descontinuación de la falta de disponibilidad. Hay, además, 35 series descontinuadas al origen, sin venta en todo el bloque de validación, que la cohorte publicada y la A contienen solo porque vuelven a vender en la prueba: su vida observada, de la primera a la última venta, alcanza los dos bloques y les permite superar el paso de presencia en validación. En ese paso, la A excluye a las descontinuadas al origen que llegan a él sin volver a vender. Sin esas 35, en las 1.777 series de la A activas o dormidas al origen, la D del motor es de 74,8 % y la de esa réplica, de 99,7 %; la B, que exige actividad al origen, no las contiene. La sensibilidad no reemplaza el resultado principal, que es el de la cohorte evaluable publicada (75,4 %): mide que, en las dos alternativas declaradas, el motor sigue primero entre los once modelos a un paso, a una distancia similar de esa réplica, y que en la evaluación multihorizonte LightGBM sigue siendo el modelo de menor D global (72,9 % en la A y 72,1 % en la B, frente a 71,9 %).

En síntesis, la validación a un paso confirma que el motor automatizado cumple su propósito principal. Ese propósito es seleccionar y aplicar de forma automática, para cada combinación SKU-canal-regional, el modelo de mejor desempeño en validación. Con ello alcanza el menor error compuesto valorizado del portafolio, con una mejora de efecto grande que se sostiene con incertidumbre agrupada por SKU, frente a la réplica de la fórmula base sin ajustes de consenso del plan final, medida sobre las ventas observadas.

4.3.2.2 Evaluación multihorizonte del error

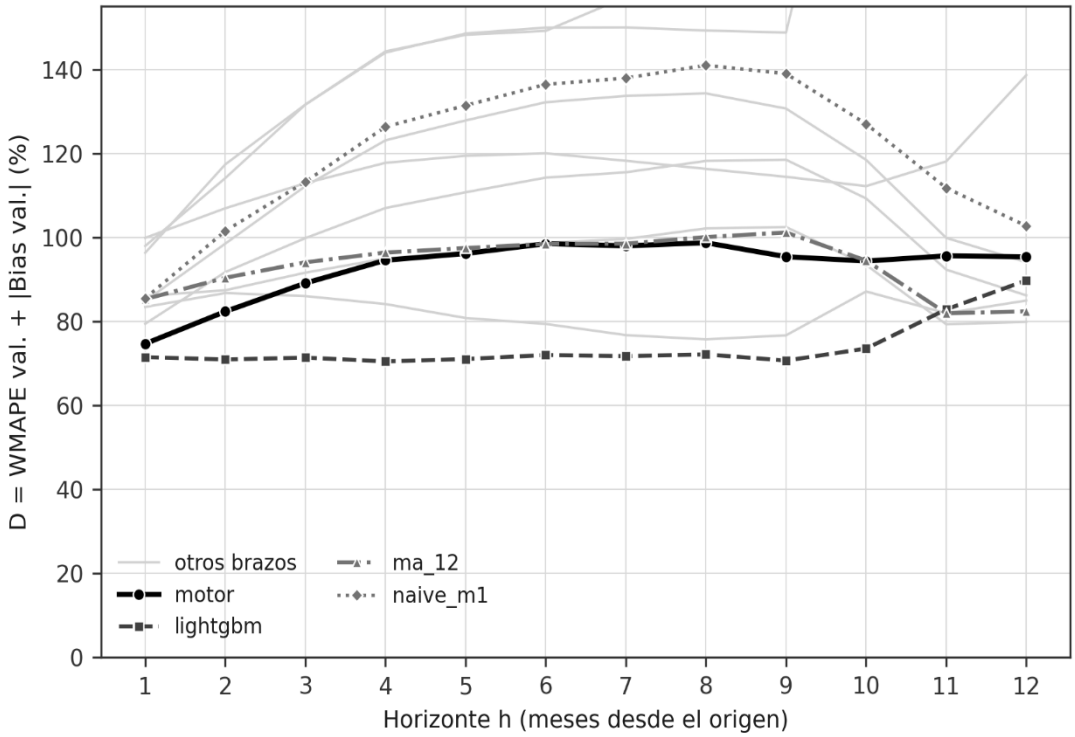
La validación a un paso responde a la pregunta de qué modelo pronostica mejor el mes inmediato; la operación de planificación, sin embargo, proyecta con meses de anticipación. Para medir esa dimensión se realizó una evaluación multihorizonte con

orígenes rodantes, que replica la mecánica de la corrida mensual de planificación. Desde el cierre de cada uno de los 12 meses que van de marzo de 2025 a febrero de 2026 se proyectó de forma recursiva hasta 12 meses hacia adelante. En cada origen se reentrenó LightGBM con la historia disponible hasta ese origen y con el número de iteraciones congelado del ajuste base (la parada temprana no se repitió, para no volver a mirar validación en cada origen), como lo haría la corrida mensual, que reajusta el modelo global; los brazos estadísticos conservaron los parámetros estimados en entrenamiento, por la regla del protocolo que los estima una sola vez, y solo avanzaron sus estados con la demanda observada; la selección que el motor realizó en validación se mantuvo congelada. Esa asimetría se midió con una corrida de ablación en la que también los brazos estadísticos reestimaron sus parámetros en cada origen, con la misma historia hasta el origen (variante 5 del Anexo 9): Holt-Winters mejoró su D global en el horizonte de 81,2 % a 78,1 %, el suavizado exponencial empeoró de 103,8 % a 106,8 % y Croston de 93,5 % a 94,7 %, mientras que LightGBM (71,9 %) y el motor (91,2 %) no cambiaron. El hallazgo del horizonte no depende, por tanto, de esa asimetría. El primer origen es el último mes del bloque de validación. El horizonte de cada origen se recortó al cierre del histórico disponible, marzo de 2026. Por eso el primer origen aporta 12 meses evaluados y el último aporta 1, y todos los meses evaluados caen dentro del bloque de prueba. La métrica D se recalculó agregando todos los pares origen-horizonte.

Los resultados invierten parcialmente el podio de la evaluación a un paso. LightGBM sostiene el horizonte con una D global de 71,9 %, la mejor del estudio, prácticamente plana hasta el noveno mes, seguido por Holt-Winters (81,2 %) y por el motor (91,2 %). El suavizado exponencial simple, competitivo a un paso, se degrada hasta 103,8 %. Los dos métodos de referencia simples del contraste se distancian casi 26 puntos entre sí: el promedio móvil de 12 meses queda en 94,6 % y el método ingenuo en 120,5 %; el promedio móvil de 2 meses, en 116,6 %, acompaña de cerca al ingenuo (Figura 11). Las variantes con factor de crecimiento divergen al componer su pendiente mes tras mes; las de nivel ingenuo y de promedio de 2 meses llegan a valores extremos de varios cientos por ciento (nota de la Figura 11).

Figura 11

Error compuesto valorizado D por horizonte de pronóstico (orígenes rodantes)



Nota. Cada punto agrega todos los orígenes que alcanzan ese horizonte, desde doce orígenes en h = 1 hasta uno solo en h = 12, por lo que los horizontes largos se apoyan en menos orígenes y se leen con esa cautela. El eje vertical está recortado en 155 %, límite que deja completos los cuatro brazos destacados: quedan fuera del recuadro el promedio móvil de dos meses con factor de crecimiento, que llega a 522 %, y el método ingenuo con factor de crecimiento, que llega a 881 %. Los rótulos de los brazos son los de la Figura 10. Elaboración propia a partir de las salidas del motor.

La curva de LightGBM en la Figura 11 también responde a la configuración, pese a la realimentación recursiva. Su D quedó entre 70,5 % y 72,2 % hasta el noveno mes y, por origen, entre 69,2 % y 83,6 %, el rango más estrecho del estudio (Holt-Winters, 76,8 % a 92,3 %; motor, 65,5 % a 105,2 %). Como límites, el sesgo deriva de −4,3 % (mes 3) a −13,6 % (mes 10) y los meses 11 y 12, con dos orígenes y uno, se deterioran. La configuración previa (variante 4 de la Tabla 23) tenía un WMAPE similar (62,2 % a un paso y 64,2 % en el horizonte, frente a 62,9 % y 63,2 %), pero subestimaba entre 28 % y 41 % y su D subía de 88,5 % a cerca de 100 % desde el quinto mes. La adoptada, con las variables nuevas, conservó la magnitud del error y

redujo el sesgo sin perder estabilidad: toda la mejora de la D a un paso (95,3 % a 77,0 %) vino del sesgo (−33,1 % a −14,1 %). Como hipótesis, el mecanismo combinaría la L2, los pocos árboles y el submuestreo, que deja fuera de cerca del 42 % de los árboles la venta del mes anterior, la propia predicción en la recursión.

La lectura conjunta de ambas modalidades fundamenta el diseño híbrido de la propuesta. Los métodos estadísticos compiten en el corto plazo, donde el motor los aprovecha serie por serie. En cambio, el modelo de aprendizaje automático es el que mejor sostiene el horizonte de planificación (D global de 71,9 %, seguido de Holt-Winters con 81,2 %, o 78,1 % cuando también se lo reestima por origen; la ablación del reentreno confirma el hallazgo), la capacidad que el proceso de abastecimiento más necesita. La selección del motor, realizada sobre el error a un paso, hereda esa miopía. En una corrida de ablación que cambió únicamente esa ventana de decisión (variante 2 del Anexo 9), tomarla del error multihorizonte de validación redujo la D global del motor en el horizonte de 91,2 % a 82,8 %, es decir 8,4 puntos porcentuales. Con ese criterio, el motor asignó a las variantes con factor de crecimiento 232 de las 1.668 series, frente a 206 con el criterio a un paso (suma de las tres variantes en la Tabla 44). Ese mismo cambio de criterio mejoró además levemente su error a un paso, de 75,4 % a 74,6 %, sin ceder el liderazgo frente a LightGBM (77,0 %). Ambas cifras se calculan sobre las 1.513 series con costo del bloque de prueba. La ablación no revierte el hallazgo del horizonte, donde el motor así seleccionado permanece por detrás de LightGBM (71,9 %) y de Holt-Winters (81,2 %). Sí muestra, en cambio, que el criterio de decisión es en sí mismo una palanca de mejora. Por eso ese cambio de criterio se recoge en las recomendaciones. Otras dos variantes registradas en el Anexo 9 acotan la sensibilidad del resultado. Sin el tratamiento del evento exógeno (variante 1), la D del motor fue de 74,7 % a un paso y de 91,6 % en el horizonte, y la de LightGBM de 75,9 % y 71,5 %, sobre las 1.505 series con costo de la cohorte de 1.660 que retiene la cascada de inclusión en esa corrida (los criterios de inclusión se miden sobre el entrenamiento sin tratar): el tratamiento, adoptado por coherencia con la práctica documentada de la empresa, no altera el podio en ninguna de las dos modalidades ni mueve esas cifras más de 1,2 puntos. Con la regla de selección por error absoluto, sin componente de sesgo (variante 3), el motor obtuvo 74,6 % a un paso, con un WMAPE

menor (67,1 %) y un sesgo mayor (−7,6 %), y 84,8 % en el horizonte: la ventaja frente a la réplica de la fórmula base sin ajustes de consenso se mantiene con cualquiera de las dos reglas, y la regla compuesta se conserva porque acota el sesgo, que es el término con consecuencia operativa.

La estratificación por régimen de demanda ADI-CV², anticipada en el marco conceptual (apartado 1.3.4), y por tipo de categoría (apartado 2.6.2) permite verificar dónde gana cada enfoque (Tabla 9). A un paso, los métodos estadísticos compiten y hasta lideran en los estratos de demanda regular: el suavizado exponencial en la demanda suave y Croston en las categorías recurrentes. El modelo de aprendizaje automático, en cambio, encabeza ya desde el paso uno los estratos difíciles: errática, esporádica y estacional.

Tabla 9
Error compuesto valorizado D por estrato: mejor método estadístico, motor y LightGBM, a un paso y en el horizonte

Estrato (series con costo)	Mejor estadístico un paso	Motor un paso	LightGBM un paso	Mejor estadístico horizonte	Motor horizonte	LightGBM horizonte
Suave (278)	Suav. exponencial · 56,1	59,6	67,7	Holt-Winters · 66,7	77,2	62,1
Errática (579)	Suav. exponencial · 88,0	79,0	77,7	Croston · 95,8	90,3	70,6
Intermitente (38)	Suav. exponencial · 85,8	89,6	93,1	Prom. móvil 12 m · 89,3	89,7	83,4
Esporádica (618)	Ingenuo · 108,2	100,1	94,5	Holt-Winters · 99,3	117,6	91,7

Estrato (series con costo)	Mejor estadístico un paso	Motor un paso	LightGBM un paso	Mejor estadístico horizonte	Motor horizonte	LightGBM horizonte
Estacional (706)	Ingenuo · 110,3	95,2	84,9	Holt-Winters · 121,7	112,2	83,2
Recurrente (807)	Croston · 63,7	66,2	73,4	Holt-Winters · 71,0	78,8	65,3

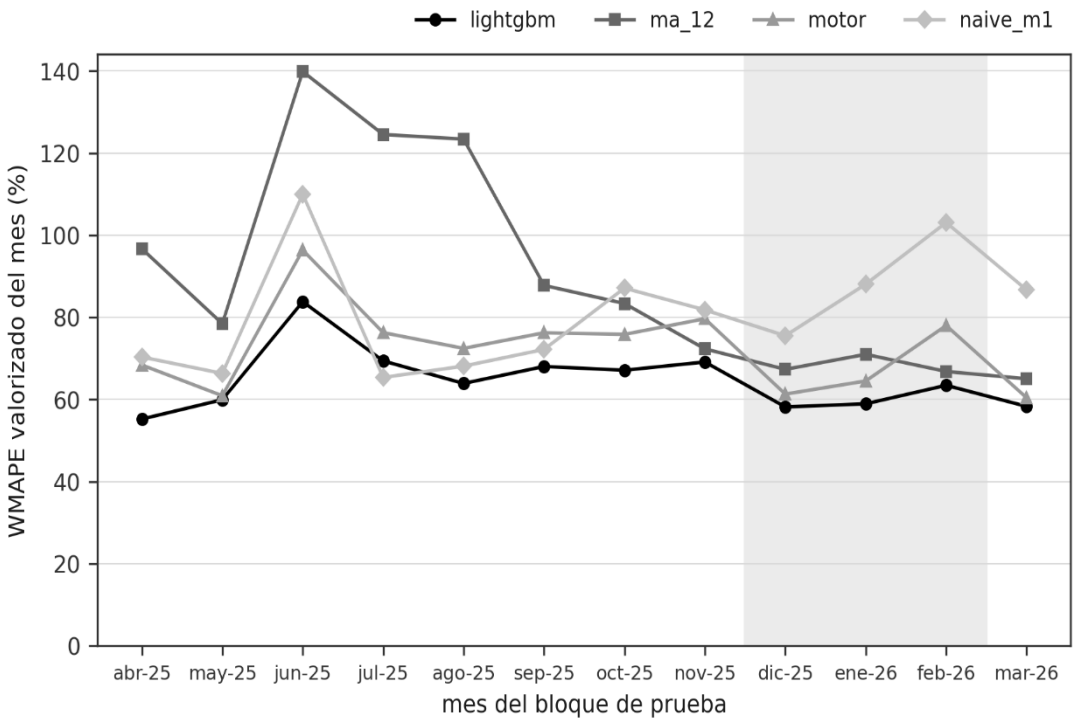
Nota. D = WMAPE + |Bias| valorizados, en porcentaje, sobre el bloque de prueba; "un paso" y "horizonte" corresponden a las dos modalidades de evaluación del estudio. Los regímenes siguen la clasificación ADI-CV² calculada sobre el entrenamiento; las cuatro primeras filas reparten las 1.513 series con costo por régimen, y las dos últimas, las mismas series por tipo de categoría. En "mejor estadístico" se indica el método de menor D del grupo y su valor. Elaboración propia a partir de las salidas del motor.

En el horizonte el cuadro se vuelve unánime: LightGBM presenta la menor D en los seis estratos. La brecha máxima aparece en las categorías estacionales, con 83,2 % frente a 121,7 % del mejor método estadístico. Ese segmento es justamente el que concentra la campaña escolar y decide el abastecimiento. Esta lectura estratificada confirma que la ventaja del aprendizaje automático no depende de un subconjunto favorable de series, y explica la mezcla que el motor elige serie por serie. La columna del motor confirma, estrato por estrato, la miopía señalada en la evaluación multihorizonte: al decidir sobre el error a un paso, el motor queda en el horizonte por detrás del mejor método estadístico en cuatro de los seis estratos y solo conserva ventaja en las series erráticas y en las categorías estacionales.

La Figura 12 traslada esa lectura al calendario del bloque de prueba, con el error valorizado de cada mes y los meses de pico sombreados. Dentro del pico (diciembre a febrero) el modelo de aprendizaje automático registra el menor error del estudio: un WMAPE valorizado de 59,6 %, frente a 68,5 % del promedio móvil anual y 86,1 % del método ingenuo. La descomposición del sesgo por temporada explica el mecanismo. El promedio móvil de doce meses reparte la campaña en el año:

subestima el pico en 45,8 % y sobrestima el resto en 27,4 %. El método ingenuo, por su parte, tiene como único insumo la venta del mes anterior y llega tarde a los giros de la campaña. En febrero de 2026 arrastra el nivel de enero y sobrestima la demanda del mes en 58,7 %, con un WMAPE valorizado de 103,1 %, el peor de los tres meses de pico. Su peor mes de todo el bloque de prueba es, en cambio, junio de 2025, con 110,0 %, un mes de valle en el que el error absoluto pesa sobre una base valorizada mucho menor. El motor y el modelo global mantienen, en cambio, un error estable dentro y fuera de temporada (66,1 % y 73,2 % el motor; 59,6 % y 65,5 % el modelo global).

Figura 12
WMAPE valorizado por mes del bloque de prueba, por modelo



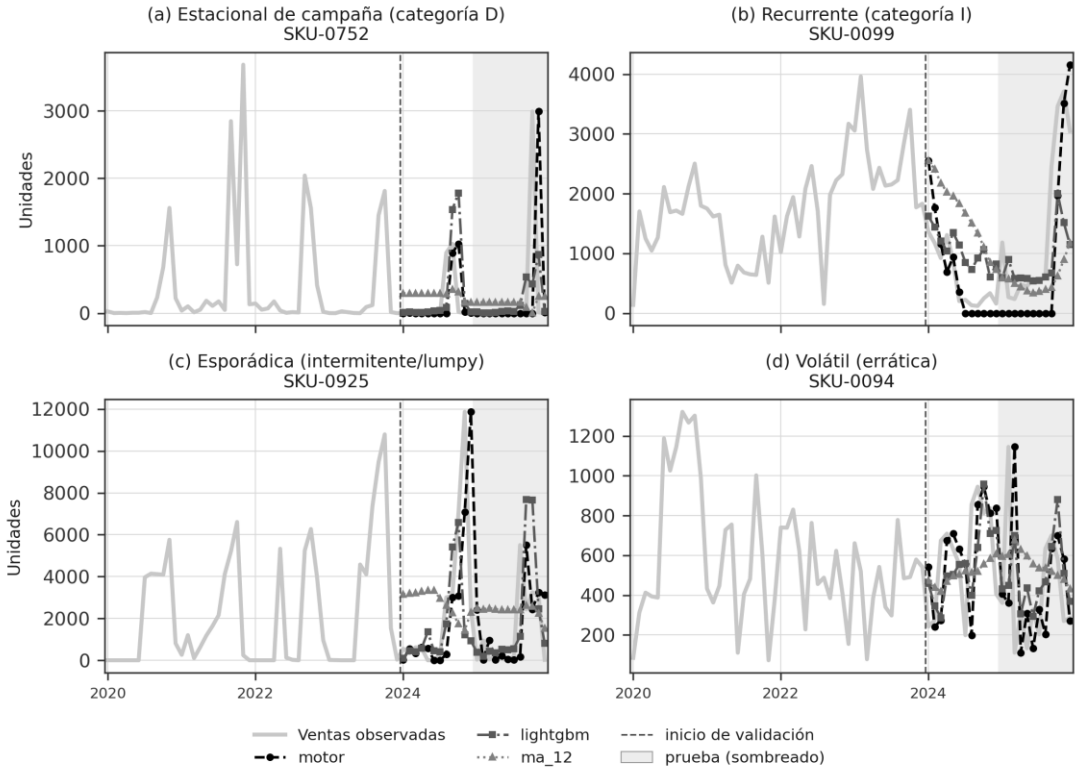
Nota. El WMAPE del mes es el error absoluto valorizado sobre la demanda valorizada de ese mes. Las franjas grises marcan los meses de pico estacional, aquellos cuya participación mensual en la demanda valorizada de entrenamiento supera el umbral declarado en el manifiesto. Los rótulos de los brazos son los de la Figura 10. Elaboración propia a partir de las salidas del motor.

El comportamiento serie por serie ilustra los regímenes que el motor arbitra. La Figura 13 presenta cuatro casos representativos: (a) estacional de campaña, (b)

recurrente, (c) esporádico y (d) volátil (de régimen errático), con las ventas observadas y los pronósticos de los principales brazos:

Figura 13

Casos representativos por régimen de demanda: ventas observadas y pronósticos en validación y prueba. Paneles: (a) estacional de campaña; (b) recurrente; (c) esporádico; (d) volátil



Nota. Los identificadores de producto están seudonimizados. Cada caso es la serie de mayor demanda valorizada de su régimen. La línea vertical marca el inicio del bloque de validación y el sombreado, el bloque de prueba; cada marca del eje horizontal señala abril del año rotulado, primer mes de una gestión comercial. La curva del motor es la del brazo que eligió para cada serie, y los rótulos de los brazos son los de la Figura 10. Elaboración propia.

Los cuatro paneles condensan el comportamiento de los brazos en los regímenes del portafolio. En el caso estacional de campaña (a), el motor, que en esa serie eligió el método ingenuo, replica el último mes observado y llega un mes tarde a la subida de la campaña. El promedio móvil anual la reparte en el año y aplana el pico. El modelo global, en cambio, la anticipa a través de la media del mismo mes y el rezago interanual. En el recurrente (b), en el bloque de prueba el modelo global y el promedio

móvil anual siguen el nivel con error moderado y la diferencia entre ambos se decide por el sesgo; el motor, que en esa serie eligió el ingenuo con factor de crecimiento, cae a cero en la mayor parte de la prueba, porque el factor negativo del año móvil lleva la proyección por debajo de cero, y solo recupera el nivel con el repunte de los últimos meses. En el esporádico (c), la selección por serie contiene los meses sin venta y el error queda dominado por los picos aislados. En el volátil (d), que corresponde al régimen errático de la Tabla 9, ningún brazo anticipa los saltos (no hay estructura temporal que aprender) y la ventaja del modelo global se reduce a contener el error, exactamente lo que la estratificación por régimen de la Tabla 9 documenta a escala del portafolio completo.

4.3.2.3 Evaluación comparativa de referencia (benchmarks) de los modelos elegidos

La evaluación comparativa de referencia se planteó en dos planos: el externo recoge lo que las competencias y los estudios publicados reportan para cada familia del conjunto de modelos candidatos, y el interno mide, sobre las mismas series y bajo el mismo protocolo, cuánto cuesta y cuánto acierta cada brazo. Las magnitudes externas no se comparan con la D valorizada, porque difieren la métrica, la frecuencia, el horizonte y los datos; sí es comparable la mejora relativa frente a una referencia simple (Hyndman & Koehler, 2006). En ese plano, a un paso, el motor reduce la D del modelo ingenuo en un 11,9 % (75,4 % frente a 85,6 %, diferencia que se sostiene por SKU y no al remuestrear meses; Tabla 20 del Anexo 8) y la del ingenuo estacional, medido fuera del conjunto, en un 8,9 % (frente a 82,7 %); las dos reducciones se calculan con las D sin redondear. El detalle está en el Anexo 16.

El plano externo es cualitativo. En la competencia M4, la referencia que combina tres suavizados exponenciales resultó difícil de superar, los primeros puestos fueron un método híbrido y combinaciones, y los métodos puros de aprendizaje automático no superaron a esa referencia (Makridakis et al., 2020): respalda el suavizado exponencial y Holt-Winters en el conjunto y la combinación como evolución. En la M5, la mayoría de los primeros puestos usó LightGBM como modelo global con variables explicativas, y la ventaja sobre las referencias se estrechó en el nivel de ítem

(Makridakis et al., 2022): respalda el brazo global y la escala del error de la Tabla 8. Syntetos y Boylan (2005) respaldan, en la demanda intermitente, el enfoque de Croston con su corrección de sesgo, la aproximación de Syntetos y Boylan (SBA, por su sigla en inglés). El contrapeso es Makridakis et al. (2018): en series mensuales de la M3, las redes neuronales y otros métodos de aprendizaje automático, ninguno de boosting por gradiente, no superaron a los estadísticos; por eso el motor conserva nueve brazos estadísticos. Como interpretación de este trabajo, y no de esas fuentes, el resultado propio (LightGBM gana en el horizonte y no a un paso) queda entre la M4 y la M5. El ingenuo estacional y el método Theta, referencias habituales, no integran el conjunto.

En el plano interno, en la corrida principal, los nueve brazos estadísticos ajustaron y pronosticaron a un paso en 1,39 segundos, y Holt-Winters, el más costoso por su rejilla de 96 combinaciones, en 0,71. LightGBM requirió 11,25 segundos, y unos 39 con la preparación de variables (27,8), que solo él consume: unas 28 veces la suma de los estadísticos. La explicación TreeSHAP (63,8 segundos), también exclusiva suya, es un costo opcional de transparencia. El motor completo, con la selección por serie, ronda los 45 segundos, y la calibración de LightGBM costó 461 segundos. A un paso, ese cómputo adicional compra precisión; en el horizonte, el motor (91,2 %) sale de la frontera entre costo y precisión, dominado por Holt-Winters (81,2 % en 0,71 segundos) y LightGBM (71,9 %), y aun el ingenuo estacional lo supera (84,1 %). Es la miopía de la selección a un paso leída como costo y beneficio, que respalda trasladar el criterio al horizonte. Los tiempos son de una sola medición en un contenedor de un solo hilo, sin registro de procesador ni memoria, y las centésimas que separan a los estadísticos no alcanzan para ordenarlos.

La extensión exploratoria mide el costo de las redes neuronales que el apartado 4.2.1 invoca para dejarlas fuera del conjunto, en otro entorno, con aceleración gráfica, no comparable uno a uno con el anterior. En la gestión 2026, ajustar y pronosticar a un paso le llevó a TFT 146,1 segundos, a DLinear 66,0, a N-HiTS 37,0 y al modelo fundacional 29,1, frente a 10,62 de LightGBM; calibrar N-HiTS costó 497 segundos y TFT 1.949, en 25 ensayos cada una. Entre los pronosticadores de la extensión, en 2026 solo el fundacional superó a LightGBM a un paso (74,3 % frente a 77,0 %); en

2025, de quiebre, lo superaron N-HiTS (70,6 % frente a 83,0 %) y el fundacional (81,3 %); en el horizonte, ninguno en ninguna gestión. Quedaron sin medir XGBoost, CatBoost, Random Forest, ARIMA automático y Theta; hacerlo con calibración equivalente costaría de 12 a 20 horas de desarrollo y de 4 a 6 de cómputo. SBA no mejoró a Croston (88,5 % frente a 86,1 % a un paso; 99,1 % frente a 93,5 % en el horizonte).

4.3.3 Extensión exploratoria: combinación de pronósticos y conmutación por régimen

Concluida la validación, se condujo una etapa exploratoria adicional bajo el mismo protocolo congelado: idéntica partición temporal, idéntica métrica de decisión e idénticas reglas de no fuga. Conviene declarar, sin embargo, dos diferencias que afectan directamente al brazo denominado motor. La primera: su conjunto de candidatos pasa de los 10 modelos de la sección anterior a los 15 de esta etapa. La segunda: la ventana con la que compara a esos candidatos pasa del error a un paso al desempeño multihorizonte. Ese error a un paso fija la configuración de la validación; el desempeño multihorizonte fija la configuración de la extensión. Por eso el brazo motor de esta etapa, cuya D valorizada a costo sobre las 1.513 series con costo fue de 79,9 % a un paso en el bloque de prueba (gestión 2026), no es el motor validado en la sección anterior, cuya D fue de 75,4 % en el mismo bloque y sobre el mismo subconjunto: sus cifras no deben leerse como una nueva medición de aquel, ni la distancia entre ambas atribuirse por completo a una sola de las dos diferencias declaradas. La corrida de ablación de la evaluación multihorizonte, que cambió solo el criterio sobre el conjunto de diez, obtuvo 74,6 %, de modo que el cambio de criterio por sí solo no explica esa distancia; el resto, hasta 79,9 %, aparece al pasar a quince candidatos, lectura coherente con la caída de la tasa de acierto de 20,8 % a 9,4 % que se reporta más adelante: más candidatos agravan la maldición del ganador. La etapa se orientó a dos preguntas que los resultados anteriores dejaron abiertas: si la selección de un único modelo por serie es la mejor manera de aprovechar el conjunto disponible, y en qué medida las conclusiones dependen de la gestión elegida como bloque de prueba. Los hallazgos de esta etapa informan la evolución del sistema

propuesto y no modifican la validación precedente. Esta etapa se ejecutó fuera del contenedor del flujo principal, dado que los brazos neuronales y el modelo fundacional requieren un entorno adicional con aceleración por hardware gráfico. Ese entorno se declaró con versiones fijas en el archivo 'requirements-ml2.txt' del repositorio: PyTorch, NeuralForecast, PyTorch Lightning y la implementación de referencia de Chronos. Las semillas quedan fijadas y la corrida final de cada gestión de prueba, repetida en el mismo equipo, reprodujo exactamente los resultados de su corrida previa, del 23 de agosto de 2026, conservada con su manifiesto; aun así, el entrenamiento acelerado por hardware no garantiza una reproducción idéntica en otro equipo o con otras versiones de las bibliotecas, limitación que no alcanza a las cifras de la validación principal.

4.3.3.1 De la selección a la combinación de pronósticos

La tasa de acierto del motor es la frecuencia con la que el candidato elegido en validación resulta después el de menor error compuesto (MAE + |Bias|) en el bloque de prueba. Esa tasa quedó lejos de la certeza en la corrida principal y en las dos corridas de la extensión. Con el conjunto de 10 candidatos fue del 20,8 % sobre las 1.668 series de la muestra en la gestión 2026, frente al 10,0 % que acertaría una elección al azar entre ellos, cifra ya reportada en el contraste estadístico. Con el conjunto ampliado de esta extensión fue del 9,4 % sobre esas mismas 1.668 series de la gestión 2026. También fue del 10,7 % sobre las 1.613 series de la cohorte de la partición desplazada a la gestión 2025 que se describe más adelante en este mismo apartado. En ambos casos, una elección al azar habría acertado el 6,7 %. Cada corrida supera su propio azar, pero por un margen que deja la mayor parte de la decisión serie por serie en el terreno del ruido de muestreo. Este fenómeno, conocido como la maldición del ganador, refuerza la recomendación de la literatura de pronóstico, confirmada en las competencias, de combinar en lugar de seleccionar (Bates & Granger, 1969; Makridakis et al., 2020; Timmermann, 2006).

Para poner esa recomendación a prueba se amplió primero el conjunto de candidatos con cuatro arquitecturas de redes neuronales globales, a saber, DLinear (Zeng et al., 2023), N-HiTS (Challu et al., 2023), TFT (Lim et al., 2021) y DeepAR

(Salinas et al., 2020), y un modelo fundacional de series de tiempo aplicado sin reentrenamiento, Chronos-Bolt (Ansari et al., 2024), todos bajo el protocolo congelado. El cuarteto inicial cubría las cuatro familias vigentes del pronóstico neuronal (la línea base lineal, el apilamiento jerárquico sucesor directo de N-BEATS, la atención con covariables y la recurrencia probabilística), de modo que la conclusión no dependiera de una arquitectura particular. DeepAR, representante de la familia recurrente probabilística, se evaluó en las iteraciones iniciales de la extensión y se retiró del conjunto por desempeño. Su error compuesto quedó entre 147,8 % y 196,7 %, frente al 74,3 % del mejor candidato. Por eso la corrida final reportada se apoya en las tres arquitecturas restantes y en el modelo fundacional, a los que se suma una variante del propio modelo global que proyecta el horizonte de forma directa, esto es, sin realimentar sus propias predicciones como hace la proyección recursiva de la evaluación multihorizonte; con ella, el conjunto ampliado queda en los 15 candidatos declarados. Esa variante coincide por construcción con la recursiva a un paso (es el mismo ajuste base; D de 77,0 %) y no la mejoró en el horizonte (D global de 84,0 % frente a 71,9 %). Tres lecciones dejó la ampliación. La primera: el sesgo de la función de pérdida domina sobre la arquitectura. La lección de la pérdida Tweedie del modelo campeón se replicó en las redes. La segunda: las configuraciones que elige la búsqueda de hiperparámetros no conservan su desempeño tras un cambio de régimen económico. Los ganadores del pliegue interno, ajustado sobre meses previos a la crisis cambiaria, se degradaron severamente en la prueba posterior a ella. La tercera: el modelo fundacional, calibrado por categoría con factores estimados en validación, resultó el mejor pronosticador individual a un paso del estudio en la gestión normal (D de 74,3 %) sin reentrenamiento sobre los datos de la empresa. Ante la degradación de la búsqueda, se conservaron de todos modos las configuraciones que ella eligió. Recuperar configuraciones anteriores por su desempeño observado en la prueba habría constituido una selección sobre el propio bloque de evaluación. Por eso ninguna configuración de hiperparámetros de esta extensión se eligió con evidencia de prueba. Las dos decisiones que sí se tomaron con la evidencia de las gestiones medidas, el diseño del sistema conmutado (la composición de su conjunto diverso y los tres valores

de su detector) y la lectura post hoc que excluye a TFT, se identifican como tales donde se reportan.

La combinación se comportó como anticipa la literatura, con su condición de funcionamiento a la vista. El conjunto curado (seleccionado con criterio entre los candidatos) reúne cinco pronosticadores: LightGBM, el fundacional calibrado, el suavizado exponencial, Holt-Winters y TFT. Su promedio simple alcanzó una D de 74,9 % a un paso, 0,5 puntos por debajo del motor validado en la sección anterior (75,4 %). La ventaja proviene de la magnitud del error y no del sesgo: el WMAPE valorizado baja de 70,1 % a 64,5 %, mientras el sesgo pasa de −5,3 % a −10,4 %. Una lectura post hoc ilustra la sensibilidad de la mezcla a sus integrantes: excluir a TFT, el de mayor error en el bloque de prueba de esa gestión, reduce a 70,0 % la D del promedio de los cuatro restantes; como TFT no era el más débil en validación (donde lo era Holt-Winters, cuya exclusión eleva la D de la mezcla a 78,5 %), esa cifra se declara como lectura sobre el propio bloque de evaluación y no como resultado confirmatorio. La mecánica es la promediación de errores no correlacionados, reforzada por una cancelación parcial de sesgos opuestos (LightGBM subestima, con un sesgo de −14,1 %, mientras Holt-Winters, con +5,7 %, y el resto de los integrantes lo compensan en parte: el conjunto de cinco cierra con −10,4 %), y su condición es la calidad de los integrantes: un pronosticador de error alto no aporta diversidad, erosiona la mezcla. La ponderación por el desempeño de validación de cada serie, que con integrantes parejos no supera al promedio simple (la paradoja del promedio simple, apartado 1.2.14), sí aporta cuando el conjunto arrastra un integrante débil (74,0 % frente a 74,9 %). Frente al motor validado, esas reducciones de la D son evidencia descriptiva del conjunto evaluado: con incertidumbre agrupada por SKU, el intervalo de la diferencia de D contiene el cero tanto para el promedio simple (−0,5 puntos, de −3,4 a 2,3) como para la variante ponderada (−1,4 puntos, de −3,9 a 1,3; Tabla 21 del Anexo 8). La diferencia mediana por serie, en cambio, favorece a las dos mezclas y se sostiene por SKU (−0,16 y −0,25 unidades, con intervalos de −0,28 a −0,02 y de −0,37 a −0,14), aunque no al remuestrear meses. La mezcla fue, además, la primera configuración del estudio en superar al método ingenuo a un paso con un tamaño del efecto pequeño y ya no insignificante. El contraste se midió sobre el error compuesto por serie en

unidades de las 1.668 series del bloque de prueba de la gestión normal ($p = 1{,}1 \times 10^{-7}$ y $r = -0{,}13$; su variante ponderada, $p = 1{,}7 \times 10^{-16}$ y $r = -0{,}20$). Con incertidumbre agrupada por SKU, esa ventaja sobre el ingenuo se sostiene en la diferencia mediana por serie (−0,66 unidades, con intervalo de −0,97 a −0,40; la variante ponderada, −0,69, de −0,98 a −0,42) y en la D del portafolio, pero no en la diferencia media por serie, cuyo intervalo contiene el cero y que es, por tanto, evidencia descriptiva del conjunto evaluado; al remuestrear meses, solo la diferencia de D excluye el cero (Tabla 21). El motor validado de la sección anterior, en cambio, había obtenido en el contraste por serie un tamaño del efecto insignificante ($p = 2{,}04 \times 10^{-4}$ y $r = -0{,}09$), y el brazo motor de esta extensión, corrido sobre el conjunto ampliado a quince candidatos, también ($p = 0{,}364$ y $r = -0{,}01$). Con incertidumbre agrupada, ninguno de los dos tiene frente al ingenuo una diferencia por serie que excluya el cero, ni por SKU ni al remuestrear meses (Tabla 20 y filas de la gestión 2026 de la Tabla 21). Por su parte, un calendario comercial de temporadas por categoría, dirigido a la estacionalidad de campaña, se declaró como variables exógenas deterministas. Ese calendario redujo el sesgo valorizado del modelo global de −14,1 % a −10,7 % en una corrida de ablación idéntica en todo lo demás para el modelo global (la sexta iteración de la extensión; su configuración, 'config/config_ml2_v6.yaml', y su auditoría de verificación, 'docs/auditoria_ml2_v6.md', se conservan en el repositorio del Anexo 7). El costo fue un error absoluto valorizado mayor, de 77,09 a 78,20 millones de bolivianos, equivalentes a un WMAPE valorizado de 62,9 % a 63,8 %, sobre las 1.513 series con costo del bloque de prueba de la gestión 2026.

4.3.3.2 Sensibilidad al régimen: la prueba de dos gestiones

Para acotar la dependencia del corte único de prueba, el protocolo completo se repitió desplazado un año: entrenamiento hasta la gestión 2023, validación en la gestión 2024 y prueba en la gestión 2025. Esa última gestión es precisamente la del inicio de la crisis cambiaria. El histórico se truncó en marzo de 2025 para que ningún dato posterior participara. Los resultados separan con nitidez lo que es propiedad del sistema de lo que era propiedad del año.

Sobrevive el hallazgo estructural del horizonte: LightGBM presenta la menor D global multihorizonte en ambas gestiones (71,9 % y 70,1 %), y las mezclas mantienen su ventaja sobre el promedio móvil (r entre −0,34 y −0,54 según la mezcla y la gestión), que se sostiene con incertidumbre agrupada por SKU (Tabla 21): en las dos gestiones, los intervalos por conglomerados de las cuatro mezclas contrastadas (el promedio simple, la ponderada por validación y la ponderada por horizonte del conjunto curado, y el sistema conmutado) excluyen el cero en la diferencia mediana por serie, en la media y en la D del portafolio, y también al remuestrear bloques de meses. En la gestión de quiebre, en cambio, ninguno de los seis sistemas contrastados con Wilcoxon (las cuatro mezclas, el brazo motor de la extensión y LightGBM) supera significativamente al método ingenuo en el contraste pareado ($p \geq 0,45$), que con una D de 78,7 % resulta a un paso mejor que el brazo motor de la extensión (80,9 %) y que el promedio simple del conjunto curado (78,8 %), aunque peor que el sistema conmutado (72,9 %) y que la mezcla ponderada (77,1 %); la ventaja de las mezclas en el contraste pareado de esa gestión se limita al promedio móvil. Esa lectura de la gestión de quiebre también se sostiene con incertidumbre agrupada por SKU (Tabla 21): frente al ingenuo, ninguno de los seis sistemas tiene un intervalo por conglomerados de la diferencia mediana por serie que excluya el cero a su favor, y los seis intervalos de la diferencia media lo excluyen en contra de los sistemas; en cambio, las diferencias de D con el ingenuo, en uno y otro sentido, son evidencia descriptiva del conjunto evaluado, porque sus seis intervalos contienen el cero. Sobrevive también un resultado de alto valor práctico: el promedio móvil anual y Holt-Winters (el nivel base de la fórmula de planificación de la empresa y su refinamiento natural) resultaron los métodos más frágiles ante el quiebre (D superiores a 111 %). El podio a un paso, en cambio, se reordena. En la gestión de crisis los integrantes estructurales del conjunto sobrestiman a la vez, del +7,2 % del suavizado al +22,5 % de Holt-Winters. El conjunto de cuatro de la lectura post hoc de la gestión normal carece de sesgos negativos que lo compensen y su D sube de 70,0 % a 84,4 %. Los brazos de sesgo negativo estructural se convierten entonces en el contrapeso: N-HiTS, de los más débiles del año normal, resulta el mejor pronosticador individual del quiebre (D de 70,6 %). Los conjuntos que lo incluyen amortiguan la caída. Ningún conjunto fijo domina ambos

regímenes, por la misma razón leída en los dos sentidos: la gestión estable premia la estructura; la gestión de quiebre premia la adaptividad y el contrapeso de sesgos.

4.3.3.3 Conmutación por régimen

La respuesta constructiva se midió en dos etapas. La primera consistió en un conjunto deliberadamente diverso en sesgos: los cinco anteriores más N-HiTS, de sesgo negativo persistente, y el método ingenuo. Con él se rescataron 6,8 puntos de D en la gestión de quiebre (sobre los valores sin redondear), con 72,1 % a un paso frente a 78,8 % del conjunto curado. El precio fue un punto en la gestión estable: 75,9 % frente a 74,9 %. Es decir, una póliza de seguro, con su prima medida. La segunda consistió en un sistema de conmutación que decide entre ambos conjuntos con una señal disponible en el momento de pronosticar. Esa señal es el sesgo valorizado del propio sistema sobre los últimos tres meses ya observados. La conmutación sigue una rampa declarada: activación al 10 % de sesgo y conmutación plena al 20 %. Los tres valores se fijaron sobre la evidencia de las dos gestiones medidas. La ventana de tres meses es la más corta que promedia el ruido mensual sin retrasar la señal más de un trimestre. La rampa del 10 % al 20 % gradúa la respuesta: filtra parte de la variación ordinaria de las gestiones normales, donde la volatilidad de campaña produce activaciones transitorias. Además, garantiza la conmutación plena ante el episodio de quiebre, cuya señal la excede con holgura y de forma sostenida, del +21 % al +77 % durante ocho meses consecutivos. Al haberse calibrado sobre las mismas gestiones en que se lo mide, el sistema conmutado debe leerse como prueba de concepto del mecanismo y no como estimación de su desempeño futuro. La Tabla 10 resume los sistemas de combinación y el sistema conmutado medidos en ambas gestiones (el conjunto diverso y el curado sin TFT, solo a un paso); la Figura 14 ordena por su peor caso a un paso a los tres sistemas medidos en ambas modalidades junto con los pronosticadores individuales de referencia.

En la Tabla 10, el menor valor de cada columna corresponde a una fila distinta: ninguna configuración estática domina las cuatro. Al leer la tabla, conviene tener presente que las dos gestiones no descansan sobre la misma base. El desplazamiento del protocolo un año atrás recalculó la cascada de inclusión sobre un histórico truncado

en marzo de 2025, por lo que la gestión 2026 se evaluó sobre una muestra de 1.668 series, 1.513 de ellas con costo asignado, y la gestión 2025, sobre una de 1.613 series, 1.468 de ellas con costo. En la modalidad de horizonte, cada columna agrega además los doce orígenes rodantes de su bloque, de modo que la cobertura decrece al alejarse el horizonte: de 1.513 a 983 series con costo en la gestión 2026 y de 1.468 a 950 en la 2025. Por eso las columnas no son estrictamente comparables entre sí, y las diferencias entre gestiones se leen en su dirección y no en sus décimas. En cuanto a las filas, el conjunto diverso y el curado sin TFT se midieron mediante la recombinación de los mismos pronósticos publicados, y en el horizonte el papel del diverso queda representado por el sistema conmutado, que lo incorpora a través de su regla. Los contrastes pareados que se informan para la extensión, por su parte, se calcularon sobre la muestra completa de cada gestión y sobre el error compuesto en unidades. Las dos corridas de la extensión que sustentan la tabla se ejecutaron en Windows con aceleración gráfica y Python 3.12.13, y tardaron 4.832,1 s la de la gestión 2026 y 4.565,4 s la de la gestión 2025; el commit sobre el que corrieron versiona sus dos configuraciones con el contenido que sellan los manifiestos.

Tabla 10

Error compuesto valorizado D de los sistemas de combinación y del sistema conmutado en las dos gestiones de prueba

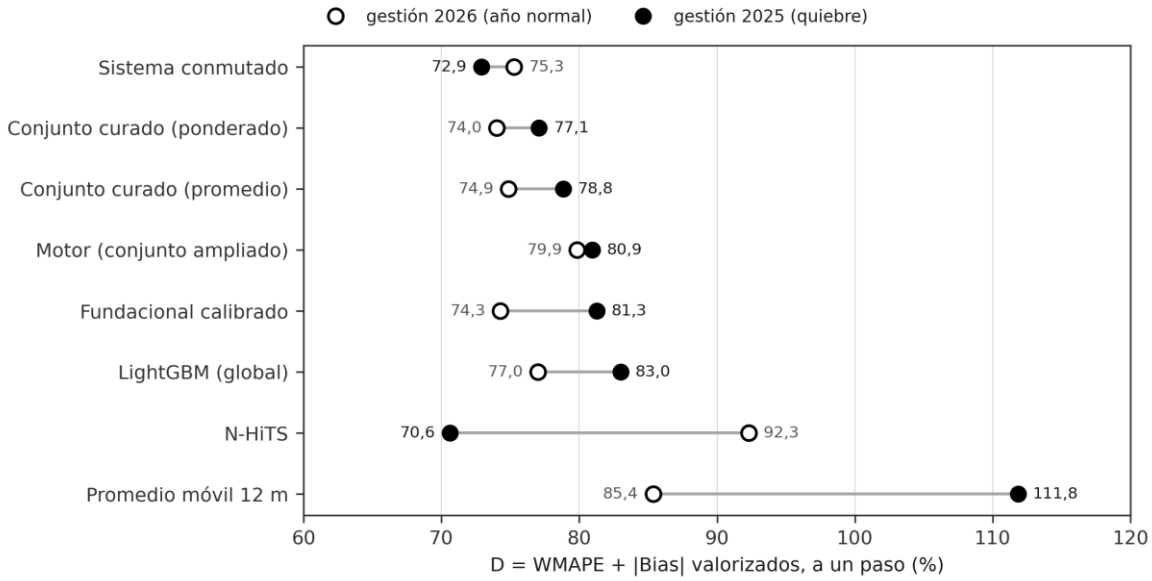
Sistema	Gestión 2026, un paso (1.513 series con costo)	Gestión 2026, horizonte (mismas series, 12 orígenes rodantes)	Gestión 2025, un paso (1.468 series con costo)	Gestión 2025, horizonte (mismas series, 12 orígenes rodantes)
Conjunto curado (promedio de 5)	74,9	82,3	78,8	80,6
Conjunto curado sin TFT (promedio de 4, lectura post hoc)	70,0	n. d.	84,4	n. d.

Sistema	Gestión 2026, un paso (1.513 series con costo)	Gestión 2026, horizonte (mismas series, 12 orígenes rodantes)	Gestión 2025, un paso (1.468 series con costo)	Gestión 2025, horizonte (mismas series, 12 orígenes rodantes)
Conjunto curado (ponderado por validación)	74,0	82,6	77,1	75,6
Conjunto diverso (promedio de 7)	75,9	n. d.	72,1	n. d.
Sistema conmutado	75,3	83,0	72,9	71,5

Nota. D = WMAPE + |Bias| valorizados, en porcentaje, sobre el bloque de prueba de cada gestión; “un paso” y “horizonte” corresponden a las dos modalidades de evaluación del estudio. n. d.: no medido en esa modalidad. Las dos gestiones provienen de dos corridas de la extensión del 19 de octubre de 2026, 'salidas_ml2_v9' (gestión 2026) y 'salidas_ml2_v9_blindaje' (gestión 2025), con las configuraciones 'config/config_ml2_v9.yaml' y 'config/config_ml2_v9_blindaje.yaml', sobre la misma captura de ventas que la corrida principal (SHA-256 5d1190ff295e); sus manifiestos tienen SHA-256 c0940a4eca15 y 0fcae1db6aa2. Las dos corridas se ejecutaron sobre el commit 472b891 del repositorio del Anexo 7, con el árbol de trabajo limpio. Elaboración propia a partir de las salidas del motor.

Figura 14

Sensibilidad al régimen en la extensión exploratoria: error compuesto valorizado D a un paso en las dos gestiones de prueba



Nota. Cada fila une la D valorizada a un paso de dos gestiones. La primera es la gestión 2026, año normal (marcador vacío); la segunda, la gestión 2025, inicio del quiebre cambiario (marcador lleno). En los dos casos, la D se mide sobre el bloque de prueba y las series con costo de la cohorte de cada gestión (1.513 y 1.468). Las filas se ordenan por su peor caso. Elaboración propia a partir de las salidas de ambas corridas de la extensión.

El sistema conmutado presenta el mejor peor caso a un paso del estudio (75,3 %; Figura 14). En el horizonte del quiebre logra además el mejor resultado de cualquier sistema después del modelo global (71,5 %, a 1,4 puntos de LightGBM). Su ventaja sobre el promedio móvil alcanza un tamaño del efecto mediano en la gestión 2026 (r = −0,41) y grande en la gestión 2025 (r = −0,54) y se sostiene con incertidumbre agrupada por SKU en las dos (Tabla 21). Ninguno de los pronosticadores individuales contrastados (LightGBM y el motor) llega a esa magnitud. El detector, además, deja seguir su comportamiento mes a mes en la gestión de quiebre, y el recorrido no es limpio. En la gestión de quiebre la conmutación es plena desde el primer mes y se sostiene durante ocho meses consecutivos; la señal después se apaga y vuelve a activarse con signo contrario dentro de la misma gestión, porque la rampa responde a la magnitud del sesgo y no a su signo. La traza mensual completa de la señal y del peso asignado se reproduce en el Anexo 10. Ese giro a signo negativo hacia el cierre

de la gestión aparece en las dos gestiones medidas, de modo que la oscilación de la señal no puede atribuirse solo al régimen de quiebre. Tres limitaciones se declaran. La primera es que la señal de 3 meses es ruidosa en gestiones normales, donde oscila entre −27,1 % y +33,9 % por la variación ordinaria de la demanda dentro y fuera de campaña. Esa señal activa el detector en 7 de los 12 meses de la gestión 2026, 5 de ellos con peso mayoritario o pleno sobre el conjunto diverso (Anexo 10). Esa activación cuesta 0,4 puntos de D a un paso como prima del seguro: 75,3 % del sistema conmutado frente a 74,9 % del promedio simple del conjunto curado. La segunda es que el conjunto diverso estático logra a un paso un desempeño comparable al del sistema conmutado sin requerir detector. La tercera es que el diseño del detector se definió retrospectivamente sobre las dos gestiones medidas, por lo que su validez plena queda supeditada a gestiones futuras.

Para la adopción, la lectura conjunta de la validación y de la extensión exploratoria recomienda un camino evolutivo. El motor de selección validado es la base auditada del sistema. Su primera evolución es la combinación de un conjunto curado de integrantes sólidos, con la advertencia, leída post hoc, de que un integrante débil erosiona la mezcla. A ella se suma la diversidad de sesgos como salvaguarda de régimen, sea mediante el conjunto diverso estático o mediante la conmutación gobernada por el sesgo móvil. Esa conmutación es el sistema con el mejor peor caso a un paso del estudio y una ventaja de efecto mediano a grande sobre el promedio móvil de 12 meses en ambas gestiones, que se sostiene con incertidumbre agrupada por SKU.

4.3.4 Valoración económica

La valoración económica tuvo como propósito estimar el impacto potencial que la implementación del motor automatizado de pronóstico de demanda generaría en NOVAPACK S.A. La estimación consideró principalmente los beneficios operativos, financieros y estratégicos asociados a la mejora de la precisión en la planificación de inventarios y abastecimiento.

4.3.4.1 Eficiencia operativa

Antes del desarrollo del motor, la elaboración de pronósticos requería entre 3 y 5 días de trabajo del área de planificación, según lo declarado por el informante clave IC-01 al describir el armado de las hojas de cálculo (Anexo 1). Dentro de ese rango, el equipo declaró durante la sesión de observación estructurada (Anexo 3) que la consolidación demanda aproximadamente 3 días antes de una reunión de validación de 2 horas. En ambos instrumentos la fuente del dato es la declaración de los responsables del proceso, no una medición cronometrada por el investigador; así se lo asume en esta valoración.

La automatización genera los pronósticos de las 1.668 series de la muestra, con sus métricas, tablas y figuras, en una sola corrida de menos de 40 minutos de cómputo y con mínima intervención humana. Son 37,4 minutos según la duración total que declara el manifiesto de la corrida registrada. El registro de flujo suma por etapas 37,4 minutos, 0,5 segundos más que el manifiesto: los dos registros usan relojes distintos (el manifiesto mide con el reloj del sistema entre el inicio de la corrida y su sellado; cada etapa, con un contador monotónico propio), y la diferencia se declara sin resolverse. La cifra de referencia de este trabajo es la del manifiesto. El manifiesto registra la plataforma de ejecución y la versión de Python, consistentes con el entorno local reproducible descrito en los recursos empleados, pero no registra procesador ni memoria: el tiempo informado corresponde a esa plataforma y no a un equipo de referencia especificado.

Tomando jornadas de 8 horas, los 37,4 minutos de cómputo que registra el manifiesto de la corrida equivalen al 2,6 % de los 3 días laborales declarados. Frente a los 5 días, equivalen al 1,6 %. Es decir, el tiempo de máquina representa menos del 3 % del tiempo de trabajo que el diagnóstico atribuye al armado y la consolidación de las hojas de cálculo. La comparación enfrenta magnitudes de naturaleza distinta, tiempo de cómputo frente a jornadas de personas, y también alcances distintos. Lo cronometrado es la corrida completa sobre las 1.668 series de la muestra, el 37,9 % de las 4.406 series de la población objetivo. El diagnóstico, en cambio, no delimita a qué conjunto de series corresponde el tiempo declarado para el armado manual. Por eso, ambos alcances no son directamente equiparables. Dentro de esa corrida, la mayor parte del tiempo corresponde a la evaluación multihorizonte de orígenes

rodantes. Se trata de un protocolo de validación que no se repetiría en el uso mensual. Las etapas que van de la carga de los datos a la selección del modelo por serie, con los hiperparámetros ya fijados, suman menos de 1 minuto. Así consta en el registro de etapas de la corrida (Anexo 9). La automatización tampoco sustituiría todo el proceso. La reunión de validación de 2 horas y el juicio comercial que fija la cifra final permanecerían. Lo que se liberaría es el tiempo dedicado al armado y la consolidación de las hojas de cálculo, que quedaría disponible para tareas de análisis.

La Tabla 11 condensa el contraste entre el proceso vigente y el propuesto en las dimensiones que el diagnóstico midió u observó:

Tabla 11
Contraste entre el proceso de planificación vigente y el proceso propuesto

Dimensión	Proceso actual (diagnóstico)	Proceso propuesto (motor)
Tiempo de elaboración	De 3 a 5 días de armado manual en hojas de cálculo, más una reunión de validación de 2 horas (Anexos 1 y 3)	37,4 minutos de cómputo por corrida completa sobre la muestra (alcance no equiparable al armado manual) y menos de 1 minuto hasta la selección por serie; la reunión de validación se conserva
Medición del error	Sin métricas de evaluación (MAE, MAPE o Bias) ni comparación sistemática contra la venta real (Tabla 5)	MAE, MAPE, RMSE y Bias por serie y métrica valorizada D, con D de 75,4 % frente a 100,0 % de la réplica de la fórmula base sin ajustes de consenso (Tabla 8)
Criterio de proyección	Nivel base (último mes o promedio móvil de 2 o 12 meses) más factor de crecimiento, con ajustes por juicio sin registro formal	Selección automática por serie entre diez modelos, con regla declarada y registro de las 1.668 asignaciones (Figura 9)
Trazabilidad	Planillas dispersas; las referencias usadas en la reunión difieren de la fórmula de las planillas (Anexo 3)	Manifiesto por corrida (huella SHA-256 de la captura, versiones y parámetros) y registro de flujo de las 15 etapas

Dimensión	Proceso actual (diagnóstico)	Proceso propuesto (motor)
Retroalimentación	Inexistente: el pronóstico anterior no se compara con las ventas reales (Tabla 5)	Previsto en el diseño (Figura 5): el motor mide su propio error por serie en cada corrida; la medición del plan consensuado frente a la venta real empieza en el piloto en paralelo y se incorpora al proceso en la segunda etapa de la hoja de ruta (apartado 4.4 y Tabla 12); el diseño de ese lazo (error por etapa y valor agregado del pronóstico en cada cierre mensual) está en el apartado 4.2.5.3 y en la Tabla 38
Registros auxiliares	Venta perdida, quiebres de inventario y tipo de cambio se llevan por separado y no alimentan la proyección	Quiebres, venta perdida, precio y tipo de cambio integrados como variables explicativas, con un aporte conjunto hoy inferior al 5 % (apartado 4.2.1.3 y Figura 6); el mismo registro de venta perdida delimita además el margen en juego (Tabla 6)

Nota. La columna del proceso actual resume los hallazgos del diagnóstico (Tablas 3 a 5 y Anexos 1 y 3); la del proceso propuesto, los resultados de este capítulo. Elaboración propia.

4.3.4.2 Optimización de inventarios

La literatura de gestión de la cadena de suministro sostiene que el error de pronóstico es uno de los factores que gobiernan el inventario de seguridad requerido y la frecuencia de las reposiciones de urgencia, junto con el plazo de reposición y el nivel de servicio objetivo, de modo que reducirlo disminuye la exposición a costos de almacenamiento y a compras no planificadas (Chopra, 2019), tal como se expuso en el marco teórico. Este trabajo retoma esa relación únicamente en su forma cualitativa y no le atribuye ninguna elasticidad numérica entre precisión y costo. Expresarla en términos monetarios exigiría parámetros de costo de faltante y de exceso de inventario de los que la empresa no dispone de forma sistematizada, según se detalla al cerrar este apartado. Ninguna salida del motor la mide. Eso se debe a que el costo unitario por combinación interviene en la valorización de la demanda y del error, no en la medición de costos de inventario.

En el caso de NOVAPACK S.A., el motor redujo la métrica de decisión D en la evaluación a un paso del bloque de prueba (gestión 2026). Las referencias eran 85,4 % con el promedio móvil de 12 meses y 100,0 % con su variante con factor de crecimiento, réplica de la fórmula base sin ajustes de consenso. El motor la dejó en 75,4 %: entre 10,0 y 24,6 puntos porcentuales de D según se tome la variante simple o la fórmula con factor de crecimiento (Tabla 8). Medida en error absoluto valorizado, la misma mejora asciende a entre 13,2 y 16,8 millones de bolivianos, magnitud que no es convertible en las brechas anteriores, porque D agrega al error absoluto el sesgo y las dos lecturas no coinciden. La base de ambos cálculos es la demanda valorizada al costo unitario del bloque de prueba, 122,5 millones de bolivianos. Esa cifra corresponde a las 1.513 series con costo unitario asignado, de las 1.668 que integran la muestra. Las 155 restantes carecen de ficha de costo vigente y quedan fuera de la agregación por valor de forma idéntica para todos los modelos comparados. Su peso en bolivianos no puede estimarse desde estas salidas. Sobre esa base, el error absoluto del motor asciende a 85,9 millones, frente a 99,0 del promedio móvil de doce meses y 102,7 de su variante con factor de crecimiento. Las diferencias entre esas magnitudes, calculadas sobre los valores sin redondear, son las cifras señaladas. Conviene declarar que, en esa misma unidad, LightGBM deja un error absoluto menor, 77,1 millones de bolivianos, 8,8 millones por debajo del motor. El criterio de adopción de este trabajo no es el error absoluto sino D. La razón es que el signo del sesgo agregado indica si el error se acumula como faltante o como exceso. El sesgo del motor, además, se sitúa en −5,3 % frente al −14,1 % de LightGBM (Tabla 8). La relación citada en el párrafo anterior es cualitativa y no un cálculo aplicable a estas cifras: el mecanismo por el que esta mejora se traduciría en menor costo no se cuantifica aquí, por la ausencia ya señalada de costos unitarios de faltante y de exceso sistematizados. Un menor error absoluto valorizado es desviación de pronóstico evitada, no un ahorro contable realizado.

Además, en campaña la subestimación de la demanda valorizada en los meses de pico pasa del −45,8 % del promedio móvil anual al −8,5 % del motor, según el error por temporada del bloque de prueba, de modo que una reducción de quiebres frente al nivel base anual de la fórmula de planificación de la empresa es plausible, pero

queda como hipótesis de impacto: el estudio pronostica ventas observadas y no mide quiebres ni nivel de servicio; el sesgo residual del motor sigue siendo de subestimación, por lo que el efecto es relativo y no absoluto. Como documenta el registro interno de venta perdida presentado en el diagnóstico (Tabla 6), la demanda no atendida por quiebre equivalió entre las gestiones 2022 y 2026 al 15,5 % de la demanda solicitada. Esa proporción fue del 16,3 % en los meses de pico de la campaña escolar, de diciembre a febrero. El registro muestra además una tendencia creciente, que alcanza el 18,4 % en las dos últimas gestiones. Se trata del registro bruto, sin depuración de valores atípicos, por lo que indica el orden de magnitud del margen en juego y no una cota: puede contener consultas repetidas y no registra la demanda que no llegó a consultarse.

4.3.4.3 Orden de magnitud del impacto económico

La empresa no tiene sistematizados los costos unitarios de faltante y de exceso de inventario. Este trabajo tampoco tuvo acceso a una valorización monetaria del costo operativo del área de planificación. Por esa razón la valoración se plantea en términos de orden de magnitud y no de retorno. Del lado del costo, este trabajo no valoriza la inversión: sus componentes son bibliotecas de código abierto, infraestructura de cómputo ya disponible y capacitación del personal que lo opera. A esos componentes se suma el costo humano recurrente de operación y mantenimiento, que tampoco se estima. Lo único medido es tiempo de cómputo: los 37,4 minutos que el manifiesto registra para la corrida completa del experimento. Esa corrida abarca la evaluación multihorizonte y el trazado de las figuras además de la generación del pronóstico, por lo que sobrestima lo que costaría una corrida de producción. Del lado de la exposición evitada, la única gestión de prueba disponible es la gestión 2026. En ella, la mejora de precisión frente a los métodos de referencia equivale a entre 13,2 y 16,8 millones de bolivianos de error absoluto valorizado evitado. Esos montos están medidos al costo unitario sobre las 1.513 series con costo de la muestra y sobre la base de 122,5 millones ya señalada. Esa equivalencia es una magnitud de exposición y no un ahorro contable, y al provenir de un único bloque de prueba no puede proyectarse sin más a las gestiones siguientes. Como referencia independiente del margen en juego sirve el

registro interno de venta perdida: bruto, sin depuración de valores atípicos, que indica un orden de magnitud y no una cota. Ese registro sitúa la demanda no atendida por quiebre en el 15,5 % de la demanda solicitada entre las gestiones 2022 y 2026, valorizada a precio de venta y sobre el registro completo (Tabla 6). Medida sobre el mismo universo que las cifras anteriores, es decir, al costo unitario, en la gestión de prueba y sobre las 1.513 series con costo, esa demanda no atendida asciende a 34,2 millones de bolivianos. Es una medición distinta y no la conversión de unidad de la anterior. El canal principal de ese valor no es la reducción de costos sino el nivel de servicio. Que un pronóstico más preciso en campaña reduzca los quiebres que hoy dejan demanda sin atender es una hipótesis de impacto y no un resultado: el motor pronostica las ventas observadas y su efecto sobre los quiebres no se midió. Ese efecto se propagaría además aguas arriba, al dotar a compras, producción y logística de visibilidad sobre la demanda esperada por combinación. La contraposición entre un costo marginal de minutos de cómputo y una exposición del orden de decenas de millones de bolivianos es, por tanto, cualitativa. Ni la inversión ni el retorno están cuantificados. Por eso este trabajo establece el orden de magnitud del beneficio y su mecanismo, y no un valor puntual de retorno. A las dos magnitudes medidas, el tiempo de cómputo y la exposición evitada, se suma un beneficio no cuantificado: el mejor aprovechamiento de los datos históricos como activo estratégico.

4.3.4.4 Conclusión de la valoración económica

En términos globales, la valoración económica sitúa el orden de magnitud del beneficio y describe su mecanismo. La rentabilidad puntual queda fuera del alcance. Ello se debe a la restricción de costos ya declarada y a que este trabajo no calculó ningún indicador de retorno. Lo medido es acotado y verificable. En precisión, sobre las 1.513 series con costo del bloque de prueba, el motor situó el error compuesto valorizado del portafolio (D) en 75,4 %. Esa cifra se compara con el 85,4 % del promedio móvil de 12 meses y con el 100,0 % de su variante con factor de crecimiento, réplica de la fórmula base sin ajustes de consenso. Así lo recoge la constatación técnica. En tiempo, la corrida completa sobre la muestra de 1.668 series se resolvió en menos de una hora de máquina, según la duración registrada en el manifiesto. Esa

corrida, además de los pronósticos, produce las métricas, las tablas, las figuras y la evaluación multihorizonte, en la que se concentra la mayor parte del cómputo. El diagnóstico declara, en cambio, 3 a 5 días para el armado manual de las hojas de cálculo. Sobre esa base, la implementación crearía las condiciones para reducir costos de inventario y compras no planificadas, efecto que este trabajo no cuantifica. A ello se suma un beneficio acreditado por artefactos: la trazabilidad de los pronósticos. Está documentada en el registro de flujo, que describe las 15 etapas de la corrida con sus entradas, salidas, decisiones, conteos, artefactos y duración. Está documentada también en el manifiesto, que fija el SHA-256 del archivo de ventas y del archivo de configuración, el commit del repositorio junto con el estado del árbol de trabajo y las versiones de las dependencias. Está documentada, por último, en el registro de selección, que deja asentado el modelo elegido para cada una de las 1.668 series. La mejora de la toma de decisiones y el fortalecimiento de la cultura de planificación basada en datos se enuncian como expectativas, sin medición en este trabajo.

En consecuencia, este capítulo deja demostrado que el motor automatizado de pronóstico de demanda es técnicamente viable sobre los datos reales de NOVAPACK S.A. En el bloque de prueba y sobre las 1.513 series con costo, el motor redujo el error compuesto valorizado del portafolio a una D de 75,4 %. El promedio móvil de doce meses quedó en 85,4 % y su variante con factor de crecimiento, réplica de la fórmula base sin ajustes de consenso, en 100,0 %. También deja demostrado que la corrida completa, con sus métricas, tablas y figuras, se resolvió en menos de una hora de cómputo, 37,4 minutos según el manifiesto de trazabilidad. Ese tiempo se contrapone, con alcances no equiparables (apartado 4.3.4.1), a los 3 a 5 días que el informante clave IC-01 atribuye al armado manual de las hojas de cálculo (Anexo 1). No se calculó, en cambio, ningún indicador de retorno de la inversión: ni el ROI, ni el valor actual neto (VAN), ni la tasa interna de retorno (TIR), ni el período de recuperación, porque los costos unitarios de faltante y de exceso de inventario no están sistematizados en la empresa. La decisión de adopción se apoya, por lo tanto, en la mejora de precisión aquí medida, en el tiempo de cómputo registrado y en el orden de magnitud del beneficio estimado en el apartado anterior, y no en un valor puntual de rentabilidad.

4.4 Hoja de ruta de implementación propuesta

El alcance propositivo del estudio excluye la puesta en producción del motor; no obstante, del diseño y de su validación se deriva una hoja de ruta concreta para llevarlo a la operación. Se propone en tres etapas secuenciales, sin fechas comprometidas: la duración mínima de cada etapa la fija el protocolo de la Tabla 12, y su inicio dependería de la disponibilidad de los recursos previstos en el apartado 4.2.6.2.

La primera etapa es un piloto en paralelo. El motor se ejecutaría cada mes sobre la captura vigente, sin sustituir el procedimiento actual. Ambos números, el del motor y el de las hojas de cálculo, llegarían a la reunión de planificación. El error de cada uno frente a la venta real se mediría con las mismas métricas del estudio. Esta convivencia acota el riesgo de adopción y produce la evidencia interna que la decisión de reemplazo requiere. Las etapas que van de la carga de los datos a la selección por serie suman menos de 1 minuto de cómputo. El costo de cómputo del paralelo es, por tanto, marginal; el costo humano de operarlo corresponde a la dotación del apartado 4.2.6.2 y no se estimó en este trabajo.

Además de las lecturas previstas en las recomendaciones, el piloto separaría las series que cumplen los criterios de la muestra, pronosticadas con la configuración validada y comparables con la constatación del estudio, de las restantes, tratadas con las reglas del apartado 4.2.3 y agrupadas por estado y meses de historia, cuyo error se mediría por primera vez. Si el modelo global se entrenara sobre la población completa, la primera lectura verificaría que esa ampliación no degrada el resultado validado. Planificación validaría el maestro de equivalencias, los análogos de los productos nuevos y las marcas de calidad.

La segunda etapa es la adopción del motor como número base. Verificada la ventaja en el piloto con la regla de la Tabla 12, el pronóstico del motor pasaría a ser, por categorías y de manera escalonada, la cifra inicial de la reunión de consenso, en reemplazo del armado manual. El juicio del área comercial se conservaría como ajuste registrado sobre esa base. De ese modo, la diferencia entre el número del motor y el

número consensuado quedaría documentada y podría auditarse contra la venta real. Con ello se cierra el lazo de retroalimentación de la Figura 5.

La tercera etapa es la operación sostenida y la evolución. Con el motor en régimen, la mejora continua seguiría las líneas que la validación dejó señaladas. La primera es recalibrar periódicamente los hiperparámetros del modelo global. La segunda es evaluar la combinación de pronósticos y la conmutación por régimen exploradas en el apartado 4.3.3, antes de promoverlas al protocolo confirmatorio. La tercera es ampliar gradualmente las variables externas en el orden previsto en las recomendaciones. Esta etapa requiere la dotación descrita en el apartado 4.2.6.2, en particular el científico de datos que opere y mantenga el motor y el soporte de tecnologías de la información que programe la corrida mensual.

Cada etapa de la hoja de ruta tendría, así, un alcance técnico acotado dentro de la arquitectura propuesta en el apartado 4.2.5. El piloto en paralelo necesitaría el orquestador, el núcleo con la partición operativa, el almacén de corridas y el visor ya construido, y llevaría el pronóstico a la reunión como un archivo con huella; la API podría limitarse a la consulta. La adopción como número base activaría el contrato por etapa de la Tabla 38, el registro de ajustes y el plan consensuado con versión y huella, y la medición del error y del valor agregado de cada etapa, iniciada en el piloto, quedaría sostenida al cierre de cada mes, con lo que se cerraría el lazo de la Figura 5. La operación sostenida sumaría los módulos opcionales en sombra, la señal de régimen, la recalibración por gestión cerrada, las alertas de la Tabla 39 y la programación de la corrida a cargo del soporte de TI. El tiempo de la corrida mensual completa, con la proyección a doce meses incluida, se mediría en el piloto, antes de dimensionar la infraestructura de las etapas siguientes.

La constatación de este trabajo es retrospectiva por diseño. La evaluación con orígenes rodantes sobre un bloque de prueba ajeno a la selección y al ajuste de los modelos es el protocolo con que la literatura de pronóstico estima el desempeño fuera de muestra (Bergmeir & Benítez, 2012; Tashman, 2000), y reproduce en cada origen la información que habría estado disponible. Lo que ese protocolo no puede medir es el efecto del motor sobre la operación, porque los quiebres, la venta perdida, el

inventario y el tiempo del proceso dependen además de las decisiones de compra y abastecimiento que el pronóstico alimenta. Por eso la hoja de ruta incorpora un protocolo de medición del impacto operativo, resumido en la Tabla 12. En el piloto en paralelo el número que gobierna las compras sigue siendo el vigente, de modo que esa etapa mide la precisión y el valor agregado de cada etapa del plan, no el impacto. El impacto se mediría en la adopción, que se haría de manera escalonada: las categorías que adoptan primero el número del motor se compararían, en los mismos meses, con las que siguen con el procedimiento vigente, un diseño cuasiexperimental con grupos intactos en los términos de Hernández Sampieri et al. (2014), con la diferencia antes y después entre ambos grupos como estimación del efecto. Ninguno de los indicadores de impacto de la adopción lleva umbral previo: son las hipótesis de impacto de este trabajo, y se informarían con su intervalo de incertidumbre agrupado por SKU, como en la Tabla 20.

Tabla 12

Protocolo de medición del impacto operativo en la hoja de ruta de implementación

Etapa y diseño	Duración	Indicador	Línea base del estudio	Regla de decisión o lectura	Mide / decide
1. Piloto en paralelo: el número del motor y el del procedimiento actual llegan a la reunión; las compras siguen el vigente	Una gestión completa (doce cierres), con lectura intermedia al cerrar la campaña escolar	D valorizada a un paso del motor, de la propuesta de Planificación y del plan consensuado, con la cifra vigente un mes antes	Gestión 2026, retrospectiva: motor 75,4 %; réplica de la fórmula 100,0 % (Tabla 8)	Adopción si la D del motor queda más de un punto por debajo de la de la propuesta de Planificación en la gestión y en la campaña, y nunca por encima de la referencia ingenua	El científico de datos mide; Planificación valida; la jefatura de Planificación decide
Ídem	Ídem	Error y FVA de cada etapa del plan (Tabla 38)	Inexistente (Tabla 5)	Se informa, sin umbral	Ídem

Etapa y diseño	Duración	Indicador	Línea base del estudio	Regla de decisión o lectura	Mide / decide
Ídem	Ídem	Sesgo valorizado móvil de tres meses	Tabla 39	Alerta si supera 20 % en valor absoluto dos meses seguidos con el mismo signo	Ídem
2. Adopción escalonada por categoría: las que adoptan frente a las que siguen con el procedimiento vigente, en los mismos meses	Una gestión por tramo de adopción	Quiebres: semanas con existencia cero por SKU y regional (inventario semanal)	Registro desde abril de 2022 (apartado 3.4.3 y Tabla 5)	Diferencia antes y después entre grupos, con intervalo agrupado por SKU; sin umbral previo	El científico de datos mide; TI provee el inventario; la dirección recibe el informe
Ídem	Ídem	Venta perdida registrada sobre la demanda solicitada	15,5 % en las gestiones 2022 a 2026 y 18,4 % en las dos últimas (Tabla 6); registro bruto	Ídem, después de depurar las consultas repetidas, como proponen las recomendacion es	Ídem
Ídem	Ídem	Inventario valorizado a costo (inventario semanal por costo unitario)	No medido en el estudio	Ídem	Ídem
Ídem	Ídem	Horas del área dedicadas a armar y consolidar el plan	3 a 5 días declarados (Anexos 1 y 3)	Registro de horas durante el piloto y la adopción; reemplaza la declaración por una medición	Planificación registra; el científico de datos consolida
3. Operación sostenida	Cada gestión cerrada	D por gestión, tasa de acierto y reparto de la selección	Tabla 39	Recalibración nivel (ii) con la puerta de un punto (apartado 4.2.5.6)	El científico de datos y la jefatura de Planificación

Nota. Las líneas base de la etapa 1 son retrospectivas y no se comparan directamente con las del piloto: el piloto compara, en los mismos meses, el motor con la propuesta real de Planificación. La campaña escolar va de noviembre a febrero.

Los indicadores de la etapa 2 son las hipótesis de impacto del apartado 4.3.4.
Elaboración propia.

CONCLUSIONES

La presente investigación tuvo como propósito diseñar un motor híbrido y automatizado de pronóstico de demanda basado en series temporales, integrando modelos estadísticos y de aprendizaje automático para mejorar la precisión en la planificación de la demanda de NOVAPACK S.A. A partir de los resultados obtenidos, se comprobó la viabilidad técnica y metodológica del enfoque propuesto. En la evaluación a un paso, el motor redujo el error de pronóstico de las ventas mensuales observadas frente a la réplica de la fórmula base sin ajustes de consenso y frente al promedio móvil de 12 meses, con diferencias que se sostienen con incertidumbre agrupada por SKU (Tabla 20 del Anexo 8). Frente al modelo ingenuo, la diferencia por serie es evidencia descriptiva del conjunto evaluado; solo la menor D del portafolio se sostiene por SKU, y no al remuestrear meses. Se estimó, además, un potencial de mejora en la eficiencia operativa del proceso de planificación, a partir del tiempo de cómputo observado frente al tiempo declarado del procedimiento manual vigente.

El análisis teórico y metodológico permitió establecer una base conceptual sólida sobre los modelos de pronóstico, destacando la complementariedad entre los enfoques estadísticos y los de aprendizaje automático. Se determinó que los métodos tradicionales ofrecen estabilidad en series regulares bajo régimen estable, y que dos de ellos, el promedio móvil anual y Holt-Winters, resultaron en la extensión exploratoria los más frágiles ante el cambio de régimen, mientras que los modelos de aprendizaje automático presentan mayor capacidad de adaptación frente a patrones de demanda complejos o irregulares. Esta comprensión fundamentó la propuesta de integrar ambos enfoques dentro de un sistema híbrido y automatizado.

El diagnóstico del proceso actual de planificación evidenció una alta dependencia de procedimientos manuales y empíricos, carentes de métricas de evaluación y de retroalimentación estadística. El análisis de los datos históricos de ventas (2017–2026) permitió identificar estacionalidades marcadas y diferencias

cuantificables entre regionales, lo que confirmó la necesidad de una herramienta que optimice la estimación de la demanda y reduzca los márgenes de error en la toma de decisiones. La triangulación de esos hallazgos derivó siete requisitos de diseño (Tabla 7), que el motor atiende uno por uno, dos de ellos solo en parte (Tabla 27 del Anexo 12).

El desarrollo del motor híbrido propuesto permitió estructurar una arquitectura funcional basada en la metodología CRISP-DM, que integra diez modelos estadísticos y de aprendizaje automático bajo un criterio único de selección por serie. Este diseño modular posibilita la automatización completa del proceso de pronóstico, aplicando un criterio reproducible y auditable que selecciona, para cada combinación SKU-canal-regional, el candidato de menor error compuesto en la ventana de validación. Asimismo, su arquitectura extensible facilita la incorporación de nuevos algoritmos o variables explicativas, como lo evidenció la extensión exploratoria, que sumó cinco pronosticadores adicionales bajo la misma partición, la misma métrica y las mismas reglas de no fuga, con código adicional en el módulo de modelado y un entorno de ejecución propio, sin alterar la estructura de cinco módulos del núcleo. Con quince candidatos, la selección por serie empeoró (de 74,6 % a 79,9 % con el mismo criterio multihorizonte) mientras las mezclas de cinco pronosticadores curados superaron al motor validado (en la D del portafolio, como evidencia descriptiva del conjunto evaluado; Tabla 21 del Anexo 8), lo que indica que la extensibilidad exige curar los candidatos y no solo sumar más.

El diseño se completa con la propuesta para su operación, que este trabajo no midió ni la empresa opera. Esa propuesta fija una política de tratamiento de datos por estado de actividad y meses de historia (apartado 4.2.3), un protocolo para los eventos exógenos con registro declarado, dueño y tratamientos definidos de antemano (apartado 4.2.4) y una arquitectura de microservicio para la corrida mensual (apartado 4.2.5): lectura de la base de datos por vistas de contrato, publicación del pronóstico base a la plataforma de planificación colaborativa que la empresa adopte, medición del error por etapa, observabilidad del servicio y una política de reentrenamiento en tres niveles en la que la promoción de un modelo nunca es automática. Los contratos y las señales que la sostienen se detallan en los Anexos 14 y 15.

La validación técnica demostró que, en la evaluación a un paso, el motor de selección automática alcanza el menor error compuesto valorizado del portafolio (D = 75,4 %), frente al 85,4 % del promedio móvil de 12 meses y al 100,0 % de su variante con factor de crecimiento, réplica de la fórmula base sin ajustes de consenso del plan final; la conclusión se limita a esa réplica: el plan final consensuado incorpora recortes por suministro y ajustes de juicio, y su error no es comparable con el de un pronóstico de demanda (apartado 3.4.3).

Ese 75,4 % corresponde a la cohorte evaluable, las 1.668 series con venta en el bloque de prueba; sin exigir esa venta (1.812 series) o con solo las series activas al origen de la prueba (1.661), el motor conserva la menor D de los once modelos (75,1 % y 74,5 %, frente a 100,0 % y 98,8 % de la réplica de la fórmula base sin ajustes de consenso), según el análisis de sensibilidad del apartado 4.3.2 y de la Tabla 25 del Anexo 11.

El contraste estadístico, cuya evidencia principal son los intervalos con incertidumbre agrupada por SKU y por bloques de meses (Tabla 20 del Anexo 8), mostró que la diferencia frente a esa réplica se sostiene en las tres magnitudes medidas y en los dos esquemas (diferencia de D de −24,6 puntos, intervalo al 95 % por SKU de −32,0 a −17,0) y es de efecto grande en la prueba por serie, complementaria (Wilcoxon unilateral, $p < 0,001$; $r = −0,53$). Frente al promedio móvil simple de 12 meses, más exigente que su variante con factor en la gestión de prueba y por tanto patrón de comparación más conservador que esa réplica, la diferencia también se sostiene con incertidumbre agrupada por SKU en las tres magnitudes, aunque al remuestrear meses el intervalo de la mediana llega al cero, y es de efecto mediano ($r = −0,31$; el motor obtiene menor error en el 57,1 % de las series, 952 de 1.668). Frente al modelo ingenuo, la diferencia por serie no se sostiene en ninguno de los dos esquemas y es de efecto insignificante ($r = −0,09$), mientras que la menor D del motor a un paso se sostiene por SKU, pero no al remuestrear meses; la ventaja del motor sobre él en el horizonte (91,2 % frente a 120,5 %) no tiene intervalo agrupado y es, como la diferencia por serie, evidencia descriptiva del conjunto evaluado. La prueba de Friedman, complementaria y que también trata las series como

independientes, rechazó la igualdad de los once modelos comparados ($\chi^2 = 1.897{,}3$; $p < 0{,}001$).

La evaluación multihorizonte agregó el matiz decisivo: el modelo de aprendizaje automático es el que sostiene el horizonte de planificación (D global de 71,9 %), hallazgo que fundamenta la evolución del criterio de selección hacia el desempeño multihorizonte. La confirmación de la hipótesis frente al promedio móvil de 12 meses, con y sin factor de crecimiento, descansa en los intervalos agrupados por SKU y, como complemento, en el contraste pareado a un paso ya señalados, medidos sobre las ventas observadas.

La extensión exploratoria posterior a la validación aportó dos hallazgos que delimitan la evolución del sistema. Primero, la combinación de pronósticos superó a la selección en el conjunto evaluado: el promedio simple de cinco pronosticadores curados redujo el error compuesto valorizado a un paso de 75,4 % a 74,9 % en la gestión normal, y su variante ponderada por validación a 74,0 %, por el promedio de errores no correlacionados, que en el promedio simple bajó el WMAPE de 70,1 % a 64,5 % a costa de un sesgo mayor (−10,4 % frente a −5,3 %); una lectura post hoc mostró además la condición de esa ventaja: un integrante débil la erosiona en lugar de ampliarla (70,0 % sin él). Esas reducciones de la D frente al motor validado son evidencia descriptiva del conjunto evaluado, porque sus intervalos agrupados por SKU contienen el cero, mientras que la menor diferencia mediana por serie de las dos mezclas sí se sostiene con incertidumbre agrupada por SKU, aunque no al remuestrear meses (Tabla 21). Segundo, la repetición del protocolo completo sobre una segunda gestión de prueba (la del inicio de la crisis cambiaria) mostró que ningún conjunto fijo domina ambos regímenes: el curado del año normal comparte el signo del sesgo en el quiebre y cede el podio a los que incluyen contrapeso de sesgos. Un sistema de conmutación por régimen, gobernado por el sesgo móvil ya observado con umbrales declarados, obtuvo el mejor peor caso a un paso del estudio y una ventaja sobre el promedio móvil de 12 meses que se sostiene con incertidumbre agrupada por SKU en ambas gestiones (diferencia de D de −10,1 y −38,9 puntos; Tabla 21), con sus limitaciones expresamente declaradas.

En conclusión, los resultados obtenidos evidencian que la integración de técnicas de analítica avanzada en un motor híbrido de pronóstico representa una vía técnicamente viable para mejorar la precisión del pronóstico en la planificación de la demanda; el fortalecimiento de la gestión empresarial basada en datos queda como expectativa, sin medición en este trabajo. La propuesta desarrollada demuestra su viabilidad técnica sobre datos reales de la empresa, mediante una evaluación retrospectiva controlada sobre información histórica, y su potencial para mejorar la eficiencia operativa de NOVAPACK S.A. Como el motor pronostica las ventas observadas y no la demanda solicitada, sus efectos sobre los quiebres, el nivel de servicio y los costos de inventario quedan como hipótesis de impacto que este trabajo no midió, y la desviación de pronóstico evitada no equivale a un ahorro contable ni a un retorno de la inversión. A futuro, se espera que su implementación operativa, con la medición del impacto prevista en la Tabla 12, el traslado del criterio de selección al desempeño multihorizonte y la incorporación de nuevos algoritmos y de variables externas adicionales a las ya integradas (precio, quiebres de inventario, venta perdida y tipo de cambio) permitan ampliar su capacidad predictiva y consolidarlo como una herramienta estratégica para la toma de decisiones en la empresa.

RECOMENDACIONES

A partir de los resultados obtenidos y del cumplimiento de los objetivos planteados en la presente investigación, se formulan las siguientes recomendaciones orientadas a fortalecer la gestión de la planificación de la demanda en NOVAPACK S.A. y a promover la sostenibilidad técnica del sistema propuesto:

Implementar progresivamente el motor automatizado de pronóstico, iniciando con el piloto en paralelo, primera etapa de la hoja de ruta (apartado 4.4), sobre la captura vigente, con dos lecturas separadas: la de los SKU que concentran el 80 % del valor (Figura 16 del Anexo 11), donde el impacto de la mejora sobre el error valorizado es mayor, y la del estrato estacional, donde la ventaja del motor sobre el mejor método estadístico a un paso es más amplia (Tabla 9), las dos con el protocolo de medición de la Tabla 12. Se espera que esta etapa permita ajustar parámetros, validar la estabilidad del modelo y facilitar la adopción gradual del sistema por parte del equipo de planificación.

Integrar el motor con la base de datos de la empresa mediante vistas de contrato de solo lectura y un esquema propio de escritura, según la arquitectura de microservicio propuesta en el apartado 4.2.5, y con la plataforma de planificación colaborativa que la empresa adopte, publicando el pronóstico base de cada corrida y leyendo de vuelta el plan consensuado, de modo que los pronósticos generados se actualicen en cada cierre mensual y se sincronicen con los procesos de compras, inventario y distribución. Antes de comprometer infraestructura, medir en el piloto el tiempo del núcleo, con la proyección a doce meses incluida, sobre la población completa de series.

Capacitar al personal del área de planificación y tecnología en el uso, interpretación y mantenimiento del motor. La apropiación interna de la herramienta es fundamental para garantizar su sostenibilidad y aprovechar plenamente sus capacidades analíticas.

Establecer un sistema de control y retroalimentación continua, basado en las métricas de precisión del estudio (MAE, MAPE, RMSE, Bias y el error compuesto valorizado D), que permita monitorear el desempeño de los pronósticos y realizar ajustes periódicos a los modelos utilizados.

Completar ese control con la medición del error de cada etapa del plan y de su valor agregado frente a la etapa anterior, con el sesgo valorizado móvil como alerta de umbrales iniciales revisables con cada gestión cerrada y con la tasa de acierto de la selección frente al azar, y sostenerlo con las prácticas de operación de modelos de la Tabla 40 del Anexo 15: registro de los modelos entrenados, integración continua con las pruebas como compuerta, recalibración por gestión cerrada con campeón y retador en sombra, y reversión a la corrida anterior, de acuerdo con la política de reentrenamiento del apartado 4.2.5.6.

Trasladar el criterio de selección del motor del error a un paso al desempeño multihorizonte, de modo que la elección de modelo por serie refleje el horizonte real con que planifica la empresa; en la corrida de ablación del estudio, este cambio de criterio redujo la D global del motor en el horizonte de 91,2 % a 82,8 % y mejoró levemente su error a un paso (de 75,4 % a 74,6 %), sin alterar su posición detrás de LightGBM y de Holt-Winters en el horizonte; el traslado no impide por sí solo la elección de brazos que divergen en el horizonte (en esa misma corrida, la selección multihorizonte asignó 232 de las 1.668 series a las variantes con factor de crecimiento, frente a 206 con el criterio a un paso), por lo que conviene acompañarlo de la exclusión de esos brazos del conjunto operativo de candidatos.

Recalibrar los hiperparámetros del modelo global con cada gestión cerrada, con el protocolo del estudio (pliegue interno igual a la última gestión del entrenamiento, D interna valorizada, búsqueda TPE con semilla fija y tabla de ensayos publicada), y cuando el sesgo valorizado móvil indique un cambio de régimen, tras el cual las configuraciones que elige la búsqueda no conservan su desempeño; evaluar como criterio de la búsqueda la D multihorizonte del pliegue interno, en paralelo con el traslado del criterio del motor; ampliar el rango de la L2, cuyo valor elegido quedó cerca del techo explorado, e incorporar a la búsqueda la penalización L1 y la regularización

de las variables categóricas, hoy por defecto (apartado 4.2.1.3); y adoptar una configuración nueva solo si reduce la D interna en más de un punto porcentual sin perder estabilidad en el horizonte.

Evolucionar el motor hacia la combinación de pronósticos medida en la extensión exploratoria. En la etapa de evolución prevista en la hoja de ruta (apartado 4.4), evaluar en paralelo al motor validado el promedio del conjunto curado de cinco integrantes medido en la extensión (LightGBM, el fundacional calibrado, el suavizado exponencial, Holt-Winters y TFT), que requiere el entorno adicional con aceleración gráfica declarado en el apartado 4.3.3, y revisar su composición con cada gestión cerrada, pues la medición mostró que un integrante débil erosiona la mezcla. Adoptar ese promedio como pronóstico operativo solo después de validarlo bajo el protocolo confirmatorio con al menos una gestión cerrada adicional, y mantener la selección por serie como base auditada de comparación. Incorporar, además, el monitoreo del sesgo valorizado móvil como salvaguarda de régimen, conmutando hacia la mezcla con contrapeso de sesgos cuando la señal supere los umbrales declarados. La señal y sus umbrales deben revisarse con cada gestión cerrada, dado que su diseño se calibró retrospectivamente sobre las dos gestiones disponibles.

Fortalecer la calidad y consistencia de los datos históricos, implementando procedimientos de depuración, registro y almacenamiento centralizado y, en particular, extendiendo hacia atrás y sosteniendo el registro de quiebres de inventario y de tipo de cambio, hoy limitado a 48 meses. La precisión del pronóstico depende directamente de la integridad de los datos de entrada.

Formalizar, antes del piloto, el tratamiento de datos propuesto en el apartado 4.2.3: versionar el maestro de equivalencias con el factor, el tipo y la fecha de vigencia de cada reemplazo; completar la ficha de costo de los 31 SKU de la muestra que no la tienen e imputar mientras tanto su costo, con marca; incorporar a la captura el precio efectivo mensual (neto facturado sobre cantidad) que el histórico de ventas ya registra, en lugar del precio de lista vigente, para que el modelo pueda ver cambios de precio y promociones; sostener los registros de quiebres y de venta perdida, depurando las consultas repetidas, para que la demanda solicitada (ventas más venta perdida) pueda

evaluarse como objetivo alternativo cuando el registro acumule historia (Tabla 30 del Anexo 14); completar los atributos logísticos del maestro (peso y volumen); y deduplicar en la ingesta las filas repetidas íntegramente.

Evaluar periódicamente la inclusión de nuevos modelos predictivos, tales como XGBoost (Chen & Guestrin, 2016), alternativa de la misma familia de boosting por gradiente que permite contrastar la implementación adoptada, o Prophet (Taylor & Letham, 2018), cuyo tratamiento nativo del calendario de eventos aborda el hueco que la propia extensión exploratoria identificó en el sesgo de campaña, y profundizar la evaluación de las arquitecturas neuronales y del modelo fundacional medidos en la extensión exploratoria, con el fin de mantener actualizado el sistema y adaptarlo a posibles cambios en los patrones de demanda.

Ampliar la aplicación del motor a otras áreas de la empresa, como planificación de compras, logística o producción, aprovechando su estructura modular para generar pronósticos operativos y estratégicos de manera integrada.

Desarrollar investigaciones futuras orientadas a incorporar variables externas adicionales a las ya integradas (precio, quiebres de inventario, venta perdida y tipo de cambio) en este orden: primero el calendario escolar y las promociones, por el sesgo de campaña documentado y por el campo de promociones incompleto en la fuente, y luego las condiciones macroeconómicas y el clima; así como técnicas de reconciliación jerárquica entre los niveles SKU, canal y regional, que permitan mejorar la capacidad explicativa del modelo y aumentar su valor predictivo en contextos complejos.

Pronosticar también la demanda solicitada, es decir, las ventas más la venta perdida registrada, y medir el valor agregado del pronóstico contra ella, cuando el registro interno de venta perdida esté sistematizado, validado y cubra una historia suficiente: en la captura del estudio ese registro es sustantivo recién desde la gestión 2022 y se tomó en bruto, por lo que el motor pronostica ventas observadas y usa la venta perdida y los quiebres como variables explicativas (Tabla 6, Tabla 30 y apartado 4.3.4).

Institucionalizar el registro de eventos exógenos del apartado 4.2.4 como insumo declarado del motor, administrado por el área de planificación y alimentado por

el área comercial en la reunión mensual de planificación; sostener desde ahora el registro de promociones y de cambios de lista de precios, para tratarlos como variables conocidas a futuro tras dos gestiones; adoptar cada tratamiento de eventos solo después de una ablación con y sin él sobre una gestión cerrada; y extender, una vez validado, el detector de régimen a alcances de categoría y regional.

En conjunto, estas recomendaciones buscan consolidar la adopción efectiva del motor de pronóstico, promover la toma de decisiones basadas en datos y contribuir a la transformación digital de los procesos de planificación en NOVAPACK S.A., con miras a un uso sostenible y estratégico de la analítica avanzada en la gestión empresarial.

REFERENCIAS BIBLIOGRÁFICAS

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623–2631). ACM. https://doi.org/10.1145/3292500.3330701

Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Pineda Arango, S., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M., & Wang, Y. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*. https://openreview.net/forum?id=gerNCVqqtR

Asamblea Legislativa Plurinacional. (2011). *Ley N.º 164, Ley General de Telecomunicaciones, Tecnologías de Información y Comunicación.* Gaceta Oficial del Estado Plurinacional de Bolivia.

Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly, 20*(4), 451–468. https://doi.org/10.1057/jors.1969.103

Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences, 191*, 192–213. https://doi.org/10.1016/j.ins.2011.12.028

Bergstra, J., Bardenet, R., Bengio, Y., & Kégl, B. (2011). Algorithms for hyper-parameter optimization. En J. Shawe-Taylor, R. Zemel, P. Bartlett, F. Pereira, & K. Weinberger (Eds.), *Advances in Neural Information Processing Systems 24.* Curran Associates. https://proceedings.neurips.cc/paper_files/paper/2011/hash/86e8f7ab32cfd12577bc2619bc635690-Abstract.html

Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research, 13*(10), 281–305. https://www.jmlr.org/papers/v13/bergstra12a.html

Box, G. E. P., & Tiao, G. C. (1975). Intervention analysis with applications to economic and environmental problems. *Journal of the American Statistical Association, 70*(349), 70–79. https://doi.org/10.1080/01621459.1975.10480264

Boylan, J. E., & Syntetos, A. A. (2021). *Intermittent demand forecasting: Context, methods and applications.* John Wiley & Sons. https://doi.org/10.1002/9781119135289

Castro Morales, U. M. (2024). *Pronóstico de ventas a corto plazo en el sector de consumo masivo a través de modelos de machine learning* [Trabajo de grado de maestría, Universidad de los Andes]. Repositorio Séneca. https://hdl.handle.net/1992/73287

Challu, C., Olivares, K. G., Oreshkin, B. N., Garza Ramírez, F., Mergenthaler Canseco, M., & Dubrawski, A. (2023). NHITS: Neural hierarchical interpolation for time series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence, 37*(6), 6989–6997. https://doi.org/10.1609/aaai.v37i6.25854

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Chollet, F. (2018). *Deep learning with Python.* Manning Publications.

Chopra, S. (2019). *Supply chain management: Strategy, planning, and operation* (7.ª ed.). Pearson.

Clemen, R. T. (1989). Combining forecasts: A review and annotated bibliography. *International Journal of Forecasting, 5*(4), 559–583. https://doi.org/10.1016/0169-2070(89)90012-5

Comisión de la Comunidad Andina. (2000). *Decisión 486: Régimen común sobre propiedad industrial.* Gaceta Oficial del Acuerdo de Cartagena n.º 600. https://www.wipo.int/wipolex/es/legislation/details/9451

Congreso Nacional. (1992). *Ley N.º 1322, Ley de Derecho de Autor.* Gaceta Oficial de Bolivia.

Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly, 23*(3), 289–303. https://doi.org/10.1057/jors.1972.50

DAMA International. (2017). *DAMA-DMBOK: Data management body of knowledge* (2.ª ed.). Technics Publications.

Davydenko, A., & Fildes, R. (2013). Measuring forecasting accuracy: The case of judgmental adjustments to SKU-level demand forecasts. *International Journal of Forecasting, 29*(3), 510–522. https://doi.org/10.1016/j.ijforecast.2012.09.002

Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research, 7*(1), 1–30. https://www.jmlr.org/papers/v7/demsar06a.html

Estado Plurinacional de Bolivia. (2009). *Constitución Política del Estado.* Gaceta Oficial del Estado Plurinacional de Bolivia.

Fildes, R., Goodwin, P., Lawrence, M., & Nikolopoulos, K. (2009). Effective forecasting and judgmental adjustments: An empirical evaluation and strategies for improvement in supply-chain planning. *International Journal of Forecasting, 25*(1), 3–23. https://doi.org/10.1016/j.ijforecast.2008.11.010

Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys, 46*(4), Artículo 44. https://doi.org/10.1145/2523813

Gilliland, M. (2010). *The business forecasting deal: Exposing myths, eliminating bad practices, providing practical solutions.* Wiley. https://doi.org/10.1002/9781119199885

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, M. del P. (2014). *Metodología de la investigación* (6.ª ed.). McGraw-Hill Education.

Huber, J., & Stuckenschmidt, H. (2020). Daily retail demand forecasting using machine learning with emphasis on calendric special days. *International Journal of Forecasting, 36*(4), 1420–1438. https://doi.org/10.1016/j.ijforecast.2020.02.005

Hurtado de Barrera, J. (2010). *Metodología de la investigación: Guía para la comprensión holística de la ciencia* (4.ª ed.). Quirón Ediciones; Fundación Sypal.

Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2.ª ed.). OTexts. https://otexts.com/fpp2/

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679–688. https://doi.org/10.1016/j.ijforecast.2006.03.001

Hyndman, R. J., Koehler, A. B., Ord, J. K., & Snyder, R. D. (2008). *Forecasting with exponential smoothing: The state space approach.* Springer. https://doi.org/10.1007/978-3-540-71918-2

Hyndman, R. J., Koehler, A. B., Snyder, R. D., & Grose, S. (2002). A state space framework for automatic forecasting using exponential smoothing methods. *International Journal of Forecasting, 18*(3), 439–454. https://doi.org/10.1016/S0169-2070(01)00110-8

International Organization for Standardization & International Electrotechnical Commission. (2022). *Information security, cybersecurity and privacy protection: Information security management systems: Requirements* (Norma ISO/IEC n.º 27001:2022). https://www.iso.org/standard/27001

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. En I. Guyon, U. von

Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems 30.* Curran Associates. https://proceedings.neurips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

Kolassa, S. (2016). Evaluating predictive count data distributions in retail sales forecasting. *International Journal of Forecasting, 32*(3), 788–803. https://doi.org/10.1016/j.ijforecast.2015.12.004

Kreuzberger, D., Kühl, N., & Hirschl, S. (2023). Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access, 11*, 31866–31879. https://doi.org/10.1109/ACCESS.2023.3262138

Kruchten, P. B. (1995). The 4+1 view model of architecture. *IEEE Software, 12*(6), 42–50. https://doi.org/10.1109/52.469759

Kuhn, M., & Johnson, K. (2013). *Applied predictive modeling.* Springer. https://doi.org/10.1007/978-1-4614-6849-3

Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting, 37*(4), 1748–1764. https://doi.org/10.1016/j.ijforecast.2021.03.012

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence, 2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9

Maciel Carpio, Z. X., Salas Barrera, F. A., Sánchez Anticona, C. S., Sánchez Chacón, G. de los A., & Santana Fernández, J. D. (2023). *Aplicación de modelos de Machine Learning para la planificación de la demanda en la empresa CBC Peruana S.A.C.* [Trabajo de suficiencia profesional, Universidad ESAN]. Repositorio Institucional Universidad ESAN. https://hdl.handle.net/20.500.12640/3891

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods: Concerns and ways forward. *PLOS ONE, 13*(3), Artículo e0194889. https://doi.org/10.1371/journal.pone.0194889

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting, 36*(1), 54–74. https://doi.org/10.1016/j.ijforecast.2019.04.014

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting, 38*(4), 1346–1364. https://doi.org/10.1016/j.ijforecast.2021.11.013

Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting, 37*(4), 1632–1653. https://doi.org/10.1016/j.ijforecast.2021.03.004

Newman, S. (2021). *Building microservices: Designing fine-grained systems* (2.ª ed.). O'Reilly Media.

Órgano Ejecutivo del Estado Plurinacional de Bolivia. (2013). *Decreto Supremo N.º 1793, Reglamento a la Ley N.º 164, de 8 de agosto de 2011, para el desarrollo de tecnologías de información y comunicación.* Gaceta Oficial del Estado Plurinacional de Bolivia.

Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., Barrow, D. K., Ben Taieb, S., Bergmeir, C., Bessa, R. J., Bijak, J., Boylan, J. E., Browell, J., Carnevale, C., Castle, J. L., Cirillo, P., Clements, M. P., Cordeiro, C., Cyrino Oliveira, F. L., De Baets, S., Dokumentov, A., . . . Ziel, F. (2022). Forecasting: Theory and practice. *International Journal of Forecasting, 38*(3), 705–871. https://doi.org/10.1016/j.ijforecast.2021.11.001

Power, D. J. (2002). *Decision support systems: Concepts and resources for managers.* Quorum Books.

Salinas, D., Flunkert, V., Gasthaus, J., & Januschowski, T. (2020). DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International*

Journal of Forecasting, 36(3), 1181–1191. https://doi.org/10.1016/j.ijforecast.2019.07.001

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. En C. Cortes, N. Lawrence, D. Lee, M. Sugiyama, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems 28*. Curran Associates. https://proceedings.neurips.cc/paper_files/paper/2015/hash/86df7dcfd896fcaf2674f757a2463eba-Abstract.html

Spiliotis, E., Makridakis, S., Semenoglou, A.-A., & Assimakopoulos, V. (2022). Comparison of statistical and machine learning methods for daily SKU demand forecasting. *Operational Research, 22*(3), 3037–3061. https://doi.org/10.1007/s12351-020-00605-2

Syntetos, A. A., & Boylan, J. E. (2001). On the bias of intermittent demand estimates. *International Journal of Production Economics, 71*(1–3), 457–466. https://doi.org/10.1016/S0925-5273(00)00143-2

Syntetos, A. A., & Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting, 21*(2), 303–314. https://doi.org/10.1016/j.ijforecast.2004.10.001

Syntetos, A. A., Boylan, J. E., & Croston, J. D. (2005). On the categorization of demand patterns. *Journal of the Operational Research Society, 56*(5), 495–503. https://doi.org/10.1057/palgrave.jors.2601841

Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting, 16*(4), 437–450. https://doi.org/10.1016/S0169-2070(00)00065-0

Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician, 72*(1), 37–45. https://doi.org/10.1080/00031305.2017.1380080

Teunter, R. H., Syntetos, A. A., & Babai, M. Z. (2011). Intermittent demand: Linking forecasting to inventory obsolescence. *European Journal of Operational Research, 214*(3), 606–615. https://doi.org/10.1016/j.ejor.2011.05.018

Timmermann, A. (2006). Forecast combinations. En G. Elliott, C. W. J. Granger, & A. Timmermann (Eds.), *Handbook of economic forecasting* (Vol. 1, pp. 135–196). Elsevier. https://doi.org/10.1016/S1574-0706(05)01004-9

Valdivia Espinosa, L. C. (2019). *Estimación de la demanda de productos perecibles en un supermercado* [Memoria de título, Universidad de Chile]. Repositorio Académico de la Universidad de Chile. https://repositorio.uchile.cl/handle/2250/173464

Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence, 37*(9), 11121–11128. https://doi.org/10.1609/aaai.v37i9.26317

BIBLIOGRAFÍA

Caplice, C. (s. f.). *Supply chain fundamentals* [MOOC]. MIT Learn. https://learn.mit.edu/courses/course-v1:MITxT+CTL.SC1x

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS. https://public.dhe.ibm.com/software/analytics/spss/documentation/modeler/14.2/es/CRISP-DM.pdf

Géron, A. (2023). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (3.ª ed.). O'Reilly Media.

Huyen, C. (2022). *Designing machine learning systems: An iterative process for production-ready applications*. O'Reilly Media.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Hyndman, R. J., & Khandakar, Y. (2008). Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software, 27*(3), 1–22. https://doi.org/10.18637/jss.v027.i03

Kolassa, S., Rostami-Tabar, B., & Siemsen, E. (2024). *Demand forecasting for executives and professionals*. CRC Press. https://doi.org/10.1201/9781003399599

Makridakis, S., & Hibon, M. (2000). The M3-Competition: Results, conclusions and implications. *International Journal of Forecasting, 16*(4), 451–476. https://doi.org/10.1016/S0169-2070(00)00057-1

Silver, E. A., Pyke, D. F., & Thomas, D. J. (2017). *Inventory and production management in supply chains* (4.ª ed.). CRC Press. https://doi.org/10.1201/9781315374406

Vandeput, N. (2021). *Data science for supply chain forecasting* (2.ª ed.). De Gruyter. https://doi.org/10.1515/9783110671124

Wallace, T. F., & Stahl, R. A. (2008). *Sales & operations planning: The how-to handbook* (3.ª ed.). T. F. Wallace & Company.

ANEXOS

ANEXO 1. Guía de entrevista semiestructurada: diagnóstico del proceso de planificación de la demanda en NOVAPACK S.A.

Objetivo del instrumento:

Recolectar información sobre el estado actual del proceso de planificación de la demanda en NOVAPACK S.A., con el fin de caracterizar sus prácticas, herramientas y limitaciones actuales, y establecer el contexto de aplicación del sistema propuesto en la presente investigación.

Tipo de instrumento:

Entrevista semiestructurada.

Tipo de informante:

Persona responsable del proceso de planificación de la demanda en NOVAPACK S.A.

Nombre del informante:

Informante clave IC-01. Se omiten los datos personales por confidencialidad.

Fecha de aplicación:

6 de abril de 2026

Modo de aplicación:

Entrevista presencial o virtual (según disponibilidad).

Guía de preguntas

- ¿Cómo se lleva actualmente el proceso de planificación de la demanda en NOVAPACK S.A.?
- ¿Qué herramientas utilizan para construir los pronósticos de ventas o abastecimiento?
- ¿Qué tipo de información o datos se consideran más relevantes para la estimación de la demanda?

- ¿Con qué frecuencia se realizan los pronósticos? ¿Quiénes participan en su elaboración?
- ¿Considera que los pronósticos actuales son suficientemente precisos? ¿Por qué?
- ¿Qué problemas han identificado asociados a la planificación actual (quiebres de stock, sobreacumulación, etc.)?
- ¿Existen diferencias significativas en el comportamiento de la demanda entre productos, canales o regiones?
- ¿Qué mejoras considera necesarias para optimizar la planificación de la demanda en la empresa?
- ¿Estaría dispuesta la empresa a adoptar un sistema automatizado de pronóstico? ¿Qué condiciones se deberían cumplir?
- ¿Hay algún otro aspecto importante del proceso actual que considere relevante mencionar?

Transcripción de la entrevista.

1. ¿Cómo se lleva actualmente el proceso de planificación de la demanda en NOVAPACK S.A.?

Respuesta: “Actualmente es un proceso bastante manual y, hasta cierto punto, descentralizado. Cada responsable de línea o categoría descarga sus propios datos históricos de ventas y trabaja sus proyecciones de manera individual. Luego nos reunimos para consolidar, pero no tenemos un flujo estandarizado único para todos.”

2. ¿Qué herramientas utilizan para construir los pronósticos de ventas o abastecimiento?

Respuesta: “Básicamente, dependemos de Microsoft Excel. Exportamos la base de datos del sistema, armamos tablas dinámicas y aplicamos fórmulas de promedios móviles simples. No contamos con ningún software especializado ni modelos estadísticos automatizados.”

3. ¿Qué tipo de información o datos se consideran más relevantes para la estimación de la demanda?

Respuesta: “Nos fijamos mucho en el historial de ventas del mismo mes en el año anterior y en el promedio de los últimos tres meses. Sin embargo, el ajuste final recae mucho en el criterio empírico y la experiencia del planificador, quien decide si subir o bajar el número basado en su ‘feeling’ comercial.”

4. ¿Con qué frecuencia se realizan los pronósticos? ¿Quiénes participan en su elaboración?

Respuesta: “Hacemos una planificación mensual. En este proceso participamos desde la jefatura de planificación, los analistas del área y los responsables comerciales de cada canal y región para validar los números.”

5. ¿Considera que los pronósticos actuales son suficientemente precisos? ¿Por qué?

Respuesta: “Sinceramente, no. Manejamos un portafolio muy grande, de más de 900 SKU que, entre canales y regionales, superan las 4.000 combinaciones. Es humanamente imposible analizar el comportamiento individual de cada producto en Excel con el nivel de detalle que se requiere. Además, actualmente no medimos objetivamente nuestro error; no usamos indicadores estadísticos, así que no sabemos con exactitud qué tan desviados estamos hasta que ocurren los problemas.”

6. ¿Qué problemas han identificado asociados a la planificación actual (quiebres de stock, sobreacumulación, etc.)?

Respuesta: “Tenemos ambos extremos. Por un lado, sufrimos quiebres de stock en temporadas altas (como la campaña escolar), lo que se traduce en ventas perdidas y reclamos comerciales. Por otro lado, en productos de baja rotación a veces sobrestimamos la demanda, generando sobreacumulación en los almacenes, lo que inmoviliza capital.”

7. ¿Existen diferencias significativas en el comportamiento de la demanda entre productos, canales o regiones?

Respuesta: “Totalmente. El canal mayorista tiene picos de demanda muy agresivos y concentrados, mientras que el minorista e institucional son más irregulares. Regionalmente, Santa Cruz no se comporta igual que el resto del país, y la estacionalidad de nuestros productos escolares y de papelería marca el ritmo de casi todo el año.”

8. ¿Qué mejoras considera necesarias para optimizar la planificación de la demanda en la empresa?

Respuesta: “Necesitamos estandarizar la metodología y automatizar el cálculo. Nos toma demasiado tiempo (entre 3 y 5 días) armar las hojas de cálculo. Deberíamos tener una herramienta que procese los datos históricos de forma centralizada y nos dé una base matemática sólida para que nuestro equipo solo se dedique a analizar excepciones y estrategias, no a cruzar datos.”

9. ¿Estaría dispuesta la empresa a adoptar un sistema automatizado de pronóstico? ¿Qué condiciones se deberían cumplir?

Respuesta: “Sí, estamos muy dispuestos y es una necesidad urgente. Para que lo adoptemos, el sistema debe ser capaz de procesar el gran volumen de SKU que tenemos, considerar las diferencias por canal y región, e integrarse de manera amigable para que no dependamos de procesos manuales. Sobre todo, necesitamos que nos demuestre que reduce el error respecto a lo que hacemos hoy.”

10. ¿Hay algún otro aspecto importante del proceso actual que considere relevante mencionar?

Respuesta: “Solo recalcar que la falta de retroalimentación es un problema. Como no comparamos formalmente y de forma sistémica el pronóstico vs. la venta real del mes anterior con métricas de error nos cuesta aprender de nuestras fallas. Un sistema que nos indique cuál es el mejor modelo para cada producto nos cambiaría totalmente la forma de trabajar.”

ANEXO 2. Acuerdo de confidencialidad para el uso de información empresarial

Acuerdo de confidencialidad

Entre el suscrito, Nicolas Oporto Rojas, en calidad de investigador del trabajo final de grado titulado "*Diseño de un motor de pronóstico de demanda basado en series temporales para mejorar la precisión de la planificación de la demanda en NOVAPACK S.A. para la gestión 2026*", de la Maestría en Ciencia de Datos e Inteligencia Artificial de la Universidad Autónoma "Gabriel René Moreno", y la empresa NOVAPACK S.A., representada por su subgerencia general, se establece el siguiente compromiso de confidencialidad respecto al uso de la información proporcionada por la organización para fines académicos:

Cláusulas:

1. **Objeto del acuerdo:**

Este acuerdo tiene como objeto asegurar el tratamiento reservado y ético de la información interna proporcionada por NOVAPACK S.A. en el marco del desarrollo del trabajo final de grado, que incluye procesos, datos históricos, opiniones de personal clave, documentos técnicos, entre otros elementos compartidos durante entrevistas, revisión documental y observación de procesos.

2. **Alcance de la información confidencial:**

Se entenderá como información confidencial toda aquella que no sea de dominio público y que haya sido facilitada por NOVAPACK S.A. directa o indirectamente durante el desarrollo del estudio, incluyendo (pero no limitada a):

- Información sobre procesos de planificación de la demanda
- Datos históricos de ventas, productos y canales
- Opiniones o declaraciones emitidas por personal de la empresa
- Diagramas de flujo, herramientas internas y estrategias operativas

3. **Finalidad académica:**

El uso de la información queda estrictamente limitado a los fines de desarrollo, análisis y presentación del trabajo académico requerido para la obtención del grado correspondiente. No se permitirá su reproducción, difusión o uso para fines comerciales ni será compartida con terceros sin el consentimiento expreso de NOVAPACK S.A.

4. **Seudónimo:**

La empresa acepta que en el trabajo, en sus anexos, en su repositorio de código y en toda presentación derivada se la identifique con el seudónimo NOVAPACK S.A., y que no se publiquen su razón social, los nombres de sus sistemas o esquemas de datos, nombres de personas, códigos de producto ni datos reservados.

5. **Obligaciones del investigador:**

El investigador se compromete a:

- No divulgar ni permitir el acceso a la información confidencial a personas no autorizadas
- Utilizar la información únicamente dentro del marco de esta investigación
- Citar y referenciar adecuadamente los elementos utilizados, garantizando el anonimato cuando corresponda
- Solicitar autorización en caso de requerir la presentación del trabajo en espacios públicos (como repositorios digitales)

6. **Vigencia:**

Este acuerdo tendrá vigencia durante el proceso de desarrollo del trabajo final de grado y se extenderá por un período de cinco (5) años posteriores a su presentación y evaluación.

7. **Declaración final:**

Ambas partes reconocen la importancia de mantener la confidencialidad como parte de un ejercicio ético y profesional en la generación de conocimiento aplicado. El presente acuerdo es una muestra de ese compromiso.

ANEXO 3. Guía de observación estructurada

Observación del proceso de planificación de la demanda en NOVAPACK S.A.

Objetivo del instrumento:

Registrar de manera sistemática cómo se desarrolla el proceso real de planificación de la demanda en NOVAPACK S.A., verificando el uso de herramientas, criterios aplicados, nivel de sistematización, participación de actores clave y ajustes realizados en las proyecciones.

Formato del instrumento:

Datos generales de la sesión observada:

Fecha de la observación: _____

Duración estimada: _____

Área o equipo observado: _____

Nombre del observador: _____

Lugar (físico o virtual): _____

Aspectos por observar (Tabla 13):

Tabla 13
Guía de observación estructurada del proceso de planificación de la demanda

Categoría	Ítem observado	Observación / Comentario del investigador
Herramientas utilizadas	¿Se usa Excel, algún sistema ERP u otra herramienta digital?	
	¿Se accede a bases de datos históricas?	
Criterios de proyección	¿Se aplican modelos cuantitativos? ¿Cuáles?	
	¿Se aplican ajustes por juicio experto? ¿En qué momento?	

Categoría	Ítem observado	Observación / Comentario del investigador
Participación del equipo	¿Quiénes participan de la reunión?	
	¿Cómo se toman las decisiones? ¿Hay consenso o jerarquía?	
Procesos clave	¿Se sigue un flujo definido (datos → análisis → decisión)?	
	¿Se documentan las decisiones tomadas?	
Tiempo y eficiencia	¿Cuánto tiempo toma generar el pronóstico?	
	¿Se presentan revisiones de resultados anteriores?	

Nota. Elaboración propia.

Instrucciones de uso:

Este instrumento puede aplicarse de forma presencial o remota y debe utilizarse de manera no intrusiva, limitándose a la observación directa sin intervención activa. Se recomienda solicitar autorización formal para asistir a la reunión o sesión de trabajo observada.

Registro de la sesión de observación (Tabla 14).

Fecha de la observación: 10 de mayo de 2026

Duración estimada: 2 horas

Área/Equipo observado: Departamento de Planificación

Nombre del observador: Ing. Nicolas Oporto Rojas

Lugar: Sala de reuniones principal, NOVAPACK S.A.

Tabla 14

Registro de la sesión de observación aplicada

Categoría	Ítem observado	Observación / comentario del investigador
Herramientas utilizadas	**¿Se utiliza Excel, algún sistema ERP u otra herramienta digital?**	Se exporta la data bruta del ERP corporativo; sin embargo, todo el análisis y cálculo se realiza exclusivamente en múltiples libros de Excel. Se observó lentitud al procesar archivos pesados.
	¿Se accede a bases de datos históricas?	Sí, pero se descargan manualmente cada mes. No existe conexión en tiempo real ni un repositorio centralizado de datos.
Criterios de proyección	**¿Se aplican modelos cuantitativos? ¿Cuáles?**	Únicamente se calculan promedios móviles simples de 3 y 6 meses, además de comparaciones porcentuales con el mismo mes del año anterior.
	¿Se aplican ajustes por juicio experto? ¿En qué momento?	Sí. Después de calcular el promedio en Excel, los analistas y responsables comerciales modifican los valores finales con base en su experiencia sobre la temporada o el comportamiento de los clientes.
Participación del equipo	**¿Quiénes participan en la reunión?**	Participan la jefatura de planificación, dos analistas de datos y representantes comerciales del canal mayorista.
	¿Cómo se toman las decisiones? ¿Existe consenso o jerarquía?	Las metas finales se definen por consenso; sin embargo, en caso de discrepancia prevalece el criterio comercial empírico sobre el dato histórico.
Procesos clave	**¿Se sigue un flujo definido (datos → análisis → decisión)?**	El proceso es secuencial (descarga de datos → procesamiento en Excel → reunión de validación), pero no está documentado como un procedimiento estándar formal.
	¿Se documentan las decisiones tomadas?	Solo se conserva el archivo final de Excel con el número meta. No queda registro formal de por qué se ajustó matemáticamente un pronóstico ni se emplean métricas de error como MAE o MAPE.
Tiempo y eficiencia	**¿Cuánto tiempo toma generar el pronóstico?**	El equipo indicó que requiere aproximadamente 3 días de consolidación en Excel antes de la reunión final de validación de 2 horas.
	¿Se presentan revisiones de resultados anteriores?	No se observó una revisión sistemática de los pronósticos previos frente a las ventas reales, por lo que no existe retroalimentación formal del desempeño del proceso.

Nota. Elaboración propia.

ANEXO 4. Ficha de registro documental

Objetivo del instrumento:

Sistematizar la recopilación y el análisis de la información proveniente de los documentos internos de NOVAPACK S.A., tales como reportes históricos de ventas, registros de planificación y formatos de consolidación de información, asegurando la trazabilidad, pertinencia y relevancia de los datos para el diagnóstico.

Instrucciones de uso:

Llenar una ficha (Tabla 15) por cada documento o conjunto de documentos analizados, registrando de manera clara y precisa la información relevante para el problema de investigación.

Tabla 15

Campos de la ficha de registro documental

Campo	Descripción de la información extraída
Nombre o título del documento	_____
Fecha de emisión / período	_____
Área o departamento emisor	_____
Tipo de documento	( ) Planilla de cálculo ( ) Reporte de sistema ERP ( ) Política / Manual ( ) Otro: _____
Nivel de desagregación de los datos	( ) Por SKU ( ) Por canal ( ) Por regional ( ) Consolidado general
Variables clave identificadas	_____
Limitaciones o inconsistencias observadas	_____
Aporte al problema de investigación	_____

Nota. Elaboración propia.

ANEXO 5. Estructura de la matriz de recolección y análisis de datos históricos

Objetivo del instrumento:

Establecer la estructura de la base de datos mediante la cual se extrajeron, organizaron y tabularon los registros de ventas mensuales correspondientes al período de abril de 2017 a marzo de 2026. Esta matriz (Tabla 16) constituye el insumo principal para el análisis descriptivo de la demanda y para la evaluación comparativa de los modelos predictivos considerados en la investigación.

Estructura del conjunto de datos (Data Frame)

Tabla 16
Variables de la matriz de recolección y análisis de datos históricos

Nombre de la variable	Tipo de dato	Descripción / rol en el análisis	Ejemplo de registro
Fecha	Fecha (Date)	Mes y año del registro de venta. Variable temporal principal.	2023-01-01
Cod_SKU	Categórico	Código único de identificación del producto.	SKU-9045
Categoría	Categórico	Familia o línea de producto.	Categoría D
Canal	Categórico	Canal de comercialización.	Mayorista
Regional	Categórico	Zona geográfica de la venta.	Santa Cruz
Volumen_Venta	Numérico	Cantidad de unidades vendidas. Variable objetivo de análisis y pronóstico.	1.250
Valor_Venta	Numérico	Monto económico de la venta, derivable del producto entre el volumen y el precio unitario. No se persiste en la matriz: la valorización del estudio se realiza con el costo unitario del maestro de productos.	15.625,00

Nombre de la variable	Tipo de dato	Descripción / rol en el análisis	Ejemplo de registro
Precio_Unitario	Numérico	Precio de lista vigente al momento de la captura, único por combinación en todo el período (no es una serie histórica de precios). Variable explicativa de nivel del modelo de aprendizaje automático: su variación mensual solo distingue los meses sin venta.	12,50
Venta_Perdida	Numérico	Demanda no atendida, registrada cuando un vendedor consulta un producto y el sistema verifica que no hay existencia suficiente para atenderlo. Variable explicativa del modelo y base del diagnóstico de quiebres.	320
Promocion_Activa	Booleano	Indica si el producto estuvo bajo campaña estacional o promoción (1 = Sí, 0 = No). Campo previsto en el instrumento de recolección; su registro en la fuente resultó incompleto y no se incorporó como variable del modelo (ver Recomendaciones).	1

Nota. Elaboración propia.

La matriz se complementa con tres registros auxiliares alineados por mes, los dos primeros también por producto: el costo unitario del maestro de productos, que pondera el error de cada serie en la métrica valorizada; el registro de quiebres de inventario, expresado como porcentaje del período con existencia insuficiente; y la serie mensual del tipo de cambio. Los dos últimos alimentan, además, variables explicativas del modelo de aprendizaje automático.

Las cantidades están en la unidad principal del código vigente (apartado 2.5.3). El precio y el costo unitarios son valores vigentes al momento de la captura, repetidos en todos los meses de cada combinación: el precio de lista del maestro (o, si falta, el último precio promedio histórico) y el costo del maestro de productos. Por eso las valorizaciones del estudio están a costos y precios constantes, y el modelo no ve

cambios de precio ni promociones. El precio promedio efectivo mensual (neto facturado sobre cantidad), que el histórico de ventas registra y la captura no incorporó, queda como mejora de datos en las recomendaciones.

ANEXO 6. Ejemplo de ficha documental aplicada

La Tabla 17 presenta la ficha del Anexo 4 aplicada al reporte histórico consolidado de ventas.

Tabla 17
Ficha documental aplicada al reporte histórico consolidado de ventas

Campo	Descripción de la información extraída
Nombre o título del documento	Reporte Histórico Consolidado de Ventas (2017–2026)
Fecha de emisión / período	Extraído el 7 de agosto de 2026 mediante consulta directa al sistema de gestión. Cubre de abril de 2017 a marzo de 2026, equivalente a las gestiones comerciales 2018 a 2026; el manifiesto de extracción registra 204.096 filas y el hash SHA-256 del archivo resultante.
Área o departamento emisor	Sistemas / Planificación, NOVAPACK S.A.
Tipo de documento	Planilla de cálculo / Base de datos CSV
Nivel de desagregación de los datos	Por SKU, por canal y por regional
Variables clave identificadas	Código de producto (SKU), categoría de producto, fecha de transacción, volumen de unidades vendidas, canal de distribución, sucursal/regional, precio unitario y venta perdida registrada por consulta sin existencia disponible
Limitaciones o inconsistencias observadas	Se identificaron meses con registros en cero para productos de baja rotación. Existen diferencias en la nomenclatura de canales en los años más antiguos (2017–2018), lo que requirió limpieza y estandarización para el análisis.

Campo	Descripción de la información extraída
Aporte al problema de investigación	La base de datos es lo suficientemente extensa y detallada para el análisis comparativo de modelos de pronóstico. Asimismo, confirma la alta dimensionalidad del problema, con más de 900 SKU y más de 4.000 combinaciones SKU-canal-regional, lo que justifica la dificultad de realizar previsiones manuales precisas.

Nota. Elaboración propia.

ANEXO 7. Enlace al repositorio

https://github.com/noportor/tfg-motor-pronostico-demanda.git

El repositorio contiene el código fuente completo del motor: el pipeline reproducible del experimento (empaquetado en Docker), la configuración declarada de cada corrida, incluidas las de la extensión exploratoria ('config/config_ml2*.yaml'), las pruebas automatizadas del contrato de datos y del control de confidencialidad, la búsqueda de hiperparámetros de los brazos neuronales ('scripts/ajustar_neuronal.py'), la auditoría de verificación de la extensión ('docs/auditoria_ml2_v6.md') y el script del contraste estadístico presentado en el Anexo 8 ('scripts/anexo_h_contraste.py'). En cumplimiento del acuerdo de confidencialidad del Anexo 2, el repositorio no publica la captura de datos ni las salidas de cada corrida, que contienen una fila por serie del portafolio; las salidas se regeneran ejecutando el pipeline sobre la captura congelada, y cada corrida produce un manifiesto que registra los datos, la configuración y la versión del código con que se obtuvo cada resultado que el documento toma de ella. El repositorio incluye también la búsqueda de hiperparámetros del modelo global ('scripts/ajustar_lightgbm.py'), las tablas de ensayos de las tres búsquedas realizadas ('resultados/ensayos/'), que no contienen filas por serie, y el script que arma la Tabla 28 ('scripts/tabla_hiperparametros.py'); la tabla de ensayos del modelo global respalda esa tabla y la Figura 18. El repositorio incluye además los scripts que arman, desde las salidas de las corridas, la Tabla 20 del Anexo 8 ('scripts/incertidumbre_agrupada.py'), la Tabla 21 del Anexo 8 ('scripts/incertidumbre_extension.py') y la Tabla 25 del Anexo 11 ('scripts/sensibilidad_cohorte.py'), y el que redibuja la Figura 13 ('scripts/figura_casos.py'). La reproducibilidad es, por eso, condicionada: con acceso autorizado a la captura sellada y a los registros auxiliares bajo custodia (Anexo 18) y a la imagen de ejecución que conserva el autor (nota de la Tabla 48), la corrida publicada y las sensibilidades A y B se rehacen y se cotejan por sus huellas; sin ese acceso, el repositorio permite verificar el código, la configuración declarada y las huellas publicadas, no reproducir los resultados. Las corridas de la extensión exploratoria se ejecutaron fuera de esa imagen, en un entorno con aceleración por

hardware gráfico que no garantiza una reproducción idéntica en otro equipo (apartado 4.3.3). Los commits de la rama principal posteriores a la revisión 17893d4 son exclusivamente documentales (citas de anexos y tablas con la numeración del documento final); la constancia complementaria 08 del autor, conservada bajo custodia con las diferencias completas, lo verifica (nota de la Tabla 47 del Anexo 18).

ANEXO 8. Script de contraste estadístico de la hipótesis (Python)

El cuerpo del documento resume el contraste; las Tablas 18 y 19 reproducen el detalle que el apartado 4.3.2 remite a este anexo, calculado sobre la matriz de error por serie que la corrida publica como archivo. En el contraste pareado contra el modelo ingenuo, el motor obtiene menor error en 702 de las 1.668 series (42,1 %), mayor en 549 (32,9 %) y empata exactamente en 417 (25,0 %); descontados los empates, la proporción a favor del motor es del 56,1 %, frente al 63,0 % que alcanza sobre esa misma base contra el promedio móvil de 12 meses y al 76,8 % contra su variante con factor de crecimiento (1.146 series a favor, 346 en contra y 176 empates).

Tabla 18
Normalidad de las diferencias pareadas del contraste (prueba de Shapiro-Wilk)

Comparación	W de Shapiro-Wilk	p
Motor frente a promedio móvil de 12 meses	0,22	$< 1 \times 10^{-16}$
Motor frente a promedio móvil de 12 meses con factor de crecimiento	0,18	$< 1 \times 10^{-16}$
Motor frente a modelo ingenuo	0,16	$< 1 \times 10^{-16}$
LightGBM frente a promedio móvil de 12 meses	0,22	$< 1 \times 10^{-16}$
LightGBM frente a modelo ingenuo	0,20	$< 1 \times 10^{-16}$

Nota. Elaboración propia. En las cinco comparaciones la prueba se aplicó sobre las 1.668 diferencias por serie del bloque de prueba. Las filas de LightGBM se obtienen con el script de este anexo sustituyendo la variable PROPUESTO; se reproducen las dos que el cuerpo cita.

Tabla 19
Rangos medios de Friedman y post hoc de Nemenyi frente al motor

Modelo	Rango medio	Distancia al motor	p de Nemenyi
Motor de selección automática	4,667	n. d.	n. d.
Promedio móvil de 2 meses	4,630	0,04	1,000
Ingenuo (Naïve)	4,964	0,30	0,253

Modelo	Rango medio	Distancia al motor	p de Nemenyi
Suavizado exponencial simple	5,220	0,55	< 0,05

Nota. Elaboración propia. Diferencia crítica de Nemenyi: 0,37 (α = 0,05); las distancias menores que ese umbral no permiten distinguir los modelos entre sí; n. d.: no disponible, porque la fila del motor es la referencia de las distancias. El script de este anexo reproduce todos los valores a partir de la matriz de error por serie.

La Tabla 20 mide la incertidumbre de las diferencias del contraste cuando se respeta la dependencia entre series que el apartado 4.3.2 remite a este anexo. Las pruebas de Wilcoxon y de Friedman tratan cada serie como un bloque independiente, pero las series de un mismo SKU comparten producto y campaña, y todas se evalúan sobre el mismo bloque de prueba de doce meses. Por eso las diferencias se remuestrearon de dos maneras, sin volver a ajustar ningún modelo: por conglomerados, sorteando con reposición los 369 SKU de la muestra, cada uno con todas sus series, y por bloques móviles circulares de tres meses consecutivos del bloque de prueba, que recalculan el error de cada serie y la D del portafolio con los meses sorteados. Cada remuestreo genera 2.000 réplicas con la semilla 20260408, las mismas en las cinco comparaciones, y sus intervalos son percentiles al 95 %. Una diferencia se sostiene con incertidumbre agrupada por SKU cuando su intervalo por conglomerados excluye el cero; cuando no lo excluye, se lee como evidencia descriptiva del conjunto evaluado. Los dos remuestreos se aplicaron por separado, sin un esquema que los combine, y juntos forman la evidencia principal del contraste: el de bloques de meses se informa al lado del de SKU y, cuando el intervalo por SKU excluye el cero y el de bloques no, la diferencia se declara sostenida solo por SKU. El script que arma la tabla verifica el hash de cada insumo contra el manifiesto de la corrida y no lee los datos de origen.

Tabla 20

Incertidumbre agrupada de las diferencias del contraste, por conglomerados de SKU y por bloques de meses

Comparación	Magnitud	Estimación	Intervalo al 95 % por SKU	¿Excluye el cero?	Intervalo al 95 % por bloques de 3 meses	¿Excluye el cero?
Motor frente al promedio móvil de 12 meses (p < 0,001; r = −0,31)	Diferencia media por serie (unidades)	−32,77	[−49,01; −19,11]	sí	[−101,85; −11,44]	sí
	Diferencia mediana por serie (unidades)	−0,38	[−0,56; −0,20]	sí	[−1,24; 0,00]	no
	Diferencia de D del portafolio (puntos porcentuales)	−10,0	[−14,0; −6,1]	sí	[−75,3; −1,3]	sí
Motor frente a la réplica de la fórmula base sin ajustes de consenso (p < 0,001; r = −0,53)	Diferencia media por serie (unidades)	−42,52	[−65,58; −24,01]	sí	[−74,15; −15,27]	sí
	Diferencia mediana por serie (unidades)	−2,02	[−2,54; −1,60]	sí	[−2,76; −0,72]	sí
	Diferencia de D del portafolio (puntos porcentuales)	−24,6	[−32,0; −17,0]	sí	[−45,7; −10,2]	sí
Motor frente al modelo ingenuo (p < 0,001; r = −0,09)	Diferencia media por serie (unidades)	−3,77	[−9,34; 0,99]	no	[−44,87; 9,55]	no
	Diferencia mediana por serie (unidades)	0,00	[0,00; 0,00]	no	[0,00; 0,00]	no

Comparación	Magnitud	Estimación	Intervalo al 95 % por SKU	¿Excluye el cero?	Intervalo al 95 % por bloques de 3 meses	¿Excluye el cero?
	Diferencia de D del portafolio (puntos porcentuales)	−10,2	[−14,7; −5,4]	sí	[−32,1; 0,9]	no
LightGBM frente al promedio móvil de 12 meses (p < 0,001; r = −0,09)	Diferencia media por serie (unidades)	−32,21	[−49,42; −18,00]	sí	[−102,25; −23,43]	sí
	Diferencia mediana por serie (unidades)	−0,07	[−0,40; 0,24]	no	[−1,74; 0,12]	no
	Diferencia de D del portafolio (puntos porcentuales)	−8,3	[−14,0; −2,9]	sí	[−84,6; 2,5]	no
LightGBM frente al modelo ingenuo (p = 0,9998; r = 0,09)	Diferencia media por serie (unidades)	−3,21	[−10,64; 2,74]	no	[−65,49; 10,30]	no
	Diferencia mediana por serie (unidades)	0,36	[0,02; 0,71]	sí	[−1,95; 2,50]	no
	Diferencia de D del portafolio (puntos porcentuales)	−8,6	[−13,7; −3,3]	sí	[−30,0; 0,4]	no

Nota. Elaboración propia con el script 'scripts/incertidumbre_agrupada.py' del repositorio del Anexo 7, sobre las salidas publicadas de la corrida (commit 472b891). Diferencias del propuesto menos la referencia: un valor negativo indica que el propuesto erra menos. Error compuesto por serie = MAE + |Bias|, en unidades; D = WMAPE valorizado + |sesgo valorizado agregado|, sobre las 1.513 series con costo. La estimación es la de la muestra completa, sin remuestrear. El p y el r son los del Wilcoxon unilateral del apartado 4.3.2. La diferencia media en unidades la dominan las series de mayor volumen; con doce meses, los intervalos por bloques son amplios y asimétricos. Las dos columnas sobre la exclusión del cero no distinguen el sentido: todos los intervalos que excluyen el cero lo hacen a favor del propuesto, salvo el de la diferencia mediana de LightGBM frente al ingenuo por SKU, que lo excluye en su contra.

La Tabla 21 aplica el mismo remuestreo a los contrastes de la extensión exploratoria del apartado 4.3.3, que también tratan cada serie como una observación independiente. Sobre las salidas publicadas de sus dos corridas, y sin volver a ajustar ningún modelo, se remuestrearon las diferencias de las cuatro mezclas, del brazo motor de la extensión y de LightGBM frente al promedio móvil de 12 meses y frente al modelo ingenuo, en las dos gestiones de prueba: la gestión 2026, con 369 SKU que agrupan 1.668 series, y la gestión 2025, la del inicio de la crisis cambiaria, con 368 SKU que agrupan 1.613 series. Una de esas cuatro mezclas, el conjunto curado ponderado por horizonte, no figura en la Tabla 10. En la gestión 2026 se remuestreó además la diferencia de las dos mezclas del conjunto curado de la Tabla 10 (promedio de 5 y ponderado por validación) frente al motor validado de la corrida principal, que evalúa las mismas series con la misma venta y el mismo costo. Esa comparación no se contrastó con Wilcoxon y por eso, en esta tabla, no lleva p ni r. El remuestreo conserva los parámetros con que se calculó la Tabla 20, y dentro de cada gestión todas las comparaciones usan las mismas réplicas. Las filas de LightGBM de la gestión 2026 coinciden con las de esa tabla, porque el modelo, las series y las réplicas son los mismos. La regla de lectura es la de la Tabla 20: una diferencia se sostiene con incertidumbre agrupada por SKU cuando su intervalo por conglomerados excluye el cero, y se lee como evidencia descriptiva del conjunto evaluado cuando no lo excluye. El script que arma esta tabla verifica sus insumos del mismo modo que el de la tabla anterior, tampoco lee los datos de origen y se detiene si el Wilcoxon recalculado no reproduce el r y el p que publica cada corrida.

Tabla 21

Incertidumbre agrupada de las diferencias de la extensión exploratoria en sus dos gestiones de prueba, por conglomerados de SKU y por bloques de meses

Comparación	Gestión	p; r	Diferencia mediana por serie (unidades)	Diferencia media por serie (unidades)	Diferencia de D (puntos porcentuales)	¿Excluye el cero? Por SKU	¿Excluye el cero? Por bloques de 3 meses
Conjunto curado (promedio de 5) frente al promedio móvil de 12 meses	2026	p < 0,001; r = −0,37	−1,07 [−1,47; −0,75]	−30,73 [−47,10; −17,09]	−10,5 [−14,4; −7,0]	sí, sí, sí	sí, sí, sí
	2025	p < 0,001; r = −0,44	−1,53 [−2,04; −1,23]	−65,74 [−104,51; −33,19]	−33,0 [−43,0; −23,5]	sí, sí, sí	sí, sí, sí
Conjunto curado (ponderado por validación) frente al promedio móvil de 12 meses	2026	p < 0,001; r = −0,48	−1,25 [−1,74; −0,89]	−33,86 [−51,57; −19,32]	−11,3 [−15,3; −7,6]	sí, sí, sí	sí, sí, sí
	2025	p < 0,001; r = −0,51	−1,60 [−2,05; −1,25]	−70,43 [−110,56; −35,85]	−34,8 [−44,6; −25,2]	sí, sí, sí	sí, sí, sí
Conjunto curado (ponderado por horizonte) frente al promedio móvil de 12 meses	2026	p < 0,001; r = −0,34	−1,02 [−1,48; −0,72]	−31,63 [−48,35; −17,80]	−10,8 [−15,0; −7,1]	sí, sí, sí	sí, sí, sí
	2025	p < 0,001; r = −0,43	−1,63 [−2,03; −1,29]	−66,18 [−104,81; −33,20]	−33,2 [−43,5; −23,6]	sí, sí, sí	sí, sí, sí
Sistema conmutado frente al promedio móvil de 12 meses	2026	p < 0,001; r = −0,41	−1,26 [−1,60; −0,93]	−32,83 [−49,36; −18,69]	−10,1 [−14,1; −6,7]	sí, sí, sí	sí, sí, sí
	2025	p < 0,001; r = −0,54	−1,99 [−2,49; −1,62]	−75,63 [−119,09; −38,40]	−38,9 [−49,8; −28,2]	sí, sí, sí	sí, sí, sí

Comparación	Gestión	p; r	Diferencia mediana por serie (unidades)	Diferencia media por serie (unidades)	Diferencia de D (puntos porcentuales)	¿Excluye el cero? Por SKU	¿Excluye el cero? Por bloques de 3 meses
Brazo motor de la extensión frente al promedio móvil de 12 meses	2026	p < 0,001; r = −0,21	−0,20 [−0,40; −0,05]	−22,32 [−35,55; −12,05]	−5,5 [−9,1; −2,2]	sí, sí, sí	no, sí, sí
	2025	p < 0,001; r = −0,25	−0,43 [−0,77; −0,18]	−50,40 [−82,63; −21,94]	−30,9 [−43,6; −18,1]	sí, sí, sí	no, sí, sí
LightGBM frente al promedio móvil de 12 meses	2026	p < 0,001; r = −0,09	−0,07 [−0,40; 0,24]	−32,21 [−49,42; −18,00]	−8,3 [−14,0; −2,9]	no, sí, sí	no, sí, no
	2025	p < 0,001; r = −0,15	−0,46 [−1,00; 0,11]	−70,87 [−117,56; −31,65]	−28,8 [−39,2; −18,6]	no, sí, sí	no, sí, no
Conjunto curado (promedio de 5) frente al modelo ingenuo	2026	p < 0,001; r = −0,13	−0,66 [−0,97; −0,40]	−1,72 [−8,35; 3,76]	−10,7 [−15,7; −5,2]	sí, no, sí	no, no, sí
	2025	p = 1,0000; r = 0,12	0,34 [−0,02; 0,74]	18,58 [8,87; 31,46]	0,2 [−11,7; 12,3]	no, sí, no	no, no, no
Conjunto curado (ponderado por validación) frente al modelo ingenuo	2026	p < 0,001; r = −0,20	−0,69 [−0,98; −0,42]	−4,86 [−12,55; 0,82]	−11,5 [−16,2; −6,4]	sí, no, sí	no, no, sí
	2025	p = 0,9978; r = 0,07	0,03 [−0,16; 0,34]	13,89 [6,68; 23,21]	−1,6 [−12,1; 9,1]	no, sí, no	no, no, no
Conjunto curado (ponderado por horizonte) frente al modelo ingenuo	2026	p < 0,001; r = −0,13	−0,70 [−0,98; −0,41]	−2,62 [−9,50; 2,92]	−11,0 [−16,0; −5,4]	sí, no, sí	no, no, sí
	2025	p = 1,0000; r = 0,12	0,36 [−0,01; 0,80]	18,14 [8,32; 30,85]	−0,1 [−11,9; 12,0]	no, sí, no	no, no, no
Sistema conmutado frente al modelo ingenuo	2026	p < 0,001; r = −0,17	−0,76 [−1,04; −0,53]	−3,82 [−10,47; 1,72]	−10,3 [−15,1; −4,9]	sí, no, sí	no, no, sí

Comparación	Gestión	p; r	Diferencia mediana por serie (unidades)	Diferencia media por serie (unidades)	Diferencia de D (puntos porcentuales)	¿Excluye el cero? Por SKU	¿Excluye el cero? Por bloques de 3 meses
	2025	p = 0,456; r = −0,003	−0,25 [−0,45; 0,07]	8,69 [2,76; 16,17]	−5,7 [−16,0; 5,2]	no, sí, no	no, no, no
Brazo motor de la extensión frente al modelo ingenuo	2026	p = 0,364; r = −0,01	0,00 [−0,01; 0,00]	6,68 [−1,26; 15,74]	−5,7 [−9,9; −1,3]	no, no, sí	no, no, sí
	2025	p = 1,0000; r = 0,19	0,24 [0,02; 0,50]	33,92 [18,91; 53,09]	2,3 [−7,8; 11,1]	sí, sí, no	no, no, no
LightGBM frente al modelo ingenuo	2026	p = 0,9998; r = 0,09	0,36 [0,02; 0,71]	−3,21 [−10,64; 2,74]	−8,6 [−13,7; −3,3]	sí, no, sí	no, no, no
	2025	p = 1,0000; r = 0,26	2,17 [1,52; 3,01]	13,45 [4,01; 24,49]	4,3 [−8,1; 17,5]	sí, sí, no	no, no, no
Conjunto curado (promedio de 5) frente al motor validado	2026	sin contraste publicado	−0,16 [−0,28; −0,02]	2,04 [−1,54; 6,05]	−0,5 [−3,4; 2,3]	sí, no, no	no, no, no
Conjunto curado (ponderado por validación) frente al motor validado	2026	sin contraste publicado	−0,25 [−0,37; −0,14]	−1,09 [−5,29; 2,97]	−1,4 [−3,9; 1,3]	sí, no, no	no, no, no

Nota. Elaboración propia con el script 'scripts/incertidumbre_extension.py' del repositorio del Anexo 7 (commit 17893d4, que versiona el script y esta tabla), sobre las salidas publicadas de las dos corridas de la extensión, las mismas corridas de la Tabla 10, identificadas en su nota (configuraciones 'config/config_ml2_v9.yaml' y 'config/config_ml2_v9_blindaje.yaml'). La gestión 2026 corresponde al bloque de prueba de abril de 2025 a marzo de 2026 (1.513 series con costo), y la 2025, al de abril de 2024 a marzo de 2025 (1.468 con costo). Diferencias del propuesto menos la referencia: un valor negativo indica que el propuesto erra menos. Error compuesto por serie = MAE + |Bias|, en unidades; D = WMAPE valorizado + |sesgo valorizado agregado|. Entre corchetes, el intervalo al 95 % por conglomerados de SKU. Las dos últimas columnas indican, en el orden mediana, media y D, si excluyen el cero el intervalo por SKU y el de bloques móviles circulares de 3 meses del bloque de prueba; los límites por bloques están en 'resultados/tablas/tabla_H4_incertidumbre_extension.csv'. Esas columnas no distinguen el sentido: los intervalos que excluyen el cero lo hacen a favor del propuesto, salvo, frente al modelo ingenuo, los de la diferencia mediana de

LightGBM en las dos gestiones y, en la gestión 2025, los de la diferencia media de los seis sistemas y el de la mediana del brazo motor, que lo excluyen por SKU en su contra. La estimación es la de la muestra completa, sin remuestrear. El p y el r son los del Wilcoxon unilateral que publica cada corrida. Las dos últimas filas comparan las mezclas de la gestión 2026 con el motor validado de la corrida principal (Tabla 8). El conjunto curado ponderado por horizonte pondera a cada integrante por su desempeño de validación en cada horizonte, agregado sobre todas las series.

El siguiente script reproduce íntegramente el contraste estadístico reportado en la validación técnica. Toma como insumo la matriz serie × modelo del error compuesto por serie (MAE + |Bias|, en unidades) que genera la corrida del motor, y devuelve los mismos valores citados en el cuerpo del documento: el estadístico de Shapiro-Wilk sobre las diferencias, las tres pruebas de Wilcoxon pareadas del motor frente a los métodos de referencia con su tamaño del efecto, y el Friedman de los once modelos con la diferencia crítica de Nemenyi. El listado es una versión abreviada de 'scripts/anexo_h_contraste.py', con los mismos cálculos.

```
import numpy as np
import pandas as pd
import scikit_posthocs as sp
from scipy import stats

RUTA = "matriz_contraste.csv"      # matriz serie x modelo del error compuesto
PROPUESTO = "motor"
REFERENCIAS = ["ma_12", "ma_12_gf", "naive_m1"]   # promedio movil simple, formula vigente (con
factor) y linea base ingenua
ALFA = 0.05

matriz = pd.read_csv(RUTA).set_index("serie").dropna()
print(f"series con bloque completo: {len(matriz)} | modelos: {matriz.shape[1]}")

# --- Wilcoxon pareado unilateral, con Z corregido por empates ---------------
for referencia in REFERENCIAS:
    a = matriz[PROPUESTO].to_numpy(float)
    b = matriz[referencia].to_numpy(float)
    diferencia = a - b
    no_nulas = diferencia[diferencia != 0]
    n = no_nulas.size

    w_shapiro, p_shapiro = stats.shapiro(diferencia)
    estadistico, p = stats.wilcoxon(
        a, b, alternative="less", zero_method="wilcox", method="approx"
    )

    rangos = stats.rankdata(np.abs(no_nulas))
    w_pos = rangos[no_nulas > 0].sum()
    media = n * (n + 1) / 4.0
    _, cuentas = np.unique(np.abs(no_nulas), return_counts=True)
    varianza = n * (n + 1) * (2 * n + 1) / 24.0 - ((cuentas**3 - cuentas).sum()) / 48.0
    z = (w_pos - media) / np.sqrt(varianza)
    r = z / np.sqrt(len(matriz))          # tamano del efecto r = Z / raiz(N)

    print(f"\n{PROPUESTO} vs {referencia}")
    print(f"  Shapiro-Wilk W = {w_shapiro:.4f} -> se rechaza la normalidad")
    print(f"  a favor: {(diferencia < 0).sum()} | en contra: {(diferencia > 0).sum()}"
          f" | empates: {(diferencia == 0).sum()}")
    print(f"  W = {estadistico:,.1f}  Z = {z:.4f}  p = {p:.3g}  r = {r:.4f}")

# --- Friedman omnibus + post hoc de Nemenyi ---------------------------------
chi2, p_friedman = stats.friedmanchisquare(*[matriz[c] for c in matriz.columns])
n_series, k = matriz.shape
kendall_w = chi2 / (n_series * (k - 1))
q_alfa = stats.studentized_range.ppf(1 - ALFA, k, np.inf) / np.sqrt(2)
cd = q_alfa * np.sqrt(k * (k + 1) / (6.0 * n_series))

print(f"\nFriedman: chi2 = {chi2:,.4f}  p = {p_friedman:.3g}  W de Kendall = {kendall_w:.4f}")
print(f"Diferencia critica de Nemenyi (alfa = {ALFA}): CD = {cd:.3f}")
print("\nrangos medios (1 = mejor):")
print(matriz.rank(axis=1).mean().sort_values().round(3).to_string())

nemenyi = sp.posthoc_nemenyi_friedman(matriz.to_numpy())
nemenyi.index = nemenyi.columns = matriz.columns
```

```
print(f"\nNemenyi, p-valores de {PROPUESTO} contra cada modelo:")
print(nemenyi[PROPUESTO].drop(PROPUESTO).round(4).to_string())
```

ANEXO 9. Registro de flujo de la corrida principal: etapas, duración, entorno y variantes

El registro de flujo de la corrida principal documenta las 15 etapas del pipeline, cada una con su entrada, su salida, las decisiones aplicadas, los conteos resultantes, los artefactos producidos cuando los hay y su duración, medida por el reloj propio de la etapa. La Tabla 22 reproduce el identificador, una descripción breve y la duración de cada etapa. El anexo recoge además el inventario de salidas de la corrida, el entorno de ejecución con sus versiones y semillas, y las corridas de variantes con sus anulaciones (Tabla 23). El cuerpo del documento cita este registro al medir el costo de cómputo del núcleo productivo y de la instrumentación del estudio.

Tabla 22
Etapas del registro de flujo de la corrida principal y su duración

Identificador en el registro	Etapa	Duración (s)
carga	Carga del archivo crudo	1,2
poblacion	Población objetivo del estudio	0,1
series	Construcción de las series mensuales	0,6
inspeccion	Inspección de los datos	0,9
evento_exogeno	Tratamiento del evento exógeno	0,1
particion_cohorte	Partición temporal y criterios de inclusión	0,8
features	Variables derivadas, sin fuga temporal	27,8
modelos	Ajuste y optimización de los modelos	12,7
motor	Motor de selección por serie	5,0
unidad_analisis	Unidad de análisis: evidencia de la serie elegida	2,8
metricas	Métricas por serie y suite valorizada	1,2
explicacion	Contribuciones TreeSHAP y Pareto del valor	63,8
contraste	Contraste estadístico de la hipótesis	0,7
evaluacion_multihorizonte	Evaluación multihorizonte (orígenes rodantes)	2.117,5

Identificador en el registro	Etapa	Duración (s)
figuras	Figuras del estudio (catálogo programático)	7,5

Nota. Elaboración propia a partir del registro de flujo de la corrida principal. Cada duración proviene del reloj monotónico de su propia etapa.

La corrida principal depositó 46 archivos de salida: los pronósticos consolidados, las métricas por modelo y por serie, las tablas del estudio, el catálogo de figuras y los dos artefactos de trazabilidad. El manifiesto sella el SHA-256 del archivo de datos y el de la configuración efectiva, el commit del código y el estado del árbol de trabajo, la plataforma de ejecución, la versión del lenguaje y la de las ocho bibliotecas cargadas, y la duración total. Los sellos de esta corrida y de las otras cuatro se reproducen en la Tabla 48 del Anexo 18. El registro del flujo documenta las 15 etapas una por una, con los campos enumerados al inicio de este anexo. Desde la corrida publicada sobre el commit 472b891 el manifiesto sella además cada archivo auxiliar de la captura (costos, quiebres, tipo de cambio, tabla de categorías, mapeo de códigos y manifiesto de extracción) con su nombre, tamaño y SHA-256, bajo datos.auxiliares.

El entorno de la corrida principal comprende Python 3.13.16, pandas 3.0.2, NumPy 2.4.4, SciPy 1.17.1, scikit-learn 1.8.0, LightGBM 4.7.0, PyYAML 6.0.2, matplotlib 3.10.8 (figuras elaboradas a partir de las salidas del motor) y scikit-posthocs 0.14.0 (verificación independiente del post hoc de Nemenyi); la búsqueda de hiperparámetros añade Optuna 4.1.0. Las semillas declaradas son 20260406 para el flujo principal y 20260408 para la búsqueda de hiperparámetros.

Tabla 23
Corridas de variantes del estudio y sus anulaciones

Variante	Anulación aplicada sobre la configuración declarada
1	Deja sin tratar el tramo del evento exógeno
2	Traslada al horizonte el criterio de selección del motor
3	Sustituye la regla de selección por el error absoluto, sin componente de sesgo
4	Desactiva seis variables del modelo global y lleva ocho hiperparámetros a valores de referencia previos a la búsqueda (14 anulaciones simultáneas)

Variante	Anulación aplicada sobre la configuración declarada
5	Reestima en cada origen del multihorizonte los parámetros de los brazos estadísticos (suavizado, Holt-Winters y Croston) con la historia hasta el origen

Nota. Elaboración propia. Las variantes A y B de la Tabla 25 (Anexo 11) también son corridas completas del motor, pero se ejecutaron con un archivo de configuración propio, que hereda la configuración declarada, y no por anulación; por eso no figuran en esta tabla.

ANEXO 10. Traza mensual del detector de régimen en las dos gestiones de prueba

El apartado 4.3.3 resume el comportamiento del detector de régimen del sistema conmutado. La Tabla 24 reproduce su traza mensual completa en las dos gestiones de prueba de la extensión exploratoria: la señal de sesgo valorizado móvil de los últimos tres meses y el peso asignado al conjunto diverso, entre 0 y 1.

Tabla 24
Señal de sesgo móvil y peso del conjunto diverso, mes a mes

Gestión de prueba	Mes	Señal de sesgo móvil (%)	Peso del conjunto diverso
2025 (quiebre)	Abril de 2024	+20,6	1,00
2025 (quiebre)	Mayo de 2024	+77,4	1,00
2025 (quiebre)	Junio de 2024	+53,4	1,00
2025 (quiebre)	Julio de 2024	+47,4	1,00
2025 (quiebre)	Agosto de 2024	+28,7	1,00
2025 (quiebre)	Septiembre de 2024	+26,3	1,00
2025 (quiebre)	Octubre de 2024	+23,2	1,00
2025 (quiebre)	Noviembre de 2024	+25,9	1,00
2025 (quiebre)	Diciembre de 2024	+8,2	0,00
2025 (quiebre)	Enero de 2025	−20,9	1,00
2025 (quiebre)	Febrero de 2025	−10,6	0,06
2025 (quiebre)	Marzo de 2025	−7,2	0,00
2026 (normal)	Abril de 2025	+11,2	0,12
2026 (normal)	Mayo de 2025	+5,6	0,00
2026 (normal)	Junio de 2025	+0,4	0,00
2026 (normal)	Julio de 2025	+4,6	0,00
2026 (normal)	Agosto de 2025	+11,5	0,15
2026 (normal)	Septiembre de 2025	+33,9	1,00

Gestión de prueba	Mes	Señal de sesgo móvil (%)	Peso del conjunto diverso
2026 (normal)	Octubre de 2025	+8,8	0,00
2026 (normal)	Noviembre de 2025	+0,6	0,00
2026 (normal)	Diciembre de 2025	−19,8	0,98
2026 (normal)	Enero de 2026	−27,1	1,00
2026 (normal)	Febrero de 2026	−24,5	1,00
2026 (normal)	Marzo de 2026	−17,5	0,75

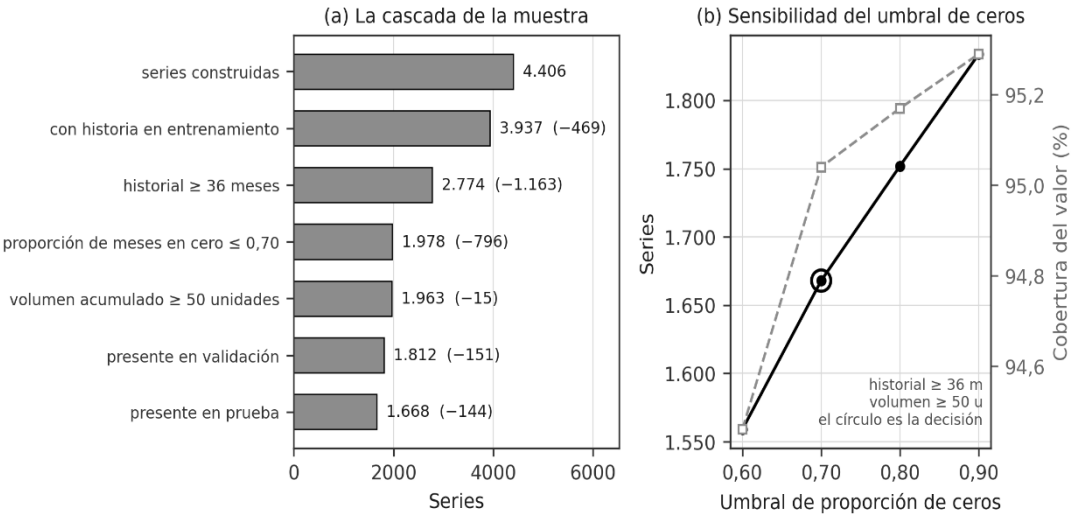
Nota. Elaboración propia a partir de las salidas de la extensión exploratoria (corridas de las gestiones de prueba 2026 y 2025). Un peso de 1,00 indica conmutación plena al conjunto diverso y uno de 0,00, el uso exclusivo del curado; el detector responde a la magnitud absoluta de la señal, no a su signo.

ANEXO 11. Caracterización del histórico y justificación del muestreo

Este anexo reúne la caracterización gráfica del histórico y la justificación de los criterios de muestreo del estudio: la cascada de conformación de la muestra con la sensibilidad de sus umbrales y de la cohorte de evaluación, la concentración del valor del portafolio y la demanda valorizada por gestión comercial con su asignación a los bloques del diseño. El cuerpo del documento cita cada pieza desde el apartado donde su resultado se utiliza. En la Tabla 25, que mide esa sensibilidad de la cohorte, las variantes A y B son corridas completas del motor en las que el modelo global se reentrena; por eso las series activas del panel (b), medidas dentro de la corrida A, no repiten la D de la fila B.

Figura 15

Cascada de conformación de la muestra y sensibilidad del umbral de intermitencia. Paneles: (a) cascada de inclusión; (b) sensibilidad del umbral



Nota. El panel (a) muestra las series que sobreviven a cada criterio de la cascada; el (b), el tamaño de la muestra y la cobertura de valor al variar el umbral de proporción de ceros, con el historial y el volumen fijos en los valores adoptados (el círculo marca la decisión adoptada). Elaboración propia.

Tabla 25

Sensibilidad de la cohorte de evaluación: tamaño, cobertura y D valorizada a un paso en el bloque de prueba

Panel (a). Cohortes

Cohorte	Series	Series con costo	Cobertura del valor de entrenamiento (%)	D motor (%)	D réplica de la fórmula base (%)	D promedio móvil de 12 meses (%)	D ingenuo (%)	D LightGBM (%)	Motor menos réplica de la fórmula base (pp)	Posición del motor
Original (publicada)	1.668	1.513	95,04	75,4	100,0	85,4	85,6	77,0	−24,6	1 de 11
A: sin exigir venta en prueba	1.812	1.657	96,18	75,1	100,0	85,4	85,6	77,1	−24,9	1 de 11
B: solo activas al origen	1.661	1.506	91,66	74,5	98,8	84,3	85,2	75,6	−24,3	1 de 11

Panel (b). Variante A por estado al origen y venta en el bloque de prueba

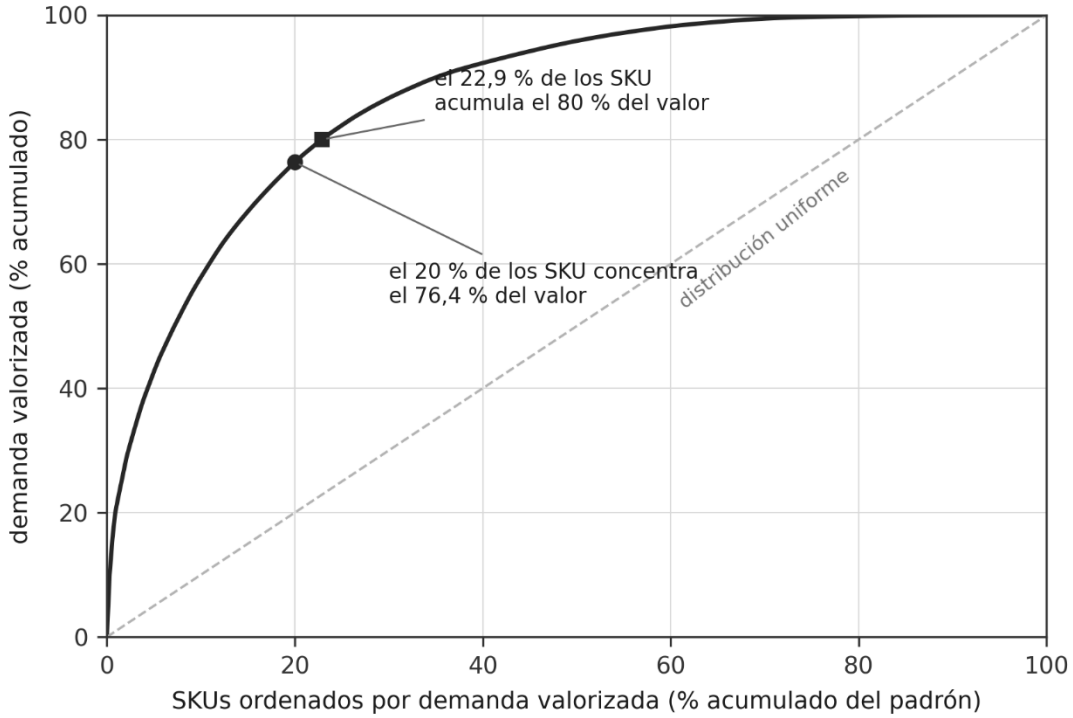
Grupo de la variante A	Series	Series con costo	Cobertura del valor de entrenamiento (%)	D motor (%)	D réplica de la fórmula base (%)	Motor menos réplica de la fórmula base (pp)
Todas	1.812	1.657	96,18	75,1	100,0	−24,9
Con venta en prueba	1.668	1.513	95,04	75,1	100,0	−24,9
Sin venta en prueba	144	144	1,14	n. d.	n. d.	n. d.
Activas o dormidas al origen	1.777	1.622	95,49	74,8	99,7	−25,0
Activas al origen	1.661	1.506	91,66	74,2	98,8	−24,6
Activas, con venta en prueba	1.565	1.410	90,68	74,2	98,8	−24,6
Activas, sin venta en prueba	96	96	0,98	n. d.	n. d.	n. d.

Grupo de la variante A	Series	Series con costo	Cobertura del valor de entrenamiento (%)	D motor (%)	D réplica de la fórmula base (%)	Motor menos réplica de la fórmula base (pp)
Dormidas al origen	116	116	3,83	111,3	159,0	−47,6
Dormidas, con venta en prueba	68	68	3,67	111,3	159,0	−47,6
Dormidas, sin venta en prueba	48	48	0,16	n. d.	n. d.	n. d.
Descontinuadas al origen (todas con venta en prueba)	35	35	0,69	172,9	178,2	−5,2

Nota. D = WMAPE valorizado + |sesgo valorizado agregado|, a un paso en el bloque de prueba (gestión 2026), sobre las series con costo de cada cohorte; cada D se compara con la de los otros modelos de su misma cohorte. Réplica de la fórmula base: el promedio móvil de 12 meses con factor de crecimiento, réplica de la fórmula base de planificación de la empresa sin ajustes de consenso (apartado 2.7). Cobertura: valor de entrenamiento de la cohorte, valorizado al costo unitario, sobre el de la población objetivo, como en la Tabla 31. Original: la cohorte publicada (cascada del apartado 2.6.3). A, sin exigir venta en prueba: sin el requisito de presencia en el bloque de prueba y con la vida de cada serie extendida con ceros hasta marzo de 2026; es una sensibilidad retrospectiva, porque la presencia en validación se sigue midiendo sobre la vida observada de cada serie, de su primera a su última venta en todo el período, incluida la prueba. B, solo activas al origen: la A restringida a las series activas al origen; es la sensibilidad más estricta, porque, dentro de la población objetivo, su composición no depende de ventas posteriores al cierre de validación. En el repositorio (Anexo 7) y en el manifiesto expurgado bajo custodia (fila 7 de la Tabla 47), A y B llevan los rótulos 'cohorte al origen' y 'cohorte al origen, sólo activas'. Estado al origen según la regla del apartado 4.2.3 y del Anexo 14, medido al cierre de validación (marzo de 2025) sobre la actividad observada. En los grupos sin venta en prueba la D no existe, porque la demanda valorizada es nula. n. d.: no disponible. Las diferencias se calculan con las D sin redondear. Elaboración propia con el script 'scripts/sensibilidad_cohorte.py' del repositorio (Anexo 7), a partir de las salidas de las tres corridas (todas sobre el commit 472b891, con el árbol limpio).

Figura 16

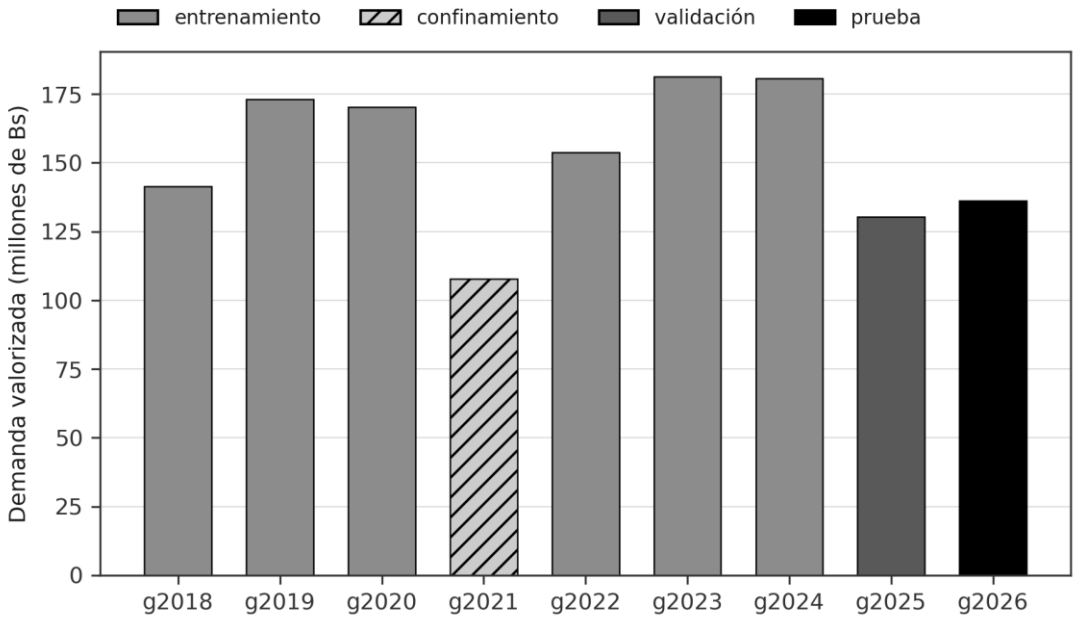
Curva de concentración de la demanda valorizada por SKU (Pareto)



Nota. Curva construida sobre los 338 SKU de la muestra con costo asignado; la demanda corresponde al período completo del estudio, de abril de 2017 a marzo de 2026, valorizada al costo unitario. La diagonal punteada representa la distribución uniforme. Elaboración propia.

Figura 17

Demanda valorizada por gestión comercial y su asignación a los bloques del estudio



Nota. Cada gestión comercial abarca de abril del año anterior a marzo del año que la nombra. El evento exógeno se extiende de marzo de 2020 a febrero de 2021, por lo que la gestión 2021, marcada con trama y rotulada “confinamiento” en la leyenda, concentra once de sus doce meses; la gestión 2020 solo aporta su último mes y no se marca. Las gestiones 2025 y 2026 conforman los bloques de validación y de prueba. Elaboración propia.

ANEXO 12. Documentación del diseño y la calibración del motor

Este anexo documenta el diseño y la calibración del motor: el conjunto de modelos candidatos con la hipótesis, el criterio de inclusión y el respaldo de cada brazo; el recorrido de la búsqueda de hiperparámetros del modelo global; el efecto de las variables explicativas y de la calibración; la trazabilidad de los requisitos de diseño del diagnóstico en el motor propuesto; y los hiperparámetros del modelo global, con el valor elegido, el rango explorado, la función de cada uno y la lectura de la búsqueda. En la Tabla 28, esa lectura (la meseta, la importancia y las correlaciones) es descriptiva y no tiene valor inferencial, porque los ensayos no son una muestra independiente.

Tabla 26
Conjunto de modelos del estudio: hipótesis, criterio de inclusión y respaldo

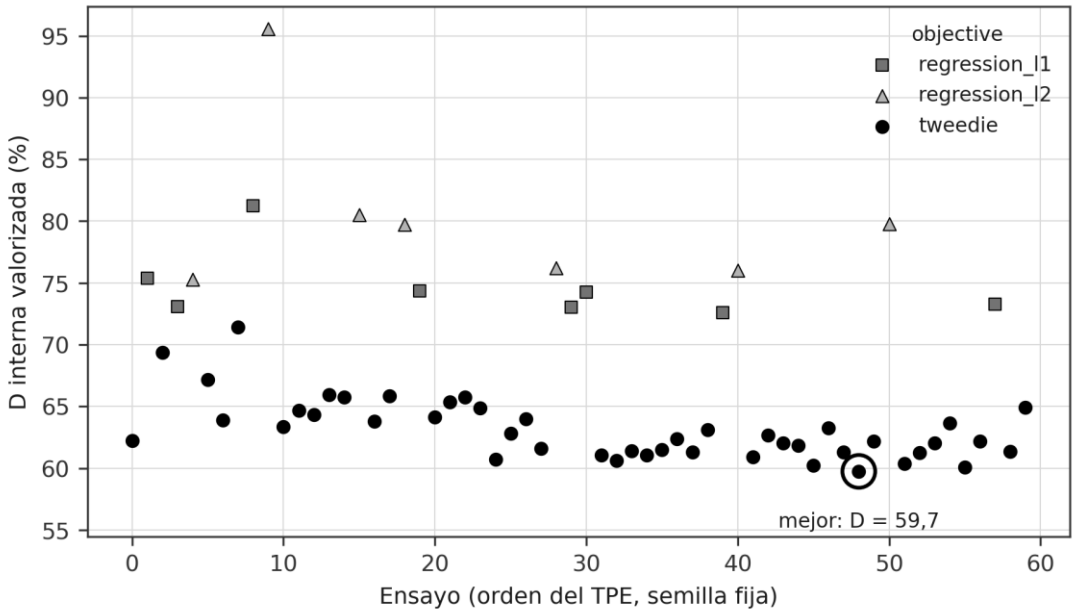
Brazo(s)	Hipótesis que aporta	Criterio de inclusión	Respaldo
naive_m1 / naive_m1_gf	persistencia del último mes, sin y con factor de crecimiento	línea base estándar del área y, con factor de crecimiento, réplica de la fórmula base de la empresa sin ajustes de consenso, con el último mes como nivel base	Hyndman y Athanasopoulos (2018); diagnóstico
ma_2, ma_12, ma_2_gf, ma_12_gf	nivel de corto plazo y promedio anual, sin y con factor de crecimiento	fórmula aplicada por planificación (variantes con factor de crecimiento, ventanas de 2 y 12 meses) y su nivel base sin corrección	análisis documental del diagnóstico
exp_smooth_opt	nivel con memoria exponencial, parámetro optimizado por serie	clásico automatizable bajo un mismo criterio para todas las series	Hyndman et al. (2002)
holt_winters	nivel, tendencia y estacionalidad anual	la campaña escolar exige un componente estacional explícito	Hyndman et al. (2008)
croston	demanda intermitente: tamaño e intervalo por separado	régimen intermitente y esporádico del padrón	Croston (1972); Syntetos y Boylan (2005)
lightgbm (pérdida Tweedie)	relaciones no lineales y aprendizaje global entre series	mejor familia en demanda minorista; pérdida adecuada para conteos con ceros	Ke et al. (2017); Kolassa (2016); Makridakis et al. (2022)

Brazo(s)	Hipótesis que aporta	Criterio de inclusión	Respaldo
motor	selección del mejor modelo por serie en validación	heterogeneidad de regímenes del portafolio	antecedentes: Valdivia Espinosa (2019); Castro Morales (2024)

Nota. Elaboración propia; el detalle de cada criterio se desarrolla en el apartado 4.2.1.3.

Figura 18

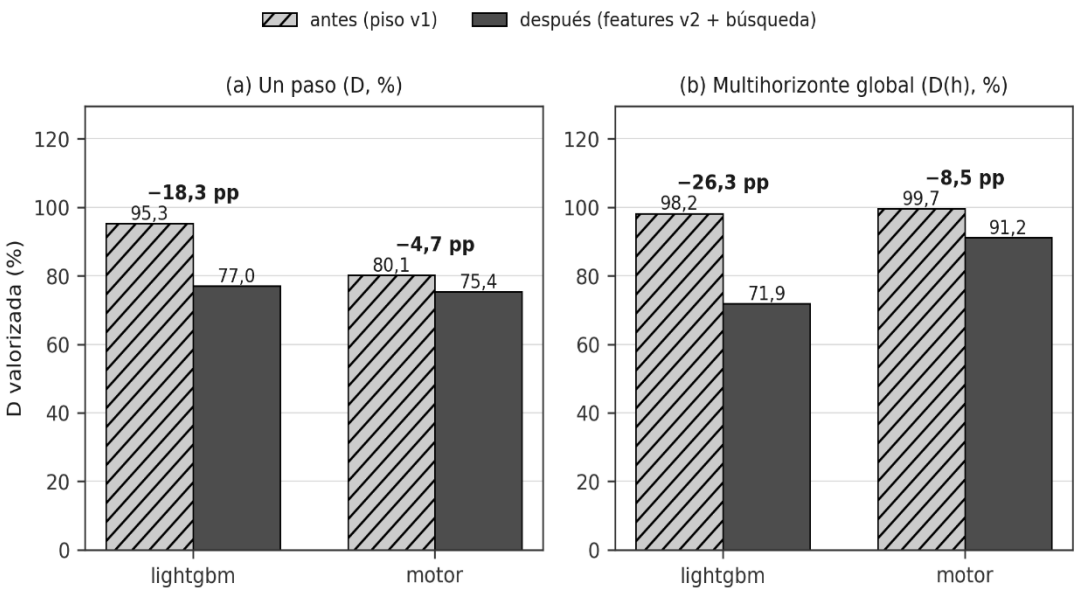
Búsqueda de hiperparámetros: error interno valorizado por ensayo y función de pérdida



Nota. Cada punto es un ensayo del optimizador bayesiano (TPE, semilla fija, pliegue interno de la gestión 2024); el círculo marca el mejor ensayo (D interna = 59,7 %, ensayo 48, función de pérdida Tweedie). En la leyenda, regression_l1 es la pérdida absoluta y regression_l2, la cuadrática. Elaboración propia.

Figura 19

Efecto de las variables explicativas y de la calibración: D valorizada antes y después, a un paso y en el horizonte. Paneles: (a) a un paso; (b) en el horizonte



Nota. “Antes” (“piso v1” en la leyenda) corresponde al modelo con las variables de la versión inicial y sus parámetros originales; “después” (“features v2 + búsqueda” en la leyenda), al modelo con el conjunto completo de variables, es decir, las derivadas de la propia serie (media del mismo mes, razón interanual, momentum y extremos móviles), el precio, los quiebres, la venta perdida, el tipo de cambio y la categoría, y la función de pérdida Tweedie con hiperparámetros calibrados. Elaboración propia.

Tabla 27

Trazabilidad de los requisitos de diseño del diagnóstico en el motor propuesto

Requisito de diseño (Tabla 7)	Componente del motor que lo atiende	Evidencia de cumplimiento
Incorporar automatización integral del proceso de pronóstico	Flujo integral que ejecuta las fases de manera secuencial a partir de una configuración única (módulos 1 a 5)	Corrida completa registrada en el manifiesto: 37,4 minutos (apartado 4.3.4)
Diseñar un flujo de trabajo unificado y parametrizable	Configuración única de la corrida y entorno reproducible en imagen de contenedor	Manifiesto y registro de flujo de cada corrida (apartado 4.2.1.6); cinco corridas de variantes sin editar código (apartado 4.2.2.2)
Integrar métricas de evaluación como MAE, MAPE, RMSE y Bias	Módulo de evaluación: métricas por serie y métrica valorizada D	Tabla 8 y Figura 20 del Anexo 13 (apartado 4.3.2)

Requisito de diseño (Tabla 7)	Componente del motor que lo atiende	Evidencia de cumplimiento
Optimizar tiempos mediante ejecución automatizada y programación periódica	Ejecución secuencial de la cadena completa sin intervención manual	De 3 a 5 días de armado manual a 37,4 minutos de cómputo, alcances no equiparables (apartado 4.3.4); la programación periódica de la corrida queda para la implementación (apartado 4.4), con su diseño en el apartado 4.2.5; la integración con las herramientas de visualización se declara como trabajo futuro (apartado 4.2.1.6)
Establecer un repositorio centralizado de datos históricos	Captura del histórico con huella SHA-256 e ingesta validada (módulo 1)	Captura de 204.096 filas y huella registrada en el manifiesto (apartado 4.2.6.4); el repositorio centralizado queda planteado en las recomendaciones; el almacén de capturas selladas del apartado 4.2.5 cubre el insumo del motor
Incorporar selección automática del modelo según comportamiento histórico	Motor de selección por serie sobre el bloque de validación (módulo 4)	Reparto de la selección (Figura 9) y ventaja en la métrica D (Tabla 8)
Minimizar la intervención manual y fortalecer la validación objetiva	Selección con regla declarada y registro por serie del modelo elegido	Intervalos con incertidumbre agrupada y, como complemento, contraste de Wilcoxon y Friedman con post hoc de Nemenyi (apartado 4.3.2)

Nota. Los requisitos provienen de la columna “Requisito de diseño derivado” de la Tabla 7; la evidencia remite al apartado del capítulo IV donde se constata. Elaboración propia.

Tabla 28

Hiperparámetros del modelo global: valor elegido, rango explorado, función y lectura de la búsqueda

Hiperparámetro	Valor elegido	Rango explorado (escala)	Función	Rango en la meseta (16 ensayos)	Importancia en la búsqueda (Optuna, Tweedie)	Correlación de rangos con la D interna (Tweedie)
Función de pérdida ('objective')	Tweedie	Absoluta, 8 ensayos (D interna de 72,6 a 81,3); cuadrática, 7 (75,3 a 95,6); Tweedie, 45 (59,7 a 71,4) (categórica)	Estructural: decide qué estadístico de la demanda aprende el modelo	Tweedie en los 16	0,84 (sobre los 60 ensayos)	n. d.
Potencia de la varianza Tweedie ('tweedie_variance_power')	1,465	1,1 a 1,6 (lineal; solo con pérdida Tweedie)	Forma de la pérdida: cuánto crece la varianza con el nivel	1,39 a 1,59	0,20	−0,30
Tasa de aprendizaje ('learning_rate')	0,053	0,02 a 0,12 (logarítmica)	Ritmo: contrae el aporte de cada árbol	0,028 a 0,081	0,05	+0,12
Número de árboles (parada temprana)	87 en el pliegue interno; 76 en la corrida principal	No se busca: parada a las 100 rondas sin mejora, con techo de 3.000 (de 33 a 226 en los ensayos Tweedie)	Ritmo: se compensa con la tasa	52 a 144	n. d.	−0,03
Número máximo de hojas ('num_leaves')	137	15 a 255 (logarítmica, entera)	Capacidad de cada árbol	77 a 189	0,25	−0,29

Hiperparámetro	Valor elegido	Rango explorado (escala)	Función	Rango en la meseta (16 ensayos)	Importancia en la búsqueda (Optuna, Tweedie)	Correlación de rangos con la D interna (Tweedie)
Mínimo de observaciones por hoja ('min_data_in_leaf')	61	10 a 200 (logarítmica, entera)	Capacidad: evidencia mínima de cada hoja	38 a 113	0,05	+0,19
Fracción de variables por árbol ('feature_fraction')	0,578	0,5 a 1 (lineal)	Regularización: submuestreo de columnas	0,54 a 0,75	0,11	+0,32
Fracción de filas por iteración ('bagging_fraction')	0,870	0,5 a 1 (lineal)	Regularización: submuestreo de filas	0,73 a 0,88	0,13	−0,02
Penalización L2 ('lambda_l2')	24,47	0 a 30 (lineal)	Regularización: encoge el valor de cada hoja	22,2 a 29,9	0,21	−0,49
Valores fijos (no buscados)	Semilla del modelo 20260406; semilla de la búsqueda 20260408; un hilo; modo determinista; submuestreo de filas en cada iteración	n. d.	Reproducibilidad	n. d.	n. d.	n. d.

Nota. Criterio: D interna valorizada, WMAPE más |Bias| ponderados por el costo unitario sobre las series del pliegue con costo asignado. El valor elegido es el del mejor ensayo, el 48 (D interna de 59,7 %, WMAPE de 59,6 % y sesgo de +0,2 %). Los ensayos se numeran desde 0. Meseta: los 16 ensayos, todos Tweedie e incluido el elegido, cuya D interna quedó a menos de 2 puntos de la mejor. Importancia en la búsqueda: fracción de la varianza de la D interna que atribuye a cada hiperparámetro el evaluador de importancia por defecto de la biblioteca Optuna (Akiba et al., 2019), versión 4.1.0; promedio de cinco semillas del evaluador (0 a 4), calculado sobre los 45 ensayos Tweedie, salvo la fila de la pérdida, calculada sobre los 60 ensayos sin la potencia, que solo existe con pérdida Tweedie. Correlación de rangos de Spearman

entre el valor de cada hiperparámetro y la D interna en los 45 ensayos Tweedie: un signo negativo indica que los valores altos acompañan D internas menores, es decir, mejores. n. d.: no disponible, porque la medida no corresponde a esa fila. Elaboración propia con el script 'scripts/tabla_hiperparametros.py' del repositorio del Anexo 7, a partir de la tabla de ensayos ('resultados/ensayos/lightgbm_tuning_ensayos.csv') y de la configuración declarada ('config/config.yaml').

ANEXO 13. Validación metodológica y desempeño desagregado

Este anexo reúne la validación metodológica documental y el desempeño desagregado del estudio: la coherencia entre el marco metodológico declarado y la propuesta desarrollada, la descomposición del error compuesto valorizado por modelo y la dispersión del error por serie.

Tabla 29

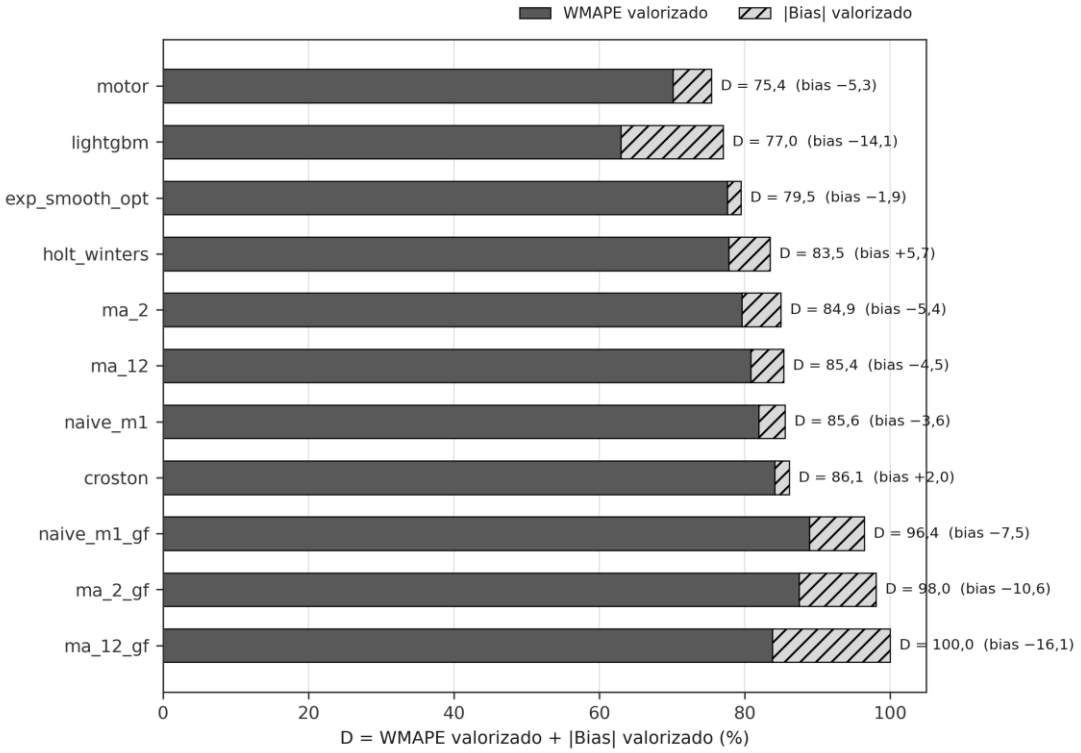
Coherencia entre el marco metodológico declarado y la propuesta desarrollada

Elemento metodológico	Aplicación en la propuesta
Enfoque mixto (predominancia cuantitativa)	Análisis cuantitativo de los datos históricos de ventas de abril de 2017 a marzo de 2026 mediante las métricas por serie (MAE, MAPE, RMSE y Bias), la métrica valorizada de decisión D = WMAPE + |Bias| y pruebas de significancia estadística, integrado con la información cualitativa de la entrevista y la observación mediante triangulación metodológica.
Tipo propositivo (aplicado)	Diseño de una solución funcional para un problema empresarial real, sin requerir implementación operativa.
Diseño no experimental, longitudinal y retrospectivo	Backtesting temporal: comparación del desempeño de los once brazos de pronóstico sobre la misma partición cronológica y con las mismas métricas.
Métodos teóricos	Analítico-sintético, inductivo-deductivo, histórico-lógico y abstracto-concreto para estructurar el diseño del motor.
Métodos empíricos	Entrevista semiestructurada, análisis documental, observación estructurada y procesamiento de datos históricos.
Hipótesis de investigación	Verificación mediante resultados de desempeño y contraste estadístico (intervalos con incertidumbre agrupada; Wilcoxon y Friedman-Nemenyi como complemento): a un paso, el motor reduce el error de pronóstico frente a la réplica de la fórmula base sin ajustes de consenso y frente al promedio móvil de 12 meses, con diferencias que se sostienen con incertidumbre agrupada por SKU; frente al modelo ingenuo, solo la menor D del portafolio se sostiene, y solo por SKU (Tabla 20 del Anexo 8).

Nota. Elaboración propia.

Figura 20

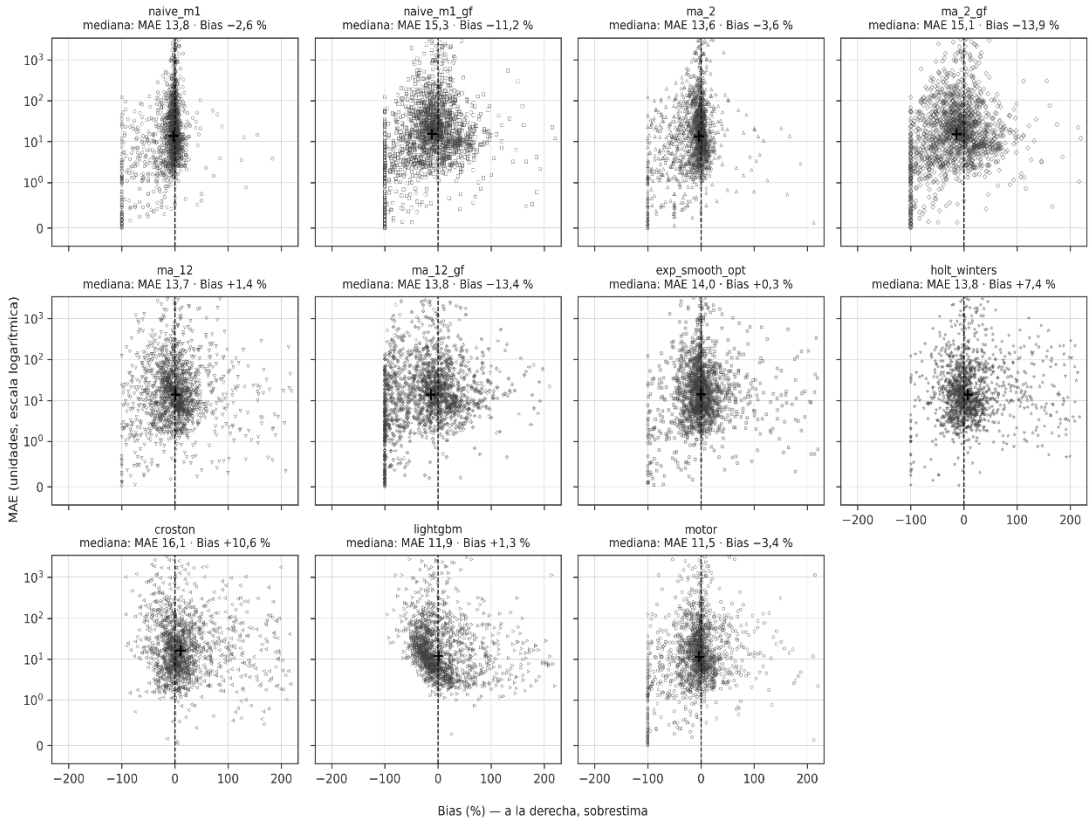
Descomposición del error compuesto valorizado D por modelo (bloque de prueba, a un paso)



Nota. Cada barra descompone la D del modelo en sus dos términos. El segmento oscuro es el WMAPE valorizado y el segmento con trama, el valor absoluto del Bias valorizado, por lo que su longitud no distingue entre subestimación y sobrestimación; la anotación al final de la barra repite la D y el Bias con su signo. Ambos términos se calcularon sobre las 1.513 series con costo unitario asignado, en el bloque de prueba (gestión 2026) y en evaluación a un paso. Los rótulos de los brazos son los de la Figura 10. Elaboración propia a partir de las salidas del motor.

Figura 21

Dispersión del error por serie: MAE frente a Bias, por modelo (bloque de prueba)



Nota. Cada punto es una serie. El eje horizontal está recortado al percentil 95 de |Bias| (±220 %) y el vertical al percentil 99,5 del MAE (3.251 unidades), en escala logarítmica simétrica con tramo lineal por debajo de 1; quedan fuera del recuadro 1.010 puntos de 18.348 (5,5 %). La cruz marca la mediana de cada modelo, calculada sobre todas las series, y la columna de puntos en Bias = −100 %, que reúne 712 de esos 18.348 puntos (3,9 %), corresponde a series cuyo pronóstico colapsa a cero en el bloque de prueba. Los rótulos de los brazos son los de la Figura 10. Elaboración propia.

ANEXO 14. Tratamiento de datos y de eventos exógenos para la operación

Este anexo reúne la evidencia que sustenta los apartados 4.2.3 y 4.2.4. La Tabla 30 resume el tratamiento propuesto por caso de dato. La reclasificación por estado, el conjunto elegible y los respaldos de esa tabla son diseño propuesto, no implementado, y las D que informa son descriptivas y no intervinieron en ninguna selección. La Tabla 31 cruza el estado de actividad de las 4.406 combinaciones de la población objetivo con su inclusión en la muestra, y la Tabla 32 atribuye cada una al primer criterio de la cascada que la excluyó, con su peso en el valor de entrenamiento. En la Tabla 31, la población se reparte por estado en 2.493 activas, 1.044 descontinuadas, 469 sin historia, 227 dormidas, 92 recientes y 81 nuevas; la muestra reúne 1.668 series (1.513 con costo) y el 95,04 % del valor de entrenamiento, y las 2.738 excluidas, 2.113 de ellas con costo, reúnen el 4,96 % restante. Las series sin historia figuran con cero en la columna “Con costo”, porque la salida publicada no permite distinguir si tienen costo unitario asignado. Las Tablas 31 y 32 y los conteos de costo faltante del párrafo que sigue a la Tabla 32 se reproducen con el script 'scripts/anexo_n_estados.py' del repositorio (Anexo 7). El script lee las salidas publicadas de la corrida principal, se detiene si no reproduce la cascada de exclusión y escribe solo agregados; como control, reproduce además la D del ingenuo y del promedio móvil de dos meses de la Tabla 8. Las cifras de la gestión de prueba fuera de la muestra (apartado 4.2.3 y Tabla 30) y las de razón entre costo y precio y de duplicados se calcularon sobre la captura, con la misma clasificación por serie. La Tabla 33 presenta la taxonomía de eventos exógenos del apartado 4.2.4. La Tabla 34 llena la ficha de registro de ese protocolo con la pandemia, el único evento que el estudio trató, como ejemplo con valores reales.

Tabla 30

Tratamiento propuesto por caso de dato para la operación del motor

Caso	Cómo lo trata el estudio	Regla operativa y umbral	Modelo o respaldo	Evidencia del estudio
1. Sin historia o producto nuevo, sin venta antes del origen	Excluida en el primer paso de la cascada (sin venta en el entrenamiento).	Alta del producto con su fecha prevista de lanzamiento. Planificación declara un análogo (producto existente por un factor de escala); si no lo hay, se usa el perfil de categoría, canal y regional. La extensión de un producto existente a otra combinación hereda el perfil del mismo producto. Marca “juicio” y registro como ajuste.	Hasta la primera venta, el análogo o el perfil; desde ella, LightGBM global con respaldo en el promedio móvil de dos meses (pasa a la fila 2).	469 series: 129 extensiones y 340 productos nuevos. 388 venden en la gestión de prueba y reúnen el 4,3 % de su valor a costo. D ingenuo 121,9 % y promedio móvil de dos meses 122,9 %, sobre las 385 con costo que venden en prueba.
2. Menos de 12 meses de historia (estados nueva y reciente, y toda serie con 1 a 11 meses)	Excluida por historial menor a 36 meses.	Conjunto elegible: LightGBM, ingenuo y promedio móvil de dos meses. Sin selección por serie mientras la historia no cubra la ventana de selección. Marca “historia corta”.	LightGBM global; respaldo, promedio móvil de dos meses.	81 nuevas y 92 recientes; 617 series de 1 a 11 meses entre las excluidas por historia corta. D ingenuo sobre las que venden en prueba con costo: 1 a 11 meses, 34 series, 38,8 %; recientes, 14 series, 36,5 %; nuevas, 20 series, 132,6 %.

Caso	Cómo lo trata el estudio	Regla operativa y umbral	Modelo o respaldo	Evidencia del estudio
3. Historia de 12 a 35 meses	Excluida por historial menor a 36 meses.	Conjunto reducido: con 12 a 23 meses, ingenuo, promedios móviles de 2 y 12 meses, suavizado exponencial simple y LightGBM; con 24 a 35 se suman Holt-Winters y las variantes con factor de crecimiento; Croston si ADI ≥ 1,32. LightGBM es la opción por defecto, y la selección por serie solo lo reemplaza por otro candidato elegible cuando la serie cubre completa la ventana de selección.	LightGBM global; respaldo, promedio móvil de dos meses.	546 series (201 activas, 279 descontinuadas y 66 dormidas). Sobre las que venden en prueba con costo: 150 series, D ingenuo 78,1 % y promedio móvil de dos meses 73,3 %. Activas de historia corta, 108 series: 76,7 % y 71,5 %; diez de ellas concentran el 68,1 % de su demanda valorizada. Control de la muestra: 85,6 % y 84,9 %.
4. 36 meses o más, con los criterios de la muestra	Muestra de 1.668 series: conjunto de diez candidatos y selección por serie con MAE + |Bias| en validación.	Igual que el estudio: conjunto completo y selección sobre la última gestión cerrada, fija durante la gestión (apartado 4.2.5.4).	El modelo que asigna el motor; respaldo, promedio móvil de dos meses.	D del motor 75,4 % sobre las 1.513 series con costo (Tabla 8). La muestra reúne el 89,9 % del valor a costo de la gestión de prueba.

Caso	Cómo lo trata el estudio	Regla operativa y umbral	Modelo o respaldo	Evidencia del estudio
5. Dormida (6 a 11 meses sin venta) o descontinuada (12 meses o más sin venta)	210 dormidas y 1.026 descontinuadas excluidas; 17 y 18 entran a la muestra porque cumplen los criterios.	Dormida: método de Teunter, Syntetos y Babai, que actualiza cada mes la probabilidad de demanda y la lleva hacia cero mientras no hay venta (TSB; Teunter et al., 2011). Descontinuada: pronóstico cero con alarma de reactivación; si vuelve a vender, la corrida siguiente la reclasifica con su historia. Un código retirado del portafolio sale por la fila 7.	TSB para la dormida; cero con alarma para la descontinuada.	Venden en la gestión de prueba 71 de 227 dormidas y 172 de 1.044 descontinuadas (16,5 %), con el 0,19 % y el 0,46 % del valor a precio. D ingenuo 148,4 % (69 dormidas) y 161,8 % (152 descontinuadas), sobre todas las del estado con costo y venta en prueba, dentro o fuera de la muestra.
6. Intermitencia crónica (más del 70 % de meses sin venta)	Excluida; Croston integra el conjunto solo dentro de la muestra.	Croston o su corrección de sesgo (SBA; Syntetos & Boylan, 2005) cuando ADI ≥ 1,32. El error se evalúa en agregado por categoría y canal, no por serie, porque por serie no admite una medición fiable (apartado 2.6.3).	Croston o SBA; respaldo, promedio de los últimos doce meses.	796 series y 0,85 % del valor de entrenamiento; 410 venden en prueba, con el 0,9 % de su valor a costo. D ingenuo 167,1 % sobre las 343 con costo que venden en prueba (descriptiva).

Caso	Cómo lo trata el estudio	Regla operativa y umbral	Modelo o respaldo	Evidencia del estudio
7. Reemplazo de código, combo o presentación múltiple, y código fuera del portafolio vigente	Resuelto en origen: el reporte consolidado expresa cada código en su código vigente, con el factor de conversión y en la unidad principal; combos y presentaciones múltiples, por factor al producto base; códigos fuera del portafolio vigente, excluidos. Los quiebres no se reexpresan.	Maestro de equivalencias versionado (código anterior, vigente, factor, tipo y fecha de vigencia). Historia, quiebres y venta perdida se transfieren por el factor. Reemplazo dentro del horizonte: corte en la fecha de vigencia, única regla del motor, sin curva de transición. El inventario remanente es una decisión comercial y entra como ajuste registrado. Factor y unidad se validan al alta. Reemplazo de uno a varios no previsto (si apareciera, participaciones declaradas que suman uno).	El de la serie vigente, según los meses de su historia transferida.	Maestro uno a uno (apartados 2.5.3 y 4.2.3), verificado en el código de la consulta y en la base; sin cifras del maestro, por confidencialidad.

Caso	Cómo lo trata el estudio	Regla operativa y umbral	Modelo o respaldo	Evidencia del estudio
8. Atributos del maestro faltantes o inválidos (por ejemplo precio, costo, peso y volumen)	Precio de lista vigente, único por combinación y sin faltantes. 155 series de la muestra sin costo, fuera de la agregación por valor. Peso y volumen no se usan.	Regla genérica: el contrato de entrada detecta nulos, ceros, negativos e incoherencias; cada atributo tiene una imputación declarada con marca; nada se descarta en silencio; el registro de flujo cuenta las imputaciones. Costo: razón costo/precio de la categoría. Precio: último precio promedio histórico de la serie o, si no existe, mediana de la categoría. Peso y volumen: imputación jerárquica (producto equivalente, luego categoría).	Sin cambio de modelo; las series con costo imputado quedan fuera de la medición confirmatoria.	Precio: 0 filas nulas o no positivas de 147.701; un valor por serie en las 4.406. Costo: falta por producto completo; 38 SKU y 317 series en la población (310 de la categoría K y 7 de la D); 31 SKU y 155 series en la muestra, todas de la categoría K. Razón costo/precio en la categoría K: mediana 0,535 (rango intercuartílico 0,493 a 0,582). 36 series con costo mayor que precio (12 en la muestra).
9. Atípicos, ceros intermedios y quiebres	Ningún valor se depura; ceros intermedios completados con cero dentro de la vida de la serie; quiebres como variable explicativa desde abril de 2022.	Atípico: criterio declarado de antemano, por mes calendario (frente al mismo mes de otras gestiones), marcado y no borrado. Cero: demanda nula dentro de la vida de la serie, ausencia de producto fuera de ella y demanda censurada si hay quiebre registrado.	Panel con marcas; ningún valor se reemplaza sin registro.	Un recorte a la media más tres desvíos por serie (desvío poblacional del entrenamiento) marcaría 2.709 celdas en 1.522 de las 1.668 series de la muestra (91,2 %), el 72,4 % entre noviembre y febrero, y quitaría el 4,86 % del volumen de entrenamiento de la muestra. Ceros intermedios: 42,3 % del panel de la población y 23,4 % del de la muestra.

Caso	Cómo lo trata el estudio	Regla operativa y umbral	Modelo o respaldo	Evidencia del estudio
10. Venta perdida y demanda censurada	Variable explicativa del modelo global; el objetivo es la venta efectiva.	Los meses con quiebre o venta perdida se marcan y se informan aparte al medir el error. Depuración de consultas repetidas. La demanda no restringida (venta más venta perdida) queda como objetivo alternativo cuando el registro acumule historia.	Sin cambio de modelo.	Primer registro positivo en enero de 2020, sustantivo desde 2022; 15,5 % de la demanda solicitada en las gestiones 2022 a 2026 (archivo completo, Tablas 5 y 6); 52.357 celdas serie-mes con venta perdida positiva en la población.
11. Duplicados, nomenclatura, unidad de medida y devoluciones	572 filas con clave repetida (286 pares), sumadas; nomenclatura de canales de 2017 y 2018 estandarizada (Anexo 6); devoluciones previstas, ninguna en la captura.	Conviven dos reglas (Tabla 39). Filas idénticas en todas sus columnas: se deduplican y se registran, no se suman. Misma clave con valores distintos: detiene la publicación de las series afectadas. Tabla de correspondencia de nomenclatura versionada. Unidad validada contra la unidad principal del maestro. Devoluciones separadas de la demanda y contadas.	Sin cambio de modelo.	Los 286 pares son filas idénticas en todas sus columnas, de un único producto: el 100 % de sus filas, en 8 combinaciones (5 en la muestra). Exceso del 0,48 % del volumen de la población. Las cinco combinaciones de la muestra pesan el 0,14 % de la demanda valorizada de prueba.

Caso	Cómo lo trata el estudio	Regla operativa y umbral	Modelo o respaldo	Evidencia del estudio
12. Canal institucional y categorías fuera de la población (alcance)	102 de las 1.412 combinaciones institucionales entran a la muestra (Tabla 6); siete categorías quedan fuera de la población por diseño.	Institucional: pronóstico por agregado de canal y regional con reparto por participación, o cartera de pedidos declarada. Criterio de identificación del pedido firme: adjudicado, con cantidad y fecha de entrega comprometidas; se registra como componente firme, fuera de la selección del motor, y se suma al pronóstico estadístico (apartado 4.2.3). Siete categorías: entrada por etapas con las mismas reglas.	Agregado con reparto, más el pedido firme declarado.	1.310 de las 2.738 excluidas son institucionales, pero reúnen solo el 8,9 % del valor a precio que quedó fuera de la muestra en la gestión de prueba. Las siete categorías reúnen el 27,6 % de la demanda valorizada del período.

Nota. El estado de actividad se mide al cierre del bloque de entrenamiento en el estudio y al último mes cerrado en la operación. Las D son a un paso en la gestión de prueba (2026), valorizadas a costo sobre las series con costo unitario y venta en esa gestión. El ingenuo toma la venta del mes anterior (cero si la serie no tiene historia) y el promedio móvil de dos meses, la media de los dos meses previos disponibles dentro de la vida de la serie; D = WMAPE + |Bias|. El mismo cálculo reproduce sobre la muestra los valores de la Tabla 8 (85,6 % y 84,9 % en 1.513 series). Los porcentajes de valor de la gestión de prueba se miden sobre la población objetivo. Elaboración propia a partir de las salidas del motor y de la captura.

Tabla 31

Estado de actividad e inclusión en la muestra de las combinaciones de la población objetivo

Estado	En la muestra	Series	Con costo	% del valor de entrenamiento	Meses de historia (mediana)	Meses en cero (mediana)
Activa	sí	1.633	1.478	94,85	83	17,9 %
Activa	no	860	801	3,63	51	73,9 %
Nueva	no	81	63	0,02	2	0,0 %
Reciente	no	92	77	0,14	6	7,1 %
Dormida	sí	17	17	0,13	62	39,3 %
Dormida	no	210	205	0,46	43	82,5 %

Estado	En la muestra	Series	Con costo	% del valor de entrenamiento	Meses de historia (mediana)	Meses en cero (mediana)
Descontinuada	sí	18	18	0,06	68	55,6 %
Descontinuada	no	1.026	967	0,71	20	69,8 %
Sin historia en entrenamiento	no	469	0	0,00	0	n. d.

Nota. Estado de actividad al cierre del bloque de entrenamiento (marzo de 2024): activa, con venta en los últimos seis meses; nueva, con menos de seis meses desde la primera venta; reciente, de seis a once meses desde la primera venta; dormida, de seis a once meses sin venta; descontinuada, doce meses o más sin venta; sin historia, sin ninguna venta en el entrenamiento. La condición de nueva o reciente prevalece sobre las demás. El valor de entrenamiento es la demanda observada del bloque valorizada al costo unitario, sobre el total de la población. “Con costo” cuenta las series con historia de entrenamiento y costo unitario asignado. Los meses de historia y los meses en cero se miden sobre el panel de entrenamiento, con los meses intermedios completados con cero; n. d.: no disponible, porque la serie no tiene meses de entrenamiento. Elaboración propia a partir de las salidas del motor ('scripts/anexo_n_estados.py').

Tabla 32

Combinaciones de la población objetivo por primer criterio de la cascada que las excluye y estado de actividad

Primer criterio que excluye	Activa	Nueva	Reciente	Dormida	Descontinuada	Sin historia en entrenamiento	Total	% del valor
Sin historia en entrenamiento	0	0	0	0	0	469	469	0,00
Historial menor que 36 meses	203	81	92	72	715	0	1.163	2,14
Más del 70 % de meses en cero	422	0	0	108	266	0	796	0,85
Volumen acumulado menor que 50 unidades	12	0	0	2	1	0	15	0,00
Ausente en validación	90	0	0	21	40	0	151	0,83
Ausente en prueba	133	0	0	7	4	0	144	1,14
En la muestra	1.633	0	0	17	18	0	1.668	95,04

Nota. Cada combinación se atribuye al primer criterio que no cumple, en el orden de la cascada de exclusión del apartado 2.6.3 (Anexo 11); las combinaciones de la última fila cumplen todos. Las columnas son los estados de actividad de la Tabla 31 y sus totales reproducen los de esa tabla. El porcentaje es el del valor de entrenamiento valorizado al costo unitario sobre el total de la población objetivo; en

las dos filas con 0,00 el valor es nulo (sin historia) o menor que una centésima.
Elaboración propia a partir de las salidas del motor ('scripts/anexo_n_estados.py').

La falta de costo unitario es por producto completo: ningún SKU tiene costo en unas combinaciones y no en otras. En la población objetivo, 38 de los 684 SKU carecen de costo unitario y abarcan 317 combinaciones (310 de la categoría K y 7 de la D), de las que 311 tienen historia de entrenamiento. En la muestra, la falta de costo afecta a 31 SKU y 155 combinaciones, todas de la categoría K, que reúnen el 1,64 % del volumen de entrenamiento de la muestra. La razón entre costo y precio es estrecha en la categoría K (mediana 0,535; rango intercuartílico de 0,493 a 0,582), lo que sostiene la imputación por categoría del apartado 4.2.3. En el conjunto de la población la mediana es 0,610, con percentiles 10 y 90 de 0,425 y 0,797. Hay 36 combinaciones con costo mayor que precio (12 en la muestra), que la regla genérica marcaría como anomalía. Las 572 filas duplicadas (286 pares) pertenecen a un único producto y son idénticas en todas sus columnas: son todas sus filas, en sus 78 meses con venta y en 8 combinaciones (5 en la muestra). Su suma agregó un exceso equivalente al 0,48 % del volumen de la población objetivo (0,2 % del archivo completo).

Tabla 33

Taxonomía de eventos exógenos, tratamiento propuesto y evidencia del estudio

Tipo de evento	¿Conocido ex ante?	Alcance	Tratamiento propuesto	Componente que lo sostiene	Evidencia del estudio
Choque masivo de demanda u oferta (pandemia, conflicto, bloqueo de rutas)	No	Portafolio, categoría o regional	Corrección del panel de ajuste (alcance portafolio o categoría) con ventana por regla: valor a costo frente al mismo mes de los doce meses previos al inicio, umbral declarado y revisable, dos meses consecutivos para abrir y para cerrar; o indicadora de pulso o escalón. Evaluación contra lo observado	Panel de ajuste de todos los modelos; la indicadora, solo el modelo global	COVID-19 (marzo de 2020 a febrero de 2021): −40,1 % frente a los doce meses previos; abril de 2020, −89,6 %; 7 de 12 meses bajo un corte ilustrativo de −30 %. Sin la copia (variante 1), D del motor de 74,7 % frente a 75,4 % a un paso; podio sin cambios
Choque macroeconómico (crisis cambiaria, inflación)	No	Portafolio	Exógena rezagada con persistencia; detección del régimen y conmutación de conjuntos	Modelo global; sistema conmutado (exploratorio, no validado)	Tipo de cambio: +54 % en la gestión 2025; en la 2026, máximo en junio de 2025 y cierre 42 % por debajo del inicio. Detector activo en 10 y 7 de 12 meses. El modelo global casi no lo usa: sus dos variables intervienen en 11 y 7 divisiones, frente a 493 del rezago de un mes

Tipo de evento	¿Conocido ex ante?	Alcance	Tratamiento propuesto	Componente que lo sostiene	Evidencia del estudio
Calendario escolar y comercial	Sí	Categoría	Variables deterministas calculadas para el mes pronosticado	Modelo global	Sexta iteración de la extensión: sesgo de −14,1 % a −10,7 % y WMAPE de 62,9 % a 63,8 %; según su auditoría, peor horizonte y peor motor. En exploración
Promociones y cambios de precio	Sí, si se registran	SKU o categoría	Registro ex ante; indicadora de promoción o precio planificado como variable en el horizonte	Modelo global	No tratable con la captura actual: precio de lista único por combinación (Anexo 5) y campo de promociones incompleto (apartado 3.4.4)
Lanzamientos, descontinuaciones y reemplazos de SKU	Sí	SKU	Estado de la serie, conjunto elegible y respaldo; maestro de equivalencias con corte en la fecha de vigencia (apartado 4.2.3 y Tabla 30)	Política por estado y respaldo	81 series nuevas, 1.044 descontinuadas y 227 dormidas (Tabla 31)
Pedidos institucionales o licitaciones	Sí, al adjudicarse	SKU y canal	Pedido adjudicado, con cantidad y fecha comprometidas, como componente firme que se suma al pronóstico estadístico (apartado 4.2.3)	Componente firme, fuera de la selección del motor	1.412 series del canal institucional, con mediana de 4 meses con venta; el registro no identifica contratos (apartado 3.4.4)

Tipo de evento	¿Conocido ex ante?	Alcance	Tratamiento propuesto	Componente que lo sostiene	Evidencia del estudio
Quiebres de inventario	En parte (los previstos)	SKU y regional	Exógena rezagada con persistencia; venta perdida como señal de demanda censurada; meses con quiebre aparte al medir el error	Modelo global; monitor (apartado 4.2.5)	Registro de 48 meses; en el 59,7 % de las combinaciones de producto, regional y mes hubo al menos una semana sin existencia
Cierre o apertura de una regional o de un canal	Sí	Regional o canal	Indicadora de escalón; reinicio del estado de las series afectadas	Modelo global; clasificación por estado (apartado 4.2.3)	No observado en el período de estudio

Nota. Taxonomía propuesta para la operación. Ninguna fila describe un tratamiento que la empresa aplique hoy, salvo la copia de la gestión previa, que el estudio replicó de su práctica documentada. “Conocido ex ante” indica si el evento puede registrarse antes de ocurrir y entrar como variable en el horizonte (registro en el apartado 4.2.4). Las cifras de la pandemia están a costo (convención del Anexo 5), con una sola definición: cada mes frente al mismo mes de los doce meses previos al inicio; el corte de −30 % es una lectura retrospectiva ilustrativa, no un umbral del protocolo. Las del tipo de cambio comparan el primer y el último mes de cada gestión. Las de la variante 1 (Tabla 23) provienen del apartado 4.3.2 (1.505 y 1.513 series con costo); las del calendario, del apartado 4.3.3 y de la auditoría de esa iteración (Anexo 7). Las del detector cuentan los meses con peso positivo sobre el conjunto diverso (Anexo 10); el sistema conmutado se calibró sobre las mismas dos gestiones en que se midió. Las divisiones corresponden al modelo global de la corrida principal. Elaboración propia a partir de las salidas del motor.

Tabla 34

Ficha de registro del evento exógeno de la pandemia según el protocolo propuesto

Campo del registro	Valor para la pandemia, el evento que el estudio trató
Identificador y nombre	EV-01; “covid19”, el nombre con que la configuración de las corridas declara el evento (config/config.yaml, Anexo 7)
Tipo	Choque masivo de demanda u oferta (fila 1 de la Tabla 33): pandemia de COVID-19
Alcance	Portafolio: todas las series del panel de ajuste
Conocido ex ante	No: observado ex post. Su ventana cae íntegra en el bloque de entrenamiento y no alcanza la validación ni la prueba
Fecha de alta (mes desde el que rige)	Marzo de 2020

Campo del registro	Valor para la pandemia, el evento que el estudio trató
Fecha de cierre prevista y efectiva	Febrero de 2021 en los dos casos: ventana de doce meses replicada de la práctica documentada de la empresa (apartado 2.7)
Fecha de registro	Declarado en la configuración antes de ejecutar las corridas (commit 472b891, 19 de octubre de 2026). En la operación sería el mes en que Planificación abriera el evento
Tratamiento y parámetros	Copia de la gestión previa (copiar_gestion_previa), solo en el panel de ajuste: cada mes de la ventana toma el valor de la misma serie doce meses antes. Reemplazó 24.194 de las 32.229 observaciones de la ventana, en 2.486 series; las 8.035 restantes (24,9 %), sin historia doce meses antes, conservaron su valor observado (apartado 4.2.1.2). La serie observada siguió siendo la referencia de toda evaluación
Responsable	En el estudio, el investigador. En la operación, Planificación abriría y cerraría el evento y el científico de datos ejecutaría el tratamiento
Estado	Cerrado
Evaluación ex post	Ablación sin el tratamiento (variante 1, Tabla 23): D del motor de 74,7 % a un paso y 91,6 % en el horizonte, frente a 75,4 % y 91,2 % con él; podio sin cambios (apartado 4.3.2)
Huella en la corrida	Configuración efectiva sellada en el manifiesto (Tabla 48) y etapa evento_exogeno del registro de flujo (Tabla 22, Anexo 9)
Ventana por regla (lectura retrospectiva)	Con el corte ilustrativo de −30 % del apartado 4.2.4 y dos meses consecutivos para abrir y para cerrar, a costo y contra el mismo mes de los doce meses previos al inicio, la ventana habría abierto en marzo de 2020 (marzo −48,5 % y abril −89,6 %) y cerrado en agosto de 2020 (septiembre −14,9 % y octubre −19,8 %): seis meses en lugar de doce. Enero de 2021 (−57,1 %), de nuevo bajo el corte, no la habría reabierto por ser un mes aislado. El umbral queda como parámetro del registro

Nota. Elaboración propia a partir de la configuración de las corridas (Anexo 7), del registro de flujo (Anexo 9) y de los apartados 2.7, 4.2.1.2, 4.2.4 y 4.3.2. Los campos son los del registro propuesto en el apartado 4.2.4; en “fecha de registro” y “responsable” se distingue lo que hizo el estudio de lo que haría la operación. La fila de la ventana por regla es una lectura retrospectiva con el corte ilustrativo del apartado 4.2.4, no un umbral del protocolo; sus porcentajes están a costo (convención del Anexo 5) sobre las cinco categorías de la población objetivo, con una sola definición: cada mes frente al mismo mes de los doce meses previos al inicio del evento.

ANEXO 15. Diseño del microservicio de operación: componentes, contratos, integración, observabilidad y ciclo de vida

Este anexo reúne los contratos del diseño de operación del apartado 4.2.5: componentes (Tabla 35), interfaz de programación de aplicaciones o API (Tabla 36), esquema propio (Tabla 37), integración con la plataforma de planificación colaborativa (Tabla 38), observabilidad (Tabla 39), ciclo de vida de los modelos (Tabla 40), vista de contexto (Figura 22), interfaces con los sistemas de la empresa (Tabla 41), vista de despliegue (Figura 23) y decisiones de arquitectura (Tabla 42). Salvo los componentes que la Tabla 35 marca como construidos o parciales, todo es diseño propuesto, no implementado. Las líneas base provienen de la corrida principal y de la extensión exploratoria; los umbrales son iniciales y revisables.

Tabla 35

Componentes del microservicio propuesto, principio de operación que atienden y estado

Componente	Responsabilidad	Principio de operación	Estado
1. API y autenticación	Expone el contrato de la Tabla 36; autentica y registra quién consulta y quién ajusta	Colaboración; lazos de retroalimentación	Propuesto
2. Orquestador de la corrida mensual	Lanza la corrida al cierre de ventas, pide la captura, verifica la idempotencia, aplica la ruta de falla y publica	Orquestación del flujo	Propuesto; hoy un comando lanza el flujo
3. Núcleo (módulos 1 a 5 de la Figura 7)	Los cinco módulos, más las cuatro adiciones del apartado 4.2.5	Reproducibilidad; entrenamiento y evaluación continuos	Construido; las adiciones, propuestas
4. Insumos declarados	Registro de eventos (apartado 4.2.4), maestro de equivalencias y política por estado (apartado 4.2.3), versionados	Versionado de datos, modelos y código	Parcial: un evento declarado en la configuración
5. Almacén inmutable de corridas	Captura, configuración, manifiesto, registro de flujo y salidas; nada se sobrescribe	Reproducibilidad; versionado de datos, modelos y código	Parcial: archivos con huella SHA-256 (Anexo 9)
6. Base de pronósticos, selección y métricas	Esquema propio (Tabla 37); lee por vistas de contrato	Registro de metadatos	Propuesto; hoy, archivos

Componente	Responsabilidad	Principio de operación	Estado
7. Monitor de desempeño y señal de régimen	Compara pronóstico, plan y venta; calcula D, sesgo móvil, tasa de acierto, error por etapa y valor agregado del pronóstico (FVA); evalúa las alertas	Monitoreo continuo; lazos de retroalimentación	Parcial: D por serie construida; sesgo móvil medido (Anexo 10)
8. Permisos por rol	El planificador consulta y ajusta; el científico de datos lanza, publica y versiona; la dirección consulta	Colaboración	Parcial: el visor solo expone las salidas
9. Recolector de métricas, tablero, alertas y registros	Métricas de la API, señales de la base por SQL, registros por corrida y todas las alertas por un camino; p. ej., Prometheus y Grafana, o cualquier recolector compatible	Monitoreo continuo	Propuesto
10. Visor analítico	Inspección del planificador; leería la API	Colaboración	Construido sobre archivos (apartado 4.2.1.6)
11. Integración continua, registro de modelos y configuración versionada	Pruebas en cada cambio, imagen etiquetada por commit y modelo entrenado con huella	Automatización de la integración y la entrega; versionado de datos, modelos y código	Parcial: 261 pruebas (una se omite por diseño), sin integración continua; solo se guardan parámetros estadísticos

Nota. Principios según Kreuzberger et al. (2023). “Construido”: existe en el repositorio del estudio (Anexo 7). Las filas 1 a 9 son los componentes del apartado 4.2.5.1; en la Figura 8, las filas 1 a 8 ocupan el marco de puntos, la 9 y la 10, la banda lateral de observabilidad, y la 11, la de integración continua. Elaboración propia.

Tabla 36

Contrato mínimo de la API del microservicio (versión /v1)

Operación	Método y ruta	Entrada	Salida	Rol autorizado
Lanzar una corrida	POST /v1/corridas	Corte, versión de configuración y horizonte (12 meses por defecto)	Identificador y estado; con huellas de captura y configuración ya usadas, la corrida existente	Científico de datos; orquestador

Operación	Método y ruta	Entrada	Salida	Rol autorizado
Estado, manifiesto y publicación	GET /v1/corridas/{id}; POST /v1/corridas/{id}/publicacion	Identificador; para publicar o revertir, período y motivo	Estado, duración, registro de flujo, manifiesto y puntero del período	Consulta: todos; publicación: científico de datos
Pronóstico por serie	GET /v1/pronosticos?serie=…&corrida=…	Serie; corrida o período (por defecto, la publicada)	Por mes: valor, modelo, horizonte, tramo de evidencia y marca de respaldo	Planificador, dirección, plataforma
Pronóstico por agregado	GET /v1/pronosticos/agregado	Categoría, canal o regional; corrida o período	Valor por mes con su cobertura: series y valor cubiertos, series con respaldo	Planificador, dirección, plataforma
Comparación de candidatos	GET /v1/series/{serie}/comparacion	Serie; versión de la asignación	Error en validación de los diez candidatos, elegido, válidos y empate	Planificador, científico de datos
Etapas del plan y ajustes	GET y POST /v1/plan/{periodo}/etapas	Etapa, serie o agregado, mes, cifra completa y motivo	Versión nueva con usuario y fecha; la base del motor no cambia	Registro: Planificación, Comercial y plataforma, cada uno en su etapa; consulta: también dirección
Configuración versionada	GET /v1/configuracion/{version}; POST /v1/configuracion	Configuración completa y motivo	Versión nueva con huella; ninguna se edita	Creación: científico de datos; consulta: todos
Eventos y equivalencias	GET y POST /v1/eventos y /v1/equivalencias	Campos de los apartados 4.2.4 y 4.2.3	Versión del registro o del maestro, con fecha	Alta y cierre: Planificación (Comercial propone); validación: científico de datos

Operación	Método y ruta	Entrada	Salida	Rol autorizado
Métricas	GET /v1/metricas; GET /metrics	Corrida o período, nivel, modelo y etapa; la segunda, ninguna	Señales de la Tabla 39; la segunda, métricas técnicas	Planificador, dirección, científico de datos; la segunda, el recolector en la red interna
Salud	GET /v1/salud	Ninguna	Estado, conexión a la base, versión del contrato y última corrida publicada	Todos; recolector

Nota. Un cambio incompatible abriría la versión /v2, que conviviría con la /v1. Elaboración propia.

Tabla 37

Tablas de datos del esquema propio del microservicio y sus claves

Tabla	Contenido	Clave
corrida	Corte, huellas de la captura, la configuración y la imagen, commit, anulaciones, criterio de selección, versión de la asignación, estado y duración	Identificador; única: corte, huellas y commit
corrida_etapa	Registro de flujo por etapa: entrada, salida, decisiones, conteos, artefactos y duración	Corrida y etapa
publicación	Puntero del período a la corrida publicada, con fecha, usuario, motivo e historial	Período y fecha
pronóstico	Mes objetivo, horizonte, modelo, valor, tramo de evidencia y marca de respaldo	Corrida, serie, mes y modelo
selección	Error en validación de cada candidato, elegido, criterio, válidos, empate y versión de la asignación	Corrida y serie
métrica	Por serie y modelo: MAE, MAPE, RMSE, Bias y términos valorizados; por ámbito: señales de la Tabla 39 con umbral y estado	Corrida, ámbito, modelo o señal y ventana
parámetros y artefactos	Parámetros y huella del modelo entrenado, con su ubicación en el almacén	Corrida, modelo y ámbito
costo unitario vigente	Costo, vigencia, fuente y marca de imputación	SKU y vigencia
estado de serie	Estado (apartado 4.2.3), meses de historia, conjunto elegible y marcas de respaldo y de calidad	Corrida y serie
eventos y equivalencias usados	Versiones del registro y del maestro	Corrida, insumo y versión

Tabla	Contenido	Clave
etapa del plan	Copia de lectura de la plataforma: etapa, versión, cifra, usuario, fecha, motivo y huella del consensuado	Período, serie o agregado, mes, etapa y versión
error por etapa	Error, sesgo, FVA y marca de quiebre o venta perdida, a un mes y al plazo de abastecimiento	Período, serie o agregado, mes, etapa y anticipación

Nota. La retención propuesta, pendiente de aprobación de la empresa, es de cinco años desde la publicación de cada corrida, prorrogables (unos 11 MB por captura; unos 660 MB en cinco años). Elaboración propia.

Tabla 38

Contrato de integración entre el motor y la plataforma de planificación colaborativa, por etapa del plan mensual

Etapa	Quién la produce	Dónde se guarda	Qué contiene	Qué mide el motor al cierre
0. Referencia ingenua	Motor	Base del motor	Cifra por serie y mes, con corrida y versión	Referencia del FVA (D de 85,6 % a un paso, Tabla 8)
1. Pronóstico base del motor	Motor	Base del motor; hacia la plataforma, archivo con huella en el piloto y vista versionada con API después	Corrida, versión, modelo, valor y tramo: h = 1 validado; h = 2 a 12 medido; posteriores, no validados	D, sesgo móvil y tasa de acierto; FVA frente a la etapa 0
2. Propuesta de Planificación	Planificación	Plataforma	Cifra completa por serie y mes, con versión, usuario, fecha y motivo	Error y FVA frente a la etapa 1
3. Cifra o ajuste de Comercial	Comercial	Plataforma	Ídem	Error y FVA frente a la etapa 2
4. Plan consensuado	Reunión mensual de planificación	Plataforma, versión inmutable con huella; un cambio abre otra versión con motivo	Cifra final, con referencia a la corrida base	Error frente a la venta real; FVA frente a la etapa 3 y acumulado frente a las etapas 1 y 0
5. Ajuste de suministro (opcional)	Abastecimiento, si se adopta	Plataforma	Ídem	Error y FVA frente a la etapa 4
6. Pedidos especiales (opcional)	Comercial, si se adopta	Plataforma	Pedidos firmes por serie y mes, separados del pronóstico	Cumplimiento, informado aparte

Nota. Las etapas 0 a 4 siguen el proceso observado; las 5 y 6, si la empresa las adopta. Motivos de la lista cerrada: campaña, promoción, licitación, quiebre previsto, lanzamiento, discontinuación u otro. El FVA de una etapa es el error de la etapa anterior menos el suyo, positivo si mejora (Gilliland, 2010); la medida principal usa la

cifra vigente un mes antes del mes objetivo, y el plazo de abastecimiento es lectura adicional. La plataforma es dueña de las etapas 2 a 6, y el motor, de las etapas 0 y 1 y de la medición. La tabla materializa la fila “Retroalimentación” de la Tabla 11. Elaboración propia.

Tabla 39

Señales de observabilidad del microservicio: fuente, línea base del estudio, umbral inicial y acción

Plano	Señal	Fuente	Línea base del estudio	Umbral inicial revisable	Acción
Técnico	Última corrida exitosa	API	37,4 minutos	No terminada a la fecha acordada	Alerta: rige la corrida anterior, desplazada y marcada
Técnico	Estado y duración de cada etapa	API	15 etapas; de la carga a la selección, 49,2 s	Sin alerta	Tablero
Técnico	Series sin pronóstico o con respaldo	API	0 y 0	Ninguna sin pronóstico	Tablero
Técnico	Errores, latencia y disponibilidad de la API	API	Sin línea base	Revisable, sin cifra inicial	Tablero; soporte de tecnologías de la información (TI)
Técnico	Procesador y memoria	Exportador del contenedor	No registrados	Sin alerta	Tablero
Datos	Contrato de carga	Base y recolector	204.096 filas; 108 de 108 meses; sin nulos	Cualquier incumplimiento	Alerta: no se publica; rige la anterior
Datos	Duplicados	Base	572 filas idénticas (286 pares) de un SKU y sus 8 series	Idénticas: se deduplican y registran; clave con valores distintos: cualquiera	Puerta: detiene las series afectadas
Datos	Cantidades negativas	Base	Ninguna	Cualquiera	Tablero; regla de devoluciones
Datos	Cobertura de costo y de precio	Base	Costo: 1.513 de 1.668 series (90,7 %); precio: todas	Revisable, sin cifra inicial	Tablero; imputación con marca
Datos	Frescura del inventario y del tipo de cambio	Base	Sin línea base (captura única)	Último mes cerrado ausente	Tablero; último valor conocido, con marca

Plano	Señal	Fuente	Línea base del estudio	Umbral inicial revisable	Acción
Datos	Deriva de volumen y de ceros por categoría	Base y recolector	Mediana de la proporción de meses sin venta en el entrenamiento: 19 % en la muestra; 41 % en las 3.937 series con historia	Revisable, sin cifra inicial	Alerta: nivel (iii) (Tabla 40)
Datos	Transiciones de estado	Base	2.493 activas, 227 dormidas, 1.044 descontinuadas, 81 nuevas, 92 recientes y 469 sin historia; vendieron en prueba 71 dormidas y 172 descontinuadas	Cada reactivación o serie nueva	Tablero; revisa Planificación
Datos	Cambios del maestro de equivalencias	Base	Maestro uno a uno	Cada alta, baja o cambio de factor	Tablero; valida Planificación
Modelo y negocio	D a un paso, últimos 12 meses cerrados	Base	2026, 1.513 series: motor 75,4 %, LightGBM 77,0 %, ingenuo 85,6 %, réplica de la fórmula base 100,0 %	Motor peor que el ingenuo	Tablero; insumo del nivel (ii)
Modelo y negocio	D en el horizonte, aparte	Base	Motor 91,2 %; LightGBM 71,9 % (apartado 4.3.2 y Figura 11)	Sin alerta	Tablero; criterio multihorizonte en sombra
Modelo y negocio	Sesgo valorizado móvil de 3 meses (rampa)	Base y recolector	Mezcla de la extensión, no el motor (Anexo 10): mayor que 10 % en valor absoluto en 10 de 12 meses de 2025 y 7 de 12 de 2026	Valor absoluto mayor que 10 %	Tablero, sin alerta
Modelo y negocio	Sesgo persistente	Base y recolector	Tabla 24: habría disparado en 7 de 12 meses de 2025 y 1 de 12 de 2026	Valor absoluto mayor que 20 % dos meses seguidos, con el mismo signo	Alerta: nivel (iii)
Modelo y negocio	Tasa de acierto frente a 1/k	Base	20,8 % frente a 10 % (10 candidatos)	Igual o menor que 1/k	Tablero; revisión del conjunto, nivel (ii)
Modelo y negocio	Reparto de la selección entre corridas	Base	1.301 series (78,0 %) a métodos estadísticos y 367 (22,0 %) a LightGBM (Figura 9)	Fijo durante la gestión	Seguimiento de cada recalibración

Plano	Señal	Fuente	Línea base del estudio	Umbral inicial revisable	Acción
Modelo y negocio	Estabilidad de la proyección	Base	No medida	Proyectado a 12 meses sobre vendido en los últimos 12, fuera de 0,5 a 2	Tablero; marca por serie
Modelo y negocio	Error por etapa y FVA	Base	Inexistente (Tabla 5)	Revisable, sin cifra inicial	Tablero de la plataforma y reunión (Tabla 38)

Nota. “API”: plano técnico, ruta de métricas que el recolector toma de forma continua. “Base”: tabla de métricas del esquema propio (Tabla 37), mensual y auditable por corrida, que el tablero lee por SQL; “y recolector”: expuesta además como indicador. Las cuatro alertas con acción llevan “Alerta”; la deriva y el sesgo persistente disparan el nivel (iii). La regla de sesgo persistente se formuló después de observar las gestiones de prueba. Elaboración propia.

Tabla 40

Prácticas de operación del ciclo de vida de los modelos (MLOps): lo que el estudio ya hace y lo que agrega la operación

Práctica	Principio de operación	Lo que el estudio ya hace (evidencia)	Lo que agrega la operación	Dueño
Configuración declarada	Versionado de datos, modelos y código; reproducibilidad	Anulaciones en el manifiesto; cinco variantes sin editar código (Tabla 23)	Versiones inmutables creadas por la API y registradas en cada pronóstico	Científico de datos
Versionado de datos	Versionado de datos, modelos y código	Captura de 204.096 filas sellada con SHA-256	Captura mensual sellada, retenida durante el plazo que fije la empresa (propuesta: cinco años desde la publicación, prorrogables)	Científico de datos; soporte de TI
Versionado del código y de la imagen	Versionado de datos, modelos y código; automatización de la integración y la entrega	Commit y estado del árbol en el manifiesto; imagen con versiones fijadas	Árbol limpio e imagen base fijada por su huella como condiciones para publicar	Científico de datos
Versionado del modelo entrenado	Versionado de datos, modelos y código; registro de metadatos	Parámetros estadísticos por serie; el modelo global no se guarda	Registro de modelos por corrida, con huella	Científico de datos

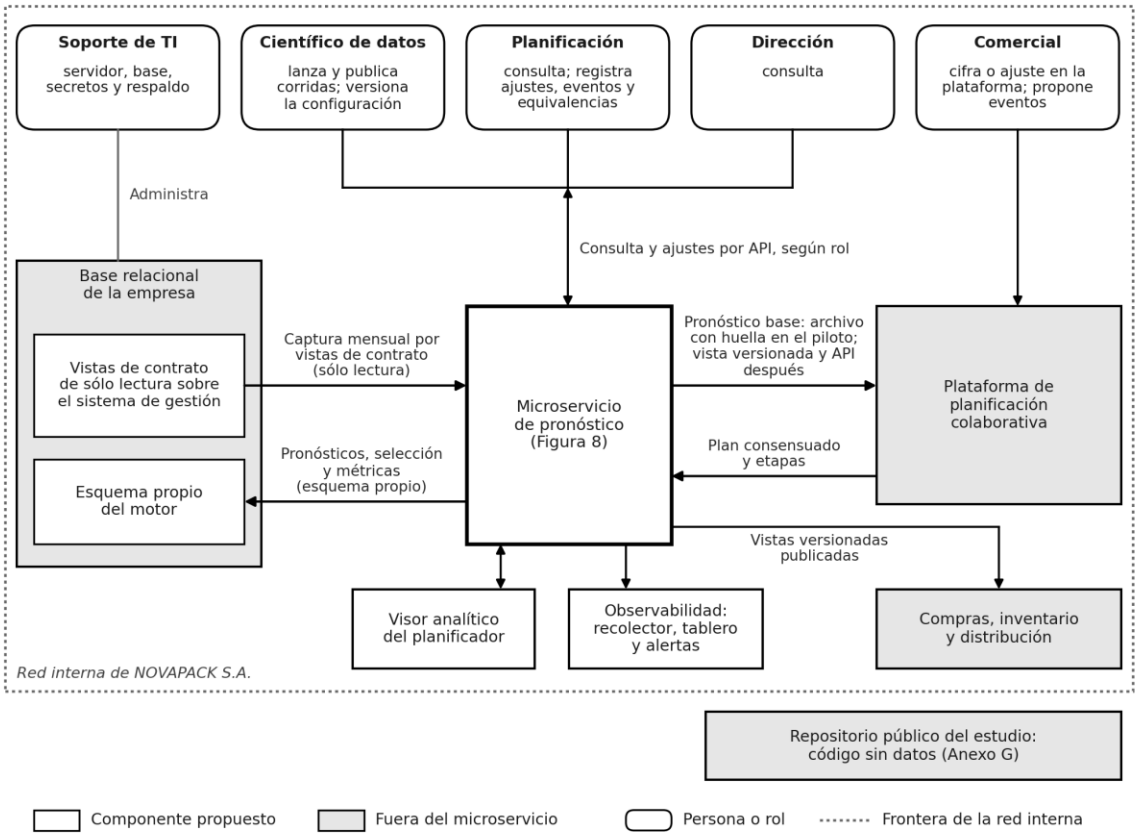
Práctica	Principio de operación	Lo que el estudio ya hace (evidencia)	Lo que agrega la operación	Dueño
Registro de metadatos	Registro de metadatos	Manifiesto y registro de flujo de 15 etapas (Anexo 9)	Persistidos en corrida y corrida_etapa, consultables por la API	Orquestador
Orquestación	Orquestación del flujo	Flujo integral lanzado con un comando	Corrida mensual idempotente, con ruta de falla y publicación por puntero	Soporte de TI; científico de datos
Pruebas como compuerta	Automatización de la integración y la entrega	261 pruebas (una se omite por diseño): contrato de datos, ausencia de fuga y confidencialidad	Integración continua; nada se publica con pruebas en rojo	Científico de datos
Determinismo	Reproducibilidad	Semillas, un hilo y LightGBM determinista	Prueba de igualdad si se reparten series entre procesos	Científico de datos
(i) Reentrenamiento mensual automático	Entrenamiento y evaluación continuos	12 reentrenos del modelo global en la multihorizonte, con árboles congelados	Cada corrida, sin intervención. Fijos: hiperparámetros, árboles, conjunto, asignación y umbrales	Orquestador
(ii) Recalibración por gestión cerrada	Entrenamiento y evaluación continuos	60 ensayos TPE con semilla en el pliegue interno; D interna 59,7 % (Tabla 28); 461 s (Tabla 45)	Búsqueda, conjunto y asignación sobre la última gestión cerrada; adopción solo si la D interna mejora en más de un punto sin perder estabilidad, tras una gestión en sombra. Fija: la configuración adoptada	Científico de datos; aprueba la jefatura de Planificación
(iii) Recalibración fuera de ciclo	Entrenamiento y evaluación continuos; monitoreo continuo	Detector de régimen y sesgo móvil medidos mes a mes (Tabla 24)	Deriva o sesgo persistente adelantan el nivel (ii), con la misma puerta y reversión. Fija hasta la promoción: la configuración vigente	Ídem
Campeón y retador	Entrenamiento y evaluación continuos	Combinación y conmutación medidas en la extensión (apartado 4.3.3)	Retadores en sombra, promovidos tras una gestión cerrada	Ídem

Práctica	Principio de operación	Lo que el estudio ya hace (evidencia)	Lo que agrega la operación	Dueño
Monitoreo	Monitoreo continuo	Métricas por serie y D por corrida; sesgo móvil en la extensión	Señales y cuatro alertas de la Tabla 39	Científico de datos
Lazo de retroalimentación	Lazos de retroalimentación	Error de los candidatos; lazo diseñado (Figura 5)	Error por etapa y FVA (Tabla 38)	Motor (medición); plataforma (etapas)
Colaboración y gobernanza	Colaboración	Repositorio público (Anexo 7)	Revisión por una segunda persona; aprobación conjunta de promociones; auditoría de ajustes	Científico de datos y jefatura de Planificación
Documentación operativa	Práctica complementaria	Instrucciones de instalación y especificación de requerimientos (apartado 4.2.6.4)	Manual del planificador y procedimiento de la ruta de falla	Científico de datos

Nota. Principios según Kreuzberger et al. (2023). Las filas (i) a (iii) son los niveles de la política de reentrenamiento (apartado 4.2.5.6). Elaboración propia.

Figura 22

Vista de contexto del motor: personas y sistemas de la empresa con los que intercambia datos



Nota. Vista de contexto, complementaria a las del modelo 4+1 de Kruchten (1995): personas y sistemas externos al motor. Diseño propuesto, no implementado. Los nombres de los sistemas son genéricos. Elaboración propia.

Tabla 41

Interfaces del motor con los sistemas de la empresa: dirección, contrato, frecuencia, autenticación y responsable

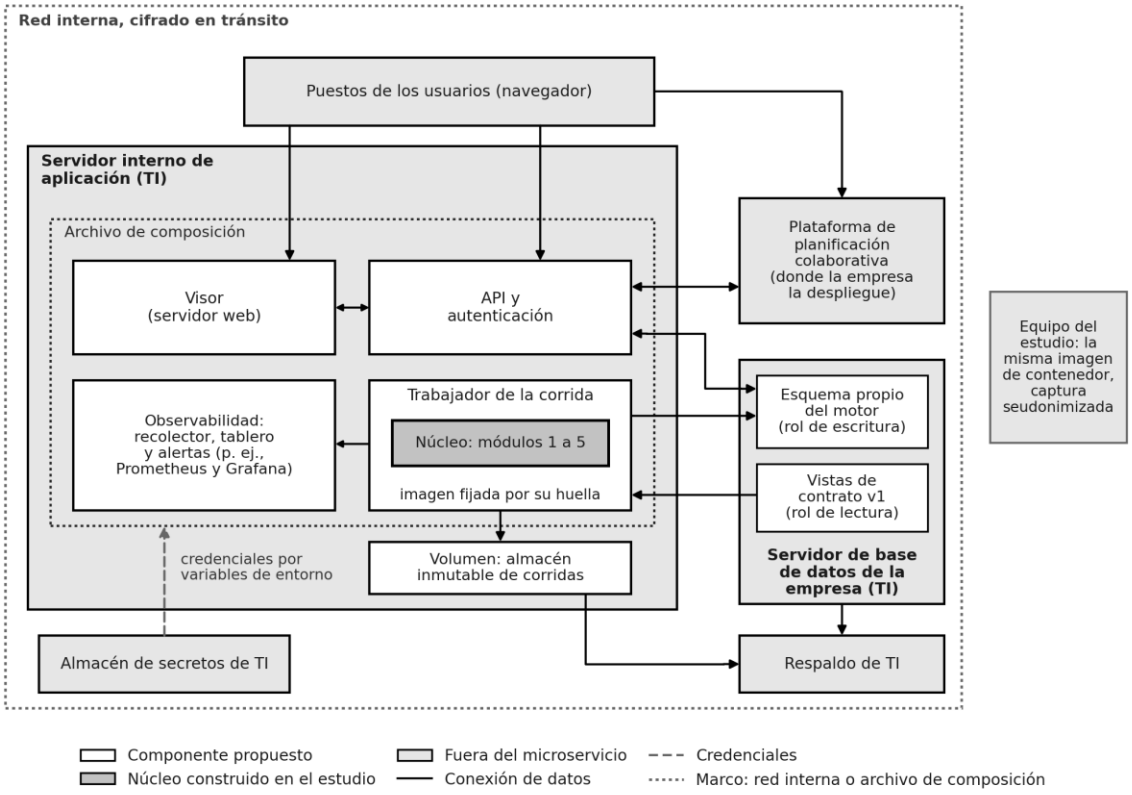
Interfaz	Sistema	Dirección	Contrato	Frecuencia	Autenticación	Responsable
Ventas mensuales consolidadas al código vigente, con precio y venta perdida	Sistema de gestión, por la base de la empresa	Base → motor	Vista de contrato versionada, solo lectura; contrato de entrada (columnas, tipos, claves, rango, frescura)	Mensual, al cierre de ventas	Rol de lectura de mínimo privilegio; credenciales del almacén de secretos de TI; cifrado en la red interna	TI mantiene la vista; el científico de datos, el contrato de entrada
Costos unitarios, inventario semanal (quiebres) y tipo de cambio	Ídem	Base → motor	Una vista de contrato por insumo	Mensual	Ídem	Ídem
Portafolio y maestro de equivalencias	Ídem; alta por la API	Base o Planificación → motor	Vista de contrato; /v1/equivalencias (Tabla 36)	Mensual y en cada alta	Ídem; API con rol	Planificación da de alta; el científico de datos valida
Registro de eventos	Motor (insumo declarado)	Planificación → motor	/v1/eventos (Tabla 36); campos del apartado 4.2.4	En la reunión mensual	API con rol	Planificación; Comercial propone
Esquema propio	Base de la empresa	Motor → base	Doce tablas de la Tabla 37; una transacción por corrida; publicación por puntero; migraciones versionadas	Mensual, por corrida	Rol de escritura solo sobre ese esquema	El científico de datos; TI administra la base
Pronóstico base	Plataforma de planificación colaborativa	Motor → plataforma	Etapas 0 y 1 de la Tabla 38: archivo con huella en el piloto; vista versionada y /v1/pronosticos después	Mensual, antes de la reunión	API con rol de plataforma	Motor (dueño del número base)
Etapas del plan y plan consensuado	Plataforma	Plataforma → motor	Etapas 2 a 6 de la Tabla 38; /v1/plan/{periodo}/etapas; copia de lectura en la tabla “etapa del plan” (Tabla 37)	Mensual, tras la reunión	API con rol	La plataforma es dueña de las etapas; el motor mide

Interfaz	Sistema	Dirección	Contrato	Frecuencia	Autenticación	Responsable
Consulta de pronósticos y agregados	Visor, tablero de la plataforma y consumidores de compras, inventario y distribución	Motor → consumidores	/v1/pronosticos, /v1/pronosticos/agregado; vistas versionadas publicadas	A demanda	API con rol (planificador, dirección, plataforma)	Planificación
Métricas técnicas y alertas	Recolector de métricas	Motor → recolector	/metrics en formato de exposición; señales de la Tabla 39	Continua	Solo en la red interna	Soporte de TI
Cuentas de usuario	Directorio o cuentas que defina TI	TI → API	Roles de la Tabla 36	Alta y baja de personas	La que defina TI	Soporte de TI

Nota. En el estudio la integración con el sistema de gestión se hizo una sola vez, con 'scripts/extraer_snapshot.py' y una configuración local que no se versiona, cuyo modelo es 'config/extraccion.ejemplo.yaml' (Anexo 7). Elaboración propia.

Figura 23

Vista de despliegue del motor en la infraestructura de la empresa



Nota. Diseño propuesto, no implementado. No se nombra el motor de base de datos; el recolector y el tablero se nombran como ejemplo, como en la Figura 8. El servidor se dimensiona en el piloto (apartado 4.4). Elaboración propia.

Tabla 42

Decisiones de arquitectura: alternativa descartada, motivo y consecuencia

Decisión	Alternativa descartada	Motivo	Consecuencia aceptada	Dónde
Microservicio: corrida por lotes con una API delgada	Programa aislado; trabajo programado con base y tablero	Contrato estable para varios consumidores y lugar para registrar ajustes con autor y motivo	Más complejidad operativa: API encendida y dos contenedores de observabilidad	1.2.4, 4.2.5, 4.2.5.1, 4.2.5.5
Cómputo sobre una captura sellada	Leer la base viva	Reproducibilidad y verificación por huella	Una extracción por corrida; la corrida no ve cambios posteriores al corte	1.2.19, 4.2.5.2

Decisión	Alternativa descartada	Motivo	Consecuencia aceptada	Dónde
Lectura por vistas de contrato versionadas	Consultar las tablas internas del sistema de gestión	Desacoplar el motor de los cambios del sistema de gestión	TI mantiene las vistas; un cambio incompatible abre otra versión	4.2.5.2
Escritura en un esquema propio de la base de la empresa	Base propia del motor	Datos en servidores de la empresa, con sus credenciales y respaldos	Dependencia de TI; base en contenedor solo para piloto o demostración	4.2.5.2, 4.2.5.7
Publicación por puntero, sin borrar; corrida idempotente	Sobrescribir resultados	Reversión inmediata y auditoría	Retención propuesta, a aprobar por la empresa: cinco años desde la publicación, prorrogables (unos 11 MB por captura)	4.2.5.2, 4.2.5.4, nota de la Tabla 37
Ajustes como etapas completas al lado del número del motor	Editar la cifra del motor	Medir el error y el valor agregado de cada etapa	Más volumen y una lista cerrada de motivos	4.2.5.3, Tabla 38
Intercambio por etapas: archivo con huella en el piloto; vistas y API después	Integración completa desde el inicio	Acotar el riesgo del piloto	Dos mecanismos durante la transición	4.2.5.3
Recolector compatible con Prometheus, nombrado como ejemplo	Herramienta fija	No atar el diseño a un producto	Configuración versionada de dos contenedores más	4.2.5.5
Códigos reales dentro de la empresa con roles, autenticación, cifrado y auditoría; seudónimos hacia fuera	Seudonimizar también la operación	Planificación necesita los códigos reales para decidir	La reserva pasa a depender del control de acceso	4.2.5.2
Promoción de modelos nunca automática; recalibración por gestión cerrada con puerta	Búsqueda mensual automática	Una búsqueda mensual se movería dentro del ruido de la meseta (Tabla 28)	Las mejoras se adoptan más despacio	4.2.5.6

Decisión	Alternativa descartada	Motivo	Consecuencia aceptada	Dónde
Servidor interno con un archivo de composición	Nube	Datos en servidores de la empresa; el diseño admite la nube	Capacidad acotada al servidor; se dimensiona en el piloto	4.2.5.7, 4.2.6.3

Nota. Ninguna decisión es nueva: todas están en los apartados de la última columna. Cuatro alternativas descartadas no están nombradas como tales en el texto y la tabla las explicita a partir de lo que sí dice: la base propia del motor, la integración completa desde el inicio, seudonimizar también la operación y la búsqueda mensual automática. Elaboración propia.

ANEXO 16. Evaluación comparativa de referencia (benchmarks) de los modelos elegidos

Este anexo reúne la evaluación comparativa de referencia (benchmarks) de los modelos elegidos que resume el apartado 4.3.2. La Tabla 43 recoge, por familia del conjunto de modelos, lo que reportan las competencias y los estudios publicados, separado del resultado de este estudio; la Tabla 44, el costo de cómputo y la precisión de cada brazo en la corrida principal; y la Tabla 45, los pronosticadores de la extensión exploratoria en las dos gestiones de prueba. En la Tabla 43, el resultado propio se acompaña de su razón frente a la D del modelo ingenuo, razón que es la forma de la mejora relativa con que las competencias leen sus resultados. Los tiempos provienen de dos entornos: un contenedor Linux con las bibliotecas numéricas fijadas a un solo hilo y, para la extensión, Windows con aceleración gráfica. Por eso no se comparan uno a uno entre tablas, y LightGBM, medido en ambos, sirve de ancla (11,25 y 10,62 segundos). Ningún manifiesto registra procesador ni memoria. Para la corrida principal queda como trabajo futuro una medición con repeticiones, por brazo y también en el horizonte, que los registre; demandaría de 3 a 4 horas de desarrollo y unos 45 minutos de corrida. Las cifras propias salen de las salidas de esas corridas, sin corridas nuevas del motor.

En la fila del motor de la Tabla 44, los diez brazos y la selección por serie suman 17,7 s, lo mismo que la etapa de ajuste completa más la selección en el Anexo 9. Quedan fuera de esa tabla la explicación TreeSHAP (63,8 s, opcional), la calibración de LightGBM (60 ensayos, 461,3 s) y la evaluación multihorizonte (2.117,5 s, sin desglose por brazo). El tiempo por serie de la Tabla 44 no equivale al costo de una serie aislada, porque los brazos estadísticos operan vectorizados sobre todas las series a la vez. Junto con LightGBM, Holt-Winters, que figura también en la Tabla 44, sirve de ancla en la Tabla 45, medido en el entorno de la extensión. Como referencia, el ingenuo tardó allí 0,02 s en la gestión 2026, con D de 85,6 % a un paso y 120,5 % en el horizonte, y 0,01 s en la gestión 2025, con D de 78,7 % y 115,1 %. Las D de las dos gestiones se calculan, como en la Tabla 10, sobre cohortes distintas. A un paso, la proyección directa de LightGBM coincide por construcción con la recursiva. Los rangos

de Friedman no se trasladan a la Tabla 45, porque dependen del número de candidatos, que en la extensión es de 15. DeepAR, que se retiró por desempeño en las iteraciones iniciales (apartado 4.3.3), no figura en esa tabla.

Tabla 43

Referencias publicadas por familia del conjunto de modelos y resultado obtenido en este estudio

Familia	Fuente	Datos	Métrica	Resultado reportado	Mejora relativa sobre la referencia simple (reportada)	Resultado en este estudio: D a un paso y en el horizonte (razón frente al ingenuo)
Ingenuo y promedios móviles (referencias del conjunto)	Makridakis et al. (2020, 2022)	M4: cien mil series de varias frecuencias. M5: demanda minorista jerárquica diaria	M4: sMAPE y MASE, resumidos en el OWA. M5: WRMSSE	Referencias simples de ambas competencias (el promedio móvil, solo en la M5), frente a las que se leen los resultados de los participantes	En la M4, el ingenuo sobre la serie desestacionalizada (Naïve 2) es la base del OWA	Ingenuo: 85,6 % (1,000) y 120,5 % (1,000). Promedio móvil de 2 meses: 84,9 % (0,993) y 116,6 % (0,967). Promedio móvil de 12 meses: 85,4 % (0,998) y 94,6 % (0,784)
Ingenuo estacional (fuera del conjunto)	Makridakis et al. (2020, 2022)	Ídem	Ídem	Referencia estándar de ambas competencias	Referencia de comparación, no base del OWA	82,7 % (0,967) y 84,1 % (0,698), medido fuera del conjunto
Suavizado exponencial simple y Holt-Winters	Makridakis et al. (2020)	M4: cien mil series de varias frecuencias	OWA	Los suavizados exponenciales integraron las referencias estadísticas; su combinación (Comb: simple, de Holt y amortiguado) resultó difícil de superar	Referencia exigente para los participantes; magnitud no transcrita	Suavizado simple: 79,5 % (0,929) y 103,8 % (0,861). Holt-Winters: 83,5 % (0,976) y 81,2 % (0,674)
Theta (no incluido en el conjunto)	Makridakis et al. (2020)	Ídem	OWA	Integró las referencias estadísticas de la competencia	Referencia de comparación; magnitud no transcrita	n. d.

Familia	Fuente	Datos	Métrica	Resultado reportado	Mejora relativa sobre la referencia simple (reportada)	Resultado en este estudio: D a un paso y en el horizonte (razón frente al ingenuo)
Croston y su corrección de sesgo	Syntetos y Boylan (2005)	Ítems de demanda intermitente	Medidas de exactitud comparadas entre métodos	Respalda, en la demanda intermitente, el enfoque de Croston con su corrección de sesgo (aproximación SBA), la más precisa entre los métodos comparados	Magnitud no transcrita	Croston: 86,1 % (1,007) y 93,5 % (0,776). SBA aproximado, fuera del conjunto: 88,5 % (1,034) y 99,1 % (0,822)
LightGBM global con variables explicativas	Makridakis et al. (2022)	M5: demanda minorista jerárquica diaria, del total al nivel de ítem	WRMSSE	La mayoría de los primeros puestos usó LightGBM como modelo global con variables explicativas	La ventaja sobre las referencias se estrechó en el nivel de ítem	77,0 % (0,900) y 71,9 % (0,597)
Combinación de pronósticos (evolución propuesta)	Makridakis et al. (2020)	M4: cien mil series de varias frecuencias	OWA	Los primeros puestos fueron un método híbrido de suavizado exponencial y redes neuronales y combinaciones de métodos	Los primeros puestos superaron a Comb	Extensión, gestión 2026. Promedio del conjunto curado: 74,9 % (0,875) y 82,3 % (0,683). Ponderado por validación: 74,0 % (0,865) y 82,6 % (0,685)

Familia	Fuente	Datos	Métrica	Resultado reportado	Mejora relativa sobre la referencia simple (reportada)	Resultado en este estudio: D a un paso y en el horizonte (razón frente al ingenuo)
Redes neuronales (extensión exploratoria)	Makridakis et al. (2018, 2020)	Series mensuales de la competencia M3; M4	Exactitud fuera de muestra; OWA en la M4	En las series mensuales de la M3, las redes neuronales y otros métodos de aprendizaje automático, ninguno de boosting por gradiente, no superaron a los métodos estadísticos; en la M4, los métodos puros de aprendizaje automático no superaron a las referencias	Sin mejora sobre las referencias estadísticas	Gestión 2026: DLinear 80,4 % (0,939) y 94,8 % (0,787); N-HiTS 92,3 % (1,079) y 93,9 % (0,779); TFT 106,1 % (1,240) y 114,1 % (0,947). Gestión 2025: N-HiTS 70,6 % (0,898) y 78,8 % (0,685), mejor pronosticador individual del quiebre

Nota. Las columnas “Resultado reportado” y “Mejora relativa sobre la referencia simple” resumen en forma cualitativa el hallazgo de cada fuente: las magnitudes externas no se transcriben. La última columna da la D valorizada de este estudio, a un paso y en el horizonte (D global de los 12 orígenes rodantes), sobre las 1.513 series con costo de la gestión 2026 salvo indicación, y entre paréntesis su razón frente a la D del modelo ingenuo sobre las mismas series (85,6 % y 120,5 % en la gestión 2026; 78,7 % y 115,1 % en la gestión 2025, sobre 1.468 series con costo). Las razones se calculan con las D sin redondear. sMAPE: error porcentual absoluto medio simétrico; MASE: error absoluto medio escalado; OWA: promedio del sMAPE y del MASE relativos a los de Naïve 2; WRMSSE: raíz del error cuadrático medio escalado y ponderado; SBA: aproximación de Syntetos y Boylan. n. d.: no disponible, porque Theta no se midió en este estudio. Elaboración propia a partir de las fuentes citadas y de las salidas del motor.

Tabla 44

Costo de cómputo y precisión por brazo en la corrida principal

Brazo	Ajuste y pronóstico a un paso (s)	Con preparación de variables (s)	Por serie, amortizado (ms)	D a un paso (%)	D en el horizonte (%)	Rango medio de Friedman (Figura 10)	Series elegidas por el motor
Motor de selección automática	12,64	45,48	27,27	75,4	91,2	4,67	n. d.
LightGBM	11,25	39,08	23,43	77,0	71,9	5,61	367
Suavizado exponencial simple	0,10	0,10	0,06	79,5	103,8	5,22	93
Holt-Winters	0,71	0,71	0,43	83,5	81,2	6,11	204
Promedio móvil 2 meses	0,07	0,07	0,04	84,9	116,6	4,63	232
Promedio móvil 12 meses	0,07	0,07	0,04	85,4	94,6	5,74	131
Ingenuo	0,01	0,01	0,01	85,6	120,5	4,96	339
Croston	0,09	0,09	0,05	86,1	93,5	6,78	96
Ingenuo con factor de crecimiento	0,07	0,07	0,04	96,4	158,0	7,49	38
Prom. móvil 2 m con factor de crecimiento	0,14	0,14	0,08	98,0	134,3	7,47	70
Prom. móvil 12 m con factor de crecimiento	0,13	0,13	0,08	100,0	113,2	7,32	98
Ingenuo estacional (fuera del conjunto)	n. d.	n. d.	n. d.	82,7	84,1	n. d.	n. d.

Brazo	Ajuste y pronóstico a un paso (s)	Con preparación de variables (s)	Por serie, amortizado (ms)	D a un paso (%)	D en el horizonte (%)	Rango medio de Friedman (Figura 10)	Series elegidas por el motor
SBA aproximado (fuera del conjunto)	n. d.	n. d.	n. d.	88,5	99,1	n. d.	n. d.

Nota. Tiempos de la corrida principal que reporta este documento, del mismo registro de flujo que resume la Tabla 22 (Anexo 9): una sola medición, sin repeticiones, del ajuste de cada brazo y su pronóstico a un paso sobre el panel de 1.668 series y 108 meses. La preparación de variables (27,83 s) es solo de LightGBM y se le imputa en la tercera columna; en la fila del motor, la segunda columna suma los diez brazos y la tercera agrega la preparación y la selección por serie (5,01 s). El tiempo por serie amortiza la tercera columna. D valorizada sobre las 1.513 series con costo del bloque de prueba (gestión 2026); en el horizonte, D global de los 12 orígenes rodantes. Rango medio de Friedman sobre las 1.668 series, como en la Figura 10. Las filas fuera del conjunto se calcularon con las salidas de esa corrida: el ingenuo estacional repite la demanda del mismo mes del año anterior, y la aproximación de Syntetos y Boylan (SBA) multiplica el pronóstico de Croston por (1 − α/2), con el α estimado para Croston en cada serie. n. d.: no disponible; en la fila del motor, la última columna no aplica, porque el motor reparte las 1.668 series entre los brazos. Elaboración propia con el script 'scripts/anexo_p_benchmarks.py' del repositorio (Anexo 7), a partir de las salidas del motor.

Tabla 45

Costo de cómputo y precisión de los pronosticadores de la extensión exploratoria en las dos gestiones de prueba

Brazo	Gestión 2026: ajuste y pronóstico a un paso (s)	Gestión 2025: ajuste y pronóstico a un paso (s)	Gestión 2026: D a un paso (%)	Gestión 2025: D a un paso (%)	Gestión 2026: D en el horizonte (%)	Gestión 2025: D en el horizonte (%)	Calibración: s (ensayos)
Chronos-Bolt (fundacional)	29,09	33,40	74,3	81,3	81,6	87,9	Sin búsqueda propia
DLinear	66,02	53,42	80,4	85,1	94,8	78,5	Sin búsqueda propia
N-HiTS	37,02	37,25	92,3	70,6	93,9	78,8	496,8 (25)
TFT	146,07	200,06	106,1	83,2	114,1	110,9	1.949,1 (25)
LightGBM con proyección directa	102,58	69,48	77,0	83,0	84,0	72,8	Sin búsqueda propia

Brazo	Gestión 2026: ajuste y pronóstico a un paso (s)	Gestión 2025: ajuste y pronóstico a un paso (s)	Gestión 2026: D a un paso (%)	Gestión 2025: D a un paso (%)	Gestión 2026: D en el horizonte (%)	Gestión 2025: D en el horizonte (%)	Calibración: s (ensayos)
LightGBM	10,62	7,26	77,0	83,0	71,9	70,1	461,3 (60)
Holt-Winters	1,02	0,53	83,5	111,5	81,2	120,0	Sin búsqueda propia

Nota. Una sola medición del ajuste y el pronóstico a un paso sobre el panel completo. D valorizada sobre el bloque de prueba de cada gestión (1.513 y 1.468 series con costo); en el horizonte, D global de los 12 orígenes rodantes. La última columna da el tiempo total de la búsqueda de hiperparámetros, aparte del ajuste: 25 ensayos para N-HiTS y 25 para TFT, tres fallidos en cada red; para LightGBM, la búsqueda de la corrida principal. El modelo fundacional no se reentrena y solo calibra un factor de escala por categoría estimado en validación; DLinear y la proyección directa no tuvieron búsqueda propia, y la rejilla de Holt-Winters va dentro de su ajuste. Elaboración propia con el script 'scripts/anexo_p_benchmarks.py' del repositorio (Anexo 7), a partir de las salidas de la extensión exploratoria.

ANEXO 17. Correspondencia entre normas, políticas de datos y mecanismos del diseño

Este anexo detalla, para cada norma o marco de referencia del apartado 1.5.3, lo que exige, la política que la atiende y el mecanismo del estudio o del diseño que la implementa.

Tabla 46

Norma, política y mecanismo: gobernanza de datos, seguridad de la información y reserva comercial

Norma o marco	Qué exige	Política (1.5.3)	Mecanismo del estudio o del diseño	Dónde
Constitución, arts. 21 y 130	Privacidad e intimidad; protección frente a datos registrados	Intimidad	Informante identificado por código; datos personales omitidos en los anexos	3.2.3, Anexo 1
Decreto Supremo N.º 1793, art. 56	Consentimiento previo y expreso, por escrito u otro medio equiparable; finalidad; medidas de seguridad	Intimidad	Consentimiento o autorización escrita de los participantes, conservada fuera del documento; informante por código; uso solo académico	1.5.3, Anexo 1, Anexo 2 (finalidad)
Ley 164, arts. 78 y 87	Validez y valoración de documentos digitales por su generación y conservación	Seguridad (integridad)	Manifiesto con SHA-256 de captura, auxiliares y configuración; commit y árbol limpio	Anexos 7 y 9
Decisión 486, arts. 260 a 262	Secreto empresarial protegido si hay medidas razonables de reserva	Reserva comercial	Acuerdo con seudónimo; datos fuera del repositorio; pruebas de confidencialidad con lista local	Anexos 2 y 7, 4.2.6.4
Ley 1322	Derecho de autor sobre la obra y el software	Reserva comercial y titularidad	Repositorio público con el código, sin datos; cesión de derechos	Anexo 7, preliminares

Norma o marco	Qué exige	Política (1.5.3)	Mecanismo del estudio o del diseño	Dónde
ISO/IEC 27001, control de acceso (A.5.15) e información de autenticación (A.5.17)	Acceso por necesidad y mínimo privilegio	Seguridad	Roles de la API; rol de lectura por vistas y rol de escritura solo en el esquema propio	4.2.5.2, Tabla 36
ISO/IEC 27001, criptografía (A.8.24)	Cifrado según el riesgo	Seguridad	Cifrado en la red interna; credenciales desde el almacén de secretos; prueba contra credenciales versionadas	4.2.5.2
ISO/IEC 27001, registro y monitoreo (A.8.15 y A.8.16)	Registrar y vigilar eventos	Seguridad	Registros por corrida; auditoría de accesos; alertas	4.2.5.5, Tabla 39
ISO/IEC 27001, respaldo (A.8.13)	Copias de la información	Seguridad (disponibilidad)	Respaldo de la base y del almacén; reconstrucción de corridas	4.2.5.7, Figura 23
ISO/IEC 27001, enmascaramiento de datos (A.8.11)	Enmascarar según la política y el riesgo	Reserva comercial	Seudonimización al extraer; seudónimos hacia fuera, códigos reales solo dentro	1.2.19, 4.2.5.2
ISO/IEC 27001, separación de entornos y gestión de cambios (A.8.31 y A.8.32)	Entornos separados; cambios controlados	Seguridad	Base en contenedor solo para piloto o demostración; revisión por una segunda persona; migraciones versionadas	4.2.5.2, 4.2.5.6, 4.2.5.7
DAMA-DMBOK, gobernanza	Titular, custodio y responsable de cada dato	Gobernanza	Empresa titular; TI custodia; Planificación dueña de insumos; científico de datos responsable de la medición	4.2.4, Tabla 38
DAMA-DMBOK, calidad de datos	Reglas de calidad declaradas y medidas	Gobernanza	Reglas de la señal; contrato de entrada; marcas; nada se descarta en silencio	4.2.3, Tablas 30 y 39
DAMA-DMBOK, metadatos	Catálogo y linaje	Gobernanza	Manifiesto, registro de flujo, huellas y versiones de las vistas	4.2.1.6, Anexo 9, Tabla 37

Nota. Numeración de controles según el anexo A de la norma ISO/IEC 27001:2022. Elaboración propia.

ANEXO 18. Índice de documentos bajo custodia

Este anexo reproduce el índice de los documentos de respaldo del estudio cuyos originales el trabajo no incluye, para no publicar información reservada (del acuerdo de confidencialidad, el Anexo 2 transcribe el texto; del manifiesto expurgado de las corridas, la Tabla 48 reproduce sus sellos): los formularios individuales de validación por juicio de experto, el consentimiento informado del informante clave, la autorización de la observación estructurada, la constancia de la empresa, el acuerdo de confidencialidad firmado, el manifiesto expurgado de las corridas con su verificador, la captura congelada de datos y las salidas de las corridas. Los documentos firmados se conservan en original en poder del autor y, en copia escaneada, bajo custodia en una carpeta compartida de la empresa con acceso restringido, que guarda también el manifiesto expurgado con su verificador, la captura y las salidas. Unos y otros se exhiben al tribunal a su solicitud, sin entrega de copias; cada firmante se identifica por su rol, conforme al acuerdo de confidencialidad (Anexo 2). El original de este índice, firmado por el autor, se exhibe al tribunal con los demás documentos firmados.

Tabla 47

Documentos bajo custodia: documento, firmante según su rol, fecha y ubicación

N.º	Documento	Firmante, según su rol	Fecha	Ubicación
1	Formulario de validación por juicio de experto, juez 1	Especialista en cadena de suministro, gerente de operaciones de la empresa	19 de octubre de 2026	Carpeta compartida
2	Formulario de validación por juicio de experto, juez 2	Director académico del trabajo	20 de octubre de 2026	Carpeta compartida
3	Consentimiento informado de la entrevista semiestructurada	Informante clave IC-01 e investigador	16 de octubre de 2026	Carpeta compartida
4	Autorización de la observación estructurada	Responsable del área observada	16 de octubre de 2026	Carpeta compartida
5	Constancia de la empresa: uso de la información y revisión del texto y del repositorio público (revisión 17893d4)	Representante autorizado de la empresa	20 de octubre de 2026	Carpeta compartida
6	Acuerdo de confidencialidad (Anexo 2)	Empresa e investigador	20 de octubre de 2026	Carpeta compartida
7	Manifiesto expurgado de las corridas y verificador de la corrida	Investigador	19 de octubre de 2026	Carpeta compartida

N.º	Documento	Firmante, según su rol	Fecha	Ubicación
8	Captura congelada de ventas y registros auxiliares (huella SHA-256 en el manifiesto)	Entregada por la empresa; resguardo del investigador	7 de agosto de 2026	Carpeta compartida
9	Salidas de las corridas (resultados por serie)	Investigador	19 de octubre de 2026	Carpeta compartida

Nota. Las fechas de las filas 1 a 6 son las de la firma de cada documento; las de las filas 7 a 9, las de su generación o entrega. Los documentos de las filas 1 a 6 se firmaron después de los hechos que documentan. Los formularios de validación, el consentimiento y la autorización (filas 1 a 4) declaran en su texto que la firma deja constancia escrita de lo valorado, consentido o autorizado en su momento: la validación de los instrumentos, en marzo de 2026; la entrevista, el 6 de abril de 2026; la observación, el 10 de mayo de 2026. La constancia de la empresa (fila 5) declara que la empresa autorizó el uso de la información de ventas y de los registros auxiliares, así como de la información recogida mediante la entrevista, la observación del proceso y la revisión documental, sin indicar la fecha de esa autorización, y respalda el acceso a los datos de la captura del 7 de agosto de 2026 (fila 8). El acuerdo de confidencialidad (fila 6) rige la reserva desde su firma y no contiene una declaración sobre ese acceso. El índice se complementa con dos constancias posteriores a su cierre, ambas del 4 de noviembre de 2026, que se conservan como los demás documentos firmados y se exhiben con él. La constancia complementaria 08, del autor, declara que los commits del repositorio público posteriores a la revisión 17893d4 son exclusivamente documentales; la acompañan las diferencias completas entre esa revisión y la rama principal. La constancia complementaria 09, firmada por la jefatura del área legal en representación de la empresa y por el autor, fija para los respaldos bajo custodia el plazo de conservación (la vigencia del acuerdo de confidencialidad, prorrogable por decisión escrita de la empresa) y su destino al vencer (el autor elimina sus copias y la empresa decide sobre la carpeta compartida). Los números 08 y 09 son los de sus archivos bajo custodia y no corresponden a filas de esta tabla. En las filas 1 a 6, la ubicación es la de la copia escaneada; el original en papel lo conserva el autor. Elaboración propia.

Tabla 48

Sellos de trazabilidad de las corridas bajo custodia: código, configuración, insumos y salida pública

Elemento	Identificación	Huella
Código (las cinco corridas)	Repositorio del Anexo 7, árbol de trabajo limpio; las tablas y figuras de resultados/ se regeneraron sin ejecutar el motor en el commit hijo 17893d4	Commit (SHA-1): 472b891eca2998e3ec55 a8a49511032be388bf96
Imagen de Docker (corridas publicada, A y B)	motor-pronostico:latest, creada el 14 de octubre de 2026; Python 3.13.16 dentro del contenedor	Id (SHA-256): 36118f8f20f3633d55608aa5bccb2 ab8 fc25c1117530a5ec515c07775df62 dfe

Elemento	Identificación	Huella
Corrida publicada	config/config.yaml con la anulación salidas.directorio=salidas_r5; sellada el 19 de octubre de 2026, 18:49 UTC; 45 salidas selladas; manifiesto de 35.719 bytes	Configuración efectiva: a69d9111303f78ef40520be02c8b40e8 b0ff0cfc2291ae15650ea3a781aa9c22 Manifiesto: ff3951cae7e265be6a160ba27d093b01 b11438190ada336795a10fb3117dc374
Sensibilidad A (sin exigir venta en prueba)	config/config_sensibilidad_a.yaml; 19 de octubre, 19:32 UTC; 45 salidas; manifiesto de 35.703 bytes	Configuración efectiva: 9cdab9ba10916b29fccd32ff56ee0830 745643acf999d4ea8997a0c10f69b705 Manifiesto: f65be35b5e037bdd2f8bfe44da3586ba d16da39b704d7e830d8a9aa28031d6e5
Sensibilidad B (solo activas al origen)	config/config_sensibilidad_b.yaml; 19 de octubre, 20:10 UTC; 45 salidas; manifiesto de 35.822 bytes	Configuración efectiva: 1c9922f863be75fc12229f66583e19ce eb38d918148043c0a36783a0d3df3bdb Manifiesto: 02a5613571c8d01b412df265960f8952 faf9508dc7f8cfe44ac99fde23420abb
Extensión V9	config/config_ml2_v9.yaml; entorno local con GPU, Python 3.12.13; 19 de octubre, 21:31 UTC; 46 salidas; manifiesto de 51.910 bytes	Configuración efectiva: 2550c63bf5634b30f580c47ca8d29ca7 ed06f990fb6c8898a3366d91177ddec1 Manifiesto: c0940a4eca15fbf47dc3c42cf99e56c2 1f546103df9b7b62f4f3aea1211ac1c3
Extensión V9 con blindaje	config/config_ml2_v9_blindaje.yaml; entorno local con GPU; 19 de octubre, 22:47 UTC; 46 salidas; manifiesto de 51.806 bytes	Configuración efectiva: 5174160382f016008e846152414ec7ed f07d6348cfc26eb5eab9ce26a0d648b8 Manifiesto: 0fcae1db6aa269ba1e971e16c35fbdae 614336a5a0fd9a3eb3839cf1237a182a

Elemento	Identificación	Huella
Insumo: ventas (objetivo)	datos/crudo/ventas_novapack.csv; 11.430.061 bytes; 204.096 registros	5d1190ff295e769374ae6cbb51a3f300 eddd31e62834789ffd099ad70d2f83aa
Insumo: costos (valorización)	datos/crudo/costos.csv; 152.700 bytes; 5.322 registros	6dc7e86c94bbd4d0781d3dc0c694d06b 2c94524f0d6229f3a9d4631b0e7c1f0e
Insumo: quiebres (covariable)	datos/crudo/quiebres.csv; 7.355.431 bytes; 220.889 registros	0d51d4ef35399b135a7d42c66597ad06 2aa08295637027b2b60413d7b5215d95
Insumo: tipo de cambio (covariable)	datos/crudo/tipo_cambio.csv; 790 bytes; 48 registros	354c695488f5f2ec885a0cca764737bc c6d02fe7c1abf4a5387aca5e14f009a8
Insumo: mapeo de categorías (seudónimos; auxiliar leído)	datos/crudo/mapeo_categoria.csv; 364 bytes; 12 registros	8ce2a16f975cfb4a01687fb42a4a7548 f8c90fbd6c7f44b90a7a675d328fa294
Insumo: mapeo de códigos (seudónimos; no lo lee la corrida)	datos/crudo/mapeo_sku.csv; 17.483 bytes; 970 registros	86e633a356a6047a009c0fd5da11af0b e5af20b4d2ba51197838d4189e5aaba1
Manifiesto de extracción (7 de agosto de 2026)	datos/crudo/manifiesto_extraccion.json; 1.503 bytes	262f4d366c756086f5a72d594a374958 cc6064da737a136841f9e9fceb885238
Salida pública: Tabla 20	resultados/tablas/tabla_H3_incertidumbre_agrupada.csv en 17893d4; 3.762 bytes	1e3a8e96e80c192fd6c5d15908115c8a 62fd888424118a4c415b6518330dd432

Nota. Valores del manifiesto expurgado bajo custodia (fila 7 de la Tabla 47), que transcribe los manifiestos (manifiesto.json) de las cinco corridas. Los rótulos de las sensibilidades A y B son los de la Tabla 25 (Anexo 11), cuya nota da su equivalencia con los nombres del repositorio y del manifiesto expurgado. El commit es la huella SHA-1 de git; las demás son SHA-256. La de la configuración efectiva la calcula src/config.py sobre el contenido interpretado, con la herencia y las anulaciones aplicadas, no sobre los bytes del archivo. Los insumos no están en el repositorio y se cotejan sobre los archivos bajo custodia (fila 8 de la Tabla 47); el código y la Tabla 20 se cotejan en el repositorio público (Anexo 7). El identificador de la imagen de Docker

proviene del manifiesto expurgado y no del manifiesto de cada corrida, que registra la plataforma de ejecución y las versiones de Python y de las bibliotecas. Ningún manifiesto de corrida sella, por tanto, el vínculo de la imagen con las corridas publicada, A y B. Ese vínculo se infiere de que las versiones de Python, de la biblioteca C del sistema (que consta en la plataforma de ejecución) y de las bibliotecas que registra el manifiesto de cada una de esas tres corridas coinciden con las de la imagen, y de las fechas de esta tabla (imagen del 14 de octubre de 2026; corridas del 19). El Dockerfile del repositorio parte de una imagen base designada por su etiqueta y no por su huella, y por sí solo no acredita ese identificador; por eso se coteja sobre la imagen conservada por el autor, que se exhibe a solicitud junto con los documentos bajo custodia. El verificador de la corrida, también bajo custodia, repite los cotejos de los insumos, del código y de la configuración efectiva, y los de las salidas selladas de cada corrida. Elaboración propia.